서브그래프 기반 이상 탐지에서 소수 클래스 표현력 강화를 위한 연구

PS-SGAD | Prototype-based Supervised Contrastive Learning for SubGraph Anomaly Detection

강다솔 · 국민대학교 소프트웨어융합대학원 · 석사학위 연구 (지도교수: 박하명)

01 연구 배경

클래스 불균형이 만드는 이상 탐지의 한계

- 금융 범죄·이상 거래는 정상 거래에 비해 극히 드물어 분류 경계가 정상 클래스에 편향됨
- 기존 GNN의 교차 엔트로피 학습만으로는 소수 클래스의 판별적 임베딩 확보에 한계
- 목표: 구조 정보와 표현학습을 결합하여 이상 서브그래프의 상위 랭킹 및 탐지력을 강화

02 데이터셋

Elliptic2 | Bitcoin 거래 서브그래프

노드 444,521개 · 엣지 367,137개 · 노드 특징 43차원

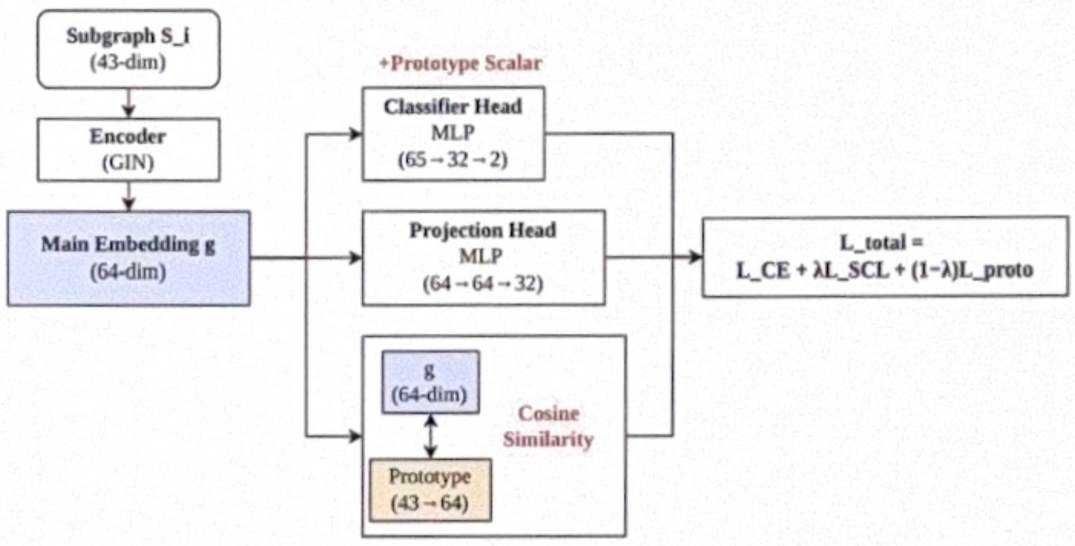
연결 요소 기반 서브그래프 약 12.2만 개 / 학습·검증·시험 70:15:15

정상(Licit) 약 98% / 의심(Suspicious) 약 2% → 극심한 클래스 불균형

03 실험 모델 구조

GIN 기반 서브그래프 인코더에 SupCon과 Prototype Alignment를 결합

Figure 2 · PS-SGAD 전체 구조도



04 실험내용

네 가지 비교 모델과 불균형·랭킹 중심 평가

비교 모델 (동일 GIN Backbone)

① Baseline: GIN + CE
② ProtoSim: 프로토타입 유사도
③ SupCon + CE: 지도형 대조학습
④ PS-SGAD + CE: 두 표현학습 결합

학습 및 검증

- Adam (lr=0.001), 최대 200 epochs
- Early stopping: Val AUPRC, patience=5
- WeightedRandomSampler 공통 적용
- AUPRC · Precision@K · Recall@K · NDCG@K
- UMAP 및 하이퍼파라미터 민감도 분석

05 결과 및 결론

Figure 3 · Precision-Recall 곡선

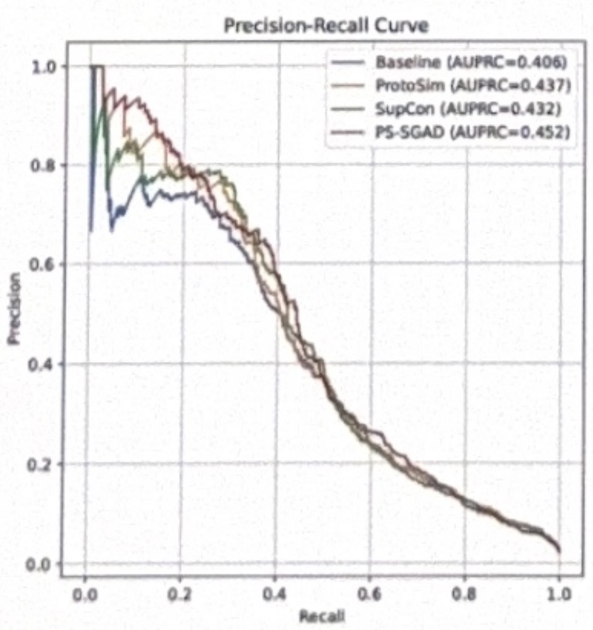
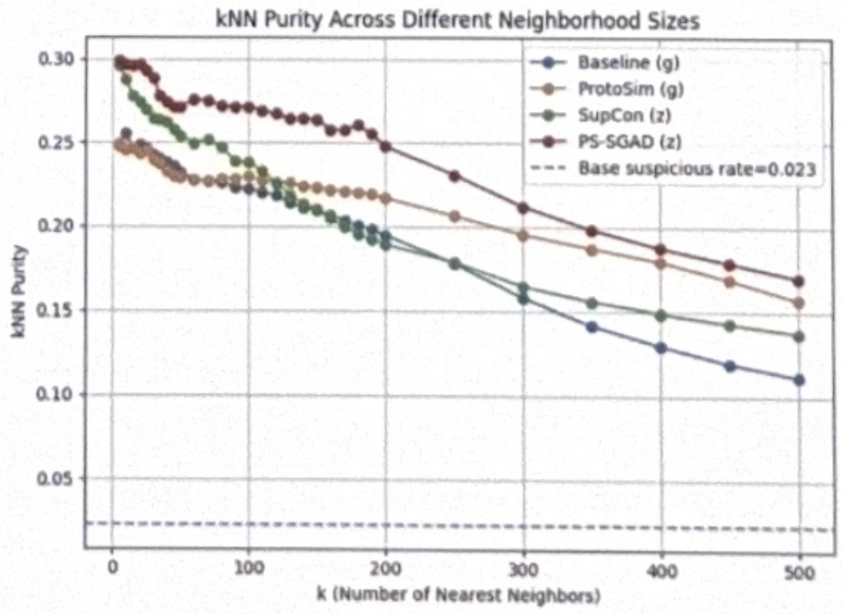


Figure 5 · 이웃수(k)변화에따른잠재공간의kNNPurity측정결과



결과

Figure 3. 제안하는 모델(PS-SGAD)은 특히 낮은 Recall구간에서 비교 모델들보다 Precision-Recall Curve가 높음이 확인됨.
Figure 5. PS-SGAD가 k 전 구간에서 응집성이 가장 높음을 확인됨.

핵심 결론

PS-SGAD는 AUPRC 0.4520으로 Baseline 0.4062 대비 약 11.3% 향상.
Top 0.2%에서 Precision 0.9189, NDCG 0.9351을 기록하여 이상 후보 우선순위화에 효과적임.

출처: 강다솔, 「서브그래프 기반 이상 탐지에서 소수 클래스 표현력 강화를 위한 연구」, 석사학위논문 (2026).

재난대응 매뉴얼 기반 의미적 검색의 한계 분석과 절차적 구조의 효과 검증

Semantic Retrieval Failure를 중심으로

황채아 · 국민대학교 소프트웨어융합대학원 인공지능전공 [redacted]

초록

재난 대응 환경에서는 제한된 시간 내에 정확한 정보를 기반으로 한 의사결정이 요구된다. 기존 재난대응 매뉴얼 기반 RAG 시스템은 의미적 유사도 중심 검색 구조를 사용하기 때문에 서로 다른 재난 유형의 정보가 함께 검색되는 문제가 발생한다. 본 연구에서는 재난 유형, 대응 단계, 행동 명칭 등의 조건을 질의로부터 자동 추출하고 이를 메타데이터 필터링에 반영하는 조건 추출형 XC-RAG(Cross-filtered & Condition-aware RAG) 모델을 제안한다. 제안 모델은 검색 이전 단계에서 조건 기반 필터링을 수행하여 질의와 무관한 재난 유형 정보를 제거하도록 설계하였다. 실험 결과, XC-RAG는 Precision@5, MRR, CMA 지표에서 기존 RAG 대비 높은 성능을 보였으며, 재난 유형별 정보 혼재율을 0%로 감소시켰다. 이를 통해 재난 대응과 같은 고위험 도메인에서 조건 기반 검색 구조의 적용 가능성을 확인하였다.

01 연구 배경 및 목적

연구 배경

재난 대응 현장에서는 매뉴얼이 존재함에도 불구하고 신속한 정보 탐색의 어려움으로 인해 실질적인 의사결정 지원 도구로 활용되지 못하는 한계가 있다. 재난대응 매뉴얼은 대부분 PDF 형태의 비정형 문서로 제공되며, 문서 분량이 크고 구조가 복잡하여 필요한 정보를 즉시 탐색하기 어렵다.

재난 도메인의 절차적 특성

- **재난 유형별 대응 절차 상이** — 화학물질 감염병 철도 등 절차 다름
- **대응 단계별 내용 변화** — 초기대응 수습 복구 절차 구분 필요
- **동일 표현 반복** — '상황접수', '초기대응' 등 여러 재난에 공통 존재
- **의미 유사성 ≠ 절차 동일성** — 표현이 유사해도 절차는 다를 수 있음

예시
유해화학물질 매뉴얼 내 '초기대응' 35회 / '초기 대응' 41회 / '상황접수' 6회 / '상황 접수' 5회
→ 동일 표현이 15개 재난 유형 전반에 걸쳐 변복 등장

02 Semantic Retrieval Failure

정의 의미적으로 유사하나 절차적으로 다른 재난 문서가 함께 검색되는 현상

발생 원인

1. 재난 간 공통 표현 변복 사용
2. 의미 유사도만으로 검색 수행
3. 절차 문맥(Procedural Context) 정보 부재

사전 실험에서 관찰된 Failure

0~50%	0.133	50%
재난유형별 정보 혼재율	CMA (기존 RAG)	보건의료 혼재율 최대

03 연구 질문 및 가설

- **RQ1** 왜 재난 도메인에서 Semantic Retrieval이 실패하는가?
- **RQ2** Failure의 주요 원인은 무엇인가?
- **RQ3** Procedural Context는 Failure 감소에 기여하는가?

가설 H1 Semantic Retrieval Failure의 주요 원인은 Procedural Context 부재이다.
→ XC-RAG의 조건 기반 필터링으로 H1을 실험적으로 검증한다.

04 XC-RAG 모델 설계

Cross-filtered & Condition-aware Retrieval-Augmented Generation

1. **① 사용자 질문 입력**
   재난 유형/대응 단계/행동 명칭을 포함한 자연어 질의 입력
2. **② 조건 추출 (Procedural Context)**
   질의에서 재난유형 / 대응단계 / 행동명칭을 자동 추출하여 검색 조건으로 활용
3. **③ Metadata Filtering**
   추출된 조건을 메타데이터 필터로 변환 → Vector DB 사전 필터링으로 재난 간 정보 혼재 차단
4. **④ Similarity Retrieval**
   필터링된 문서 집합 내에서 벡터 유사도 기반 검색 수행
5. **⑤ 답변 생성**
   Qwen2.5 LLM 기반 조건 일치 문서를 근거로 최종 답변 생성 (폐쇄망 환경 지원)

재난 유형 | 대응 단계 | 행동 명칭

05 실험 설계

실험 데이터셋

15종	150개	JSON	4단계
재난 유형 매뉴얼	실험 질의	구조화 포맷	대응단계 태깅

대응 단계 구분

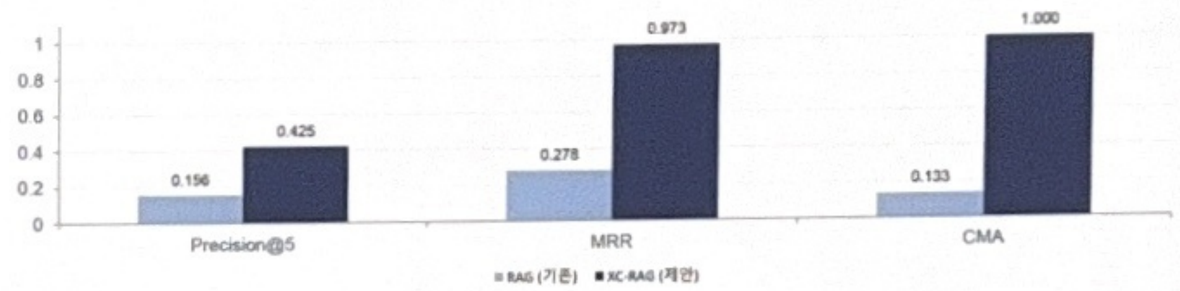
전수 감지 | 초기 대응 | 비상 대응 | 수습·복구

실험 환경

LLM	검색 플랫폼	임베딩	아키텍처
Ollama + Qwen2.5	RAGFlow	BAAI (Local Env)	XC-RAG

06 성능 평가 결과

[표 1] 전체 모델 성능 비교 (A: 기존 RAG, B: XC-RAG)



[표 2] 재난유형별 성능 비교 (전체 15종)

재난유형	정보혼재율 A/B	Hit Rate A/B	CMA A/B	결과
가축질병	0% / 0%	50% / 100%	10% / 100%	개선
고속철도 대형사고	10%→0%	50% / 100%	20% / 100%	혼재 제거
공동구 재난	10%→0%	40% / 100%	20% / 100%	혼재 제거
다중밀집건축물 붕괴	10%→0%	40% / 100%	20% / 100%	혼재 제거
다중밀집시설 대형화재	10%→0%	40% / 100%	20% / 100%	혼재 제거
대규모 수질오염	0% / 0%	30% / 100%	10% / 100%	개선
댐붕괴	10%→0%	40% / 100%	10% / 100%	혼재 제거
보건의료	50%→0%	70% / 100%	20% / 100%	혼재 제거
산불	10%→0%	20% / 100%	10% / 100%	혼재 제거
식용수	10%→0%	50% / 100%	10% / 100%	혼재 제거
원전안전	0% / 0%	70% / 100%	20% / 100%	개선
유해화학물질 유출	0% / 0%	40% / 100%	10% / 100%	개선
전력	10%→0%	60% / 100%	10% / 100%	혼재 제거
정보통신분야	10%→0%	50% / 100%	0% / 100%	혼재 제거
지하철 대형사고	10%→0%	40% / 90%	10% / 100%	혼재 제거

Precision@5: 상위 5개 검색 결과 중 관련 문서의 비율
MRR: 정답 문서가 검색 결과 상위에 얼마나 빨리 나타나는지 평가
CMA: 질의 조건(재난 유형, 대응 단계, 조치사항)과 문서 조건의 일치 여부 평가
정보혼재율: 검색 결과에 불필요하거나 다른 재난 정보가 함께 포함되는 정도

07 결론

성능 향상

Precision@5 0.156→0.425, MRR 0.278→0.973, CMA 0.133→1.000 — 전 지표 기존 RAG 대비 대폭 향상

혼재율 0% 달성

모든 재난 유형에서 정보 혼재율 0% 달성, Semantic Retrieval Failure를 실험적으로 해소

조건 기반 검색 효과

Procedural Context(재난유형·대응단계·행동명칭) 기반 메타데이터 필터링이 고위험 도메인에 유효함을 실증

폐쇄망 적용 가능성

로컬 환경(Ollama + Qwen2.5, BAAI 임베딩)에서 구현, 보안이 중요한 재난 대응 현장에 적합

08 향후 연구 계획

목표: Semantic Retrieval Failure를 정량적으로 분석하여 "왜 재난 도메인에서 Semantic Retrieval이 실패하는가"에 답한다.

01	02	03
표현 중복 분석	**Ablation Study**	**Retrieval Failure 심층 분석**
재난 간 공통 표현 빈도 정량화 Semantic Ambiguity 지표 개발	재난유형 / 대응단계 / 행동명칭 조건별 기여도 분석	오검색 사례 패턴 분석 예외 케이스 규명 (지하철 대형사고)

참고문헌

[1] R. Rawat, "DisasterQA: A benchmark for assessing the performance of LLMs in disaster response," arXiv:2410.20707, 2024.

[2] M. vs DisastQA, "DisastQA: A Comprehensive Benchmark for Evaluating Question Answering in Disaster Management."

[3] Y. Gao et al., "Retrieval-Augmented Generation for Large Language Models: A Survey," arXiv:2312.10997, 2023.

[4] S. Zhao et al., "RAG and Beyond: A comprehensive survey on how to make your LLMs use external data more wisely," arXiv:2409.14924, 2024.

[5] B. Hui et al., "Qwen2.5-Coder Technical Report," arXiv:2409.12186, 2024.

PBL 기반 생성형 AI 실무교육 모델 개발 및 적용에 관한 연구

오성경

비전공 성인 학습자를 위한 **문제 정의 중심** 생성형 AI 교육

Key Point

비전공 성인 학습자가 자신의 실무 문제를 정의하고,
생성형 AI로 해결안을 구현하는 교육 모델을 설계·적용하였다.

1. 연구 개요

본 연구는 비전공 성인 학습자를 위한 **문제 정의 중심**의
PBL 기반 생성형 AI 실무교육 모델을 설계하고 적용하였다.
학습자는 직무·관심 분야의 문제를 탐색하고,
5 Why·HMW·페르소나 분석으로 해결 과제를 구체화한 뒤,
생성형 AI를 활용해 프로토타입을 제작하였다.

2. 연구 배경

기존 · 도구 중심 교육

기능 학습 > 결과물 생성

→ 도구 사용 경험을 실제 문제 해결로 연결하는 데 한계

문제 정의 중심 PBL

문제 정의 > 해결안 기획 > AI 활용 > 피드백·개선

→ 해결할 문제를 기준으로 기획과 구현을 연결

문제 인식 (Problem)

생성형 AI와 바이브코딩은
프로그래밍 경험이 부족한 학습자도 아이디어를 구현할 수 있게 한다.
그러나 도구 기능과 프롬프트 작성법을 익히는 것만으로는
실무 문제를 정의하고 해결 전략을 세우는 과정을 충분히 다루기 어렵다.

교육 설계 과제 (Challenge)

학습자의 직무 경험에서 출발해 문제를 구체화하고,
필요한 기능과 AI 도구를 선택하며,
결과물을 검토·개선하는 학습 과정이 필요하다.

3. 제안 교육 모델

문제 정의에서 구현·개선으로 이어지는 실습 과정

STEP 1	STEP 2	STEP 3	STEP 4	STEP 5
실무 문제 정의	AI 도구 선택	해결안 기획	프로토타입 구현	피드백·반복 개선
직무·관심 분야 문제와 사용자 요구를 구체화	해결 과제와 필요한 작업에 맞는 도구 선택	주요 기능과 AI 도구 활용 시나리오 구성	기획 내용을 웹 화면·서비스 구조로 표현	피드백을 바탕으로 기능과 사용성 개선

문제를 구체화하는 질문과 분석 도구

5 Why	HMW	페르소나 분석	문제 정의서
문제의 근본 원인 탐색	해결 가능한 질문으로 전환	사용자의 상황과 요구 파악	사용자·문제·해결 목표 정리

학습자가 해결할 문제와 방향을 정하고,
생성형 AI는 기획과 구현을 지원한다.

4. 교육 운영 및 적용

대상 국민대학교 AI·SW 융합대학원 석사과정 성인 학습자
프로그래밍 경험이 부족한 IT 비전공 재직자 중심

운영 3회차 집중 강의
실시간 온라인 강의 · 비동기 학습 · 자기주도 실습 병행

차시	주제	주요 활동
1차시	생성형 AI 이해와 실무 활용	AI 도구 특성과 활용 사례 탐색
2차시	문제 정의와 도구 매핑	문제 정의서와 AI 활용 시나리오 작성
3차시	프로토타입 제작 및 발표	초기 결과물 구현 및 피드백 반영

최종 제출물 : 기획 문서 · 프로토타입 · AI 활용 과정 요약 · README.md

5. 산출물 및 적용 결과

학습자 프로토타입 사례



심장길잡이 서울

AED 위치 정보와 응급상황
질의응답을 결합한 서비스



헬스맵 AI

지역 운동시설 정보를 활용한
맞춤형 추천 서비스



#TagTune

음악 메타데이터와 무드 분석을
활용한 추천 서비스

학습자는 직무·관심 분야의 문제를 선정하고,
생성형 AI를 활용해 기획 문서와 프로토타입으로 구체화하였다.

평가 기준 · 정량 평가 항목 (총 100점)

기능적 차별성	25점	차별성 · 실용적 기능
흥미도	20점	주제의 참신성 · 관심 유도
창의성	30점	아이디어 독창성 · 기획 유연성
편의성·UX	25점	시각 구성 · 사용자 경험

분석 결과 · 정성 평가

1 프레임워크 적용

기획의 논리성	향상
해결 전략의 명료성	향상
도구 활용의 적절성	향상

완성도 상승

2 구조화 부족

산출물 목적	불명확
사용자 맥락	약화
활용 시나리오	단순화

맥락 불명확

3 역량 차이의 원인

도구 숙련도 < **문제 정의**
무엇을 만들지 < **왜 필요한지**
결과물 < **해결 과정**

차이는 문제 정의에서

결론 및 시사점

- 비전공 성인의 생성형 AI 교육은 실무 문제를 구체화하고, 적절한 도구로 해결안을 구현·검토하는 과정으로 설계할 필요가 있다.
- 본 연구는 이러한 학습 과정을 지원하는 PBL 교육 모델의 적용 사례를 제시하였다.

해안지역의 해무현상으로 인한 저시정 현상 개선 및 미확인 물체 탐지 방안에 대한 정확성 개선 방안

정민욱, *윤수연

1. 연구 개요

본 연구는 해안 지역에 발생하는 해무를 Dehaze 기법을 사용하여 제거 한 뒤 해무가 제거된 해안 지역을 수평선을 기준으로 하늘과 땅 그리고 바다로 분리한다. 이 후 바다 위에 있는 객체들만 Yolo 모델을 사용하여 추론함으로써 해양 지역을 통해 침입하는 객체들을 식별해낼수 있다.

2. 연구 배경



구분		보유	수명초과	수명연한	전력화 연도	대체장비 전력화
해안레이더		100여대	68%	15년	98 ~ 09년	해안레이더 - II (24년 이후)
TOD	소계	270여대	36%	20년	-	
	2형	160여대	58%		96 ~ 06년	3형 추가 전력화 (22년 이후)
	3형	100여대	-		13 ~ 17년	
해안복합 감시체계	소계		-	10년	14년	
	모니터링 시스템		-			
	통제시스템		-			
	감시카메라		-			

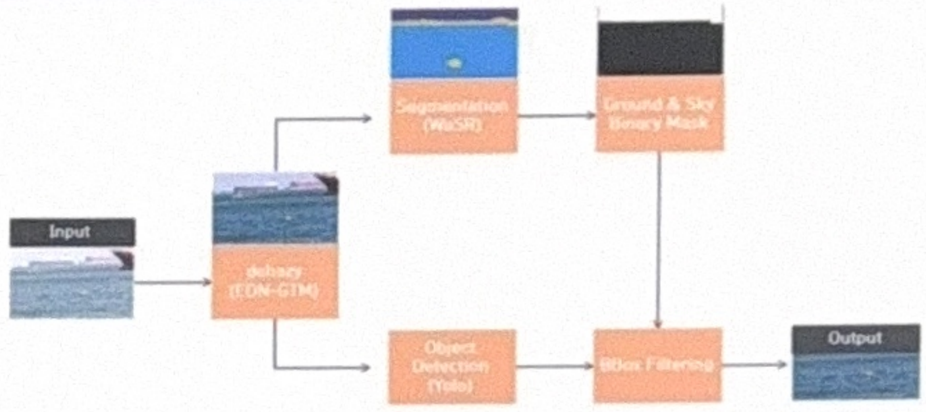
문제점 (Problem)

출생률 저하에 따른 인구 감소 문제 및 군 복무기간 단축화 등으로 인한 경계 병력 부족.
군 장비 노후화로 인한 해안 경계 작전의 어려움.
인력으로 인한 휴먼에러 발생 가능성.

솔루션 (Solution)

군부대에 AI 자동 감지 시스템을 도입하여 해안 경계 자동화 시스템 구축.
해무현상이 심한 부대에서도 사용가능한 로직을 설계.

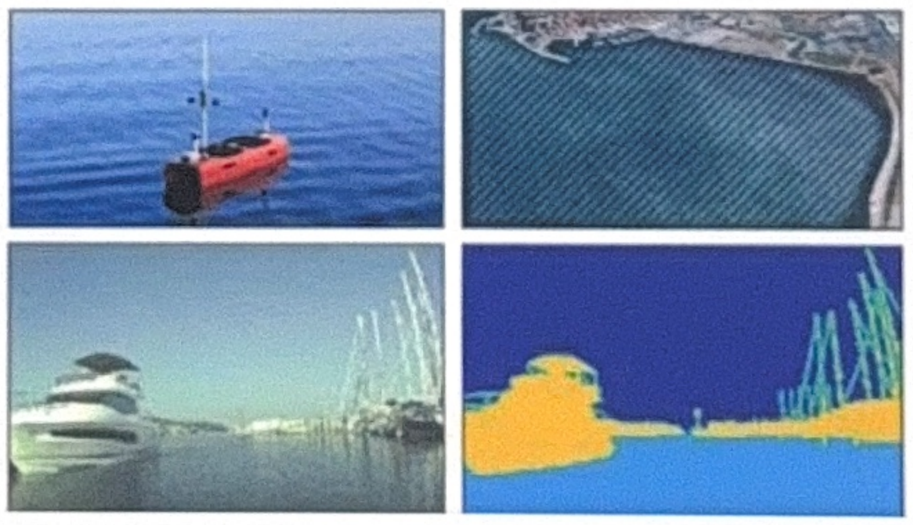
3. 프레임 워크



1. 연구 가설 설정:
   - 해양환경을 통해 입력되는 이미지로 부터 해무를 제거한 뒤 바다 위에 떠 있는 객체들만 식별하는 기술들을 결합
2. 구성도:
   - 해양이미지의 해무 부분을 제거한 뒤 WaSR 모델 통해 바다, 하늘, 땅으로 분류한 뒤 바다 위에 있는 객체들만 Yolo 모델을 사용하여 탐지.

4. 데이터셋 구성

사용 데이터셋 : MaSTr1478 + AI hub 해양 오픈 데이터셋
이 중 만여장은 해무 옵션을 추가하여 생성.



5. 실험 결과

추론 결과

<해무 제거 전>



<해무 제거 후>



- 해무 제거 전과 후의 성능 차이를 비교해보았을 때, 해무 제거가 된 후 미확인 수중물체 식별 성능이 더 정확하게 나타남.
- 노이즈가 많은 이미지에서 오탐률이 높아지며, 햇빛 반사가 심하거나 선박으로 생긴 물결 등을 미확인 수중물체로 식별하는 사례 존재.
- 객체 추론 속도에서는 Yolov7을 사용하였을때가 Yolov5를 사용하였을때에 비해 훨씬 빠름.

멀티모달(오디오·비주얼) 딥페이크 탐지 · 석사 연구

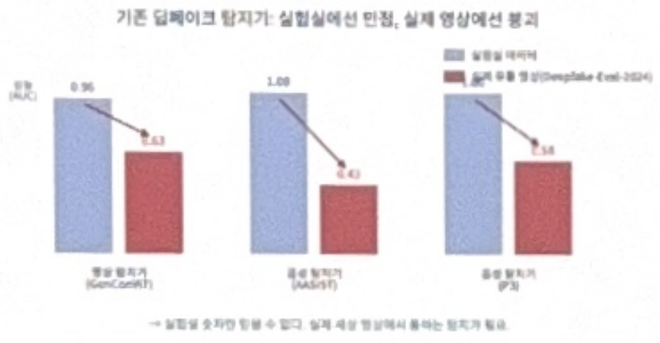
얼굴·음성·정합성 통합 멀티모달 모델을 통한 실유통 딥페이크 탐지 성능 향상 연구

Improving In-the-Wild Deepfake Detection via a Unified Face–Audio–Synchrony Multimodal Model

최재민 | 국민대학교

1 연구 배경 및 문제 정의

- 딥페이크는 얼굴 합성·립싱크·음성 복제가 결합해 오디오·영상을 동시에 조작하는 방향으로 발전.
- 단일 모달 탐지는 한쪽 품질이 높으면 취약 → 시각·음성 정합성을 함께 보는 멀티모달이 필요.
- **핵심 문제: 학습 벤치마크에서 AUC 0.95+인 탐지기도 실유통(in-the-wild)에선 0.43~0.63으로 붕괴.**



본 연구: 입술–음성 정합성을 핵심 단서로, 실유통에서 통하는 멀티모달 탐지를 목표.

2 연구 목적 및 기여

- **얼굴·음성·정합성을 하나로 통합한 멀티모달 모델 제안 (end-to-end 미세조정).**
- 실유통 zero-shot 평가(Deepfake-Eval-2024)를 정면 수행 — AV 계열에서 드문 평가.
- 정합성이 실전 최강 단서임을 입증: 단독 AUC 0.727로 공개 SOTA(0.63)를 상회.
- 기존 학습 SOTA의 실전 붕괴 원인 분해(생성기 세대 격차·전처리 강건성).
- 최신 가짜(DeepSpeak) 추가로 일반화 개선 — 데이터 세대 가설 검증.

핵심 성과

실유통 AUC 0.727

정확도(ACC) 68.2% · 실유통 zero-shot

공개 모델 최고 0.63 → 우리 정합성 0.727 (+0.10)

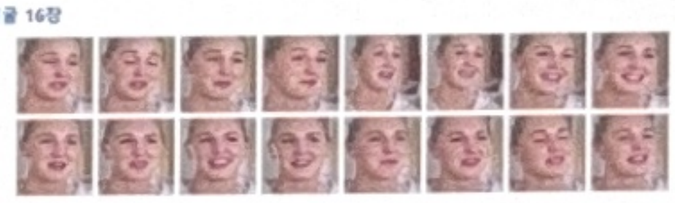
4 데이터셋 · 실제 입력

데이터셋	샘플 수	용도
DeepSpeak v2	10,650 (82.9%)	학습
FakeAVCeleb	2,195 (17.1%)	학습
Deepfake-Eval-2024	1,245	평가(zero-shot)

학습 합계 12,845 · real:fake ≈ 1:1 · 평가셋은 학습에 미사용

실제 입력 예시 (영상 통째가 아니라 조각 → 숫자)

얼굴 16장



입술 16장 (랜드마크 crop)

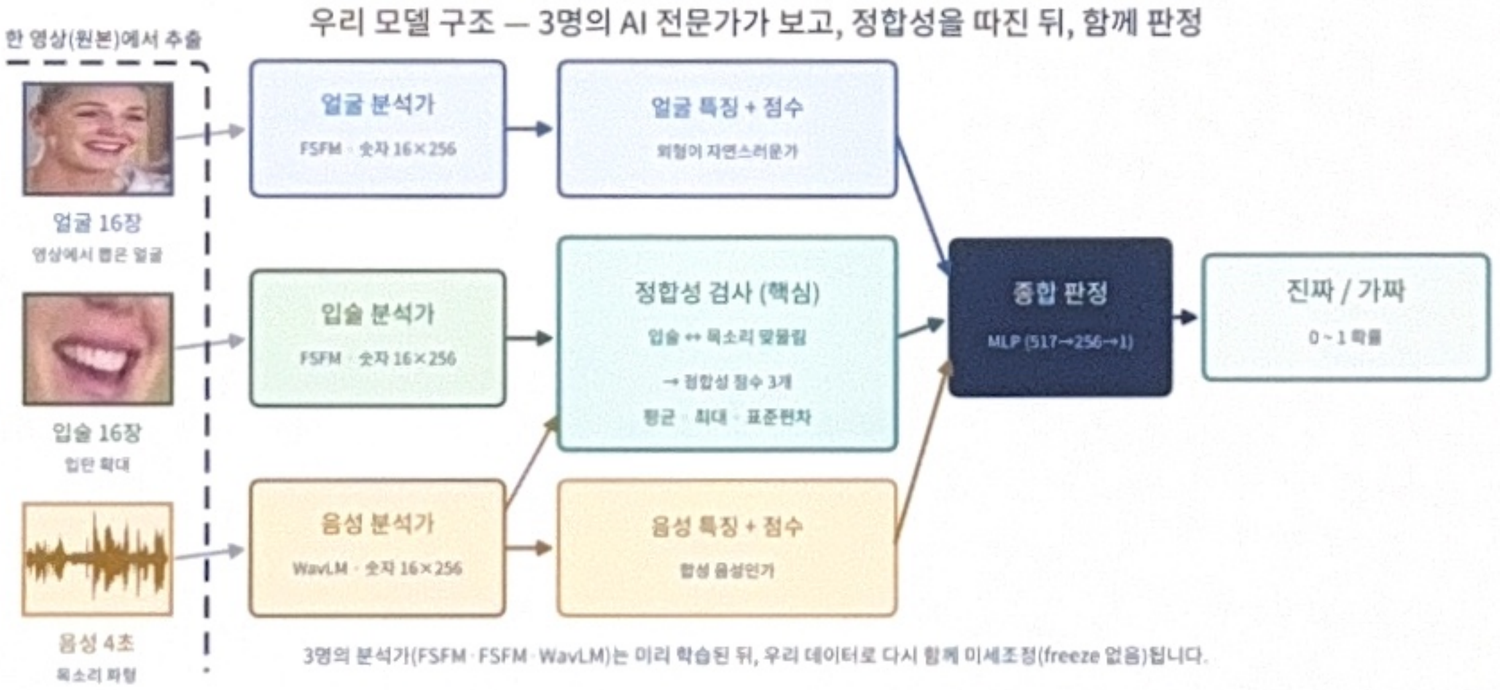


음성 4초 (16 kHz)



3 제안 모델 구조

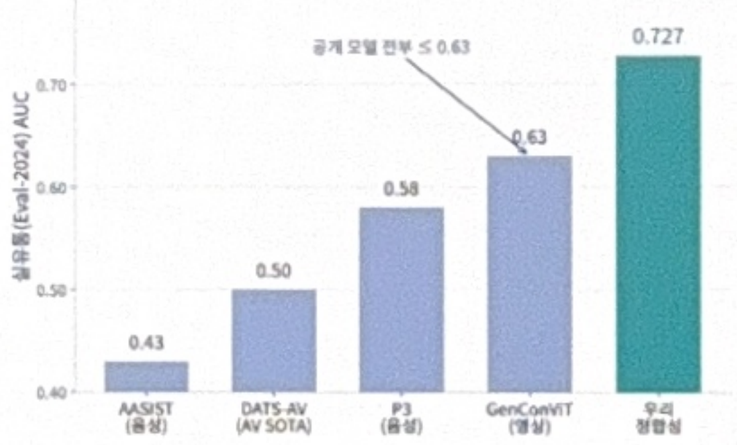
우리 모델 구조 — 3명의 AI 전문가가 보고, 정합성을 따진 뒤, 함께 판정



- 인코더 3개: 얼굴 FSFM ViT-B · 입술 FSFM ViT-B · 음성 WavLM-base+ (가중치 비공유).
- 입력: 16프레임(얼굴·입술 224×224) + 음성 4초(16 kHz) → 각 16토큰 × 256.
- 입술 ROI: 랜드마크 중심 crop(mh0.3) — 입술만 타이트하게.
- 정합성: 입술↔음성 국소 교차어텐션(window 4·stride 2) + Transformer(1층·4헤드) → 정합성 3점수.
- 결합: MLP(517→256→1) — 얼굴·음성 특징 + 점수 5개 통합.
- **학습: end-to-end 멀티태스크, 인코더까지 전부 미세조정(freeze 없음). 가짜 상황(desync·swap) 증강.**

5 실험 결과

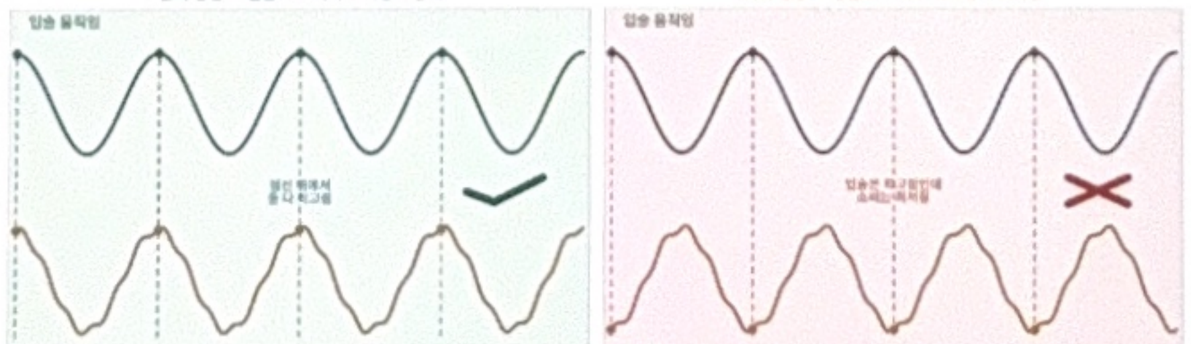
실유통(Eval-2024): 공개 모델 vs 우리



우리 단서 전부(정합성 0.727 · 음성 0.712)가 공개 SOTA(≤0.63)를 상회 — 정합성이 단일 최강 단서.

✓ 공개 모델 전부를 큰 격차로 상회
✓ 내부 테스트 AUC 0.93+ (학습 도메인)

6 핵심 단서 — 입술·음성 정합성 (왜 실유통에 강한가)



- **말할 때 입모양과 소리는 같은 순간에 움직임 — 진짜는 타이밍이 일치, 가짜는 미세하게 어긋남.**
- 측정: 입술·음성을 국소 윈도우(window 4·stride 2)로 나눠 구간별 맞물림 점수를 내고 → 평균·최대·표준편차 3값으로 요약.
- 외형 합성 품질이 아무리 높아도 '타이밍'은 맞추기 어려움 → 생성기 세대가 바뀌어도 통하는 강건한 단서.
- **실제로 정합성 단독 AUC 0.727로 공개 모델 전부(≤0.63)를 상회.**

7 결론 및 향후 연구

결론

- **얼굴·음성·정합성을 통합한 end-to-end 멀티모달 모델로 실유통(Eval-2024)에서 AUC 0.727 달성.**
- 공개 SOTA(≤0.63)를 큰 격차로 상회 — 실험실이 아닌 '실제 유통 영상'에서 통함을 입증.
- 입술–음성 정합성이 실유통에서 가장 강력하고 안정적인 단서임을 확인.
- 기존 AV SOTA(0.999→0.504)와 달리 전처리 실패 0으로 감건 — 실패 원인은 생성기 세대 격차로 규명.

향후 연구

- 결합(fusion) 전략 고도화로 정합성 활용 극대화
- 다양한 생성기·언어로 평가 확장
- 설명가능성 시각화 · 실시간 경량화

✓ 실유통 AUC 0.727 — 공개 SOTA(0.63) 대비 +0.10

8 참고문헌

[1] Rössler et al., FaceForensics++, ICCV 2019.
[2] Oorloff et al., AVFF, CVPR 2024.
[3] Anshul et al., Intra-/Cross-modal Synchronization, ICCV 2025.
[4] Khalid et al., FakeAVCeleb, NeurIPS 2021.
[5] Chandra et al., Deepfake-Eval-2024, arXiv 2025.
[6] Wang et al., FSFM, CVPR 2025.
[7] Chen et al., WavLM, IEEE JSTSP 2022.
[8] DeepSpeak Dataset v2, 2025.

엣지 SoC에서 LLM 추론의 Hetero Scheduling과 Phase별 백엔드 효율 분석

손현호, *윤수연

1. 연구 개요

본 연구는 모바일 이기종 SoC 환경에서 온디바이스 LLM의 추론 성능 최적화를 위하여, Attention 연산을 QKV Projection과 Attention Core로 세분화하여 각 단계별 최적 백엔드를 동적으로 선정하는 Dual-Stage Backend Selection 모델을 제안한다.

2. 연구 배경

NPU — 6 TOPS

RKLLM 프레임워크, INT8 GEMM 가속

CPU — Cortex-A76 4코어

MNN, 2/4-thread 구성 (cluster pinning)

GPU — Mali-G610

MNN OpenCL, fp16 dequant 후 matmul

문제 의식

"NPU가 LLM 가속에 우세하다" 라는 인식이 일반적이지만, 어느 백엔드가 어느 시나리오에서 우세한지에 대한 정량 비교는 부족

세 백앤드는 동일 LPDDR5를 공유 → 공통 대역폭상한 아래에서 백엔드별 효율을 비교 가능

3. Phase별 특성

Prefill

Prompt 전체에 대한 batch GEMM

- Compute-bound에 가까움
- GEMM 가속 성능이 백엔드 효율을 좌우
- 체감 지표 : TTFT (첫 토큰까지의 지연)

Decode

토큰별 GEMV 반복 (memory bandwidth-bound)

- Weight-KV 순회 효율이 백엔드 효율을 좌우
- Context가 길수록 KV 순회량 증가
- 체감 지표 : TPOT (토큰당 생성 시간)

4. 실험 설계

모델 / LLM 추론 SW

모델 – Llama-3.2-1B-Instruct, W8A8
추론 SW - MNN(cpu_t2-cpu_t4-OpenCL) + RKLLM(NPU)

워크로드

Wikitext-2 자연어 prefix
np ∈ {64 … 3500} × ng ∈ {32 … 2048}

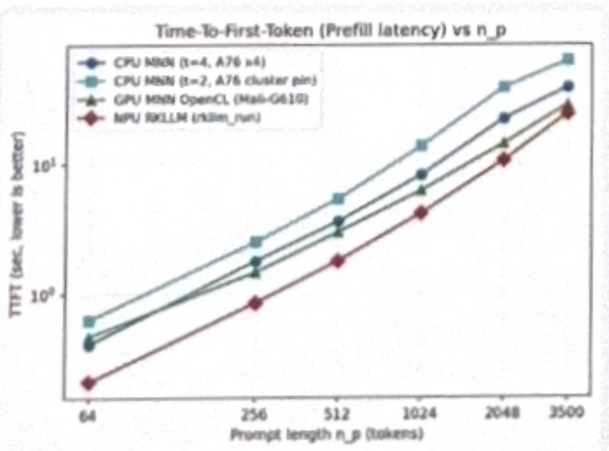
측정 방법

KV cache 활성화, 3회 반복 평균
CPU-GPU는 op-level timing probe 삽입





5. 실험 결과 및 성능 평가 분석



1.6×
ctx=3500에서 NPU가 cpu_t4 대비 빠름

주요 분석 결과

- NPU가 모든 ctx 구간에서 가장 낮은 TTFT 기록
- compute-bound 특성상 6 TOPS GEMM 가속이 직접 활용
- GPU는 중간 성능, cpu_t2는 코어 수 제약으로 최하위

Phase별 우세 백엔드 분담

사용자 Prompt	NPU Prefill	KV cache 전달	cpu_t2 Decode

$$\text{throughput}_{__} = n_g / [\,\text{TTFT}^{\sim}(n_p) + n_g \cdot \text{TPOT}^{\sim,\,__}\,]$$

측정한 NPU TTFT와 cpu_t2 TPOT를 식 (2.1)에 대입해 추정 (식 3.1)

Prefill 단계 → NPU

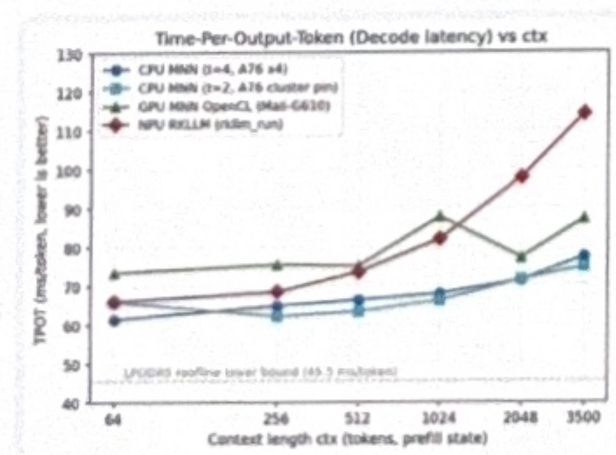
NPU의 6 TOPS GEMM 가속으로 prompt 전체 batch GEMM 수행 — 모든 ctx에서 최저 TTFT

Decode 단계 → cpu_t2

단일 A76 cluster에 pinning한 CPU MNN이 토큰별 GEMV decode 수행 — ctx≥256에서 최저 TPOT

KV cache 전달 비용

ctx=3500에서 누적 KV 약 57 MB, 이동 시간 약 2.1 ms — 전체 실행의 0.01% 이내로 무시 가능



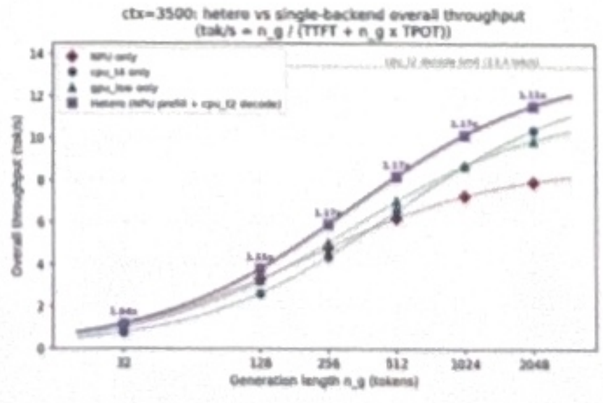
1.52×
ctx=3500에서 cpu_t2가 NPU 대비 빠름

주요 분석 결과

- ctx=64에서는 cpu_t4와 NPU가 사실상 동등
- ctx=256부터 cpu_t2가 최고 성능으로 역전
- NPU와의 격차는 ctx 증가에 따라 단조 증가

ctx=3500 추정 결과

- Prefill에는 NPU, Decode에는 cpu_t2 백엔드가 분담됨
- ng 256–1024 구간에서 단독 최고 백엔드 대비 약 1.17배, ng=32에서는 약 1.04배 향상
- ng가 커질수록 decode가 지배 → hetero 성능이 cpu_t2 decode 한계(13.4 tok/s)에 수렴



1.04–1.17×
ctx=3500에서 hetero 버전의 성능 향상폭