Autonomous Driving Computing

Midterm Review

센서 측정에서 3D 검출까지 이어지는 중간고사 범위

Lectures 2–11
Assignment 1, Lab 1, and Lab 2

Exam Scope

범위는 측정, 2D perception, 3D perception, 두 실습으로 나뉜다

Block	Coverage	Review focus
Sensors	Lecture 2	측정값과 실패 조건
2D	Lectures 3–8	표현, 검출, 분할
3D	Lectures 9–11	깊이, point, fusion
Practice	Assignment 1, Labs 1–2	계산과 tensor 흐름

계산은 좌표, IoU, AP, box offset, voxel index를 중심으로 본다.
논문은 문제의식과 바꾼 연산을 연결해서 비교한다.

Sensor Modalities

센서마다 직접 측정하는 물리량과 실패 조건이 다르다

Sensor	Direct signal	Strength	Main limit
Camera	RGB intensity	class와 표지	조도와 depth
Stereo	disparity	metric depth	대응점 오차
LiDAR	range points	3D geometry	희소성과 날씨
RADAR	range, Doppler	장거리와 속도	각해상도

Camera는 의미와 texture에 강하지만 metric depth가 모호하다.
LiDAR는 3D geometry를 주고 RADAR는 range와 상대 속도에 강하다.

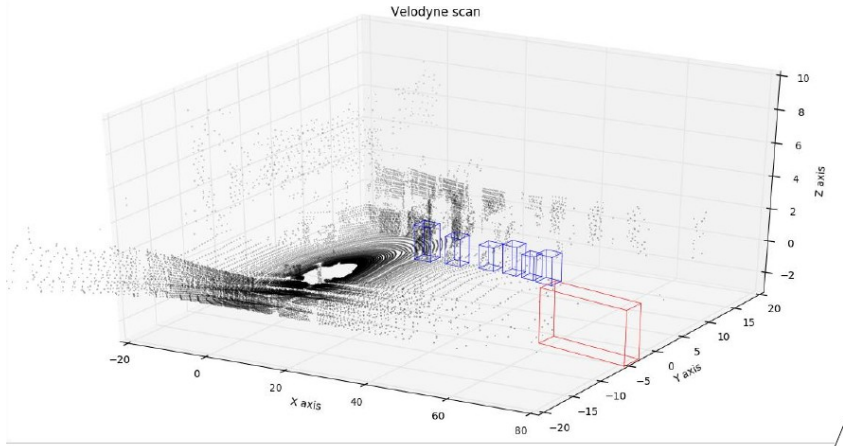
LiDAR Geometry

LiDAR point는 표면까지의 직접 거리 측정을 3D 좌표로 표현한다

LIDAR

LiDAR sample frame 시각화

3D Point cloud



국민대학교 KOOKMIN UNIVERSITY

17

축과 단위를 먼저 읽고 점의 희소성이 거리와 가림에 따라 달라짐을 본다.

Box는 point cloud와 같은 좌표계에 있어야 겹침과 거리를 계산할 수 있다.

Lecture 2, p. 17. LiDAR sample frame and 3D point cloud

Camera Projection

한 pixel은 하나의 3D 점이 아니라 camera center에서 뻗는 ray를 정한다

Stage	Input	Operation	Output
World	$X\tilde{w}$	homogeneous point	3D position
Extrinsic	R, t	world to camera	Xc
Intrinsic	K	ray to pixel	u, v
Inverse	u, v	depth required	3D point or ray

s [u,v,1]^T = K [R|t] X_w (homogeneous)
Extrinsic은 좌표계를, intrinsic은 ray를 pixel로 바꾼다.
Depth가 없으면 같은 ray 위의 여러 3D 위치가 같은 pixel에 투영된다.

Stereo Depth

Stereo depth는 disparity가 작아질수록 작은 pixel 오차에 더 민감하다

Disparity	Depth	1 px error	Meaning
35 px	10.8 m	약 0.31 m	근거리
7 px	54.0 m	약 7.71 m	원거리
0 px	정의 불가	무한대 방향	대응 실패

Rectification과 matched calibration 조건에서 $Z = fB/d$를 쓴다.
$f=700$ px, $B=0.54$ m이면 $d=35$ px에서 10.8 m, $d=7$ px에서 54 m다.

Perception Tasks

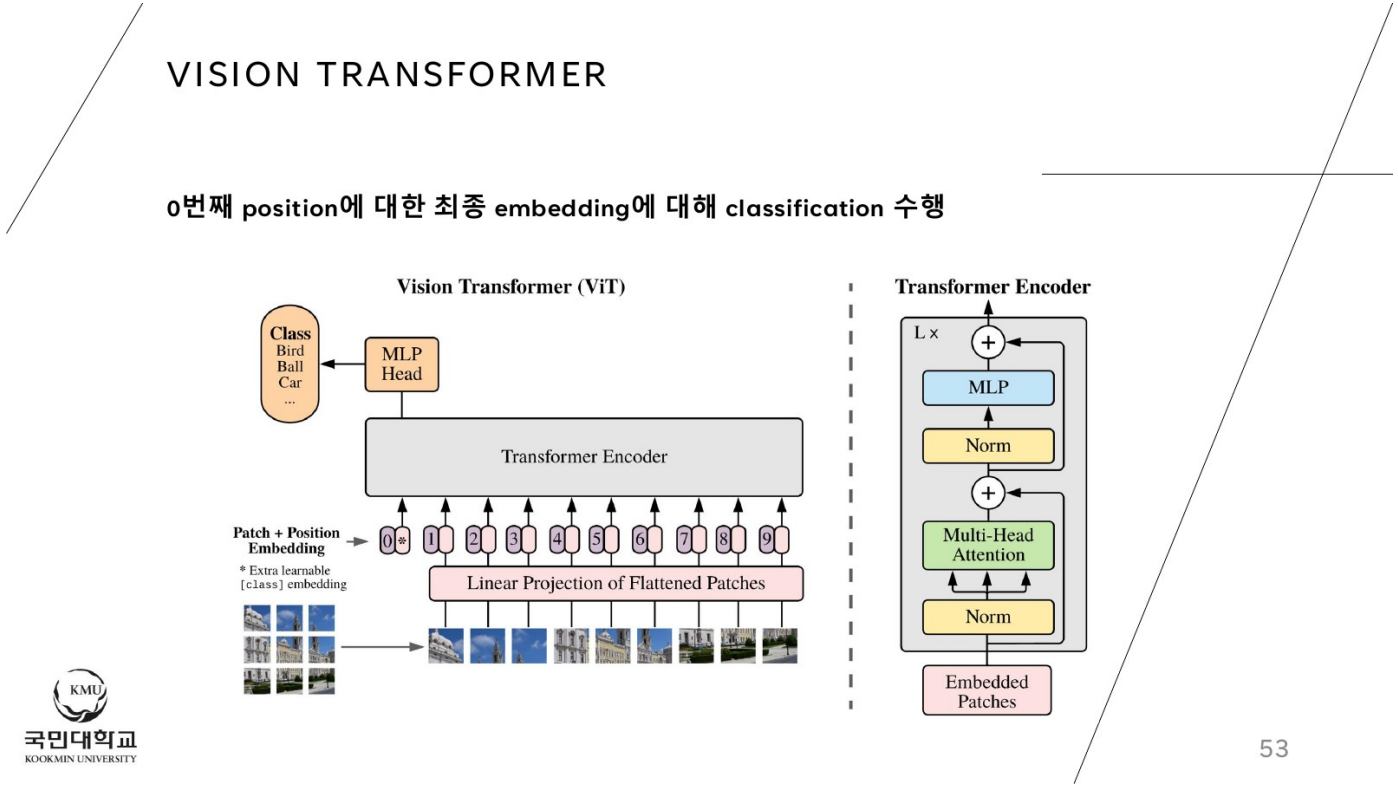
Task가 바뀌면 출력 단위와 필요한 label도 바뀐다

Task	Output	Question
Classification	class score	무엇인가
Localization	class + one box	주 객체는 어디인가
Detection	boxes + scores	각 객체는 어디인가
Semantic seg.	pixel classes	각 pixel의 종류는
Instance seg.	object masks	같은 class의 개체는

Classification은 image 하나에 class를 낸다.
Detection과 segmentation은 위치, 개체, pixel 수준 출력을 요구한다.

Visual Backbones

Backbone은 입력을 feature로 바꾸고 detector head는 class와 위치를 예측한다



VGG는 3×3 convolution을 쌓고 ResNet은 residual shortcut으로 깊은 최적화를 돕는다.

ViT는 patch token과 위치 정보를 self-attention으로 결합한다.

Lecture 3, p. 53. ViT patch embedding and Transformer encoder

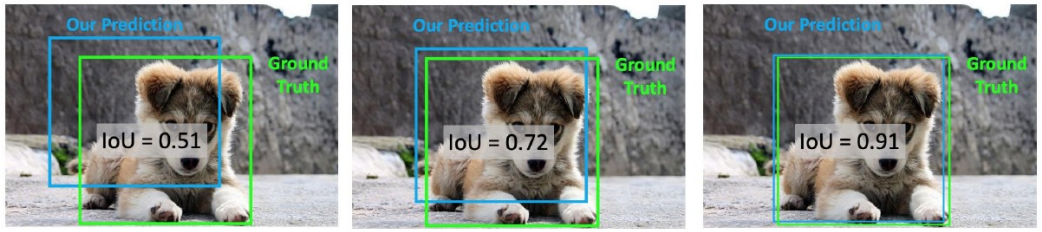
Intersection over Union

IoU는 교집합 넓이를 합집합 넓이로 나눈 겹침 비율이다

INTERSECTION OVER UNION

Q) 모델 학습 후 Bounding box prediction의 성능을 어떻게 평가?

A) Intersection (교집합) over Union (합집합) ➔ IoU



국민대학교 KOOKMIN UNIVERSITY

20

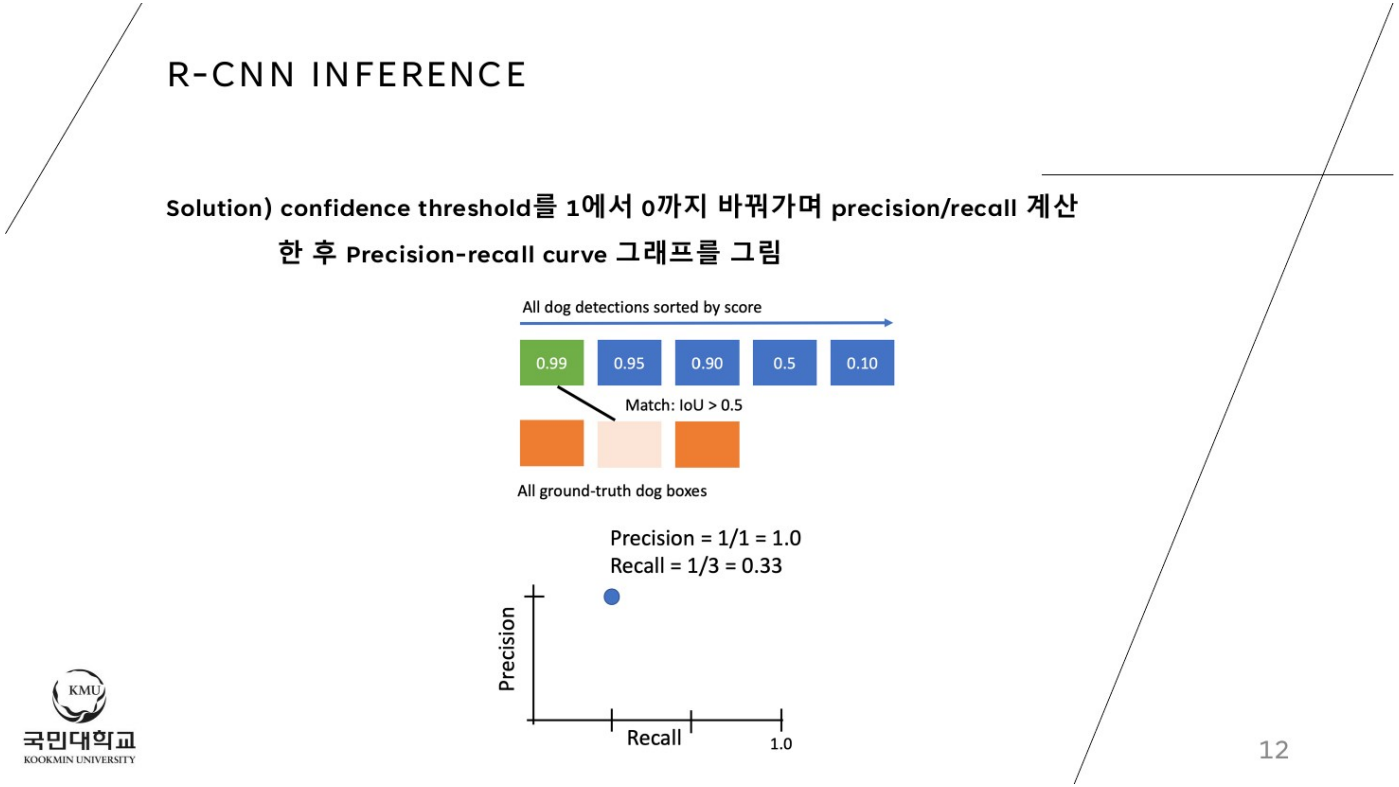
Lecture 4, p. 20. IoU increases as predicted and ground-truth boxes overlap

같은 IoU라도 anchor와 GT, prediction과 GT, prediction끼리의 비교를 구분한다.

A와 B의 넓이가 16, 교집합이 8 이면 IoU는 $8/(16+16-8)=1/3$ 이다.

Average Precision

AP는 confidence 순서로 만든 precision-recall curve의 면적이다



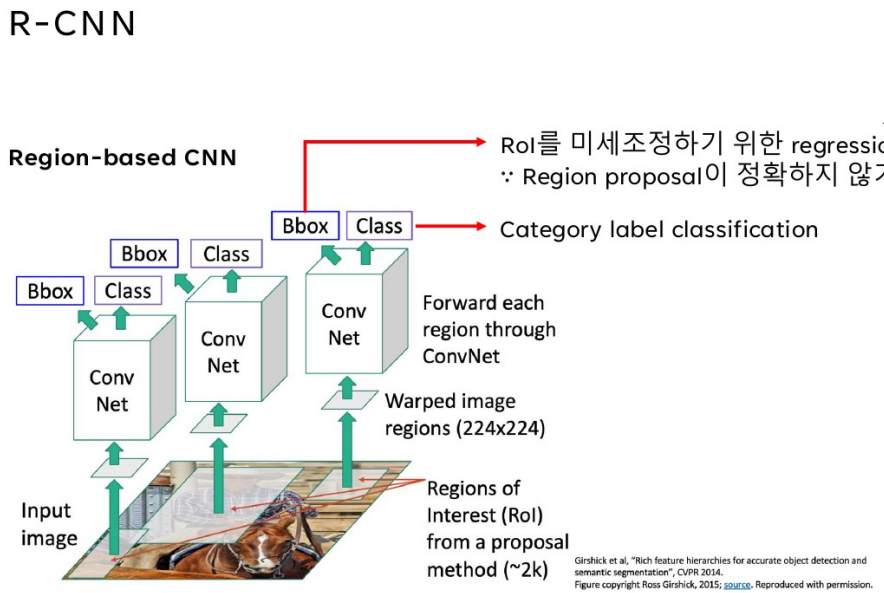
각 prediction은 같은 image와 class의 아직 쓰지 않은 GT에 한 번만 매칭한다.

TP, FP, TP, TP, FP와 GT 4개인 예시의 all-points AP는 0.625다.

Lecture 5, p. 12. First confidence-ranked detection gives precision 1 and recall 0.33

R-CNN

R-CNN은 약 2,000개 proposal마다 ConvNet을 반복해 계산한다



국민대학교 KOOKMIN UNIVERSITY

32

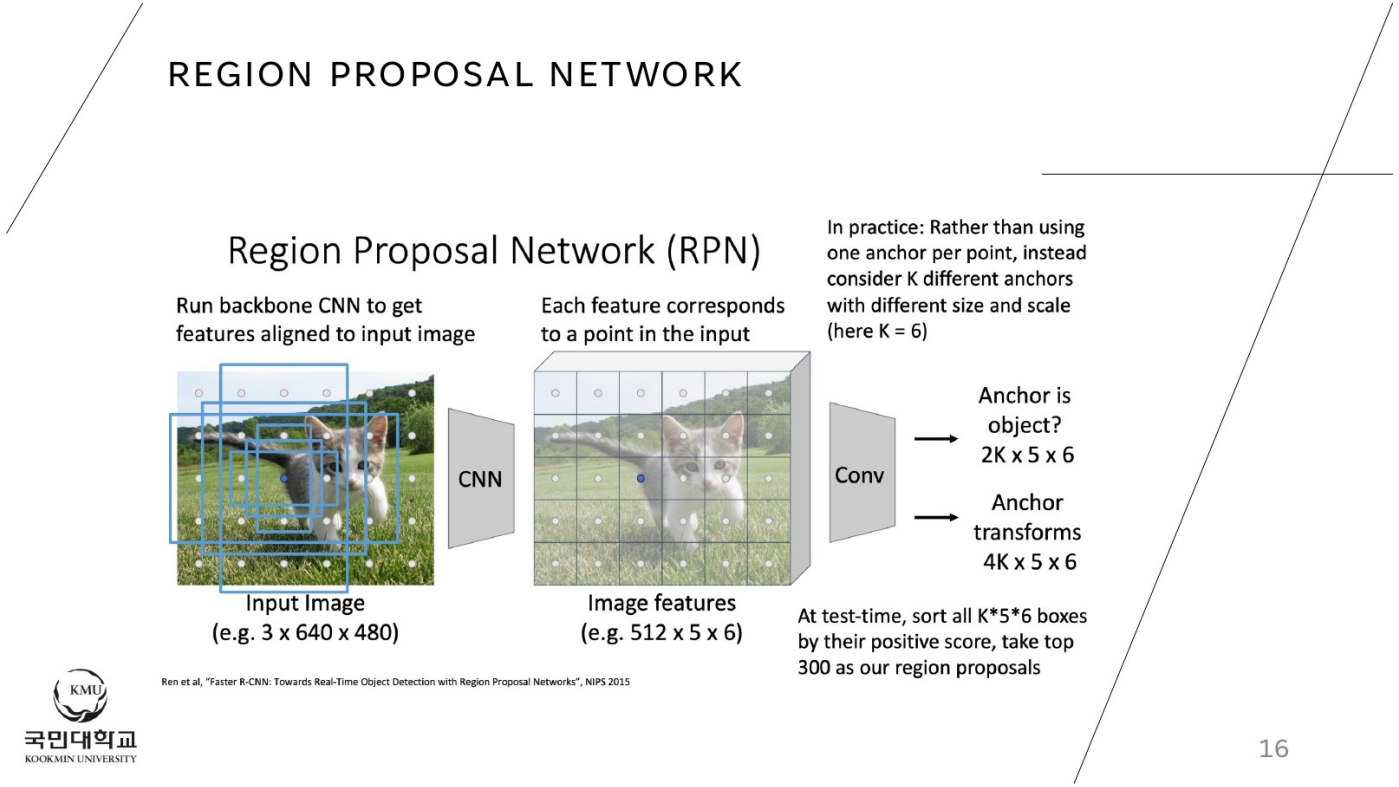
Selective Search가 후보를 만들고 각 region을 warp해 class와 box를 예측한다.

겹치는 region이 같은 image feature를 반복 계산하는 점이 핵심 병목이다.

Lecture 4, p. 32. Region-wise ConvNet computation in R-CNN

Anchors and RPN

Anchor는 기준 box이고 RPN은 objectness와 box offset을 예측한다



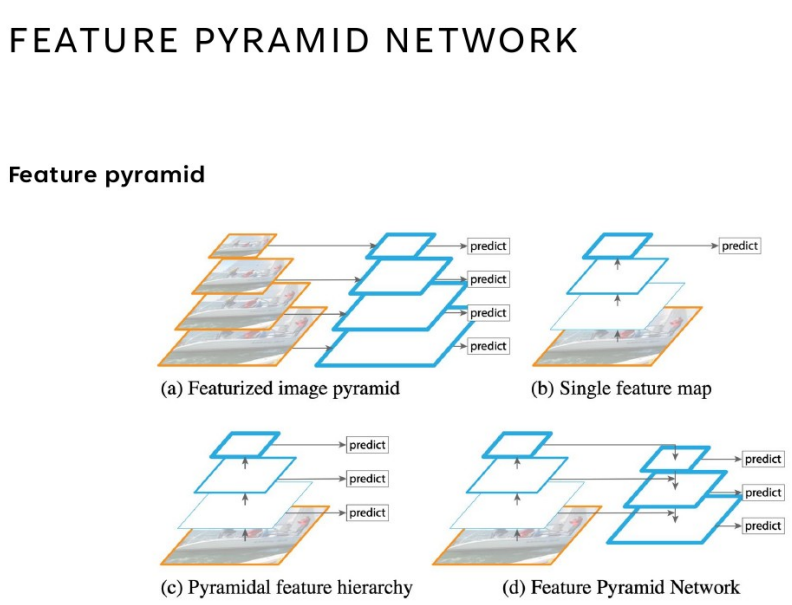
Lecture 6, p. 16. RPN outputs objectness and four transforms for K anchors

Anchor (50,40,20,10)에서 GT (54,38,30,5)의 target은 (0.2,–0.2,0.4055,–0.6931)이다.

Decode는 목표값을 되돌리는 검산이며 실제 prediction이 GT와 같다는 뜻이 아니다.

Feature Pyramid Network

FPN은 깊은 층의 의미 정보와 얕은 층의 세밀한 위치 정보를 합친다



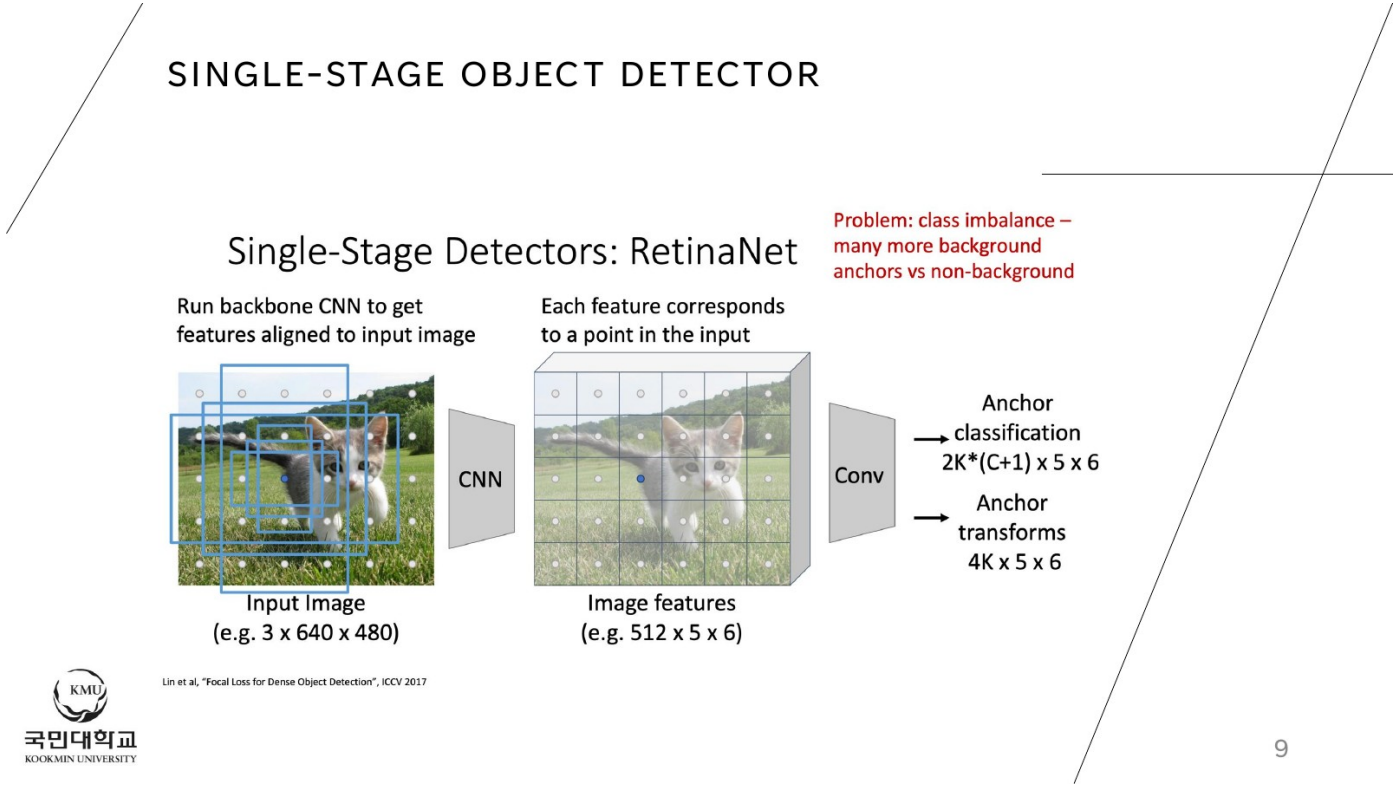
Top-down upsampling과 lateral connection이 여러 해상도의 feature를 만든다.

FPN은 detector 전체가 아니라 RPN이나 dense head가 쓰는 multi-scale feature 구조다.

Lecture 6, p. 31. Four scale-handling strategies and FPN

RetinaNet

RetinaNet은 dense anchors의 심한 foreground-background 불균형을 다룬다



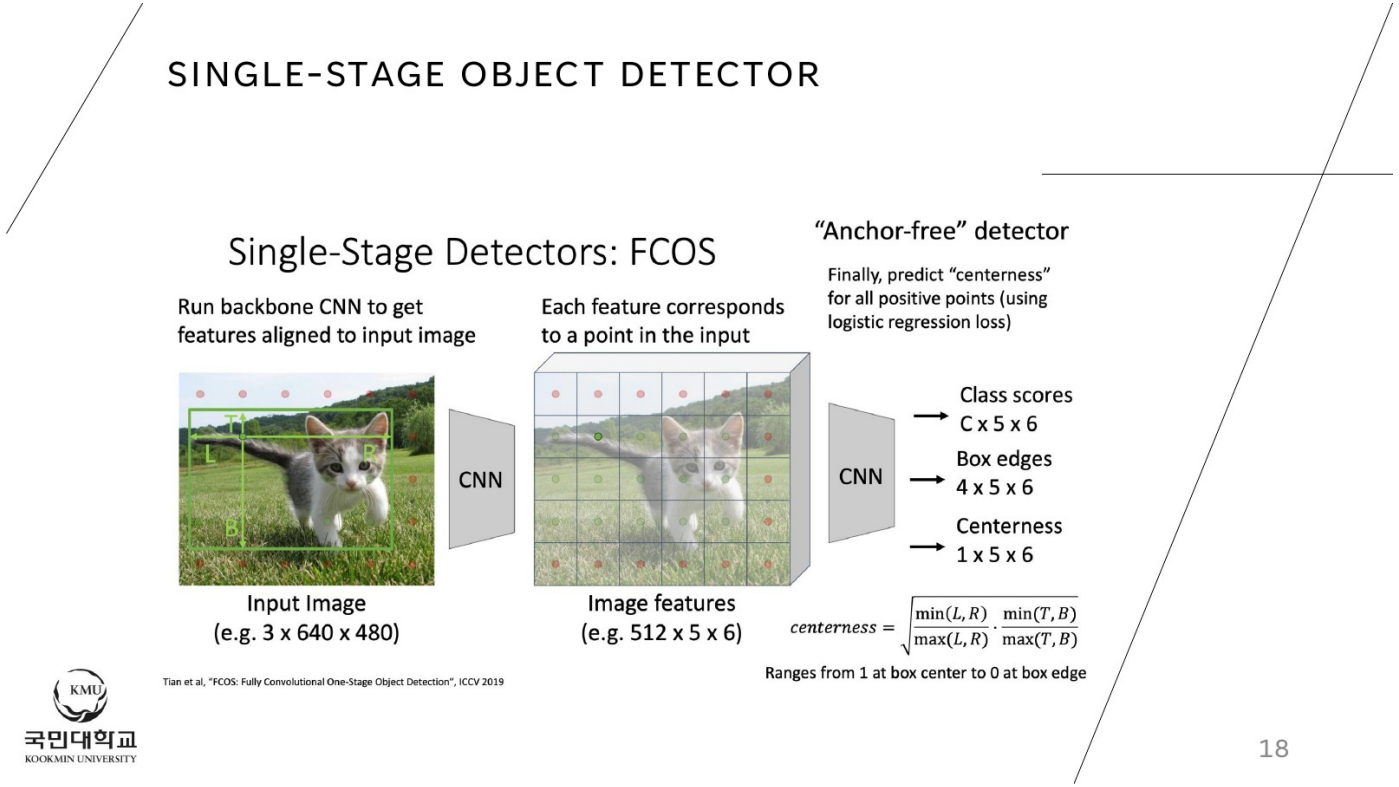
FPN의 각 위치와 anchor에서 class score와 box offset을 예측한다.

Focal loss는 쉬운 negative를 삭제하지 않고 해당 gradient의 비중을 줄인다.

Lecture 7, p. 9. Anchor-based dense classification and regression heads

FCOS

FCOS는 anchor template 대신 위치에서 box 네 변까지의 거리를 예측한다



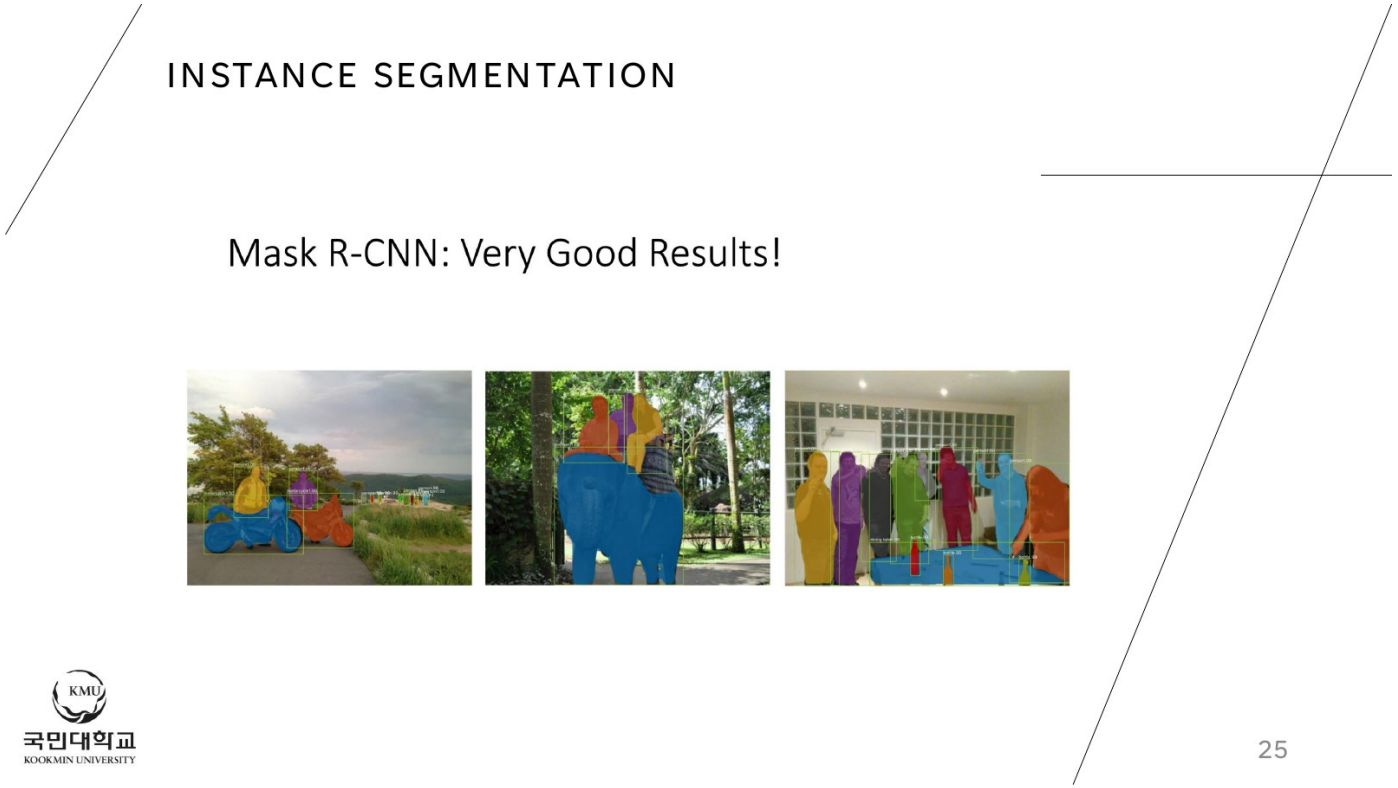
출력은 class, left-top-right-bottom 거리, centerness다.

Anchor-free여도 positive location assignment와 NMS는 남는다.

Lecture 7, p. 18. FCOS distances and centerness from each feature location

Instance Segmentation

Instance segmentation은 같은 class의 객체도 서로 다른 mask로 분리한다



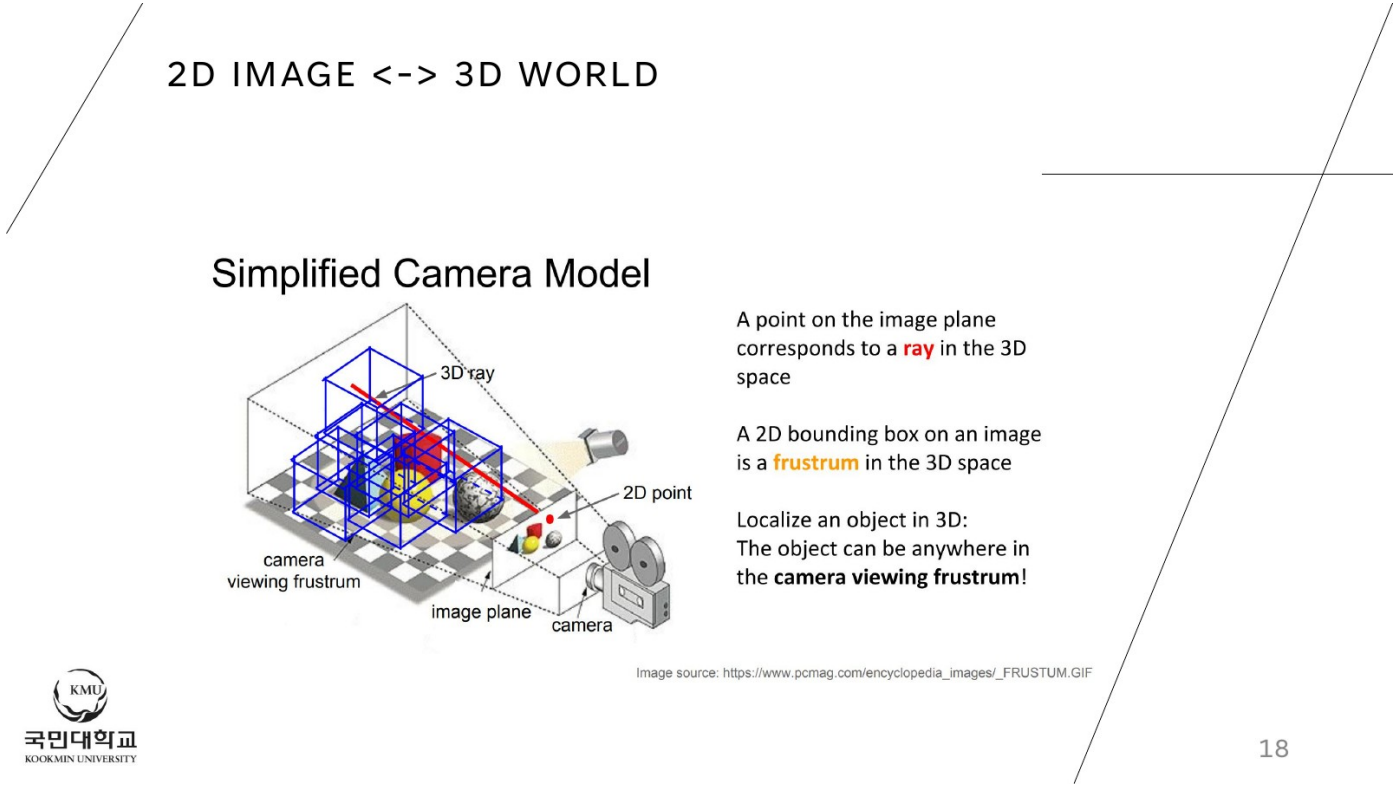
Mask R-CNN은 Faster R-CNN의 class와 box 경로에 object별 mask branch를 더한다.

RoIAlign은 좌표 반올림을 피하고 mask 경계의 공간 정렬을 보존한다.

Lecture 8, p. 25. Separate masks for different object instances

Monocular 3D Ambiguity

단안 영상의 2D box는 3D 공간에서 하나의 frustum만 정한다



Frustum 안의 여러 위치와 크기가 같은 2D 관측을 만들 수 있다.

Mono3D와 MonoRCNN은 prior와 geometry로 이 depth 모호성을 줄인다.

Lecture 9, p. 18. Multiple 3D boxes can match one image observation

Pseudo-LiDAR

Pseudo-LiDAR는 예측 depth를 metric 3D point cloud로 역투영한다



Lecture 9, p. 36. Image depth to pseudo point cloud and 3D detector

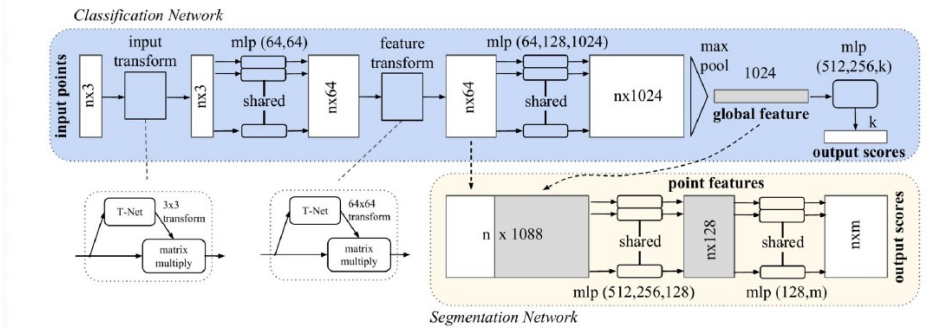
Image grid보다 3D 이웃 관계를 드러내 LiDAR detector를 적용할 수 있다.

표현을 바꿔도 잘못 추정한 depth와 calibration 오차는 그대로 남는다.

PointNet

Shared MLP과 symmetric max pooling이 point 순서에 무관한 global feature를 만든다

POINT CLOUD BACKBONE – POINTNET



- PointNet applies MLP per point, followed by **max-pooling** and a final (global) MLP
- Affine input/feature transformations for geometric invariance (small PointNets)

Qi, Su, Mo and Guibas: PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation. CVPR, 2017.

단점 : local structure 모델링을 하지 못함 – CNN의 성공 요인 recall

국민대학교 KOOKMIN UNIVERSITY

12

특징이 p1=(1,5), p2=(4,2), p3=(3,7)이면 max는 (4,7)이다.

점 순서를 바꿔도 후보 값 집합과 max가 같지만 좌표 회전 불변성까지 보장하지는 않는다.

Lecture 10, p. 12. Point-wise MLP, max pooling, and global feature

3D Representations

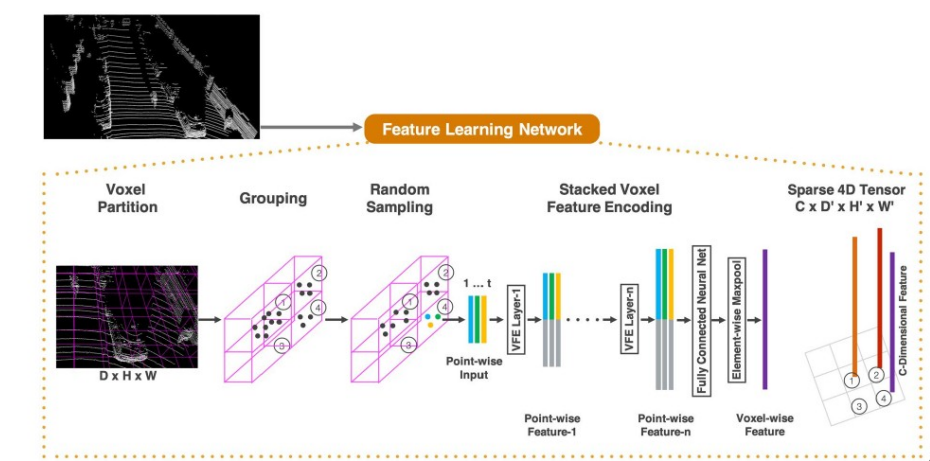
같은 point cloud도 표현에 따라 보존 정보와 계산 구조가 달라진다

Representation	Preserves	Tradeoff	Example
Raw points	개별 3D 측정	불규칙 집합	PointNet
Voxels	3D local grid	양자화와 sparse 계산	VoxelNet
BEV	지면 footprint	height 요약	PIXOR
Image projection	RGB 대응	가림과 희소성	Fusion

Point는 개별 측정을 유지하고 voxel은 3D grid 이웃을 만든다.
BEV는 높이를 channel이나 통계로 요약해 2D convolution을 쉽게 한다.

VoxelNet

VoxelNet은 voxel 내부의 point 특징을 학습하고 3D grid에서 이웃 정보를 모은다



VFE는 point 특징과 voxel별 max feature를 결합해 sparse voxel tensor를 만든다.

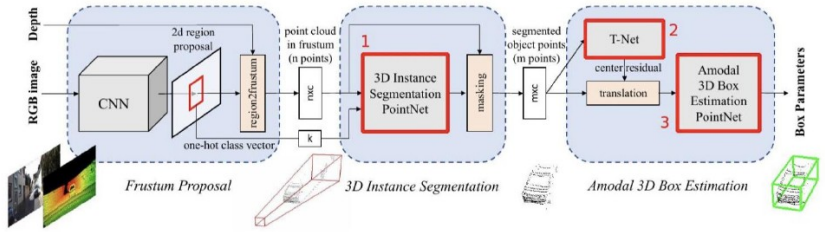
3D convolution 뒤 height 정보를 channel로 합쳐 BEV detection head에 전달한다.

Lecture 10, p. 29. Voxel partition, grouping, sampling, and VFE

Frustum PointNets

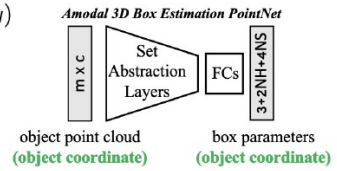
Frustum PointNets는 image box로 3D 탐색 범위를 줄인 뒤 point를 처리한다

FRUSTUM POINTNET



3D box prediction problem is split into **3 stages:** (all implemented via PointNets)

1. **Segmentation** of RGB point cloud (object vs. background)
2. **Translation** of points such that centroid aligns with 3D box center
3. **3D bounding box regression** (x, y, z, w, h, l, y)



14

객체 point 분리, 중심 보정, amodal 3D box 추정이 세 단계로 이어진다.

2D detector가 객체를 놓치면 frustum이 생기지 않아 뒤 단계도 복구하기 어렵다.

Lecture 11, p. 14. Image proposal, point segmentation, and 3D box estimation

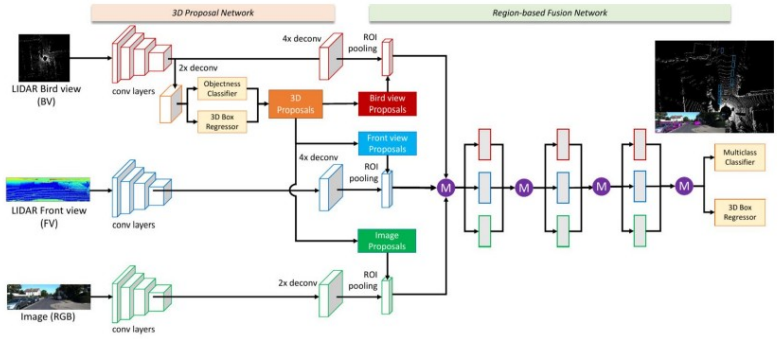
MV3D Fusion

MV3D는 LiDAR BEV proposal을 여러 view에 투영해 feature를 결합한다

MV3D

전체 pipeline

Two-stage detection pipeline



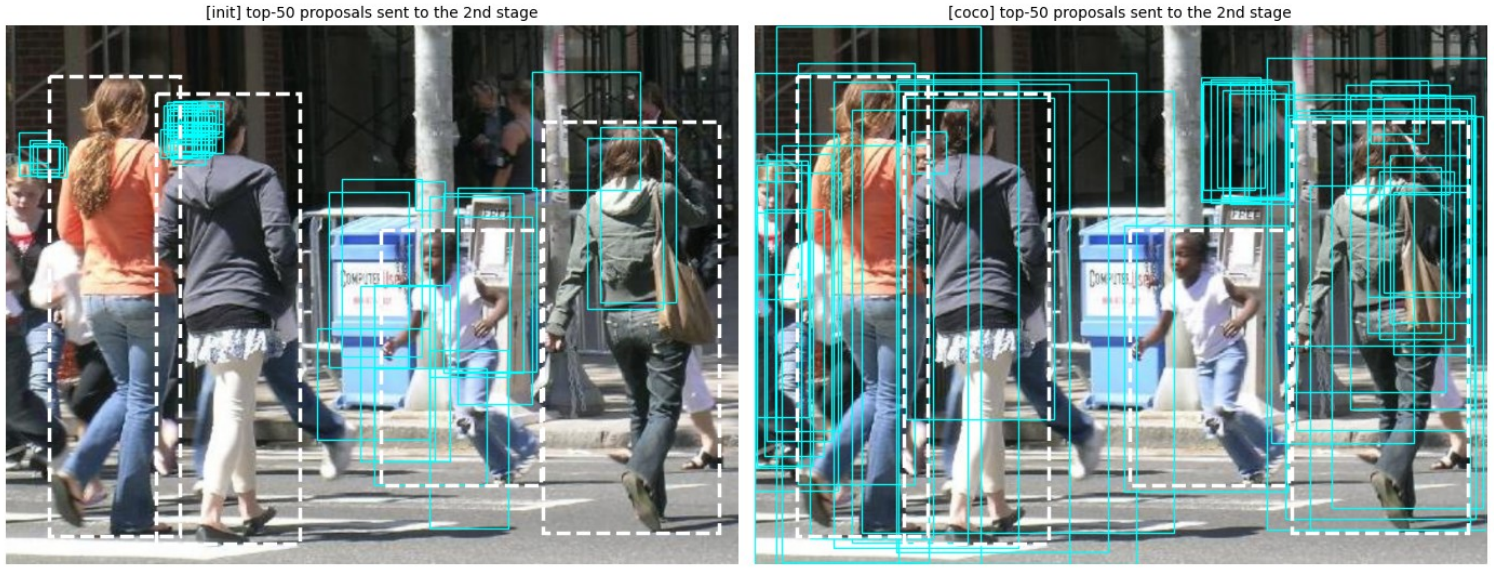
BEV, LiDAR front view, RGB의 RoI feature를 같은 3D proposal 단위로 맞춘다.

Calibration이나 BEV proposal이 틀리면 deep fusion 뒤에도 오류가 남는다.

Lecture 11, p. 21. BEV proposals and deep fusion across three views

Lab 1 Evidence

Lab 1은 two-stage proposal과 one-stage dense prediction을 같은 image에서 추적한다



청록 box는 RPN top-50 proposal이고 흰 점선은 GT다.

초기화와 COCO 모델의 차이는 저장된 한 출력이며 proposal 수만으로 성능을 판정할 수 없다.

Lab 1 solution notebook, cell 27. Saved RPN proposals before final classification

FPN Levels and Anchor Fit

작은 객체는 촘촘한 feature level에서, 큰 객체는 큰 anchor에서 더 잘 맞을 수 있다

Level	Anchor scale	Saved GT 2: best IoU
P2	32 px · 촘촘한 grid	0.01
P3 / P4	64 / 128 px	0.05 / 0.18
P5	256 px	0.73 · h/w = 2
P6	512 px · 성긴 grid	0.34

같은 GT 중심에 놓은 15개 template의 비교다. 모든 객체가 P5에 맞는다는 뜻은 아니다.
P2는 작은 객체의 위치를 세밀하게 나누지만 anchor 크기·비율도 함께 맞아야 한다.

RPN Targets and Sampling

Anchor와 GT가 label·offset target을 정하고, network는 objectness와 offset을 학습한다

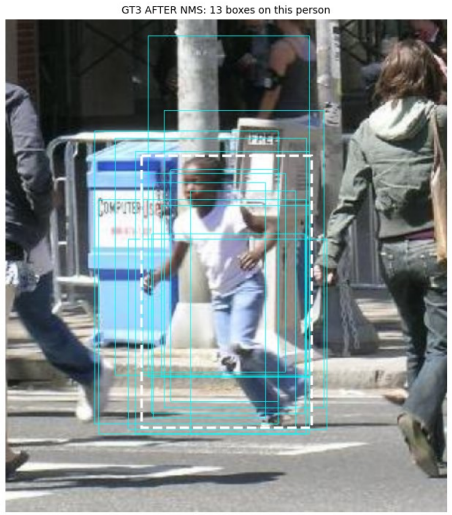
Target	Assignment rule	Saved count
Positive	IoU ≥ 0.7 또는 low-quality match	17
Negative	IoU < 0.3 · positive 제외	125,811
Ignore	어느 학습 label에도 미배정	532
Sample	총 256 · positive 최대 128	17 positive + 239 negative

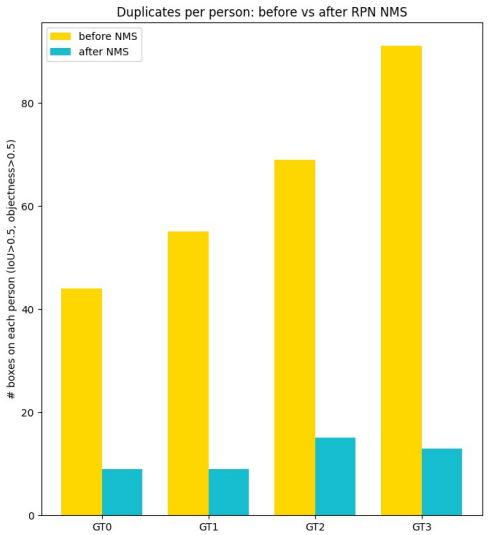
Positive가 17개뿐이면 128개로 늘리지 않고 남은 239개를 negative로 채운다.
Ignore는 classification에서 제외하고, box regression은 positive에만 적용한다.

RPN Proposal Filtering

NMS는 겹치는 후보를 줄인다. 후보 수 감소와 최종 검출 성공은 같은 지표가 아니다







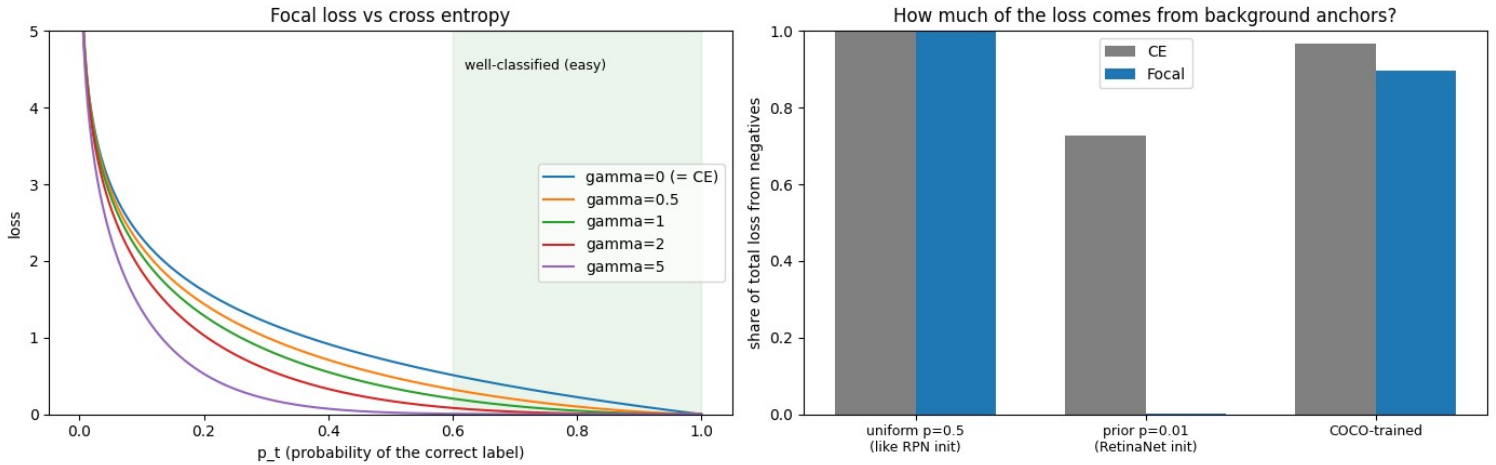
GT 3 주변 후보는 91→13개다. 흰 점선은 GT, 노랑은 후처리 전, 청록은 후처리 뒤다.

RPN NMS는 0.7, 최종 box NMS는 0.5다. NMS가 객체당 box 하나를 보장하지는 않는다.

Lab 1, cell 27. Saved proposals around GT 3 before and after filtering

Dense Anchors and Focal Loss

Focal loss는 맞히기 쉬운 negative의 기여를 줄인다. Anchor 자체를 없애는 방식은 아니다



학습 대상 94,683개 중 positive는 77개, negative는 94,606개다. Ignore 168개는 제외한다.

p=0.01 prior에서 배경 loss 비중은 CE 72.8%→FL 0.1%다. p=0.5에서는 감소하지 않는다.

Lab 1, cell 59. Focal-loss curves and saved CE/FL loss shares

Two-Stage vs One-Stage

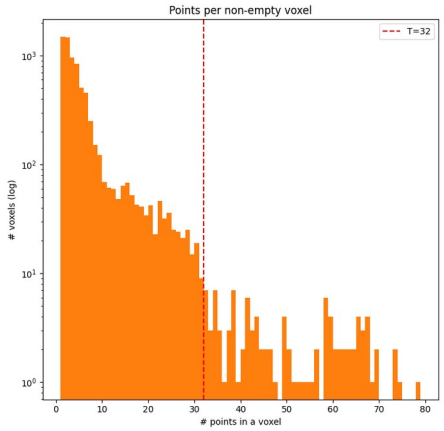
두 방식 모두 anchor·GT matching을 쓰지만 후보 선택과 class 예측의 위치가 다르다

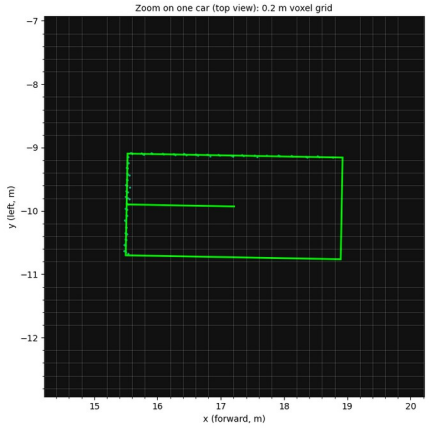
Step	Faster R-CNN	RetinaNet
Candidates	RPN → proposal → RoI	각 FPN 위치의 dense anchor
Classification	objectness 뒤 RoI class	anchor에서 바로 class
Imbalance	RPN/RoI sampling	focal loss · ignore 제외
Box refinement	RPN + RoI 두 번	dense head에서 한 번

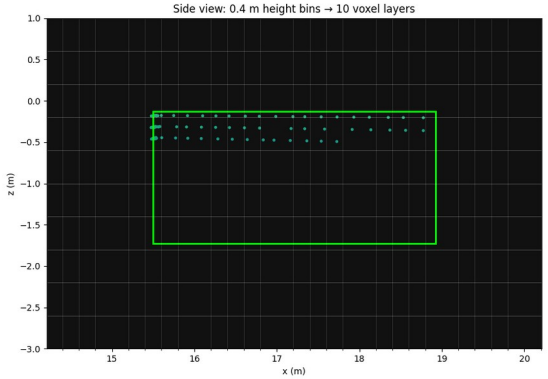
RPN이 바꾼 proposal은 RoI 단계에서 새로운 기준 box가 된다.
RetinaNet은 sampled subset 대신 valid anchor를 쓰되 쉬운 예측의 loss를 줄인다.

Lab 2 Evidence

Lab 2는 point range, voxel size, point cap을 분리해 sparse tensor를 만든다







Voxel은 0.2×0.2×0.4 m이고 grid는 256×256×10이다.

T=32는 voxel당 point cap이다. 저장 AP는 synthetic center-distance AP이며 KITTI 공식 성능이 아니다.

Lab 2 notebook, cell 25. Point-count histogram and voxel grids

Point Sets and Input Representations

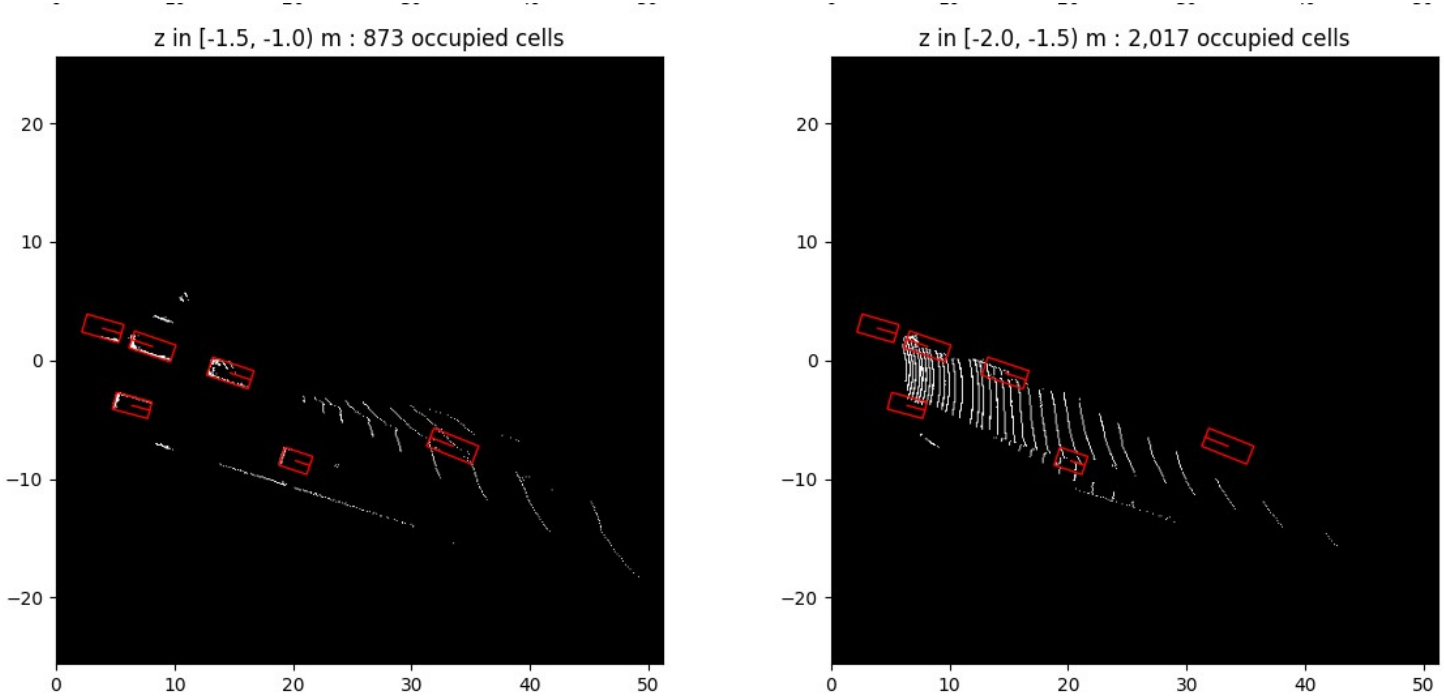
Point cloud는 순서 없는 가변 길이 집합이다. 표현 방식이 계산 가능한 이웃 구조를 바꾼다

Representation	Input handling	What changes
Raw points	N×4: x, y, z, reflectance	행 순서가 바뀌어도 같은 점 집합
PIXOR-style BEV	height별 occupancy channel	3D 위치를 2D grid로 요약
VoxelNet-style	voxel 안의 특징을 학습	불규칙 점 → 3D grid feature
PointRCNN-style	raw point에서 후보 생성	점 단위 구조를 직접 처리

저장된 KITTI frame은 (17,238, 4)다. 다른 frame도 N이 같을 필요는 없다.
Point 좌표를 바꾸는 것과 행 순서를 섞는 것은 다르다.

PIXOR Height Slices

Height channel은 같은 BEV 위치에서 도로와 차량이 어느 높이를 차지하는지 구분한다



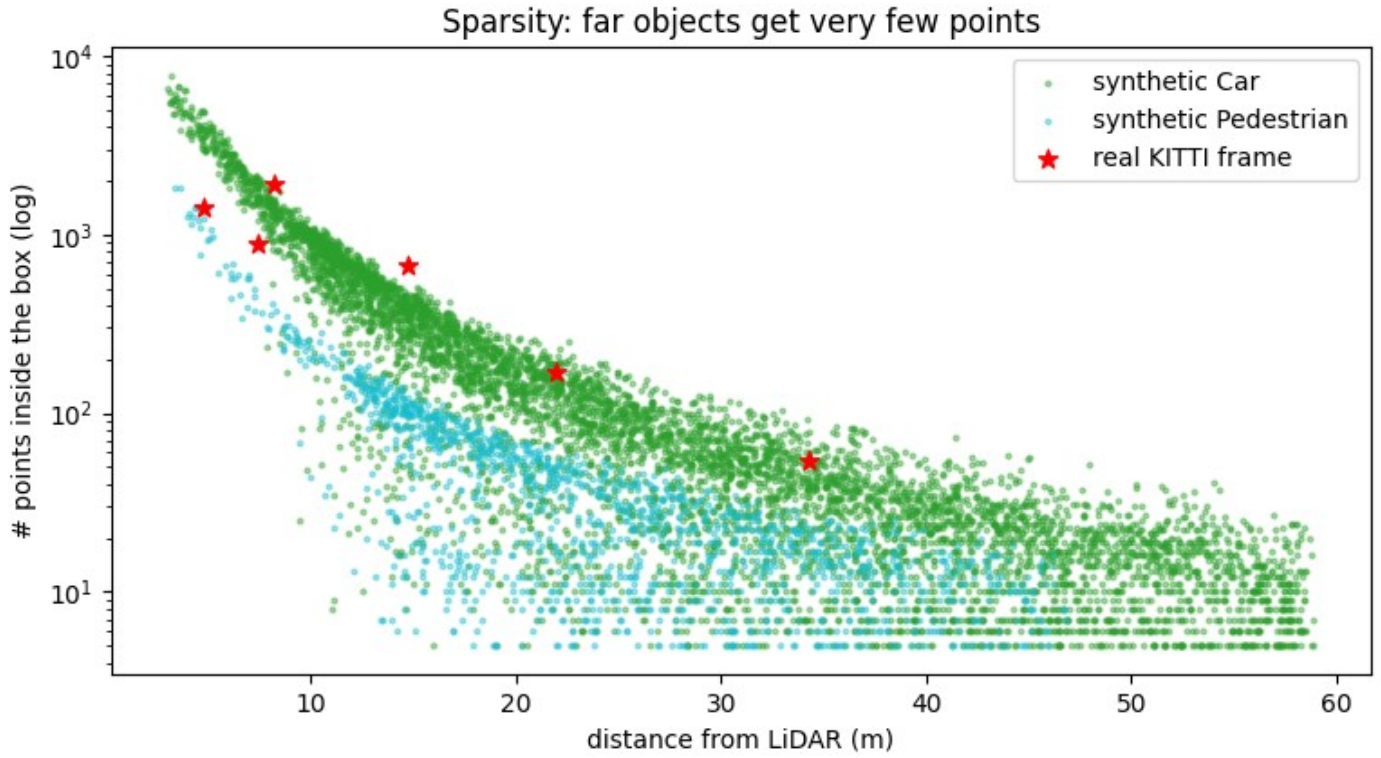
왼쪽 [−1.5,−1.0) m에는 차량, 오른쪽 [−2.0,−1.5) m에는 도로 점이 많다.

빨간 선은 GT box 투영이다. 실제 점은 흰 occupancy다. 실행 배열은 높이 7채널이며 reflectance는 합치지 않았다.

Lab 2, cell 15. Original occupancy panels cropped to car and ground height bands

Range and Point Sparsity

같은 각도 간격의 LiDAR는 멀수록 표면의 점 간격이 커져 작은 객체의 증거가 줄어든다



Lab 2, cell 21. Synthetic samples and real KITTI cars; point-count axis is logarithmic

가로는 BEV 거리(m), 세로는 객체 내부 point 수(log)다. 빨간 별은 실제 KITTI 차량이다.

예: 8.2 m에서 1,933점, 21.9 m에서 169점, 34.3 m에서 54점. 가림·방향도 점 수에 영향을 준다.

Voxel Features and BEV

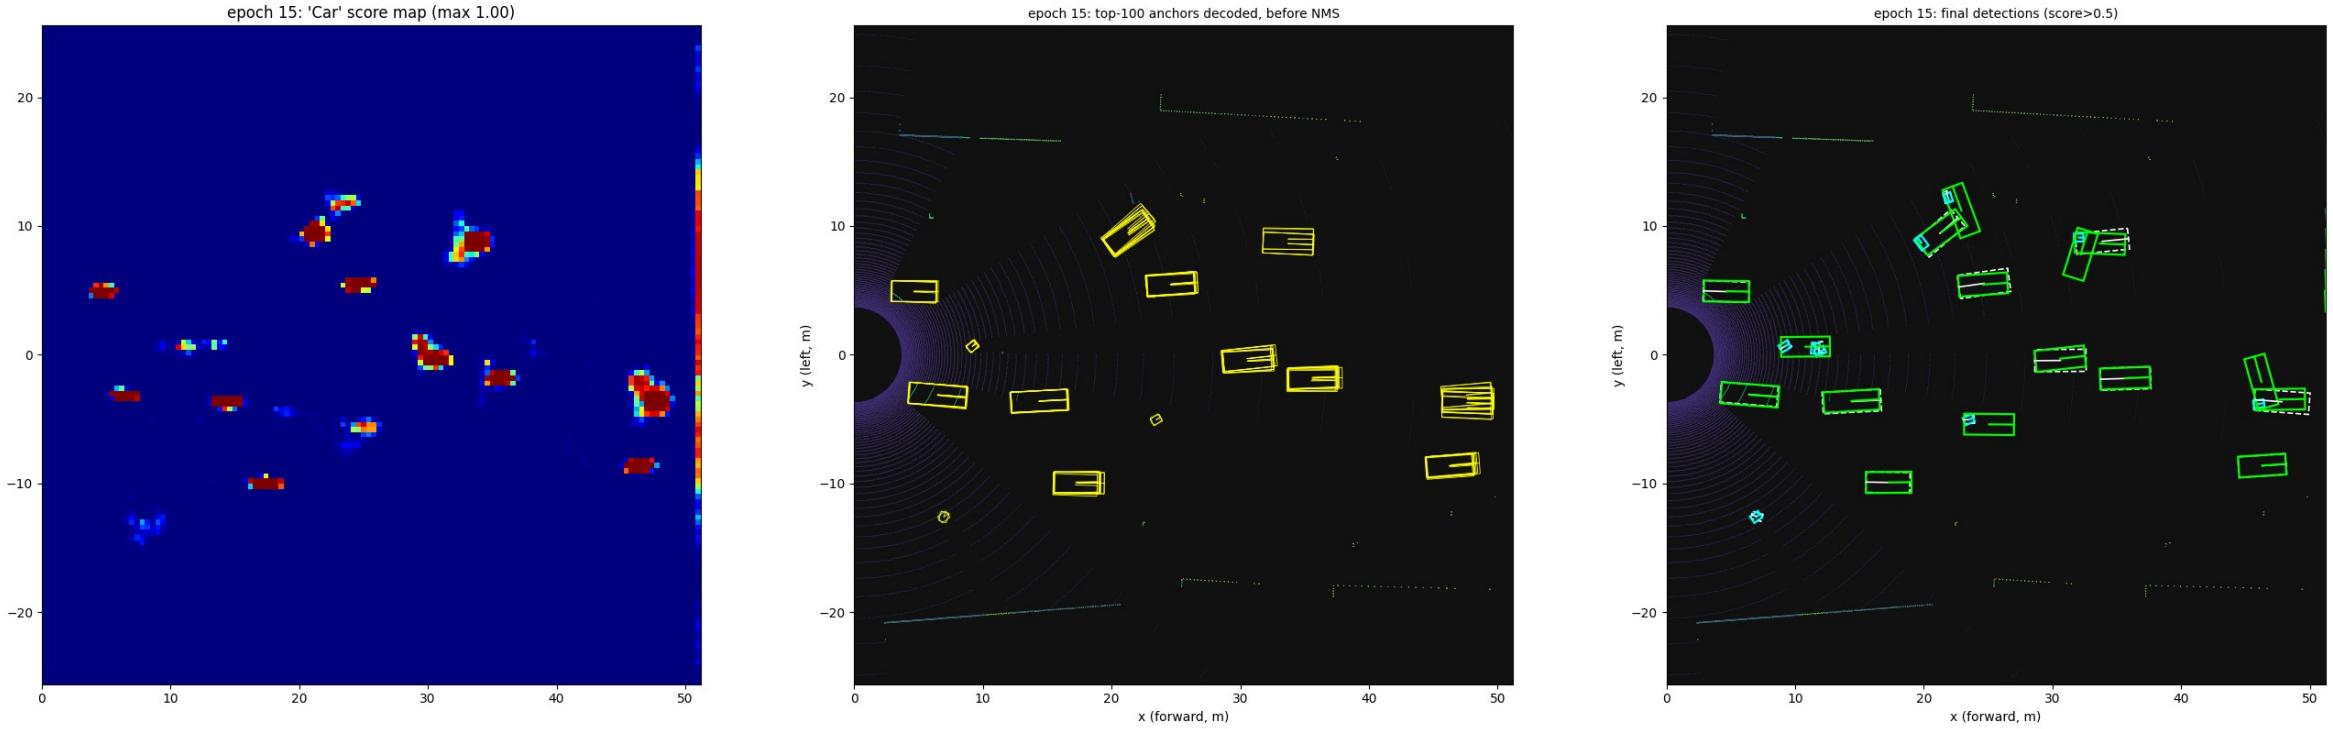
Voxel 안에서는 점을 요약하고, voxel 사이에서는 3D convolution으로 문맥을 합친다

Stage	Saved shape	Meaning
Point features	$V \times 32 \times 7$	좌표·reflectance·평균 상대 좌표
VFE + max	$V \times 64$	voxel마다 고정 길이 특징
Scatter / 3D conv	$1 \times 64 \times 10 \times 256 \times 256$ $\rightarrow 1 \times 32 \times 3 \times 256 \times 256$	grid 배치 뒤 3D 이웃 결합
BEV / box head	$1 \times 96 \times 256 \times 256$ $\rightarrow 65{,}536 \times 7$	height를 channel에 합쳐 box 예측

Point cap 32는 voxel 개수가 아니다. 저장 장면의 occupied voxel V는 7,236개다.
32 channels $\times$ 3 height = 96 channels다. Height를 평균으로 버린 것이 아니다.

Training Score Maps

왼쪽은 Car 확률, 가운데는 NMS 전 top-100 box, 오른쪽은 score〉0.5 최종 box다.
학습 뒤 객체 부근에 score가 모여도 false positive는 남을 수 있다



Lab 2, cell 38. Original epoch-15 row; map colors share the fixed 0–1 probability scale

Validation and Transfer

AP는 어떤 정답 매칭 규칙으로 계산했는지와 함께 읽어야 한다

Saved validation	Car	Pedestrian
Epoch 0 AP	0.067	0.000
Epoch 8 AP	0.943	0.922
Epoch 15 AP	0.948	0.912
Center match	BEV distance ⟨2 m	BEV distance ⟨1 m

합성 train 600 / validation 60 scenes의 수치다. KITTI 공식 3D-IoU AP가 아니다.
실제 KITTI 전이는 별도 정성 확인이다. Fine-tuning 효과도 실제 검증 자료로 확인해야 한다.

Final Recap

측정값, 표현, 후보, 예측, 평가를 같은 흐름으로 연결하면 모델 차이가 보인다

Question	Check
무엇을 측정했나	sensor와 coordinate
어떻게 표현했나	image, point, voxel, BEV
후보는 어디서 왔나	anchor, point, image, BEV
무엇을 예측했나	class, box, mask, depth
어떻게 평가했나	IoU, matching, PR, AP

수식은 좌표계와 단위를 먼저 확인하고 작은 수치로 검산한다.
논문 비교에서는 직접 확장과 같은 문제의 대안을 구분한다.