

머신러닝 기초

Lecture 1: 모델과 데이터

데이터

- 현대의 머신러닝과 인공지능 모델들이 작동할 수 있게 해준 근본적인 원인: 많은 데이터!
- 가정: 데이터는 **테이블 형식**의 컴퓨터가 읽을 수 있는 **수치적인 형태**



데이터의 벡터화

- 컴퓨터가 읽을 수 있도록 전문가가 원본데이터를 특징값 (feature)들로 변환하여 D차원의 특징 벡터로 변환

Name	Gender	Degree	Postcode	Age	Annual salary
Aditya	M	MSc	W21BG	36	89563
Bob	M	PhD	EC1A1BA	47	123543
Chloé	F	BEcon	SW1A1BH	26	23989
Daisuke	M	BSc	SE207AT	68	138769
Elisabeth	F	MBA	SE10AA	33	113888

Gender ID	Degree	Latitude (in degrees)	Longitude (in degrees)	Age	Annual Salary (in thousands)
-1	2	51.5073	0.1290	36	89.563
-1	3	51.5074	0.1275	47	123.543
+1	1	51.5071	0.1278	26	23.989
-1	1	51.5075	0.1281	68	138.769
+1	2	51.5074	0.1278	33	113.888

데이터: $\mathbf{x}_n$

데이터의 벡터화


- 변환 후: $\mathbf{X} \in \mathbb{R}^{N \times D}$
- N개의 데이터, D차원 feature
- 일반적인 규칙: 연속적인 수치값 (continuous value)을 가지는 특징벡터는 **평균이 0이고 분산이 1**이 되도록 수치를 조정

데이터 처리의 중요성

- 최신 인공지능 모델들이 부딪힌 벽: 모델을 학습할 데이터가 점점 부족해진다
- 빅테크 기업(Google, OpenAI)들이 바라보고 있는
방향성: 양을 늘릴 수 없다면 '잘' **골라진** 데이터들을 '잘'
가공해서 사용하자
- 골라진 => Data selection
- 가공 => Data preprocessing
- 그냥 양을 늘리자 => Data augmentation with generative models

모델이란?


- 입력을 받아 예측, 분포, 결정 같은 출력을 내는 함수
- 지도학습(supervised learning)에서의 데이터셋
- $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$
- 우리가 모델을 통해 알고 싶은 것?
 - 어떤 임의의 x 에 해당하는 y 값



결정론적 함수로서의 모델


- 임의의 x 값에 해당하는 y 값을 예측하기 위해 기존에 가지고 있던 데이터셋을 잘 설명하는 함수를 이용
- 예) 선형 회귀(Linear Regression)

$$f : \mathbb{R}^D \rightarrow \mathbb{R}, \text{ e.g., } f(\mathbf{x}) = \theta^\top \mathbf{x} + \theta_0$$



확률분포로서의 모델

- 임의의 x 값에 해당하는 y 값만을 예측하는 것이 아니라 한 스텝 더 나아가 예측에 대한 불확실성도 모델링하여 확률분포를 출력
 - 데이터 관측 에러(noise)라던가 데이터의 부족에 따른 모델 오류 등
- 예) 가우시안 분포 활용



머신러닝이란?

- Learning = 수 많은 **모델**과 그 모델의 **변수**(parameter)들 중 우리가 **미관측 데이터**(unseen data)에 대해 좋은 예측을 주는 모델과 변수를 찾는 과정!

머신러닝이란?

- Learning의 세 가지 단계
 - 학습(Training) / 변수 추정(Parameter estimation)
 - 결정론적 모델: 경험적 위험 최소화 (ERM; Empirical Risk Minimization)
 - 확률적 모델: 변수 추정
 - 하이퍼파라미터 튜닝(Hyperparameter Tuning) / 모델 선택(Model Selection)
 - 예측 (prediction) / 추론 (inference)

ERM & 변수 추정

- Learning에서 가장 중요한 단계인 Training 단계에서 사용하는 ERM과 변수 추정을 이해하기 위해서는?
 - 선형대수(Linear Algebra)
 - 확률론(Probability Theory)
 - 벡터 미적분학과 최적화 (Vector Calculus and Optimization)

학습에 대한 이해 후 모델

- ERM과 변수 추정에 대한 이해를 할 준비가 된 이후에는?
- 각 데이터셋과 풀고자하는 문제에 따른 모델과 학습에 대해 배움
 - Linear Regression
 - PCA (Principal component analysis)
 - GMM (Gaussian Mixture Models)
 - SVM (Support Vector Machine)
 - GP (Gaussian Processes)

Q&A