

머신러닝 기초

Lecture 4: 선형대수(3)

선형 독립(Linear Independence)

- 벡터공간 V 와 유한한 수의 벡터 $x_1, \dots, x_k \in V$ 가 있다고 가정하자. 이때 아래의 선형 조합이 자명하지 않은 해가 있는 경우 우리는 $x_1, \dots, x_k$ 을 **선형 종속(linear dependent)**이라고 하고 만약 자명한 해만 존재하는 경우를 **선형 독립(linear independent)**이라고 한다.

$$0 = \sum_{i=1}^k \lambda_i x_i$$

- $\lambda_1 = \dots = \lambda_k = 0$: 자명한 해, 이외의 경우 자명하지 않은 해

선형 독립과 선형 종속

- k 개의 벡터는 선형 독립이거나 선형 종속; 이외의 경우는 없음
- 만약 벡터 중 하나라도 0이면 이 k 개의 벡터는 선형 종속; 왜?
- k 개의 벡터 중 하나가 나머지 벡터들의 선형 조합으로 표현되면 선형 종속
- k 개의 벡터가 선형 종속이면 k 개의 벡터 중 하나가 나머지 벡터들의 선형 조합으로 표현 가능

선형 독립인지 확인하는 법

- k 개의 벡터 $x_1, \dots, x_k$ 를 합쳐 행렬 $A = [x_1 \ x_2 \ \dots \ x_k]$ 를 만들고 REF로 변환
 - 각각의 피벗 열(pivot column)들은 자신의 왼쪽에 있는 열들과 선형 독립
 - 피벗 열이 아닌 열들은 자신의 왼쪽에 있는 피벗 열들의 선형 조합으로 표현 가능
 - 따라서 $x_1, \dots, x_k$ 이 선형 독립인 것은 모든 열이 피벗 열이 되는 것과 동치

예시

$$\begin{bmatrix} -2 \\ 4 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 \\ -8 \\ -2 \\ -2 \end{bmatrix}, \begin{bmatrix} -2 \\ 3 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -1 \\ -3 \\ -1 \\ -3 \end{bmatrix}, \begin{bmatrix} 4 \\ 1 \\ 1 \\ 4 \end{bmatrix} \quad \begin{bmatrix} -2 & 4 & -2 & -1 & 4 \\ 4 & -8 & 3 & -3 & 1 \\ 1 & -2 & 1 & -1 & 1 \\ 1 & -2 & 0 & -3 & 4 \end{bmatrix}$$

$$\begin{bmatrix} 1 & -2 & 1 & -1 & 1 \\ 0 & 0 & 1 & -1 & 3 \\ 0 & 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

선형 조합 벡터들의 선형 독립성

- $b_1, \dots, b_k$ 가 선형 독립인 벡터들이라고 하자. 이때 m 개의 벡터

$$x_1 = \sum_{i=1}^k \lambda_{i1} b_i, \dots, x_m = \sum_{i=1}^k \lambda_{im} b_i$$

- $B = [b_1, \dots, b_k]$ 면 $x_j = B\lambda_j$, $\lambda_j = \begin{bmatrix} \lambda_{1j} \\ \vdots \\ \lambda_{kj} \end{bmatrix}$

선형 조합 벡터들의 선형 독립성

- $x_1, \dots, x_m$ 이 선형 독립인지 확인
- $\sum_{j=1}^m \psi_j x_j = 0$ 를 만족하는 $\psi_1, \dots, \psi_m$ 이 무엇인지 확인
- $\sum_{j=1}^m \psi_j x_j = \sum_{j=1}^m \psi_j B \lambda_j = B \sum_{j=1}^m \psi_j \lambda_j$ 이 되므로 $\sum_{j=1}^m \psi_j \lambda_j = 0$ 이 되는 $\psi_1, \dots, \psi_m$ 확인

즉, $x_1, \dots, x_m$ 이 선형 독립인 것은 $\lambda_1, \dots, \lambda_m$ 이 선형 독립인 것과 동치

$m > k$ 이면 선형 종속(why?)

생성 집합(generating set)

- 벡터 공간 $\mathcal{V} = (V, +, \cdot)$ 과 벡터 집합 $A = \{x_1, \dots, x_k\} \subseteq V$ 가 있다고 가정
- 만약 모든 $v \in V$ 가 $x_1, \dots, x_k$ 의 선형 조합으로 표현되면 우리는 집합 A 를 $\mathcal{V}$ 의 **생성 집합** 이라고 부름
- A 의 벡터들을 이용한 선형 조합들을 A 의 span 이라고 부름
- 즉 A 가 $\mathcal{V}$ 를 span 하면 A 는 $\mathcal{V}$ 의 생성 집합이고 아래와 같이 적음

$$\mathcal{V} = \text{span}[A]$$

기저(basis)

- 벡터 공간 $\mathcal{V} = (V, +, \cdot)$ 과 벡터 집합 $A = \{x_1, \dots, x_k\} \subseteq V$ 가 있다고 가정
- $\mathcal{V}$ 의 생성 집합 A 가 만약 $\mathcal{V}$ 를 span하는 $\tilde{A} \subset A$ 이 없다면 **최소 생성 집합**(minimal generating set)이라고 부름
- 모든 선형 독립인 $\mathcal{V}$ 의 생성 집합들은 최소 생성 집합이며 우리는 이것을 $\mathcal{V}$ 의 **기저**(basis)라고 부름

기저의 동치

- A 가 $\mathcal{V}$ 의 기저
- A 가 최소 생성 집합
- A 가 $\mathcal{V}$ 의 벡터들로 이루어진 최대 선형 독립 집합
- $x \in \mathcal{V}$ 가 A 의 벡터들을 이용했을 때 유일한 선형 조합 형태를 가짐(why?)

$$x = \sum_{i=1}^k \lambda_i x_i = \sum_{i=1}^k \psi_i x_i$$

예시

- 표준 기저(Standard basis)

$$B = \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}$$

- $\left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\}$

$$\left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\}$$

차원

- 벡터 공간 V 의 차원, $\dim(V)$ 는 기저 벡터의 개수를 말한다.
- 만약 U 가 V 의 부분공간이면 $\dim(U) \leq \dim(V)$
- 만약 $U=V$ 이면 $\dim(U) = \dim(V)$

기저를 찾는 법

- $U = \text{span}[x_1, \dots, x_m] \subseteq \mathbb{R}^n$ 의 기저를 찾는 법
- REF!!
- $A = [x_1 \cdots x_m]$ 의 REF 계산
- 피벗에 해당하는 열들이 기저 벡터

예시

$$\begin{bmatrix} -2 \\ 4 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 4 \\ -8 \\ -2 \\ -2 \end{bmatrix}, \begin{bmatrix} -2 \\ 3 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -1 \\ -3 \\ -1 \\ -3 \end{bmatrix}, \begin{bmatrix} 4 \\ 1 \\ 1 \\ 4 \end{bmatrix} \quad \begin{bmatrix} -2 & 4 & -2 & -1 & 4 \\ 4 & -8 & 3 & -3 & 1 \\ 1 & -2 & 1 & -1 & 1 \\ 1 & -2 & 0 & -3 & 4 \end{bmatrix}$$

$$\begin{bmatrix} 1 & -2 & 1 & -1 & 1 \\ 0 & 0 & 1 & -1 & 3 \\ 0 & 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

랭크(rank)

- 행렬 A 의 선형 독립인 열의 개수를 **랭크(rank)**라고 부름
- 그리고 이것은 A 의 선형 독립인 행의 개수와 같다는 성질이 있음
- $\text{rk}(A)$ 로 표기

랭크 예시

- $$\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 & 1 \\ -2 & -3 & 1 \\ 3 & 5 & 0 \end{bmatrix}$$

랭크의 특성

- $A \in \mathbb{R}^{m \times n}$ 인 행렬 A 에 대하여 $\text{rk}(A) = \text{rk}(A^T)$
- A 의 열들로 span되는 벡터 공간 $U \subseteq \mathbb{R}^m$ 에 대하여 $\dim(U) = \text{rk}(A)$ 이고 이런 U 를 A 의 **이미지 공간(image space)**라고 부름
- A 의 행들로 span되는 벡터 공간 $W \subseteq \mathbb{R}^n$ 에 대하여 $\dim(W) = \text{rk}(A)$
- $A \in \mathbb{R}^{n \times n}$ 이 가역 가능 $\Leftrightarrow \text{rk}(A)=n$
- $Ax=b$ 가 해가 존재 $\Leftrightarrow \text{rk}(A) = \text{rk}(A|b)$
- $A \in \mathbb{R}^{m \times n}$ 에 대해 $Ax = 0$ 이 되는 해 공간의 차원은 $n-\text{rk}(A)$ 이 되고 이런 공간을 **영 공간(null space)**라고 부름
- $\text{rk}(A)=\min(m,n)$ 이 되면 **full rank(풀 랭크)**라고 부름

선형 사상(Linear Mapping)

- 벡터 공간 V 와 W 에 대해 아래의 성질을 만족하는 함수 혹은 사상을 **선형 사상**이라고 부른다

$$\forall x, y \in V \quad \forall \lambda, \psi \in \mathbb{R} : \Phi(\lambda x + \psi y) = \lambda \Phi(x) + \psi \Phi(y)$$

- 즉, 벡터 공간의 구조를 보존하며 한 벡터 공간에서 다른 벡터 공간으로 대응시키는 함수

단사, 전사, 전단사

- 다음을 만족하는 선형 사상을 **단사(injective)**라고 부름

$$\forall x, y \in V : \Phi(x) = \Phi(y) \Rightarrow x = y$$

- 다음을 만족하는 선형 사상을 **전사(surjective)**라고 부름

$$\Phi(V) = W$$

- 전사이면서 단사인 선형 사상을 **전단사(bijective)**라고 부름

동형사상

- 동형사상(Isomorphism): $\Phi : V \rightarrow W$ 선형, 전단사
- 자기동형사상(Automorphism): $\Phi : V \rightarrow V$ 선형, 전단사
- 항등사상(Identity mapping): $\text{id}_V : V \rightarrow V, x \mapsto x$

- 유한한 차원을 가지는 두 벡터 공간 V 와 W 는 $\dim(V)=\dim(W)$ 를 만족하면 동형(isomorphic)이라고 한다.

선형 사상의 특성

- 벡터 공간 V, W, X 에 대해서 다음의 특성들이 만족
- 선형 사상 $\Phi : V \rightarrow W$ 와 $\Psi : W \rightarrow X$ 에 대해 $\Psi \circ \Phi : V \rightarrow X$ 또한 선형 사상이 됨
- 만약 $\Phi : V \rightarrow W$ 이 동형 사상이면, $\Phi^{-1} : W \rightarrow V$ 도 동형 사상이 됨
- 만약 $\Phi : W \rightarrow V$ 과 $\Psi : W \rightarrow V$ 이 선형 사상이면 $\Phi + \Psi$ 와 $\lambda\Phi, \lambda \in \mathbb{R}$ 도 선형이 됨

좌표

- 벡터 공간의 정렬된 기저 $B = (b_1, \dots, b_n)$ 를 가정
- 임의의 $x \in V$ 에 대해 아래와 같은 유일한 선형 조합을 가짐

$$x = \alpha_1 b_1 + \dots + \alpha_n b_n$$
- 이때 $\alpha_1, \dots, \alpha_n$ 을 B 에 대한 x 의 **좌표(coordinate)**이라고 부름
- 그리고 아래와 같은 벡터를 B 에 대한 x 의 좌표 벡터라고 부름


$$\alpha = \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix} \in \mathbb{R}^n$$

좌표 예시

- $\begin{bmatrix} 2 \\ 3 \end{bmatrix}$

- $\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}$

$$\begin{bmatrix} 1 \\ -1 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$



행렬과 선형 변환의 관계

- 벡터 공간 V, W 와 그에 대응하는 정렬된 기저들 $B = (b_1, \dots, b_n)$ 과 $C = (c_1, \dots, c_m)$ 이 있다고 가정하자
- 이때, 우리가 선형 변환 $\Phi : V \rightarrow W$ 존재하여 다음을 만족

$$\Phi(b_j) = \alpha_{1j}c_1 + \dots + \alpha_{mj}c_m = \sum_{i=1}^m \alpha_{ij}c_i$$
- 이 경우, 우리는 $m \times n$ 행렬 A_Φ 의 원소가 아래와 같이 구성된 경우를 Φ 의 **변환 행렬(transformation matrix)**이라 함

$$A_\Phi(i, j) = \alpha_{i,j}$$

변환 행렬의 의의

- 변환 행렬 A_{Φ} 가 있으면 기저가 바뀌었을 때 바뀌는 좌표를 쉽게 계산할 수 있음!!
- 벡터 x 가 선형 변환 Φ 에 의해 변환된 결과가 y 라고 했을 때 x 의 좌표가 $\hat{x}$ 였고 y 의 좌표가 $\hat{y}$ 라면

$$\hat{y} = A_{\Phi} \hat{x}$$

변환 행렬의 예

- $$\begin{aligned}\Phi(b_1) &= c_1 - c_2 + 3c_3 - c_4 \\ \Phi(b_2) &= 2c_1 + c_2 + 7c_3 + 2c_4 \\ \Phi(b_3) &= 3c_2 + c_3 + 4c_4\end{aligned}$$

$$x = 3b_1 + 2b_2 + 4b_3$$

$$A_{\Phi} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$

$$\hat{y} = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 7 \\ 11 \\ 27 \\ 17 \end{bmatrix}$$

Q&A