

머신러닝 기초

Lecture 8: 행렬 분해 (2)

행렬식(Determinant)

- 행렬식 혹은 determinant라고 부르는 선형대수에서 정말 중요한 컨셉!
- 이 행렬식은 $n \times n$ 형태의 행렬에 대해서만 정의가 되는 함수

$$\det(\mathbf{A}) = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix}$$

행렬식을 계산하는 법

- j 번째 열을 기준으로 계산하는 법

$$\det(\mathbf{A}) = \sum_{k=1}^n (-1)^{k+j} a_{kj} \det(\mathbf{A}_{k,j})$$

- j 번째 행을 기준으로 계산하는 법

$$\det(\mathbf{A}) = \sum_{k=1}^n (-1)^{k+j} a_{jk} \det(\mathbf{A}_{j,k})$$

고유값과 고유벡터

- 정사각행렬 $A \in \mathbb{R}^{n \times n}$ 에 대하여 다음을 만족하는 $\lambda \in \mathbb{R}$ 과 0이 아닌 벡터 $x \in \mathbb{R}^n$ 를 각각 **고유값(eigenvalue)**과 그에 대응하는 **고유벡터(eigenvector)**라고 한다.

$$Ax = \lambda x$$

Cholesky 분해

- SPD $A \in \mathbb{R}^{n \times n}$ 에 대하여 다음을 만족하는 양의 대각원소를 가지는 하삼각행렬 L 이 존재한다.

$$A = LL^{\top}$$

- 뭐가 유용할까?
 - $A^{-1} = (LL^{\top})^{-1} = (L^{-1})^{\top}(L^{-1})$
 - L^{-1} 는 RREF 계산을 통해 쉽게 계산 가능
 - $\det(A) = \det(L)^2$

고유분해와 대각화

- $A \in \mathbb{R}^{n \times n}$ 와 닮은 대각행렬 D 를 찾자!!
- Why?
 - 행렬식, 역행렬 등을 계산하기 쉬워짐
- 만약 행렬 $A \in \mathbb{R}^{n \times n}$ 가 대각행렬 $D = P^{-1}AP$ 와 닮음이면 A 를 **대각화 가능(diagonalizable)**이라고 함

고유분해와 대각화

- 대각화 가능임을 어떻게 확인할 수 있을까?
- A의 고유벡터들을 모았을 때 새로운 기저를 형성하면 됨!
- $(\lambda_1, \dots, \lambda_n)$ 이 고유값들이고 $(p_1, \dots, p_n)$ 이 그에 해당하는 고유벡터라면...

$$P = [p_1 \cdots p_n]$$

$$AP = PD$$

- why? $Ap_i = \lambda_i p_i$
- 알 수 있는 점! P가 가역가능해야 한다
- 즉, $(p_1, \dots, p_n)$ 이 선형 독립이어야 한다

고유분해와 대각화 특성

- A 가 대각화 가능 $\Leftrightarrow A$ 가 n 개의 선형 독립인 고유벡터들을 가지고 있음
- 대칭행렬 S 는 항상 대각화 가능임

$$S = PDP^{\top}$$

$$A^k = (PDP^{-1})^k = PD^kP^{-1}$$

특이값 분해(Singular Value Decomposition)

- 여태까지의 행렬 분해는 $n \times n$ 행렬에서...
- 이제는 $m \times n$ 행렬을 분해하는 법!

$$A = U \Sigma V^T$$

$$A \in \mathbb{R}^{m \times n} \quad U \in \mathbb{R}^{m \times m} \quad \Sigma \in \mathbb{R}^{m \times n} \quad V \in \mathbb{R}^{n \times n}$$

- U 는 열벡터 u_i 들로 이루어진 직교벡터(left singular vector)
- V 는 열벡터 v_i 들로 이루어진 직교벡터(right sv)
- Σ 는 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$ 로 이루어진 대각행렬

대칭행렬의 SVD

- $S = S^T = PDP^T$
- 그리고 SVD의 꼴은 $S = U\Sigma V^T$
- 따라서 $U=P=V, D=\Sigma$
- 대칭행렬의 SVD는 대각화와 같음!

SVD를 계산하는 법

- Right singular vector를 구성하는 법 $v_1, \dots, v_n \in \mathbb{R}^n$

$$\begin{aligned}
 A^T A &= P D P^T = P \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} P^T \\
 &= (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T = V \begin{bmatrix} \sigma^2 & & \\ & \ddots & \\ & & \sigma_n^2 \end{bmatrix} V^T \\
 V &= P \quad \text{and} \quad \sigma_i^2 = \lambda_i
 \end{aligned}$$

SVD를 계산하는 법

- Left singular vector를 구성하는 법 $u_1, \dots, u_m \in \mathbb{R}^m$

$$AA^{\top} = (U\Sigma V^{\top})(U\Sigma V^{\top})^{\top} = U\Sigma V^{\top}V\Sigma U^{\top} = U \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_m^2 \end{bmatrix} U^{\top}$$

알수 있는 점

- $A^T A$ 와 AA^T 의 고유값이 같다

SVD의 사용처(1)

- SVD는 전통적으로 추천 시스템에서 많이 사용되어 왔음

$$\begin{array}{|c|} \hline \text{Star Wars} \\ \text{Blade Runner} \\ \text{Amelie} \\ \text{Delicatessen} \\ \hline \end{array}
 \begin{array}{c} \text{Ali} \\ \text{Beatrix} \\ \text{Chandra} \end{array}
 \begin{bmatrix} 5 & 4 & 1 \\ 5 & 5 & 0 \\ 0 & 0 & 5 \\ 1 & 0 & 4 \end{bmatrix} = \begin{bmatrix} -0.6710 & 0.0236 & 0.4647 & -0.5774 \\ -0.7197 & 0.2054 & -0.4759 & 0.4619 \\ -0.0939 & -0.7705 & -0.5268 & -0.3464 \\ -0.1515 & -0.6030 & 0.5293 & -0.5774 \end{bmatrix}$$

$$\begin{bmatrix} 9.6438 & 0 & 0 \\ 0 & 6.3639 & 0 \\ 0 & 0 & 0.7056 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} -0.7367 & -0.6515 & -0.1811 \\ 0.0852 & 0.1762 & -0.9807 \\ 0.6708 & -0.7379 & -0.0743 \end{bmatrix}$$

SVD의 사용처(2)

- 데이터의 근사에도 많이 사용됨!!


$$A = \sum_{i=1}^r \sigma_i u_i v_i^\top = \sum_{i=1}^r \sigma_i A_i$$

- $\hat{A}(k) = \sum_{i=1}^k \sigma_i u_i v_i^\top$: rank k 근사


SVD의 사용처(2)



(a) Original image A .




(b) A_1 , $\sigma_1 \approx 228,052$.




(c) A_2 , $\sigma_2 \approx 40,647$.




(a) Original image A .




(b) Rank-1 approximation $\hat{A}(1)$.




(c) Rank-2 approximation $\hat{A}(2)$.



(d) A_3 , $\sigma_3 \approx 26,125$.



(e) A_4 , $\sigma_4 \approx 20,232$.



(f) A_5 , $\sigma_5 \approx 15,436$.



(d) Rank-3 approximation $\hat{A}(3)$.



(e) Rank-4 approximation $\hat{A}(4)$.



(f) Rank-5 approximation $\hat{A}(5)$.

Q&A