

머신러닝 기초

Lecture 12: 확률 분포(2)

점수 기준

- 성적 기대 분포
 - A+~A0: 40%, B+~B0: 40%, C+~: 20%
- 현재 중간 고사 점수 기준
 - 20%=> 84, 40% => 76, 60%=> 66, 80% => 50
- 기준 점수 설정
 - A+: 85, A0: 75, B+: 65, B0: 50
 - 과제 등의 점수 고려시 향상됨을 고려

점수 향상에 대한 어드벤처지

- 중간고사 점수보다 기말고사 점수가 많이 향상한 경우
그리고 성적 분배 기준에 걸쳐 있는 경우
 - ex) 기말 - 중간 ≥ 10 and 최종 성적 84 or 74
 - 점수 향상에 대한 어드벤처지를 통해 grade가 업이
될 수 있는 bonus reward

확률의 특성

- 확률 함수는 다음과 같은 성질을 만족함
 - $P(\Omega \setminus A) = 1 - P(A)$
 - $A \subset B \Rightarrow P(A) \leq P(B)$
 - $P(\cup_{i \geq 1} A_i) \leq \sum_{i \geq 1} P(A_i)$

이산확률변수

- 확률 변수의 값이 유한하거나 셀 수 있는 값인 경우 이산 확률변수(discrete random variable)이라고 부름
- 이러한 이산확률변수의 확률은 확률질량함수(probability mass function)로 표현함

$$p_X(x) := P(X = x)$$

- 어떤 사건 A에 대한 확률은

$$P(X \in A) = \sum_{x \in A} P(X = x) = \sum_{x \in A} p_X(x)$$

결합 확률 질량함수의 확장

- 조건부 확률

$$p_{Y|X}(y|x) = P(Y = y|X = x) = \frac{P(X = x, Y = y)}{P(X = x)} = \frac{p_{XY}(x, y)}{p_X(x)}$$

- 합 법칙

$$P(X = x) = \sum_y P(X = x, Y = y)$$

- 곱 법칙

$$P(X = x, Y = y) = P(Y = y|X = x)P(X = x)$$

연속확률변수

- 연속확률변수에서는 어느 일정 범위에 대해서만 확률을 계산할 수 있기 때문에 다음과 같은 **누적 분포 함수 (Cumulative Distribution Function)**를 사용하여 확률을 정의

$$F_X(x) := P(X \leq x)$$

$$P(x_1 \leq X \leq x_2) = F_X(x_2) - F_X(x_1)$$

연속확률 변수

- 이때 다음을 만족하는 함수 $f_X(x)$ 를 density 혹은 확률 밀도 함수라고 부름

$$F_X(x) = \int_{-\infty}^x f_X(x') dx'$$

- 확률 밀도함수는 다음과 같이 쓸 수도 있음

$$f_X(x) = \frac{d}{dx} F_X(x)$$

결합 확률 밀도 함수의 확장

- 조건부 확률 밀도 함수(conditional PDF)는

$$f_{Y|X}(y|x) = \frac{f_{XY}(x, y)}{f_X(x)}$$

- 합 법칙

$$f_X(x) = \int_{\mathbb{R}} f_{XY}(x, y) dy$$

- 곱 법칙

$$f_{XY}(x, y) = f_{Y|X}(y|x) f_X(x)$$

오늘 배울 내용

- '독립'이라는 개념
- 기대값, 평균, 분산 등 통계치 들의 개념
 - 확률적인 모델링 혹은 통계적인 해석을 통해 우리가 최종적으로 계산하고 싶은 수치!
- 변수 변환
 - 복잡한 분포를 간단한 분포로!

독립 확률 변수

- 두 개의 이산확률변수 X, Y 가 있을 때, 아래와 같은 식을 만족하면 이들을 **독립(independent)**라고 부름

$$P(X = x, Y = y) = P(X = x)P(Y = y)$$

- 표기는 $x \perp y$ 로 함.
- 이 경우

$$P(X = x|Y = y) = P(X = x)$$

독립 확률 변수

- 연속확률변수 X, Y 가 있을 때는 확률밀도함수를 통해 비슷하게 정의됨

$$f_{XY}(x, y) = f_X(x)f_Y(y)$$

- I.I.D. (independent and identically distributed) 확률 변수: 모두 같은 분포를 가진 독립 확률변수들의 집합

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n p_X(x_i)$$

$$f(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n f_X(x_i)$$

독립 확률 변수의 예시

- 성별과 안경 착용 여부

	착용	미착용
남성	0.18	0.42
여성	0.12	0.28

독립 확률 변수의 예시

- 성별과 안경 착용 여부

	착용	미착용
남성	0.25	0.35
여성	0.05	0.35

Bayes' Theorem

- (개인적인 생각) 통계 머신러닝 혹은 통계 인공지능에서 가장 중요한 정리 혹은 규칙 (**베이즈 정리** 혹은 **베이즈 법칙**)
- 이산 확률 변수의 경우
$$P(Y = y|X = x) = \frac{P(X = x|Y = y)P(Y = y)}{P(X = x)}$$
- 연속 확률 변수의 경우
$$f_{Y|X}(y|x) = \frac{f_{X|Y}(x|y)f_Y(y)}{f_X(x)}$$

베이즈 정리의 계산

$$\bullet \quad P(Y = y|X = x) = \frac{P(X = x|Y = y)P(Y = y)}{P(X = x)} = \frac{P(X = x|Y = y)P(Y = y)}{\sum_{i=1}^n P(X = x|Y = y_i)P(Y = y_i)}$$

$$f_{Y|X}(y|x) = \frac{f_{X|Y}(x|y)f_Y(y)}{f_X(x)} = \frac{f_{X|Y}(x|y)f_Y(y)}{\int f_{X|Y}(x|y')f_Y(y')dy}$$

베이즈 정리 예시

● 췌장암 데이터 예시

Symptom \ Cancer	Yes	No	Total
Yes	1	10	11
No	0	99,989	99,989
Total	1	99,999	100,000

$$P(\text{Cancer}|\text{Symptom}) = \frac{P(\text{Symptom}|\text{Cancer})P(\text{Cancer})}{P(\text{Symptom})} = \frac{1.0 \times 0.00001}{1.0 \times 0.00001 + (10/99999) \times 0.99999} = \frac{1}{11}$$

베이즈 정리의 활용

- 머신러닝과 인공지능에서...
- 주어진 데이터 $X = \{x_i\}_{i=1}^n$ 가 변수 θ 로 이루어진 모델로부터 생성되었다고 가정

$$x_1, \dots, x_n \stackrel{\text{i.i.d.}}{\sim} P(\cdot|\theta), \quad P(X|\theta) = \prod_{i=1}^n P(x_i|\theta)$$

- 여기서 등장하는 조건부 확률 $P(X|\theta)$ 를 **우도** 혹은 **likelihood**라고 부름

Bayesian Machine Learning

- 베이저안 기계학습에서는 모델의 변수 θ 가 **사전 분포** 혹은 **prior distribution** $P(\theta)$ 을 따라서 분포하고 있다고 가정
- **사후 분포** 혹은 **posterior distribution** $P(\theta|X)$ 은 데이터 X 를 보고 난 후의 모델의 변수에 대한 우리의 믿음!

$$P(\theta|X) = \frac{P(X|\theta)p(\theta)}{p(X)}$$

Bayesian Machine Learning

- 여기서 새로운 데이터 x_* 가 들어왔을때 x_* 에 대한 예측값의 분포

$$P(F(x_*)|X) = \int P(F(x_*, \theta)|\theta)P(\theta|X)d\theta$$

기대값

- 우리가 흔히 말하는 그 기대값!
 - 이 아이템이 나오려면 기대값으로 돈을 얼마나 사용해야 하나
 - 주사위를 굴리면 나올 수의 기대값이 뭐냐 등등
- 어떤 확률 변수 X 에 대한 함수 g 의 기대값(expectation):

$$\mathbb{E}[g(X)] = \sum_x g(x)p_X(x), \quad \mathbb{E}[f(x)] = \int g(x)f_X(x)dx$$

- $g(x) = x$ 인 경우를 우리는 **평균(mean)**이라고 부름
- **분산(variance)**은 $\text{Var}(x) = \mathbb{E}[(X - \mathbb{E}[X])^2]$

기대값 예시

- 각 면이 나올 확률이 같은 주사위를 굴렀을 때 나올 숫자의 기대값(평균)

$$\mathbb{E}[X] = \sum_{i=1}^6 \frac{1}{6} i = \frac{1}{6} \sum_{i=1}^6 i = \frac{1}{6} \frac{7 * 6}{2} = 3.5$$

- 분산

$$\mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - 2\mathbb{E}[X]^2 + \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

$$\mathbb{E}[X^2] = \sum_{i=1}^6 \frac{1}{6} i^2 = \frac{1}{6} \sum_{i=1}^6 i^2 = \frac{1}{6} \frac{6 \times 7 \times 13}{3!} = \frac{91}{6} \quad \frac{91}{6} - \frac{49}{4} = \frac{182 - 147}{12} = \frac{35}{12}$$

기대값 예시

- 6이 나올 확률이 1/2이고 나머지는 1/10인 경우의 기대값 (평균)

$$\mathbb{E}[X] = \frac{1}{2} * 6 + \sum_{i=1}^5 \frac{1}{10} i = 3 + \frac{1}{10} \frac{5 * 6}{2} = 3 + 1.5 = 4.5$$

공분산

- 두 개의 확률변수의 **공분산(covariance)**은 다음과 같이 정의함

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \int \int (x - \mathbb{E}[X])(y - \mathbb{E}[Y]) f_{XY}(x, y) dx dy$$

다변수 확률 변수의 기대값

- 다변수 확률 변수 $\mathbf{X} := [X_1 \dots X_d]^\top$ 의 평균

$$\mathbb{E}[\mathbf{X}] = [\mathbb{E}[X_1] \dots \mathbb{E}[X_d]]^\top$$

- 공분산

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X}])(\mathbf{X} - \mathbb{E}[\mathbf{X}])^\top] \\ &= \begin{bmatrix} \text{Var}(X_1) & \dots & \text{Cov}(X_1, X_d) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \dots & \text{Var}(X_d) \end{bmatrix} \end{aligned}$$

기대값의 성질

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

- 만약 X 와 Y 가 독립이라면,

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$$

- $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$

- Law of total variance

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y|X)] + \text{Var}[\mathbb{E}[Y|X]]$$

상관관계

- 두 확률변수 X 와 Y 의 상관관계(Correlation)은 다음과 같이 정의됨

$$\text{corr}[x, y] = \frac{\text{Cov}[x, y]}{\sqrt{\text{Var}[x]\text{Var}[y]}} \in [-1, 1]$$

Q&A