

머신러닝 기초

Lecture 13: 확률 분포(3)

앞으로 배울 내용

- 여태까지는 확률변수의 개념과 기대값등에 대해 배움
- 이제는 머신러닝, 인공지능, 통계 등 모든 분야에서 근본이 되는 가우시안 분포(Gaussian distribution) 혹은 정규 분포(normal distribution)이라고 부르는 분포에 대해 배워볼 예정
- 그리고 그에 대한 확장까지 배울 예정

가우시안 분포

- 가우시안 분포는 **가우시안 확률과정**(Gaussian Processes), **변분 추론**(Variational Inference), **강화학습**(Reinforcement Learning), **신호 처리**(Signal Processing), **제어**(Control Theory), **통계 분석**(Statistical Analysis)등 심화된 내용에서 부터 인공지능 **모델의 초기화**(Random Initialization), **랜덤 노이즈 생성**(Random Noise Sampling)등 기본적인 부분까지 정말 많은 분야의 근간이 되는 분포


일변수 가우시안 분포

- **가우시안 분포(Gaussian distribution)** 혹은 정규 분포는 실수 공간에서 정의되는 확률 분포!

$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 여기서 μ, σ^2 은 각각 평균과 분산을 나타냄
- 연속 확률변수 이므로 pdf!
- 평균이 0이고, 분산이 1인 경우를 우리는 **표준 정규 분포** (Standard Normal distribution)라고 부름

일변수 가우시안 분포 그래프



다변수 가우시안 분포

- **다변수 가우시안 분포(Multivariate Gaussian distribution)**는 n 차원 실수 공간에서 정의되는 확률 분포


$$p(x|\mu, \Sigma) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right)$$

μ Σ

- 마찬가지로 , 가 각각 평균과 공분산을 나타냄
- 어떤 확률변수 x 가 가우시안 분포를 따르는 것은 다음과 같이 표기함

$$x \sim \mathcal{N}(\mu, \Sigma)$$

다변수 가우시안 분포 그래프



가우시안 분포의 조건부 확률 분포

- 확률 변수 $[x \ y]^T \sim \mathcal{N}(\mu, \Sigma)$

$$p(x, y) = \mathcal{N} \left(\begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix} \right)$$

- 조건부 확률 분포

$$p(x|y) = \mathcal{N}(\mu_{x|y}, \Sigma_{x|y})$$

$$\mu_{x|y} = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y)$$

$$\Sigma_{x|y} = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$$

- Marginal distribution(주변 분포) $p(x) = \int p(x, y) dy = \mathcal{N}(\mu_x, \Sigma_{xx})$

조건부 확률 분포 예시

$$p(x_1, x_2) = \mathcal{N}\left(\begin{bmatrix} 0 \\ 2 \end{bmatrix}, \begin{bmatrix} 0.3 & -1 \\ -1 & 5 \end{bmatrix}\right)$$




- 조건부 $x_2 = -1$ 에서

$$\mu_{x_1 | x_2 = -1} = 0 + (-1) \cdot 0.2 \cdot (-1 - 2) = 0.6$$

$$\sigma_{x_1 | x_2 = -1}^2 = 0.3 - (-1) \cdot 0.2 \cdot (-1) = 0.1$$

- Marginal

$$p(x_1) = \mathcal{N}(0, 0.3)$$



가우시안 확률 변수의 합


- 가우시안 확률 변수 x 와 y 가 서로 독립일때,

$$p(x) = \mathcal{N}(x|\mu_x, \Sigma_x)$$

$$p(y) = \mathcal{N}(y|\mu_y, \Sigma_y)$$

- $z = x+y$ 의 분포 $p(z) = \mathcal{N}(z|\mu_x + \mu_y, \Sigma_x + \Sigma_y)$

- $t = ax+by$ 의 분포 $p(t) = \mathcal{N}(t|a\mu_x + b\mu_y, a^2\Sigma_x + b^2\Sigma_y)$




가우시안 분포의 합

- 가우시안 분포 $p_1(x)$ 와 $p_2(x)$ 의 합은 가우시안이 아니다!

$$p_1(x) = \mathcal{N}(x|\mu_1, \sigma_1^2)$$

$$p_2(x) = \mathcal{N}(x|\mu_2, \sigma_2^2)$$

- $p(x) = a * p_1(x) + (1-a) * p_2(x)$



선형 변환

- 가우시안 확률변수 $x \sim \mathcal{N}(\mu, \Sigma)$
- $y = Ax$
- $\mathbb{E}[Ax] = A\mathbb{E}[x] = A\mu, \text{Var}[Ax] = A\text{Var}[x]A^\top = A\Sigma A^\top$
 $p(y) = \mathcal{N}(y|A\mu, A\Sigma A^\top)$

선형 변환 예시


- 가우시안 확률변수 $\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \right)$

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

- $y = Ax$

- $A\mu_x = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 5 \\ 11 \end{bmatrix}$

$$A\Sigma_x A^\top = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} = \begin{bmatrix} 10 & 24 \\ 24 & 58 \end{bmatrix}$$



Sampling

- 우리가 $x \sim \mathcal{N}(0, I)$ 에서 랜덤하게 샘플을 할 수 있다고 하자!
- $y \sim \mathcal{N}(\mu, \Sigma)$?

변수 변환

- $x \sim \mathcal{N}(0, 1)$ 에 대하여 x^2 의 분포는 어떻게 될까?
- 이러한 문제들을 푸는 것이 변수 변환(change of variable)
- 먼저 이산 확률변수의 경우 $y = u(x)$ 라고 하면

$$p(y = y_1) = p(u(x) = y_1) = p(x = u^{-1}(y_1))$$

이산 확률변수 변수 변환 예시

- $x: [-2, -1, 0, 1, 2]$ 가 각각 $1/5$ 의 확률
- $y = x^2$
- $y = 0 \Rightarrow x=0: 1/5$
- $y = 1 \Rightarrow x=-1, 1: 2/5$
- $y = 4 \Rightarrow x=-2, 2: 2/5$

연속 확률 변수 변수 변환

- 연속 확률 변수에서도 마찬가지로 과정을 통해 계산
- $F_x(x_1) = P(x \leq x_1)$, $f(x)$, $y = u(x)$
- 먼저 CDF $F_y(y_1) = p(y \leq y_1)$ 를 계산
- $f(y_1) = \frac{d}{dy} F_y(y_1)$ 를 계산
- CDF는? 이산 확률 변수와 비슷하게 계산

연속 확률 변수 변수 변환 예시

- $f(x) = 3x^2$, $0 \leq x \leq 1$, $y = x^2$ 의 pdf는?

$$F_y(y_1) = P(y \leq y_1) = P(x^2 \leq y_1) = P(x \leq \sqrt{y_1})$$

$$F_x(\sqrt{y_1}) = \int_0^{\sqrt{y_1}} 3x^2 dx = x^3 \Big|_0^{\sqrt{y_1}} = (y_1)^{3/2}, \quad 0 \leq y_1 \leq 1$$

$$f(y) = \frac{d}{dy} F_y(y) = \frac{3}{2} y^{\frac{1}{2}}$$

변수 변환 technique

- $y = u(x)$, $x \in [a, b]$, u 는 가역함수

$$F_y(Y) = P(y \leq Y) = P(u(x) \leq Y) = P(x \leq u^{-1}(Y)) = \int_a^{u^{-1}(Y)} f(x)dx$$

$$f(y) = \frac{d}{dy} \int_a^{u^{-1}(y)} f(x)dx = \frac{d}{dy} (F_x(u^{-1}(y)) - F_x(a)) = f_x(u^{-1}(y)) \times \left| \frac{d}{dy} u^{-1}(y) \right|$$

$$f(y) = f_x(u^{-1}(y)) \times \left| \det \left(\frac{d}{dy} u^{-1}(y) \right) \right|$$

변수 변환을 통해 본 가우시안 선형 변환

- $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 의 pdf $f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \frac{1}{2\pi} \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right)$ 를 따름
- $y = Ax$, $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$

- $f(x) = f(A^{-1}y) = \frac{1}{2\pi} \exp\left(-\frac{1}{2} y^\top A^{-T} A^{-1} y\right)$

$$\frac{\partial}{\partial y} A^{-1} y = A^{-1} \Rightarrow \det\left(\frac{\partial}{\partial y} A^{-1} y\right) = \frac{1}{ad - bc}$$

$$f(y) = f(x) \left| \det\left(\frac{\partial}{\partial y} A^{-1} y\right) \right| = \frac{1}{2\pi} \exp\left(-\frac{1}{2} y^\top A^{-T} A^{-1} y\right) \frac{1}{|ad - bc|}$$

Q&A