

머신러닝 기초

Lecture 14: 최적화 이론

Motivation

- 머신 러닝 모델을 학습 시킨다 = 머신 러닝 모델의 변수 중 좋은 변수를 찾는다!
- 여기서 “좋은” 이란?
 - 머신 러닝 모델을 평가하는 목적 함수의 수치가 좋은 모델
- 그럼 목적 함수의 수치가 좋은 모델은 어떻게 찾을까?
 - 최적화 알고리즘

경사 하강법

- 우리가 풀고 싶은 문제를 단순화 하면...


$$\min_x f(x) \quad f : \mathbb{R}^d \rightarrow \mathbb{R}$$

- 여기서 우리가 f 가 미분 가능하지만, analytic solution(해석적 해)를 구할 수 없다고 가정하자.
- 이런 경우에 해를 수치적으로 구할 수 있게 해주는 방식이 **경사 하강법(Gradient Descent)**!

경사 하강법

- 경사 하강법은 1차 최적화 알고리즘의 한 종류

$$x_{i+1} = x_i - \gamma_i (\nabla f(x_i))^T$$



경사 하강법의 수렴성


- γ_i 값을 **step size**라고 부름.
- 이 값은 보통 사용자의 선택에 따라 결정되는 값
- 적절한 step size를 사용하여 경사 하강법을 통해 x 를 업데이트 해 나가면 $f(x_0) \geq f(x_1) \geq \dots$
- 즉 **국소 최소점(local minima)**을 찾을 수 있음

경사 하강법의 예시

- $$f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \frac{1}{2} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 2 & 1 \\ 1 & 20 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\nabla f\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}^\top \begin{bmatrix} 2 & 1 \\ 1 & 20 \end{bmatrix} - \begin{bmatrix} 5 \\ 3 \end{bmatrix}^\top$$

- 보통 그림과 같은 zigzag 형태
- 수렴이 느림



Step Size

- 경사 하강법에서 매우 중요!
- 너무 작으면? 수렴이 느림
- 너무 크면? 수렴에 실패, 발산하기도 함
- 두 가지 간단한 heuristic
 - 먼저 step을 뺀 뒤, 함수값이 증가하면 업데이트를 멈추고 stepsize를 줄임
 - 함수값이 감소하면 step size를 늘림

모멘텀 경사 하강법

- **모멘텀 경사 하강법(Momentum Gradient Descent):**
경사 하강법의 느린 수렴 속도를 해결하기 위해 고안된 방법!
- 내가 움직이고 있던 모멘텀을 유지하면서 update를 하는 방법


$$x_{i+1} = x_i - \gamma_i (\nabla f(x))^\top + \alpha \Delta x_i$$

$$\Delta x_i = x_i - x_{i-1} = \alpha \Delta x_{i-1} - \gamma_{i-1} ((\nabla f)(x_{i-1}))^\top$$

모멘텀 경사 하강법 예시

- $x_{i+1} = x_i - \gamma_i (\nabla f(x))^\top + \alpha \Delta x_i$

$$\Delta x_i = x_i - x_{i-1} = \alpha \Delta x_{i-1} - \gamma_{i-1} ((\nabla f)(x_{i-1}))^\top$$



확률적 경사 하강법

- **확률적 경사 하강법(Stochastic Gradient Descent)**: 경사 하강법의 노이즈한 근사치를 활용한 경사 하강법
- 머신 러닝에서의 목적 함수는 주로 N개의 데이터 각각에 대한 손실 함수의 합으로 구성이 되어 있음

$$L(\theta) = \sum_{n=1}^N L_n(\theta)$$
$$L_n(\theta) = \log p(y_n | x_n, \theta)$$

확률적 경사 하강법

- $\theta_{i+1} = \theta_i - \gamma_i (\nabla L(\theta_i))^\top$
$$= \theta_i - \gamma_i \sum_{n=1}^N \nabla L_n(\theta_i)^\top$$
- 그러나 N 이 매우 크면 미분을 계산하는데 필요한 시간이 너무 많이 요구됨

$$\approx \theta_i - \gamma_i \frac{N}{|B|} \sum_{n \in B} \nabla L_n(\theta_i)^\top$$

Mini Batch

- 여기서 B를 **mini batch**라고 부름
- 큰 mini batch: 근사치가 정확, 더 비쌈
- 작은 mini batch: 빠르고 값쌘, 근사치가 부정확(이 부분이 나쁜 국소 최소점을 빠져 나가는데 도움을 줄때도 있음)

뉴턴 방법론

- 뉴턴 방법론: 이차 최적화 방법, 목적함수의 Hessian을 활용



$$\theta_{k+1} = \theta_k - \eta_k H_k^{-1} g_k$$

- 목적함수의 이차 Taylor 근사를 해보면

$$\begin{aligned} f(\theta) &\approx f_k + g_k^\top (\theta - \theta_k) + \frac{1}{2} (\theta - \theta_k)^\top H_k (\theta - \theta_k) \\ &= \theta^\top A \theta + b^\top \theta + c \\ A &= \frac{1}{2} H_k, \quad b = g_k - H_k \theta_k, \quad c = f_k - g_k^\top \theta_k + \frac{1}{2} \theta_k^\top H_k \theta_k \\ \theta &= -\frac{1}{2} A^{-1} b = \theta_k - H_k^{-1} g_k \end{aligned}$$

뉴턴 방법론

- $$\theta_{k+1} = \theta_k - \eta_k H_k^{-1} g_k$$



Convexity

- 일반적인 목적 함수는 다양한 국소 최저점이 존재할 가능성이 있음
- 그러나 만약 우리의 목적 함수가 convex 함수이면 **전역 최저점 (global optimum)**이 존재!

Convex set

- 만약 집합 C 의 임의의 원소 x, y 와 $0 \leq \lambda \leq 1$ 에 대하여 아래의 조건을 만족하면 집합 C 를 **convex 집합**이라고 부른다

$$\lambda x + (1 - \lambda)y \in C$$



Convex function

- 정의역 C 가 convex 집합인 함수 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 에 대하여 정의역에 속한 임의의 $x, y \in C$ 와 $0 \leq \lambda \leq 1$ 에 대하여 아래의 조건을 만족하는 함수를 **convex 함수**라고 부른다

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

Convex function 예시

- $y = x^2$


- x_1, x_2 과 $0 \leq \lambda \leq 1$ 에 대해

$$(\lambda^2 x_1^2 + 2\lambda(1-\lambda)x_1x_2 + (1-\lambda)^2 x_2^2)$$

$$\lambda x_1^2 + (1-\lambda)x_2^2$$

$$\lambda x_1^2 + (1-\lambda)x_2^2 - (\lambda^2 x_1^2 + 2\lambda(1-\lambda)x_1x_2 + (1-\lambda)^2 x_2^2)$$


$$\lambda(1-\lambda)(x_1^2 - 2x_1x_2 + x_2^2) = \lambda(1-\lambda)(x_1 - x_2)^2$$



Convex function 예시 2

- 인공지능에서 중요한 함수인 negative entropy는 $x > 0$ 구간에서 convex 함수

$$f(x) = x \log x$$



Convex function의 특성

- Convex 함수의 합은 convex

$$f_1(\lambda x + (1 - \lambda)y) \leq \lambda f_1(x) + (1 - \lambda)f_1(y)$$

$$f_2(\lambda x + (1 - \lambda)y) \leq \lambda f_2(x) + (1 - \lambda)f_2(y)$$

$$\begin{aligned} f_1(\lambda x + (1 - \lambda)y) + f_2(\lambda x + (1 - \lambda)y) &\leq \lambda f_1(x) + (1 - \lambda)f_1(y) + \lambda f_2(x) + (1 - \lambda)f_2(y) \\ &= \lambda(f_1(x) + f_2(x)) + (1 - \lambda)(f_1(y) + f_2(y)) \end{aligned}$$

- $\alpha, \beta \geq 0$ 에 대하여 $\alpha f_1(x) + \beta f_2(x)$ 도 convex 함수

Q&A