

머신러닝 기초

Lecture 15: 모델이 데이터를 만나면?

데이터

- 현대의 머신러닝과 인공지능 모델들이 작동할 수 있게 해준 근본적인 원인: 많은 데이터!
- 가정: 데이터는 **테이블 형식**의 컴퓨터가 읽을 수 있는 수치적인 형태



데이터의 벡터화

- 컴퓨터가 읽을 수 있도록 전문가가 원본데이터를 특징값 (feature)들로 변환하여 D차원의 특징 벡터로 변환

Name	Gender	Degree	Postcode	Age	Annual salary
Aditya	M	MSc	W21BG	36	89563
Bob	M	PhD	EC1A1BA	47	123543
Chloé	F	BEcon	SW1A1BH	26	23989
Daisuke	M	BSc	SE207AT	68	138769
Elisabeth	F	MBA	SE10AA	33	113888

Gender ID	Degree	Latitude (in degrees)	Longitude (in degrees)	Age	Annual Salary (in thousands)
-1	2	51.5073	0.1290	36	89.563
-1	3	51.5074	0.1275	47	123.543
+1	1	51.5071	0.1278	26	23.989
-1	1	51.5075	0.1281	68	138.769
+1	2	51.5074	0.1278	33	113.888

데이터: $\mathbf{x}_n$

데이터의 벡터화


- 변환 후: $\mathbf{X} \in \mathbb{R}^{N \times D}$
- N개의 데이터, D차원 feature
- 일반적인 규칙: 연속적인 수치값 (continuous value)을 가지는 특징벡터는 **평균이 0이고 분산이 1**이 되도록 수치를 조정

데이터 처리의 중요성

- 최신 인공지능 모델들이 부딪힌 벽: 모델을 학습할 데이터가 점점 부족해진다
- 빅테크 기업(Google, OpenAI)들이 바라보고 있는 방향성: 양을 늘릴 수 없다면 '잘' **골라진** 데이터들을 '잘' **가공**해서 사용하자
- 골라진 => Data selection
- 가공 => Data preprocessing
- 그냥 양을 늘리자 => Data augmentation with generative models

모델이란?


- 입력을 받아 예측, 분포, 결정 같은 출력을 내는 함수
- 지도학습(supervised learning)에서의 데이터셋
- $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$
- 우리가 모델을 통해 알고 싶은 것?
 - 어떤 임의의 x 에 해당하는 y 값



결정론적 함수로서의 모델


- 임의의 x 값에 해당하는 y 값을 예측하기 위해 기존에 가지고 있던 데이터셋을 잘 설명하는 함수를 이용
- 예) 선형 회귀(Linear Regression)

$$f : \mathbb{R}^D \rightarrow \mathbb{R}, \text{ e.g., } f(\mathbf{x}) = \theta^\top \mathbf{x} + \theta_0$$



확률분포로서의 모델

- 임의의 x 값에 해당하는 y 값만을 예측하는 것이 아니라 한 스텝 더 나아가 예측에 대한 불확실성도 모델링하여 확률분포를 출력
 - 데이터 관측 에러(noise)라던가 데이터의 부족에 따른 모델 오류 등
- 예) 가우시안 분포 활용



머신러닝이란?

- Learning = 수 많은 **모델**과 그 모델의 **변수**(parameter)들 중 우리가 **미관측 데이터**(unseen data)에 대해 좋은 예측을 주는 모델과 변수를 찾는 과정!

머신러닝이란?

- Learning의 세 가지 단계

- 학습(Training) / 변수 추정(Parameter estimation)
 - 결정론적 모델: 경험적 위험 최소화 (ERM; Empirical Risk Minimization)
 - 확률적 모델: 변수 추정
- 하이퍼파라미터 튜닝(Hyperparameter Tuning) / 모델 선택(Model Selection)
- 예측 (prediction) / 추론 (inference)

Empirical Risk Minimization

- 머신러닝의 세 단계에서 학습 / 변수 추정 단계에서 필요한 것?
- 주어진 데이터를 모델이 얼마나 잘 맞추고 있는지를 판단할 **지표(metric)**이 필요함

Empirical Risk Minimization

- 주어진 학습 데이터 $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ 이 있을 때, 이 데이터를 잘 설명하는 함수 $y = f(x, \theta)$ 를 찾고 싶은 상황.
- 즉, $n = 1, \dots, N$ 에 대하여 $f(x_n, \theta^*) \approx y_n$ 이 되는 θ^* 를 찾자!
- 그러면 우리가 $f(x_n, \theta)$ 가 y_n 과 얼마나 차이가 있는지를 계산해야함

Empirical Risk Minimization

- 그 수치를 계산해주는 함수를 우리는 **오차 함수(loss function)**라고 부름

$$\ell(f(x, \theta), y)$$

- 우리는 이 오차 함수를 활용하여 학습 데이터 전체에 대해 얼마나 예측이 실제 데이터와 유사한가를 측정
- 이를 **Empirical Risk**라고 부름

$$R_{\text{emp}}(\theta, X, Y) = \frac{1}{N} \sum_{i=1}^N \ell(f(x_i, \theta), y_i)$$

Empirical Risk Minimization

- 이러한 상황에서 가장 좋은 θ 란?

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(f(\theta, x_i), y_i)$$

- 이렇게 Empirical risk를 최소화 하는 방향으로 θ 를 찾는 것을 **Empirical Risk Minimization (ERM)**이라고 부름
- 여기서 가정은 학습 데이터들이 i.i.d라는 가정이 있어야 함.

ERM 예시

- 선형 회귀에서 최소 제곱법

$$f(x, \theta) = \theta^\top x + \theta_0$$

$$\begin{aligned}\theta^* &= \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(y_i - f(x_i, \theta))^2 = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N (y_i - \theta^\top x_n - \theta_0)^2 \\ &= \arg \min_{\theta} \frac{1}{N} \|y - \hat{X}\hat{\theta}\|^2\end{aligned}$$

사실 우리가 진짜 하고 싶은것

- 앞에서 말했듯이 우리가 진짜 하고 싶은 건 그냥 학습데이터를 잘 맞추는 모델을 찾고 싶은게 아님
- 새로운 데이터에 대해서 잘 맞추는 모델을 찾고 싶음

$$\mathbf{R}_{\text{true}}(f) = \mathbb{E}_{x,y} \ell(y, f(x))$$

- 가지고 있는 데이터만 가지고 이런 모델을 어떻게 '잘' 찾을 수 있을까?

Regularization


- 너무 데이터에 모델이 과적합(overfit) 하는 걸 막기 위해 regularization을 활용
 - 모델이 과적합을 했는지 확인하기 위한 validation data를 준비
 - Validation data에 대한 오차 함수를 계산하여 training data에 대한 오차 함수 값과 validation data에 대한 오차 함수 값을 비교
 - 너무 큰 차이가 나면 training data에 과적합한 상황!
 - 학습을 할때 regularization이라고 하는 페널티 함수를 주어서 다시 찾음

$$\arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(f(x_i, \theta), y_i)$$

$$\arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(f(x_i, \theta), y_i) + \lambda \|\theta\|^2$$

Cross validation

- 보다 더 나은 검증법



변수 추정

- 예측값이 확률 분포로 모델링이 되어 있는 경우에는 변수 추정을 활용
- Maximum Likelihood Estimation (MLE): 데이터가 random variable이라고 생각 $p(x|\theta)$
- Negative log-likelihood를 줄이자!

$$\mathcal{L}_x(\theta) = -\log p(x|\theta)$$

변수 추정 예시

- 관측 오차가 $\epsilon_n \sim \mathcal{N}(0, \sigma^2)$ 으로 주어진다고 하자

$$p(y_n | x_n, \theta) = \mathcal{N}(y_n | x_n^\top \theta, \sigma^2)$$

$$p(\mathbf{y} | \mathbf{X}, \theta) = \prod_{n=1}^N p(y_n | x_n, \theta)$$

$$\mathcal{L}(\theta) = - \sum_{n=1}^N \log p(y_n | x_n, \theta)$$

변수 추정 예시

$$\begin{aligned}
 \mathcal{L}(\theta) &= - \sum_{n=1}^N \log p(y_n | x_n, \theta) \\
 &= - \sum_{n=1}^N \log \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(- \frac{(y_n - x_n^\top \theta)^2}{2\sigma^2} \right) \\
 &= - \sum_{n=1}^N \log \exp \left(- \frac{(y_n - x_n^\top \theta)^2}{2\sigma^2} \right) - \sum_{n=1}^N \log \frac{1}{\sqrt{2\pi\sigma^2}} \\
 &= \sum_{n=1}^N \frac{(y_n - x_n^\top \theta)^2}{2\sigma^2} - \sum_{n=1}^N \log \frac{1}{\sqrt{2\pi\sigma^2}}
 \end{aligned}$$


ERM에서의 regularization? MAP

$$p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$$

$$p(\theta|x) \propto p(x|\theta)p(\theta)$$

$$-\log p(x|\theta) - \log p(\theta) = \text{NLL} - \log p(\theta)$$

Small-data regime: MLE vs MAP



Q&A