

머신러닝 기초

Lecture 16: 모델이 데이터를 만나면?

Empirical Risk Minimization

- 주어진 학습 데이터 $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$ 이 있을 때, 이 데이터를 잘 설명하는 함수 $y = f(x, \theta)$ 를 찾고 싶은 상황.
- 즉, $n = 1, \dots, N$ 에 대하여 $f(x_n, \theta^*) \approx y_n$ 이 되는 θ^* 를 찾자!
- 그러면 우리가 $f(x_n, \theta)$ 가 y_n 과 얼마나 차이가 있는지를 계산해야함

Empirical Risk Minimization

- 그 수치를 계산해주는 함수를 우리는 **오차 함수(loss function)**라고 부름

$$\ell(f(x, \theta), y)$$

- 우리는 이 오차 함수를 활용하여 학습 데이터 전체에 대해 얼마나 예측이 실제 데이터와 유사한가를 측정
- 이를 **Empirical Risk**라고 부름

$$R_{\text{emp}}(\theta, X, Y) = \frac{1}{N} \sum_{i=1}^N \ell(f(x_i, \theta), y_i)$$

Empirical Risk Minimization

- 이러한 상황에서 가장 좋은 θ 란?

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(f(\theta, x_i), y_i)$$

- 이렇게 Empirical risk를 최소화 하는 방향으로 θ 를 찾는 것을 **Empirical Risk Minimization (ERM)**이라고 부름
- 여기서 가정은 학습 데이터들이 i.i.d라는 가정이 있어야 함.

Regularization

- 너무 데이터에 모델이 과적합(overfit) 하는 걸 막기 위해 regularization을 활용
 - 모델이 과적합을 했는지 확인하기 위한 validation data를 준비
 - Validation data에 대한 오차 함수를 계산하여 training data에 대한 오차 함수 값과 validation data에 대한 오차 함수 값을 비교
 - 너무 큰 차이가 나면 training data에 과적합한 상황!
 - 학습을 할때 regularization이라고 하는 페널티 함수를 주어서 다시 찾음

$$\arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(f(x_i, \theta), y_i)$$

$$\arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \ell(f(x_i, \theta), y_i) + \lambda \|\theta\|^2$$

변수 추정

- 예측값이 확률 분포로 모델링이 되어 있는 경우에는 변수 추정을 활용
- Maximum Likelihood Estimation (MLE): 데이터가 random variable이라고 생각 $p(x|\theta)$
- Negative log-likelihood를 줄이자!

$$\mathcal{L}_x(\theta) = -\log p(x|\theta)$$


ERM에서의 regularization? MAP

$$p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$$

$$p(\theta|x) \propto p(x|\theta)p(\theta)$$

$$-\log p(x|\theta) - \log p(\theta) = \text{NLL} - \log p(\theta)$$

Small-data regime: MLE vs MAP




ERM에서의 regularization? MAP

$$p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$$

$$p(\theta|x) \propto p(x|\theta)p(\theta)$$

$$-\log p(x|\theta) - \log p(\theta) = \text{NLL} - \log p(\theta)$$

Small-data regime: MLE vs MAP



확률적 모델링

- 우리가 머신러닝이나 딥러닝을 배울때 왜 확률적 모델링을 배워야 하는가?
 - 모델링, 추론(inference), 변수 추정, 모델 선택(model selection)등을 통합하는 프레임워크
 - 지난시간에 배웠듯, 심지어는 ERM도 암시적으로 확률 모델

확률적 모델링

- 확률은 세개의 level에서 사용이 가능
- 관측에서 발생하는 불확실성

$$y_n = x_n^\top \theta + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

- 모델의 불확실성

$$p(\theta) \quad p(\theta|\mathcal{D})$$

- 예측 단계에서의 기대값

$$p(y_*|x_*, \mathcal{D}) = \int p(y_*|x_*, \theta) p(\theta|\mathcal{D}) d\theta$$

잠재 변수(Latent variables)

- 잠재 변수란?

- 직접 관찰하거나 측정할 수 없는, 데이터 내에 숨겨진 추상적인 구성 개념이나 요인
- ex) 넷플릭스 추천 알고리즘
- 관측 변수 (눈에 보이는 데이터): 유저 A가 클릭한 영상 목록 ('어벤저스', '아이언맨', '스파이더맨')
- 잠재 변수 (눈에 안보이는 숨은 규칙): '마블 덕후'

잠재 변수(Latent variables)

- 머신러닝에서는?
 - 우리가 동전 던지기를 할때, 결과를 예측하기 위해서는 우리가 정확히 알 수 없는 숨은 변수, 즉 잠재 변수인 “앞면이 나올 확률”을 알아야 함
- 잠재 변수 θ 를 활용하면?
- 예측 분포 계산

$$p(y_*|x_*, \mathcal{D}) = \int p(y_*|x_*, \theta)p(\theta|\mathcal{D})d\theta \approx p(y_*|x_*, \theta)$$

- 모델 선택



$$p(\mathcal{D}) = \int p(\mathcal{D}|\theta)p(\theta)d\theta$$

잠재 변수(Latent variables)

- 방금 본 수식들은 깔끔하게 적분이 되는 경우가 흔하지 않음
- 그래서 우리는 이를 계산하기 위한 근사를 많이 활용
 - Deep Ensemble, Variational Inference 등등

Directed Graphical Models

- Directed Graphical Model은 복잡한 조건부 독립 관계를 방향성이 있는 그래프로 표현한 확률 모델을 말함
- $p(a,b,c)=p(c | a,b)p(b | a)p(a)$
 - Fully connected
- $p(x_1, x_2, x_3, x_4, x_5) = p(x_1)p(x_5)p(x_2|x_5)p(x_3|x_1, x_2)p(x_4|x_2)$
 - not fully connected




DGM 예시


- 동전 던지기에서 앞면이 나올 확률이 μ

$$p(x|\mu) = \text{Ber}(\mu)$$


$$p(x_1, \dots, x_N | \mu) = \prod_{n=1}^N p(x_n | \mu)$$



(a) Version with x_n explicit.



(b) Version with plate notation.



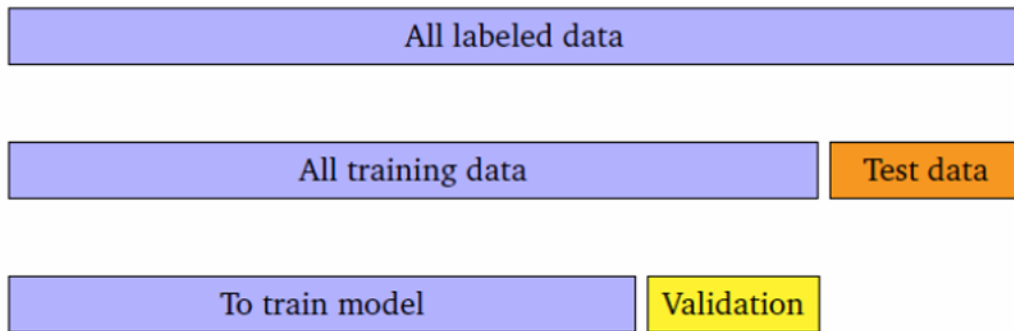
(c) Hyperparameter α on the latent μ .

Model Selection

- 우리가 어떤 문제를 풀때 다양한 모델을 활용할 수 있음
- 선형 모델, 2차 다항식 모델, k 차 다항식 모델, 뉴럴 네트워크 등등
- 그럼 그 많은 모델 중 어떤 걸 선택을 해야할까?


Nested Cross Validation

- test data에서 가장 좋은 성능을 내는 모델!



Occam's razor

- 어떤 현상을 설명할때 불필요한 가정을 최소화하고 가장 단순한 쪽을 선택하라! (14세기 영국 오컴 지역에 사는 윌리엄이라는 철학자)



$$\begin{aligned} \frac{p(M_1|\mathcal{D})}{p(M_2|\mathcal{D})} &= \frac{\frac{p(\mathcal{D}|M_1)p(M_1)}{p(\mathcal{D})}}{\frac{p(\mathcal{D}|M_2)p(M_2)}{p(\mathcal{D})}} \\ &= \frac{p(M_1)}{p(M_2)} \frac{p(\mathcal{D}|M_1)}{p(\mathcal{D}|M_2)} \end{aligned}$$

Q&A