



머신러닝 기초

Lecture 17: 선형 회귀

회귀란?

- 통계학 및 머신러닝에서 하나의 종속 변수(결과 값)와 하나 이상의 독립 변수(원인 값) 간의 관계를 수학적 모형으로 추정하고 예측하는 분석 기법




문제 구성

- 독립 변수 x 와 종속 변수 y 가 있다고 할때, 종속 변수는 관측값!
- 우리가 관측하는 모든 관측값에는 noise가 발생
- 우리는 이 noise를 ϵ 으로 정의하고 $\epsilon \sim \mathcal{N}(0, \sigma^2)$ 이라고 가정
- 여기서 우리는 $y = f(x) + \epsilon$ 로 표현이 잘되는 함수 f 를 찾고 싶음 => 회귀 문제
- 선형 회귀? $f(x) = \theta^\top x$
- 비선형 회귀로의 확장 $f(x) = \theta^\top \phi(x)$

변수 추정

- 학습데이터 $\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$
- $P(Y|X, \theta) = P(y_1, \dots, y_N | x_1, \dots, x_N, \theta)$

$$= \prod_{n=1}^N P(y_n | x_n, \theta) = \prod_{n=1}^N \mathcal{N}(y_n | x_n^\top \theta, \sigma^2)$$



- 여기서 $P(Y|X, \theta)$ 의 값이 최대가 되도록 하는 최적의 θ^* 를 찾고 이를 예측에 사용하자!

$$P(y' | x', \theta^*) = \mathcal{N}(y' | x'^\top \theta^*, \sigma^2)$$

선형 회귀 MLE

- $\theta_{\text{ML}} = \arg \max P(Y|X, \theta)$
 $= \arg \min_{\theta} -\log P(Y|X, \theta) = \arg \min_{\theta} -\log \prod_{i=1}^N p(y_n|x_n, \theta)$
 $= \arg \min_{\theta} -\sum_{n=1}^N \log p(y_n|x_n, \theta)$
 $\log p(y_n|x_n, \theta) = -\frac{1}{2\sigma^2} (y_n - x_n^{\top} \theta)^2 + \text{const}$

선형 회귀 MLE

- $$L(\theta) = -\log P(Y|X, \theta) = \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - x_n^\top \theta)^2 + \text{const}$$
$$= \frac{1}{2\sigma^2} (y - X\theta)^\top (y - X\theta) = \frac{1}{2\sigma^2} \|y - X\theta\|^2$$
- 여기서 $X = [x_1, \dots, x_N]^\top$, $y = [y_1, \dots, y_N]^\top$

최적해 구하기

$$\begin{aligned}
 \bullet \quad \frac{dL}{d\theta} &= \frac{d}{d\theta} \left(\frac{1}{2\sigma^2} (y - X\theta)^\top (y - X\theta) \right) \\
 &= \frac{1}{2\sigma^2} \frac{d}{d\theta} (y^\top y - 2y^\top X\theta + \theta^\top X^\top X\theta) \\
 &= \frac{1}{2\sigma^2} (-2y^\top X + 2\theta^\top X^\top X) = \frac{1}{\sigma^2} (-y^\top X + \theta^\top X^\top X)
 \end{aligned}$$

$$\begin{aligned}
 \frac{dL}{d\theta} = 0^\top &\Leftrightarrow \theta_{\text{ML}}^\top X^\top X = y^\top X \\
 \theta_{\text{ML}}^\top &= y^\top X (X^\top X)^{-1} \\
 \theta_{\text{ML}} &= (X^\top X)^{-1} X^\top y
 \end{aligned}$$

선형 회귀를 넘어서...


- $p(y|x, \theta) = \mathcal{N}(y|\phi^\top \theta, \sigma^2)$

$$y = \phi(x)^\top \theta + \epsilon \Rightarrow y = \sum_{k=1}^K \theta_k \phi_k(x) + \epsilon$$

다항식으로의 확장

- $\phi(x) = \begin{bmatrix} 1 \\ x \\ x^2 \\ \vdots \\ x^{K-1} \end{bmatrix} \in \mathbb{R}^K$
- Feature matrix $\Phi = \begin{bmatrix} \phi(x_1)^\top \\ \vdots \\ \phi(x_N)^\top \end{bmatrix} \in \mathbb{R}^{N \times K}$
- $\text{NLL} - \log p(Y|X, \theta) = \frac{1}{2\sigma^2} (y - \Phi\theta)^\top (y - \Phi\theta) + \text{const}$
- $\theta_{\text{ML}} = (\Phi^\top \Phi)^{-1} \Phi^\top y$
- rank가 K가 되어야 invertible

다항식으로의 확장



평가



- 우리가 학습을 할 때는 $\frac{1}{N} \sum_{n=1}^N (y_n - \phi(x_n)^\top \theta)^2$
- 하지만 평가를 할 때는 **Root Mean Square Error (RMSE)**

$$\sqrt{\frac{1}{N} \|y - \Phi\theta\|^2} = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_n - \phi(x_n)^\top \theta)^2}$$

과적합

- 우리의 모델이 M 차 다항식일때...
 - $M \leq N$ 이면 해는 유일하게 존재 $\theta_{\text{ML}} = (\Phi^T \Phi)^{-1} \Phi^T y$
 - 그 반대라면..? 유일해가 존재하지 않고 선형 방정식을 푸는 법을 활용하여 해를 구해야함
 - 무한히 많은 해가 존재!

과적합



MAP 구하기

- 과적합이 일어나는 경우에 대부분 변수들의 값이 매우 큰 값을 가지는 현상이 발생함
- 변수의 값이 매우 큰 경우 사전 분포 $p(\theta)$ 에 대한 확률이 작은 값을 가지도록 design

$$p(\theta|X, Y) = \frac{P(Y|X, \theta)p(\theta)}{p(Y|X)}$$

MAP 구하기

- $\log p(\theta|X, Y) = \log p(Y|X, \theta) + \log p(\theta) + \text{const}$
- 여기서 $\theta_{\text{MAP}} \in \arg \min_{\theta} -\log p(Y|X, \theta) - \log p(\theta)$

$$-\frac{d \log p(\theta|X, Y)}{d\theta} = -\frac{d \log p(Y|X, \theta)}{d\theta} - \frac{d \log p(\theta)}{d\theta}$$

MAP 구하기

- Gaussian prior $p(\theta) = \mathcal{N}(0, b^2 I)$

$$-\log p(\theta|X, Y) = \frac{1}{2\sigma^2} (y - \Phi\theta)^\top (y - \Phi\theta) + \frac{1}{2b^2} \theta^\top \theta + \text{const}$$

$$-\frac{d \log p(\theta|X, Y)}{d\theta} = \frac{1}{\sigma^2} (\theta^\top \Phi^\top \Phi - y^\top \Phi) + \frac{1}{b^2} \theta^\top = 0^\top$$



$$\theta^\top \left(\frac{1}{\sigma^2} \Phi^\top \Phi + \frac{1}{b^2} I \right) - \frac{1}{\sigma^2} y^\top \Phi = 0^\top$$

$$\theta^\top \left(\Phi^\top \Phi + \frac{\sigma^2}{b^2} I \right) = y^\top \Phi$$

Positive definite 보장!!

$$\theta_{\text{MAP}} = \left(\Phi^\top \Phi + \frac{\sigma^2}{b^2} I \right)^{-1} \Phi^\top y$$

MLE와 MAP 차이



Q&A