

이기종 모델을 잇는 계층형 연합학습

Agglomerative Federated Learning: Empowering Larger Model Training via End-Edge-Cloud Collaboration

Zhiyuan Wu · Sheng Sun · Yuwei Wang · Min Liu · Bo Gao · Quyang Pan · Tianliu He · Xuefeng Jiang (2024)

FedAgg: End-Edge-Cloud에서 파라미터 평균 대신 양방향 bridge-sample 지식증류를 반복한다.

문제: 데이터 위치와 모델 크기가 함께 다르다

단말은 데이터를 갖지만 작은 모델을, 상위 계층은 더 큰 모델을 둘 수 있다.

01 End 로컬 데이터·작은 모델



02 Edge 여러 단말을 잇는 중간 모델



03 Cloud 더 큰 전역 모델




04 핵심 질문 서로 다른 모델을 어떻게 함께 학습할까?

FedAgg의 출발점은 데이터 분할뿐 아니라 모델 이질성이다.

End-Edge-Cloud: 역할과 능력의 계층

공간적 계층도이며, 한 라운드의 시간 순서를 뜻하지 않는다.



실험 모델은 M1=3-layer CNN, M2=ResNet-10, M3=ResNet-18이다.

핵심 구분: 공통 벡터 평균이 아니다

FedAgg는 모델 구조가 다른 계층을 대상으로 한다.

질문

동형 평균의 전제

FedAgg의 대응

모델

같은 파라미터 형태

M1·M2·M3처럼 달라도 됨

상위 전달

파라미터 벡터 결합

bridge sample의 logits

학습

평균 뒤 각자 갱신

교사·학생 역할을 양방향 교대

‘aggregation’이라는 이름만으로 FedAvg식 평균을 추정하면 안 된다.

무엇이 어디에 남고, 무엇이 전달되는가


raw sample, embedding, bridge sample, logits를 같은 화살표로 섞지 않는다.



논문은 부모에 raw X를 저장한다고 말하지 않는다.

BSBODP는 양방향 교사-학생 갱신이다


한 쌍의 노드는 한 방향만 끝내지 않고, 교사·학생을 바꿔 다시 수행한다.



역할이 바뀌므로 ‘cloud만 teacher’라는 단순 그림은 부정확하다.

학생의 위치가 손실을 바꾼다

Eq. (2)는 non-leaf, Eq. (4)는 leaf의 손실이다.



초기화: embedding과 label을 재귀적으로 저장


Algorithm 2의 INIT은 학습 라운드와 구분되는 준비 단계다.



상위 노드가 쓰는 것은 raw sample이 아니라 저장된 ϵ 와 label이다.

실제 반복 단위: Algorithm 2의 재귀 학습 라운드

internal non-root의 병렬 for에서 각 child 분기는 재귀 호출 직후 같은 v^* -parent BSBODP를 실행한다.



leaf는 BSBODP를 한 번 호출하고, root는 child 호출만 수행하며 parent 교환은 하지 않는다.

동적 계층 변경: 정리가 보장하는 범위

두 정리는 같은 계층 parent 교체의 가능 조건과 partial-order protocol의 반례 기반 한계를 구분한다.

정리	가정과 결론	말하지 않는 것
Theorem 1	equivalence protocol이면 같은 level의 다른 parent로 교체 가능	정확도·수렴 보장 아님
Theorem 2	partial-order protocol에서는 같은 교체가 반드시 가능하지 않음	partial order 보존 정리 아님
그림 1	same-level parent switching을 예시	실험적 migration 성능 아님

equivalence는 교체를 허용하지만, partial order만으로는 같은 교체를 보장할 수 없다.

손실을 손으로 계산해 보기: 명시적 가상 예시

아래 확률과 계산은 논문 데이터가 아니라 Eq. (2)의 형태를 읽기 위한 invented toy다.

항	가상 값	계산
teacher q	$(0.70, 0.20, 0.10)$	온도 적용 뒤의 가상 확률
student p	$(0.50, 0.30, 0.20)$	bridge label은 class 1
CE	$-\ln(0.50)$	0.6931
KL-loss	$KL(p q) \approx 0.09203$	$\beta = 10$ 이면 ≈ 1.61348 (4자리 1.6135)

두 번째 방향에서는 teacher와 student를 바꿔 같은 구조를 다시 계산한다.

실험 모델과 autoencoder의 규모

Table I의 구성은 이 논문의 실험 선택이며 모든 FedAgg 배포의 고정 규격이 아니다.

구성	모델	feature extractor	classifier
M1 / End	3-layer CNN	9.31K	10.88K
M2 / Edge	ResNet-10	—	4.67M
M3 / Cloud	ResNet-18	—	10.65M
Autoencoder	6 layers	encoder 1.90K	decoder 2.47K

모델 규모 차이가 지식증류 연결을 요구하는 직접적 실험 맥락이다.

결과를 읽기 위한 실험 조건

정확도 숫자에는 dataset, K , α , tree, 모델, hyperparameter가 함께 붙는다.

항목	CIFAR-10	CIFAR-100	공통 설정
client K	225, 400	144, 196, 225	one cloud, $\sqrt{K}$ edge
heterogeneity	$\alpha = 1, 3$	$\alpha = 3$ reported	1=high, 3=low
optimization	LR .001, batch 8	LR .001, batch 8	$\gamma = 1, T=3, \beta = 10$
baselines	4개 모두	HierFAVG, DemLearn lv=3/5/7/10	dataset별 비교군이 다름

α 의 high/low 해석은 이 논문 표기의 조건부 약속이다.

CIFAR-10 cloud-model accuracy: 네 조건을 함께 읽기

Table II의 값은 test accuracy(%)이며, 모든 열이 K 와 α 로 조건화된다.

방법	225 $\alpha = 3$	225 $\alpha = 1$	400 $\alpha = 3$	400 $\alpha = 1$
HierFAVG	10.15	18.35	22.25	18.73
DemLearn	30.55	32.13	29.25	28.06
FedGKT	27.39	26.59	30.54	29.22
FedDKC	32.43	30.09	30.79	28.78
FedAgg	36.76	33.87	35.83	33.74

각 열에서 FedAgg의 best-listed-baseline 대비 이득은 4.33·1.74·5.04·4.52 points다.

CIFAR-100 $\alpha = 3$: client 수별 비교

Table III는 $\alpha = 3$ 설정에서 cloud-model test accuracy(%)를 비교한다.

방법	K=144	K=196	K=225
HierFAVG	9.11	9.42	5.03
DemLearn level 3	15.75	14.94	14.81
DemLearn level 5	14.99	14.59	14.55
DemLearn level 7	14.52	13.97	13.89
FedAgg	17.07	17.33	16.50

FedAgg의 Table-III best-listed-baseline 대비 이득은 1.32·2.39·1.69 points다.

통신 라운드 표: 시간이나 에너지로 읽지 않기

Tables IV–V는 named target accuracy까지의 communication-round count다.

dataset	조건	낮은 target	높은 target	FedAgg rounds
CIFAR- 10	225, $\alpha = 3$	25%	30%	0 / 2
CIFAR- 10	225, $\alpha = 1$	25%	30%	1 / 7
CIFAR- 10	400, $\alpha = 3$	25%	30%	1 / 4
CIFAR- 100	144, $\alpha = 3$	9%	14%	0 / 5
CIFAR- 100	225, $\alpha = 3$	9%	14%	0 / 7

0 round는 해당 target이 통신 전부터 충족됐다는 표기이며, 0 ms가 아니다.

민감도: β 와 모델 이질성의 한정된 관찰

모두 CIFAR-10, $K=225$, $\alpha = 1$ 이라는 Table VI-VIII의 조건을 유지한다.

검사	설정	accuracy (%)	해석 경계
β ablation	0.1 / 1 / 3	33.14 / 35.33 / 34.66	$\beta = 1$ 이 이 표에서는 최고
β ablation	10 / 50	33.87 / 27.21	main $\beta = 10$ 도 최적 보장 아님
client model	20%: M1→M2	32.83 vs 33.87	heterogeneous vs homogeneous
cloud model	CNN / R10 / R18	23.84 / 31.11 / 33.87	이 설정의 cloud 비교

한 ablation의 최고값을 모든 데이터·모델에 대한 규칙으로 일반화할 수 없다.

논문이 지지하는 주장과 지지하지 않는 주장

조건부 실험 결과와 formal statement의 범위를 분리한다.

주장	논문 근거	넘어가면 안 되는 해석
raw data 완화	ϵ -decoder bridge 설계	formal privacy guarantee
정확도 비교	CIFAR-10/100 표의 조건	배포 throughput·energy
계층 변경	equivalence의 허용 / partial-order 반례	임의 migration accuracy
라운드 수	target accuracy counts	wall-clock latency

좋은 재현 질문은 ‘어떤 조건에서 어떤 metric인가’를 먼저 묻는다.

읽기 순서로 정리하기

상태 → 양방향 protocol → 재귀 round → 조건부 evidence의 순서로 논문을 다시 읽는다.

01	상태	X,y / ε +label / bridge / logits 분리
02	protocol	양방향 BSBODP와 역할 교대
03	round	각 child 분기: recursion 뒤 BSBODP
04	evidence	Tables I-VIII의 조건을 보존

핵심은 ‘무엇을 평균’이 아니라 ‘무엇을 어떤 방향으로 지도’했는가다.