

# Attention Is All You Need: v1 판본 보충

Attention Is All You Need — arXiv v1 Companion

---

Ashish Vaswani et al. (2017)

arXiv:1706.03762v1 (2017-06-12) · main lecture의 v7 mechanism을 판본별로 점검한다

# 같은 제목, 서로 다른 artifact


Revision date와 publication type을 먼저 적으면 수치 출처가 섞이지 않는다

| Artifact | Date       | Source type          | Lecture role   |
|----------|------------|----------------------|----------------|
| arXiv v1 | 2017-06-12 | Initial submission   | 이 supplement   |
| NeurIPS  | 2017       | Proceedings record   | 별도 artifact    |
| arXiv v7 | 2023-08-02 | Final arXiv revision | Main mechanism |

Paper identifier가 같아도 revision과 proceedings는 동일한 text record가 아니다

# Backbone은 공유되지만 기록은 동일하지 않다

이 conceptual pipeline은 v1과 v7 모두에 있고 상세 공식은 main lecture의 v7을 따른다



# 핵심 delta: multi-head 식의 $W^O$


v1 text와 v7 text에 실제로 적힌 식을 source-location별로 구분한다

| Source       | Written formula                                      | Observed difference     |
|--------------|------------------------------------------------------|-------------------------|
| v1 p. 4      | $\text{MultiHead} = \text{Concat}(\text{heads})$     | Final $W^O$ 가 식에 없음     |
| v7 p. 5      | $\text{MultiHead} = \text{Concat}(\text{heads}) W^O$ | $W^O$ 와 shape가 명시됨      |
| Main lecture | v7 formula 사용                                        | 완전한 canonical mechanism |

v7 식을 v1 인용으로 가장하지 않고 formula source를 명시한다

# $W^O$ 는 concatenated head features를 혼합한다

두 head만 대표로 표시하며 실제 base configuration은  $h=8$ 이다



# v1 내부에도 d\_ff 값 충돌이 있다

값을 조용히 수정하지 않고 어느 위치가 무엇을 적었는지 그대로 구분한다

| Source location   | d_model | d_ff | Reading          |
|-------------------|---------|------|------------------|
| v1 p. 5 FFN prose | 512     | 2048 | 본문 dimension     |
| v1 Table 3 base   | 512     | 1024 | 표의 printed entry |
| v7 p. 5 prose     | 512     | 2048 | 본문 dimension     |
| v7 Table 3 base   | 512     | 2048 | 표와 본문 일치         |

v1 source contains conflicting values; author intent는 추가 근거 없이 진단하지 않는다

# BLEU도 artifact와 location으로 인용한다

아래 값은 하나의 시간순 성능 향상 그래프가 아니라 서로 다른 text records다

| Artifact and location | EN-DE | EN-FR | Boundary             |
|-----------------------|-------|-------|----------------------|
| arXiv v1 Table 2      | 28.4  | 41.0  | v1 big row           |
| arXiv v7 Table 2      | 28.4  | 41.8  | v7 big row           |
| v7 Sec. 6.1 prose     | 28.4  | 41.0  | v7 internal conflict |
| NeurIPS abstract      | 27.5  | 41.1  | Separate artifact    |

41.0·41.8·41.1 중 하나를 paper의 유일한 EN-FR score라고 부르지 않는다

# v1을 보존하며 정확하게 읽는 법

공통 architecture는 main lecture로 돌아가고 version-specific claim만 이 자료에서 확정한다

| Question                  | Safe answer                       |
|---------------------------|-----------------------------------|
| v1 전체가 틀렸나?               | 아니다. 공통 Transformer backbone이 있다  |
| $W^O$ 는 어디서 가르치나?         | v7 p. 5의 explicit equation        |
| Base $d_{ff}$ 는 얼마인가?     | v1 내부 conflict; v7 기준 2048        |
| EN-FR score는 하나인가?        | Artifact와 location별로 다르다          |
| Attention cost는 linear인가? | 두 판본 모두 full attention $O(n^2 d)$ |

판본 차이는 원문을 버릴 이유가 아니라 citation precision을 높일 근거다