

Attention Is All You Need: v1 판본 보충

Attention Is All You Need — arXiv v1 Companion

Ashish Vaswani et al. (2017)

arXiv:1706.03762v1 (2017-06-12) · main lecture의 v7 mechanism을 판본별로 점검한다

같은 제목, 서로 다른 artifact


Revision date와 publication type을 먼저 적으면 수치 출처가 섞이지 않는다

Artifact	Date	Source type	Lecture role
arXiv v1	2017-06-12	Initial submission	이 supplement
NeurIPS	2017	Proceedings record	별도 artifact
arXiv v7	2023-08-02	Final arXiv revision	Main mechanism

Paper identifier가 같아도 revision과 proceedings는 동일한 text record가 아니다

Backbone은 공유되지만 기록은 동일하지 않다

이 conceptual pipeline은 v1과 v7 모두에 있고 상세 공식은 main lecture의 v7을 따른다



핵심 delta: multi-head 식의 W^O


v1 text와 v7 text에 실제로 적힌 식을 source-location별로 구분한다

Source	Written formula	Observed difference
v1 p. 4	$\text{MultiHead} = \text{Concat}(\text{heads})$	Final W^O 가 식에 없음
v7 p. 5	$\text{MultiHead} = \text{Concat}(\text{heads}) W^O$	W^O 와 shape가 명시됨
Main lecture	v7 formula 사용	완전한 canonical mechanism

v7 식을 v1 인용으로 가장하지 않고 formula source를 명시한다

W^O 는 concatenated head features를 혼합한다

두 head만 대표로 표시하며 실제 base configuration은 $h=8$ 이다



v1 내부에도 d_ff 값 충돌이 있다

값을 조용히 수정하지 않고 어느 위치가 무엇을 적었는지 그대로 구분한다

Source location	d_model	d_ff	Reading
v1 p. 5 FFN prose	512	2048	본문 dimension
v1 Table 3 base	512	1024	표의 printed entry
v7 p. 5 prose	512	2048	본문 dimension
v7 Table 3 base	512	2048	표와 본문 일치

v1 source contains conflicting values; author intent는 추가 근거 없이 진단하지 않는다

BLEU도 artifact와 location으로 인용한다

아래 값은 하나의 시간순 성능 향상 그래프가 아니라 서로 다른 text records다

Artifact and location	EN-DE	EN-FR	Boundary
arXiv v1 Table 2	28.4	41.0	v1 big row
arXiv v7 Table 2	28.4	41.8	v7 big row
v7 Sec. 6.1 prose	28.4	41.0	v7 internal conflict
NeurIPS abstract	27.5	41.1	Separate artifact

41.0·41.8·41.1 중 하나를 paper의 유일한 EN-FR score라고 부르지 않는다

v1을 보존하며 정확하게 읽는 법

공통 architecture는 main lecture로 돌아가고 version-specific claim만 이 자료에서 확정한다

Question

v1 전체가 틀렸나?

W^O 는 어디서 가르치나?

Base d_{ff} 는 얼마인가?

EN-FR score는 하나인가?

Attention cost는 linear인가?

Safe answer

아니다. 공통 Transformer backbone이 있다

v7 p. 5의 explicit equation

v1 내부 conflict; v7 기준 2048

Artifact와 location별로 다르다

두 판본 모두 full attention $O(n^2 d)$

판본 차이는 원문을 버릴 이유가 아니라 citation precision을 높일 근거다
