

Safe Reinforcement Learning의 지도

A Comprehensive Survey on Safe Reinforcement Learning

Javier García, Fernando Fernández (2015)

기대 보상, 위험 기준, 탐색 제어를 구분해 읽는 2015년 JMLR survey

이 survey가 말하는 Safe RL

학습 또는 배포 중 성능과 안전 제약이 중요한 문제에서 정책을 배우는 방법의 분류

- 목표는 기대 return을 크게 하는 정책 학습이다.
- 안전은 물리적 손상 회피만 뜻하지 않는다.
- 희귀한 큰 손실, 불확실성, error state도 risk가 될 수 있다.
- 저자들의 핵심 기여는 방법들의 taxonomy와 비교 기준이다.

이 논문은 단일한 안전 보장을 제안하기보다 서로 다른 risk 개념을 정리한다

기대 return만으로는 보이지 않는 것

risk-neutral RL은 평균을 최적화하지만 return 분포의 다른 성질을 무시한다

기준	주로 보는 값	위험을 읽는 관점
risk-neutral	$E\pi(R)$	분산과 희귀한 큰 손실을 놓칠 수 있음
worst-case	가장 나쁜 return	드물어도 치명적인 결과까지 고려
risk-sensitive	return과 risk의 조합	선호하는 risk 수준
constrained	return과 제약	허용 한도를 넘는 비용

같은 평균 보상이라도 손실의 크기와 발생 방식은 다를 수 있다

교육용 예시: 평균과 최악 결과

같은 상태에서 기준을 바꾸면 선호 행동도 달라질 수 있다

행동	return 분포	기대 return	최악 return
Safe	항상 5	5	5
Risky	90%: 9, 10%: -20	$0.9 \times 9 + 0.1 \times (-20) = 6.1$	-20

기대 return 기준은 Risky를, worst-case 기준은 Safe를 고른다

학습 중 위험과 배포 후 위험


같은 방법도 어느 시점의 위험을 줄이는지에 따라 해석이 달라진다

질문	학습 과정	배포된 정책
주된 걱정	탐색 행동이 손상이나 error를 일으킴	최종 정책이 불리한 결과를 선택함
대표 개입	demonstration, teacher advice, risk-directed exploration	worst-case, risk-sensitive, constrained criterion
주의점	안전한 탐색이 최종 최적성을 자동 보장하지 않음	좋은 최종 정책이 안전한 학습 과정을 보장하지 않음

안전한 학습 경로와 위험을 고려한 최종 정책은 구별해야 한다

두 개입 지점

survey는 안전을 반영하는 위치에 따라 literature를 정리한다



목적함수 수정의 네 갈래


평균 return 이외의 기준을 최적화 문제에 넣는다

갈래	목적에 추가하는 것	source의 예
worst-case	최악 return	inherent 또는 parameter uncertainty
risk-sensitive	utility 또는 risk 항	지수 utility, variance, error 확률
constrained	기대 측도의 경계	cost 또는 error 제약
other criteria	특수한 분포 기준	VaR, R-squared, return density

각 갈래는 risk를 측정하는 방식과 필요한 가정이 다르다

worst-case와 두 종류의 불확실성

나쁜 결과의 원인을 구분해야 worst-case 기준의 의미가 선명해진다



지수 utility 기반 risk sensitivity

return을 utility로 변환해 큰 손실과 변동성에 대한 민감도를 조절한다

- 정책 평가는 raw return 대신 exponential utility를 사용한다.
- risk sensitivity parameter가 위험 회피 또는 선호의 정도를 정한다.
- parameter 선택은 application의 의사결정 선호를 반영해야 한다.
- 이 기준은 위험의 정의를 자동으로 발견하지 않는다.

utility 함수의 모양은 평균 return 이외에 무엇을 벌점으로 볼지 정한다

return과 risk의 가중 결합

기대 return에 risk measure의 벌점을 결합하는 방식

risk measure	무엇을 줄이려는가	해석 시 조건
return variance	return의 변동 폭	위험을 variance로 보는 가정
error-state probability	error state에 들어갈 가능성	error state 정의와 확률 추정
가중 계수	return과 risk의 trade-off	계수 선택이 정책을 바꿈

가중 결합은 risk 정의와 weight를 함께 정해야 의미가 있다

constrained criterion

return을 키우되 별도의 기대 측도를 허용 범위 안에 둔다

- | | | |
|----|-------------|---------------------|
| 01 | 정책 후보 | return과 cost를 함께 예측 |
| ↓ | | |
| 02 | 제약 확인 | 기대 측도가 bound를 만족하는가 |
| ↓ | | |
| 03 | feasible 정책 | 제약을 만족한 후보만 남김 |
| ↓ | | |
| 04 | return 최대화 | 남은 후보 중 목적을 최적화 |

제약의 의미는 어떤 측정값에 어떤 bound를 두는지로 결정된다

기타 목적함수 기준

survey는 금융·분포 관점의 기준도 별도 갈래로 남긴다

- r-squared와 VaR 등 금융 risk metric도 다룬다.
- 각 metric의 상세 정의와 가정은 원 논문에서 확인해야 한다.
- return density 추정은 return 분포 자체를 모델링한다.
- 서로 다른 기준은 같은 안전 뜻이나 같은 보장을 공유하지 않는다.

risk의 수학적 표현을 바꾸면 정책 비교의 의미도 바뀐다

탐색 과정 수정의 두 갈래

고전적 return 목적을 유지하면서 위험한 trial을 덜 하도록 행동 선택을 바꾼다

갈래	개입 수단	학습 초기에 바꾸는 것
external knowledge	초기 지식, demonstration, teacher advice	탐색의 출발점이나 행동 후보
risk-directed exploration	risk metric	행동을 선택할 확률

탐색 수정은 ‘무엇이 최적인가’보다 ‘무엇을 먼저 해 볼 것인가’에 초점을 둔다

초기 지식으로 탐색을 시작하는 방식

teacher example 또는 과거 정보로 초기 policy와 value를 bootstrap한다

- | | | |
|----|-------|-------------------------|
| 01 | 사전 정보 | example 또는 task 지식 |
| ↓ | | |
| 02 | 초기화 | value, policy, case에 반영 |
| ↓ | | |
| 03 | 초기 탐색 | relevant region을 먼저 시도 |
| ↓ | | |
| 04 | 후속 학습 | 관측으로 policy를 계속 갱신 |

초기 지식은 blind random exploration을 줄일 수 있지만 그 품질에 의존한다

유한 demonstration에서 정책을 얻는 방식

온라인 무작위 시도 대신 teacher가 준 example으로 offline policy를 학습한다

01 teacher demonstrations 유한한 state-action example



02 offline 학습 example으로 model 또는 policy를 유도



03 정책 도출 offline model에서 policy를 얻음



04 배포 또는 추가 학습 새 상황의 일반화는 별도 문제

demonstration은 탐색 데이터를 대체하지만 coverage와 teacher 품질이 중요하다

teacher advice의 시작 주체

advice는 누가 언제 상호작용을 시작하는지에 따라 세 갈래로 정리된다

형태	상호작용 시작	의미
learner asks	learner가 필요할 때 요청	불확실하거나 위험하다고 판단한 순간의 도움
teacher gives	teacher가 먼저 개입	teacher가 필요하다고 판단할 때 행동 또는 정보 제공
other interaction	주체가 혼합되거나 불명확	여러 teacher-learner 구조

advice의 안전 효과는 teacher의 정보와 개입 규칙에 달려 있다

risk-directed exploration

최종 목적은 유지하고 exploration action의 선택 확률에 risk를 반영한다

01 현재 state 가능한 action과 관측 정보



02 risk measure action별 위험 신호를 추정



03 탐색 확률 위험을 고려해 action probability 조정



04 경험 수집 고전적 return 목적 아래 policy 갱신

risk-directed exploration은 risk를 action selection에 쓰되 고전적 목적을 유지한다

목적함수 수정과 탐색 수정의 비교

두 흐름은 바꾸는 대상과 주장할 수 있는 범위가 다르다

질문	목적함수 수정	탐색 과정 수정
주로 바꾸는 것	정책을 평가하는 criterion	학습 중 action 선택 방식
필요한 선택	risk definition과 trade-off	prior knowledge 또는 risk signal
주요 위험	잘못된 risk metric과 weight	부정확한 advice와 부족한 coverage
학습 중 안전	별도 탐색 설계 없이는 불명확	위험 trial 감소를 겨냥

어느 흐름을 택할지는 위험의 정의와 사용할 수 있는 정보에 달려 있다

방법을 비교하는 네 차원

Section 5는 방법을 하나의 점수로 줄이지 않고 특성을 나란히 본다

차원	확인할 질문	예시
allowed learner	어떤 RL learner와 결합 가능한가	model-free 또는 특정 구조
spaces	어떤 state/action-space 규모·형태의 domain에서 적용됐는가	S/a: large/continuous state, small/discrete action
risk	무엇을 위험으로 측정하는가	variance, error probability, constraint
exploration	위험을 언제 어떻게 줄이는가	prior knowledge, advice, action probability

같은 'safe'라는 이름보다 risk 표현과 적용된 state/action domain을 먼저 비교해야 한다

열린 설계 질문

survey는 안전을 위한 단일 default를 제시하지 않고 선택해야 할 문제를 남긴다

질문	왜 필요한가	발표에서 확인할 말
risk metric	위험 정의가 행동 선택을 바꿈	무엇을 unacceptable로 보는가
optimum criterion	평균과 risk의 trade-off가 필요	최적의 의미는 무엇인가
risk detection	위험 신호가 부정확할 수 있음	어떻게 위험을 알아내는가
learning schema	prior knowledge와 learner 구조가 다름	어떤 정보가 주어지는가
exploration strategy	초기 trial 자체가 비용일 수 있음	언제 intervention하는가

Safe RL의 선택은 알고리즘 이름보다 위험 정의와 정보 가정에서 시작한다

2015년 survey의 역사적 범위

논문은 당시 literature의 taxonomy이며 이후 방법의 포괄적 성능 판정이 아니다

- source는 2015년에 출판된 JMLR survey다.
- 대표 citation들은 공통 benchmark의 직접 비교 결과가 아니다.
- 각 branch의 guarantee는 원 논문별 가정과 risk 정의에 달려 있다.
- 현대 deep RL이나 최신 safe RL 결과는 별도 source가 필요하다.

taxonomy는 출발점이며 최신 성능이나 보장의 대체 근거가 아니다

Safe RL 논문을 읽는 순서

안전이라는 말보다 먼저 위험의 정의와 개입 위치를 확인한다

- | | | |
|----|-------|---|
| 01 | 위험 정의 | 손실, uncertainty, error, constraint 중 무엇인가 |
| ↓ | | |
| 02 | 개입 위치 | 목적함수 또는 탐색 과정 |
| ↓ | | |
| 03 | 가정 확인 | model, prior knowledge, risk estimate |
| ↓ | | |
| 04 | 증거 해석 | 학습 중 위험, 배포 성능, 보장 범위를 분리 |

Safe RL은 하나의 기법 이름이 아니라 위험을 정책 학습에 넣는 설계 공간이다

공개 출처

자료	공개 위치	이 강의자료에서의 용도
JMLR survey	jmlr.org/papers/v16/garcia15a.html	정의, taxonomy, representative literature, discussion