

COVERCAL: PTQ calibration을 outlier channel coverage로 고르기

Coverage-Based Calibration for Post-Training Quantization via Weighted Set Cover over Outlier Channels

Ibne Farabi Shihab, Sanjeda Akter, Anuj Sharma (2026)

작은 calibration budget에서 무엇을 포함할지 weighted set cover로 정하는 방법

PTQ에서 calibration sample이 만드는 문제

작은 set으로 본 activation range가 quantization scale에 들어가므로, 어떤 sample을 넣는지가 중요하다

- | | | |
|----|---------------|---------------------------------------|
| 01 | FP16 model | pre-trained weight와 calibration input |
| ↓ | | |
| 02 | activation 관측 | 각 layer와 hidden channel의 range를 본다 |
| ↓ | | |
| 03 | low-bit scale | 관측된 activation으로 PTQ scale을 잡는다 |
| ↓ | | |
| 04 | inference | 보지 못한 큰 activation은 clipping될 수 있다 |

calibration set은 단순한 text sample이 아니라 quantization scale을 정하는 관측 창이다

outlier channel과 coverage의 정의

layer마다 reference pool에서 큰 activation을 보인 hidden channel을 먼저 찾는다

항목	source 정의	selection에서의 의미	실험 설정
channel score	set S에서 최대 absolute activation	한 sample이 channel을 강하게 컷는지	layer l, channel c마다 계산
threshold	$\tau(l) = \text{mean}(l) + 6 \times \text{std}(l)$	threshold 초과면 outlier	reference-pool statistic
covered	selected S 안에 threshold 초과 sample 존재	그 channel의 range를 관측	strictly greater than τ
candidate pool	P에서 sample을 고름	K개 budget이 selection을 제한	reference pool = P

coverage는 text topic의 다양성이 아니라 layer-channel activation event의 집합이다

같은 sample 수라도 놓치는 channel이 다를 수 있다

높은 activation을 여러 번 보아도 같은 channel만 반복하면 새 coverage가 늘지 않는다

selected sample	c1	c2	high-weight c3	coverage 결과
sample A	covered	covered	missed	c1, c2만 관측
sample B	covered	missed	covered	c1, c3 관측
A와 A'	반복	반복	missed	새 channel gain 없음
A와 B	covered	covered	covered	서로 보완하는 coverage

COVERCAL은 ‘강한 sample’ 하나를 반복해 고르기보다 아직 안 보인 channel을 보완한다

왜 모든 outlier channel을 같은 값으로 세지 않는가

weight는 normalized outlier magnitude와 weight-column sensitivity를 함께 반영한다

weight 요소	계산	큰 경우	coverage에서의 효과
activation magnitude	$(\text{reference outlier} / \tau)^2$	threshold보다 훨씬 큰 activation	missed clipping의 상대적 위험이 큼
weight-column norm	squared norm of $W(:,c)$	channel c 의 error가 layer output에 크게 전달	같은 activation도 더 큰 weight
full weight	두 요소의 product	두 조건이 함께 큼	greedy marginal gain이 커짐
ablation	각 요소만 쓴 variant도 평가	LLaMA-3-8B AWQ INT4 $K=128$	full product가 가장 높게 보고됨

channel count보다 weighted coverage를 최대화해 high-impact channel을 우선한다

weighted set cover로 바뀐 calibration selection

K개 sample이 cover한 outlier channel weight의 합을 크게 만드는 cardinality-constrained 문제다

- | | | |
|----|--------------------|---------------------------------|
| 01 | candidate pool P | 각 sample의 outlier mask를 준비 |
| ↓ | | |
| 02 | channel weights | high-impact channel에 큰 w 를 준다 |
| ↓ | | |
| 03 | budget K | K개 sample만 선택할 수 있다 |
| ↓ | | |
| 04 | objective $F(S)$ | 한 번 이상 covered된 weight를 합산 |

이미 covered된 channel을 또 cover하면 objective의 marginal gain은 0이다

COVERCAL의 greedy update

cached mask에서 아직 uncovered인 weighted channel만 더해 marginal gain을 계산한다



selection은 K번 반복하지만, 새로 cover하는 weight만 계산하므로 redundancy가 감점된다

교육용 greedy trace: 중복 channel의 gain

가상 channel weight $c_1=5$, $c_2=3$, $c_3=2$ 를 둔 한 번의 selection trace

단계	sample별 새 weighted gain	선택	covered after update
시작	A: $c_1+c_2=8$; B: $c_2+c_3=5$; C: $c_1=5$	A	c_1, c_2
다음	B: $c_3=2$; C: 0	B	c_1, c_2, c_3
결과	$F(S)=5+3+2=10$	A, B	C를 더해도 새 gain 0

A와 B는 서로 c_2 를 겹치지만, 두 번째 선택에서는 새 channel c_3 만 gain으로 센다

두 이론 문장과 그 경계

classical greedy bound와 clipping surrogate consistency는 서로 다른 질문에 답한다

source 결과	무엇에 대한 결과인가	조건	말하지 않는 것
Theorem 4.1	weighted coverage $F(S)$	monotone submodular, budget K	LLM accuracy의 $1 - 1/e$
Proposition 3.3	stylized clipping surrogate	covered deficit 0, missed deficit bound	full Frobenius loss upper bound
weight choice	missed weighted mass	per-channel independence surrogate	모든 PTQ backend의 exact loss
experiments	downstream metrics	모델·backend·budget setup	universal quality law

$1 - 1/e$ 는 coverage objective의 approximation guarantee이며, accuracy guarantee가 아니다

기존 PTQ backend와 연결되는 위치

COVERCAL은 quantizer parameter를 학습하거나 backend를 교체하지 않고 calibration set을 선택한다

01 FP16 profiling pool P를 한 번 통과해 activation을 기록



02 mask와 weight outlier threshold와 weighted matrix를 cache



03 COVERCAL CPU greedy로 K sample을 선택



04 AWQ 또는 GPTQ 선택 set으로 기존 PTQ calibration 실행

방법의 개입점은 PTQ 앞의 calibration selection이며, AWQ/GPTQ 자체는 그대로다

profiling cost와 selection cost는 다르다

GPU가 전혀 필요 없다는 말은 greedy selection 단계에만 해당한다

phase	입력	reported setup	wall-clock
offline profiling	10,000 sequences $\times$ length 2048	7B model, 1 $\times$ A100	about 15 min
greedy selection	cached weighted mask	same pool and K=128	CPU only, under 10 s
PTQ backend	selected calibration set	AWQ or GPTQ INT4	source가 end-to-end latency를 표로 보고하지 않음
reuse	same model profile	different K와 downstream evaluations	profiling cost can amortize

selection 자체는 cheap하지만, outlier mask를 얻는 profiling pass는 별도의 GPU 비용이다

main evaluation protocol

reported gain은 model, backend, bit-width, sample budget, pool, metric을 함께 붙여 읽는다

항목	reported condition	항목	reported condition
models	LLaMA-2-7B, LLaMA-3-8B, Mistral-7B	backends	AWQ and GPTQ, INT4, group size 128
pool	10,000 RedPajama sequences, length 2048	budgets	K=32, 64, 128, 256
main table	Table 1 caption: three seeds	random baseline	Section 5: Random five seeds
metrics	MMLU, ARC-C, HellaSwag, WinoGrande	language metric	WikiText-2 perplexity

seed 수는 Table 1 caption과 Section 5의 Random 설명이 서로 다르다

Table 1 예시: LLaMA-3-8B의 AWQ INT4 결과

K=128 결과다. Table 1 caption은 3 seeds, Section 5는 Random만 5 seeds라고 적는다

calibration	MMLU	ARC-C	HellaSwag	Wiki-PPL down
FP16	65.3	59.4	82.1	6.14
Random	63.1	57.2	80.5	6.42
Max-ActVar	63.8	57.6	80.8	6.38
COVERCAL	64.6	58.7	81.5	6.22

이 조건에서 COVERCAL은 Random보다 MMLU 1.5 point 높고 Wiki-PPL은 0.20 낮다

Table 2: measured coverage가 제안한 mechanism과 맞는가

K=128에서 COVERCAL은 channel count와 weighted mass를 모두 더 많이 cover했다고 보고한다

method	channel coverage	weighted coverage	해석
Random	16.8%	14.7%	기준 selection
Max-PPL	9.9%	8.6%	high-perplexity sample priority
Max-ActVar	10.4%	9.7%	중복 coverage가 많다고 분석
COVERCAL	26.9%	24.8%	weighted new coverage 직접 최적화

COVERCAL의 advantage는 높은 sample score보다 selected set의 낮은 redundancy와 연결된다

Figure 1과 Table 5: 작은 budget에서의 비교

LLaMA-3-8B, AWQ INT4에서 COVERCAL K=64가 Random K=256보다 높은 MMLU를 보였다

method	K=32	K=64	K=128	K=256
Random	61.2	62.1	63.1	63.8
Max-ActVar	61.8	62.7	63.8	64.1
COVERCAL	63.0	64.0	64.6	64.9
FP16 reference	65.3	65.3	65.3	65.3

64 selected samples reach 64.0 MMLU, exceeding Random 256 samples at 63.8 in this setup

weight와 threshold ablation의 읽는 법

full weight는 이 setup에서 가장 높았고, threshold 안정성도 특정 5-7 sigma 구간에서만 보였다

test	variant / threshold	MMLU	Wiki-PPL down	condition
weight	unweighted coverage	64.0	6.31	L3-8B, AWQ4, K128
weight	full product	64.6	6.22	same setting
threshold	5 sigma	64.4	6.24	same setting
threshold	6 sigma	64.6	6.22	main threshold
threshold	7 sigma	64.2	6.28	5-7 stable

full weight와 6 sigma result는 LLaMA-3-8B AWQ INT4 ablation의 관측이다

Table 10: missed outlier와 layer error

이 table은 LLaMA-3-8B의 Layer 14 세 channel을 의도적으로 isolate한 reconstruction-error construction이다

layer group	uncovered error	covered error	reduction	해석
Layer 14	4.44	0.22	95%	three channels activated by added samples
total	7.24	2.95	59%	same constructed comparison
condition	AWQ INT4, Random K=128	Random K=128 + activating samples	fixed-budget 비교 아님	channels 1847, 2903, 4011
boundary	Frobenius reconstruction error	n/a	n/a	downstream accuracy share가 아님

covered set은 Random K=128에 활성 sample을 더한 구성이지 같은 budget 비교가 아니다

COVERCAL의 적용 경계

coverage는 useful calibration-selection objective이지만, PTQ 품질 전체를 대체하는 단일 설명은 아니다

- candidate pool에 sample이 없으면 selector가 channel을 cover할 수 없다
- mean+6 sigma는 heuristic이며, source는 이 setup의 5-7 sigma 안정성만 보였다
- 실험은 INT4에 한정되고 INT3 이하에서의 결과는 보고하지 않는다
- greedy guarantee는 weighted coverage objective에만 적용된다
- clipping surrogate와 downstream quality의 연결은 empirical evidence다

outlier coverage는 이 PTQ calibration regime의 중요한 설명 변수다

논문의 핵심 논리

missed high-impact activation channel을 발견하고, K개 sample의 collective coverage로 PTQ calibration을 고른다

01	failure mode	unseen outlier channel이 clipping risk를 만든다
↓		
02	representation	sample을 outlier-channel set으로 표현
↓		
03	selection	weighted new coverage를 greedy로 최대화
↓		
04	integration	selected set을 AWQ/GPTQ calibration에 입력
↓		
05	evidence boundary	coverage theorem과 conditional PTQ results를 구분

COVERCAL은 calibration data를 대표 sample보다 coverage resource로 보는 관점이다