

Double DQN

Deep Reinforcement Learning with Double Q-Learning

Hado van Hasselt, Arthur Guez, David Silver (2016)

과대평가를 줄이는 선택과 평가의 분리

논문의 질문

가치 추정 오차가 있는 상황에서 max 연산은 무엇을 학습 target으로 선택하는가

- DQN은 Deep Q-Network의 약자다
- Q 값은 행동 뒤에 기대하는 할인 누적 보상의 추정치다
- 여러 추정값 중 최댓값을 고르면 우연히 크게 나온 오차가 선택되기 쉽다
- 그 값을 다시 학습 target으로 쓰면 과대평가가 이전 상태로 전파될 수 있다
- 논문은 행동 선택과 가치 평가를 나누어 이 결함을 약화한다

핵심은 네트워크 수보다 max 안에서 선택과 평가를 누가 담당하는가에 있다

Q-learning의 기본 기호

하나의 transition에서 다음 상태의 가치를 이용해 현재 추정치를 갱신한다

기호	뜻	주의할 점
S_t, A_t	현재 상태와 선택한 행동	정책이 실제로 수행한 행동
R_{t+1}, S_{t+1}	다음 보상과 다음 상태	관측한 transition의 결과
$Q(s, a)$	행동 뒤의 할인 return 기대값	즉시 보상이나 보장된 결과가 아님
γ	미래 보상의 할인율	0과 1 사이의 값
Y_t	현재 Q의 학습 target	보상과 다음 상태 추정으로 계산

이 논문의 변경점은 Y_t 를 계산하는 방법이다

DQN의 학습 구성

Double DQN도 replay와 target 복사 구조를 그대로 사용한다

- | | | |
|----|-----------------|--|
| 01 | Replay 표본 | 저장한 transition에서 학습 표본을 뽑는다 |
| ↓ | | |
| 02 | 현재 예측 | online θ 로 현재 $Q(S_t, A_t)$ 를 계산한다 |
| ↓ | | |
| 03 | 학습 target Y_t | 보상과 target $\theta_{_target}$ 의 다음 상태 Q로 계산한다 |
| ↓ | | |
| 04 | Online update | 현재 예측과 target의 오차로 θ 를 갱신한다 |

$\theta_{_target}$ 은 θ 의 주기적 복사본이며, 복사 사이에는 고정한다

max가 양의 오차를 선호하는 이유

교육용 예시: 두 행동의 참값은 모두 0이고 각 추정 오차는 독립적으로 -1 또는 +1이다

행동 A 추정	행동 B 추정	max	발생 확률
+1	+1	+1	1/4
+1	-1	+1	1/4
-1	+1	+1	1/4
-1	-1	-1	1/4

각 추정의 평균은 0, 최댓값의 평균은 $(1 + 1 + 1 - 1) / 4 = 0.5$

과대평가의 전파 경로

환경이 결정적이어도 함수 근사 오차와 부트스트래핑은 남는다

01	서로 다른 추정 오차	행동마다 Q 오차의 크기와 방향이 다르다
↓		
02	max 선택	상대적으로 크게 추정된 행동이 선택된다
↓		
03	큰 bootstrap 값	선택된 추정치가 target에 들어간다
↓		
04	이전 상태 갱신	큰 target이 앞선 Q 추정에 반영된다
↓		
05	정책 영향 가능성	상대 순위가 바뀌면 행동 선택도 달라질 수 있다

문제는 모든 행동에 같은 편향이 더해지는 경우가 아니라 상대 순위를 바꾸는 오차다

DQN target의 역할 결합

비종료 전이: $Y_DQN = R + \gamma \max_a Q(S_next, a; \theta_target)$

- | | | |
|----|-------------|---|
| 01 | Target Q 벡터 | $Q(S_next, \text{모든 행동}; \theta_target)$ 을 계산한다 |
| ↓ | | |
| 02 | 행동 선택 | argmax는 Q 값이 가장 큰 행동을 반환한다 |
| ↓ | | |
| 03 | 가치 평가 | max는 같은 Target Q 벡터의 최댓값을 반환한다 |
| ↓ | | |
| 04 | Target 완성 | 관측 보상 R과 γ 를 결합한다 |

다음 상태가 종료 상태이면 위 계산 대신 $Y_DQN = R$ 이다

Double Q-learning의 분리 원리

이번에 갱신할 추정기 A가 무작위로 정해졌다고 하자

- | | | |
|----|--------------|------------------------------|
| 01 | 추정기 A | 현재 가장 좋아 보이는 행동 a^* 를 선택한다 |
| ↓ | | |
| 02 | 선택한 행동 a^* | 행동의 정체성만 다음 단계로 전달한다 |
| ↓ | | |
| 03 | 추정기 B | 동일한 a^* 의 가치를 별도로 평가한다 |
| ↓ | | |
| 04 | 추정기 A 갱신 | B의 평가로 target을 만들고 A를 갱신한다 |

선택을 일으킨 양의 오차가 평가값으로 자동 재사용되지 않게 한다

Double DQN target

비종료 전이: $Y_Double = R + \gamma Q(S_next, a^*; \theta_target)$

- | | | |
|----|----------------------|--|
| 01 | Online Q 벡터 θ | 다음 상태에서 행동별 값을 계산한다 |
| ↓ | | |
| 02 | Online 선택 | argmax는 Online Q 값이 가장 큰 행동 a^* 를 반환한다 |
| ↓ | | |
| 03 | Target 평가 | $Q(S_next, a^*; \theta_target)$ 을 조회한다 |
| ↓ | | |
| 04 | Target 완성 | $R + \gamma Q(S_next, a^*; \theta_target)$ |

다음 상태가 종료 상태이면 위 계산 대신 $Y_Double = R$ 이다

계산 예시의 입력

교육용 가정: 비종료 다음 상태 s' 에는 left와 right 두 행동이 있다

입력	left	right	사용 목적
Online $Q(s', a; \theta)$	5	4	Double DQN의 행동 선택
Target $Q(s', a; \theta_{\text{target}})$	2	4	DQN의 max, Double DQN의 선택 행동 평가
관측 보상 R	1	공통	target의 즉시 보상 항
할인율 γ	0.9	공통	다음 상태 평가에 곱함

두 방법은 같은 숫자를 보지만 선택과 평가에 사용하는 위치가 다르다

DQN target 계산

비종료 전이에서 target 네트워크가 right를 선택하고 같은 값 4로 평가한다

01 Target 벡터 left 2, right 4



02 선택 $\text{argmax}(2, 4)$ 가 right를 반환한다



03 평가 target의 right 값은 4



04 계산 $Y_{\text{DQN}} = 1 + 0.9 \times 4 = 4.6$

DQN target은 4.6이다

Double DQN target 계산

비종료 전이에서 online은 left를 선택하고 target은 같은 left를 2로 평가한다

01 Online 벡터 left 5, right 4



02 선택 argmax는 left



03 Target 조회 선택된 left의 target 값은 2



04 계산 $Y_Double = 1 + 0.9 \times 2 = 2.8$

Double DQN target은 2.8이다

두 target의 올바른 해석

4.6과 2.8의 차이는 역할 분리의 결과이며 어느 값이 참값인지는 예시에서 주어지지 않았다

항목	DQN	Double DQN
행동 선택에 사용한 네트워크	target θ _target	online θ
선택한 행동	right	left
가치 평가에 사용한 네트워크	target θ _target	target θ _target
계산된 target	4.6	2.8
예시의 초점	선택과 평가를 결합	서로 다른 snapshot 사용

작은 target이 언제나 더 정확하다는 결론은 이 계산만으로 얻을 수 없다

변경된 부분과 유지된 부분

Double DQN은 DQN에 작은 알고리즘 변경을 적용한다

구성	DQN	Double DQN
Replay와 online 학습	사용	그대로 사용
Online network θ	학습되는 네트워크	target 식에서 행동 선택
Target network θ_{target}	target의 max 계산	선택된 행동의 평가
Target 복사	θ 를 주기적으로 복사	같은 구조 유지
핵심 변경	θ_{target} 이 선택과 평가	θ 가 선택하고 θ_{target} 이 평가

새 장치보다 기존 두 snapshot의 역할 재배치가 핵심이다

함수 근사만으로도 생기는 과대평가

논문 Figure 2는 환경의 확률적 보상 없이도 근사 오차가 max 편향을 만들 수 있음을 보인다

01	상태별 동일한 참값	각 상태에서 열 개 행동의 실제 Q 값은 같다
↓		
02	정확한 표본	표본 상태에서 관측값 자체는 정확하다
↓		
03	각 행동의 근사 함수	상태 사이에서 서로 다른 오차가 생긴다
↓		
04	행동별 max	여러 근사치 중 큰 오차를 선택한다
↓		
05	지속적 과대평가	상태 구간의 상당 부분에서 max가 참값을 넘는다

결정적 환경도 함수 근사 오차를 제거하지 않는다

Atari 2600 실험 설계

주요 비교는 DQN과 Double DQN이 같은 DQN 설정을 사용하고 target 계산만 다르게 둔다

항목	설정	해석
환경	ALE의 Atari 2600	주요 집계는 49개 게임
학습량	게임마다 2억 frame, GPU 1개	논문이 보고한 학습 조건
통제 비교	같은 DQN hyperparameter	논문이 밝힌 알고리즘 차이는 target 식
기준 점수	기존 DQN 연구의 보고값을 표의 baseline으로 사용	Table 1은 Mnih et al., Table 2는 Nair et al. 기준

집계 수치의 baseline 출처와 새 알고리즘의 비교 조건을 함께 읽어야 한다

추정값과 실제 return의 비교

논문은 학습된 Q 추정과 최종 정책이 실제로 얻은 할인 return을 따로 측정한다

측정값	계산 대상	질문
학습된 가치 추정	평가 중 방문한 상태의 greedy Q 값을 평균	미래 return을 얼마나 크게 예상하는가
실제 정책 가치	각 방문 상태에서 실제 얻은 할인 return을 평균	정책이 실제로 어느 정도 return을 얻는가
두 값의 차이	추정값에서 실제 return을 비교	과대평가가 관찰되는가
반복	독립적으로 다시 학습한 6개 seed	특정 run 하나의 우연인지 확인

높은 Q 추정만으로 좋은 정책을 증명할 수 없으므로 실제 return과 비교한다

Figure 3의 해석

DQN의 과대평가 증가와 성능 저하가 함께 나타난 사례가 있지만 모든 게임의 보편 법칙은 아니다

관찰	논문에서 확인한 내용	해석 범위
DQN 가치 추정	일부 게임에서 실제 return보다 크게 상승	max 편향이 deep RL에서도 나타남
Asterix, Wizard of Wor	과대평가 증가와 평가 점수 하락이 함께 관찰	두 변화의 연관을 지지하는 사례
Double DQN	표시된 사례에서 추정과 성능이 더 안정적	과대평가 감소와 정책 품질 개선의 연관
게임별 차이	과대평가가 항상 정책을 해치는 것은 아님	모든 실패 원인을 하나로 설명하지 않음

Figure 3은 메커니즘 근거를 제공하지만 보편적 인과 법칙을 증명하지 않는다

No-op 평가 조건

같은 초기 화면에서 시작 전에 조작 입력을 하지 않는 no-op 동작을 수행한다

조건	설정	목적
시작 변형	0회부터 30회의 no-op	초기 상태를 조금씩 변화
평가 길이	18,000 frame, emulator 기준 5분	episode 평가 구간
정책	ϵ -greedy, $\epsilon = 0.05$	작은 확률로 임의 행동
반복	게임당 100 episode 평균	episode 변동을 집계
정규화	$(\text{agent} - \text{random}) / (\text{human} - \text{random})$	0은 random, 1은 human 기준

정규화 점수의 퍼센트 표기는 승률이 아니라 random과 human 기준의 상대 위치다

No-op 평가 결과

49개 게임의 human-normalized score 집계

방법	Median	Mean	읽는 법
DQN baseline	93.5%	241.1%	Table 1이 인용한 기존 DQN 점수
Double DQN	114.7%	330.3%	논문의 Double DQN 집계
차이	+21.2%p	+89.2%p	49개 게임 집계 차이

중앙값과 평균이 모두 높지만 개별 게임마다 항상 우세하다는 뜻은 아니다

Human-start 평가

사람의 플레이 궤적에서 여러 시작 상태를 뽑아 단일 초기 상태 의존성을 줄인다

01	전문가 궤적	사람이 플레이한 상태 sequence를 준비한다
↓		
02	100개 시작점	게임마다 궤적에서 시작 상태를 표본화한다
↓		
03	에이전트 실행	시작 전 궤적을 포함해 최대 108,000 frame
↓		
04	보상 집계	표본 시작 이후에 얻은 보상만 계산한다
↓		
05	49개 게임 집계	human-normalized median과 mean을 비교한다

서로 다른 시작 상태는 정책이 한 시작 sequence에만 맞았는지 더 엄격하게 시험한다

Human-start 결과와 tuned 변형

tuned Double DQN은 target 식 외의 설정도 바꾸므로 별도 변형으로 읽어야 한다

방법	Median	Mean	비교 조건
DQN baseline	47.5%	122.0%	Table 2가 인용한 기존 DQN 점수
Double DQN	88.4%	273.1%	기본 DQN 설정과 target 식 변경
Tuned Double DQN	116.7%	475.2%	target 복사 간격과 탐색률, 상위층 bias도 조정

tuned 결과 전체를 선택과 평가의 분리 하나만의 효과로 돌릴 수 없다

논문이 지지하는 주장 범위

Double DQN은 max가 만드는 과대평가를 줄였지만 모든 강화학습 문제를 해결한 것은 아니다

지지되는 설명

Atari 실험에서 과대평가를 줄이고 aggregate score를 개선했다

온라인 선택과 target 평가를 분리한다

표시된 사례에서 과대평가와 성능 저하가 함께 나타났다

ALE 조건에서 과대평가를 줄이는 근거를 제시한다

과도한 설명

모든 게임에서 DQN보다 높다

서로 완전히 독립인 두 DQN을 학습한다

모든 DQN 불안정성의 원인이 과대평가다

과대평가를 없애고 모든 환경에 일반화가 증명됐다

논문의 강점은 좁고 검증 가능한 변경과 그 메커니즘을 함께 제시한 데 있다

Double DQN의 핵심

한 번의 target 계산에서 선택과 평가에 서로 다른 network snapshot을 사용한다

01	문제	max가 큰 추정 오차를 선호한다
↓		
02	DQN	target θ _target이 행동 선택과 가치 평가를 함께 한다
↓		
03	Double DQN	online θ 가 선택하고 target θ _target이 같은 행동을 평가한다
↓		
04	실험 결과	Atari에서 과대평가 감소와 aggregate score 개선을 관찰했다
↓		
05	적용 범위	작은 변경이지만 완전한 독립이나 보편적 우세를 보장하지 않는다

Y_DQN의 max를 선택 단계와 평가 단계로 풀어 쓰면 Double DQN의 차이가 보인다

부록: 행동 정책과 학습 target의 구분

환경에서 실제 행동을 고르는 과정과 replay 표본의 target을 계산하는 과정은 서로 다른 시점의 연산이다

과정	입력 상태	사용 목적	Double DQN에서의 역할
환경 행동 선택	현재 상태 S_t	새 transition을 수집	온라인 Q와 ϵ -greedy 정책으로 실제 행동을 정함
학습 target 계산	replay의 다음 상태 S_{t+1}	online gradient update용 Y_t 계산	online θ 가 a^* 를 고르고 target θ_target 이 평가
Target 복사	일정한 학습 간격	평가 snapshot을 갱신	online θ 의 값을 target θ_target 에 복사

target 식의 online 선택과 실제 환경 행동 선택은 서로 다른 연산이다