

Deep Reinforcement Learning that Matters: 재현 가능한 비교

Deep Reinforcement Learning that Matters

Peter Henderson, Riashat Islam, Philip Bachman, Joelle Pineau, Doina Precup, David Meger
(2018)

deep RL의 성능 비교를 재현성·불확실성 관점에서 점검한 실험 연구

논문의 역할: deep RL 결과를 검증하는 실험 연구

핵심 대상은 continuous-control policy-gradient baseline의 비교와 보고 방식이다

항목	원문 범위	강의에서 지킬 경계
질문	보고된 성능 향상이 의미 있는가	새 control algorithm 설명으로 확장하지 않음
알고리즘	TRPO, DDPG, PPO, ACKTR	이 넷의 모든 성질을 일반화하지 않음
환경	MuJoCo continuous control	field deployment 결과로 해석하지 않음
기여	variance와 reporting 절차 조사	보편적 통계 검정을 증명하지 않음

논문의 산출물은 더 신뢰할 수 있는 비교를 위한 증거와 권고안이다

한 개의 learning curve만으로는 비교 조건이 부족하다


알고리즘 이름 외의 선택이 run과 최종 성능 주장을 함께 바꾼다



성능은 algorithm 하나의 속성보다, 명시된 실험 조건 아래의 관측값으로 읽어야 한다

variance의 두 출처

논문은 내부 randomness와 외부 실험 선택을 함께 점검한다



주요 실험의 공통 프로토콜

조건을 읽지 않으면 표와 curve의 숫자를 공정하게 비교할 수 없다

요소	원문 설정	의미
baseline	TRPO·DDPG·PPO·ACKTR	공개 구현을 쓰는 policy-gradient 비교
환경	Hopper-v1·HalfCheetah-v1	불안정성과 dynamics가 다른 MuJoCo task
반복	평가마다 preset seed 5개	같은 seed set으로 평균과 standard error
architecture 표	2M samples 뒤 마지막 100 trajectories	final average return의 조건

원문 숫자는 ‘5 seed, 특정 환경·구현·학습량’이라는 조건을 떼어낼 수 없다

network 구조와 activation은 baseline 성능의 일부다


원문은 policy/value MLP의 구조와 activation을 하나씩 바꾸어 영향을 측정했다

바꾼 요소	원문 후보	결과를 읽는 법
MLP 구조	(64,64), (100,50,25), (400,300)	알고리즘·환경마다 효과가 다름
activation	tanh, ReLU, Leaky ReLU	한 activation의 보편적 우위로 말할 수 없음
policy/value	policy와 value 또는 Q를 각각 변화	변수 사이 상호작용 가능
측정	5 trials, 2M samples	Table 1-2의 final return $\pm$ SE

baseline 설정을 생략하면, method 차이와 configuration 차이를 분리하기 어렵다


reward scale은 학습 신호의 크기를 바꾼다

DDPG에서는 환경 reward에 scalar를 곱한 값을 학습에 사용할 수 있다



seed만 바꾼 10개 run도 다른 평균 curve를 만들 수 있다

Figure 5는 동일 TRPO 설정을 두 개의 다섯-seed 평균으로 나눈 실험이다



두 group은 경쟁 algorithm이 아니라, 동일 configuration의 seed grouping이다

구성 예시: top run 선택이 평균을 어떻게 바꾸는가

아래 숫자는 원문 데이터가 아닌, selective reporting을 설명하기 위한 산술 예시다

보고 방식	사용한 constructed returns	계산	표시값
모든 5 runs	70, 80, 90, 100, 110	$450 \div 5$	mean 90
상위 2 runs	100, 110	$210 \div 2$	mean 105
차이	같은 5개 run에서 선택만 변경	$(105 - 90) \div 90$	16.7% 증가

선택 평균 상승은 method 향상의 증거보다, 보고 규칙 변화의 신호일 수 있다

benchmark environment가 바꾸는 algorithm 순위

Table 3은 각 환경에서의 bootstrap mean과 95% bound를 따로 보고한다

환경	DDPG	TRPO	읽을 때의 경계
HalfCheetah-v1	5037 (3664, 6574)	1254.5 (999, 1464)	이 표의 seed·구현·평가 조건
Hopper-v1	1632 (607, 2370)	2965 (2854, 3076)	다른 dynamics에서 결과가 달라짐
Swimmer-v1	31 (21, 46)	214 (141, 287)	return이 행동 품질을 완전히 뜻하지 않음

한 환경에서의 우세를 모든 benchmark 또는 실제 응용의 우세로 확대할 수 없다

같은 algorithm, 다른 codebase의 비교 조건


원문은 TRPO와 DDPG의 여러 널리 쓰인 implementation을 같은 설정으로 대조했다

01	algorithm label	TRPO 또는 DDPG
↓		
02	implementation	original·Baselines·rllab 등
↓		
03	숨은 선택	optimizer·baseline·network
↓		
04	observed return	같은 설정에서도 차이 발생
↓		
05	보고	code와 구현 detail 공개

baseline 재현은 algorithm name 매칭보다 implementation 조건의 공개를 요구한다

return을 보고하기 전, 평가 관점을 정해야 한다

원문은 online-learning return과 target-policy offline evaluation을 구분한다



원문이 탐색한 uncertainty 분석 절차

여러 seed run의 return을 요약한 뒤, bootstrap과 검정을 보조 근거로 사용한다

01 run-level returns seed별 평가 return을 보존



02 bootstrap 복원 추출 → mean·95% bound



03 power check 1.25배 예시의 유의한 비율



04 tests t·KS·percent difference



05 qualified report 평균과 uncertainty 제시

원문은 이 도구들을 제안적 출발점으로 다루며, RL의 보편 정답으로 확정하지 않는다

source example: 작은 평균 차이의 해석


Walker2d-v1에서 ACKTR과 DDPG를 비교한 원문의 수치다

분석	원문 수치	원문의 해석
two-sample t	$t = 1.03, p = 0.334$	ACKTR의 작은 우세는 significant하지 않음
KS	$KS = 0.40, p = 0.697$	분포 차이의 근거가 약함
bootstrap difference	44.47% (-80.62%, 111.72%)	95% interval이 0을 가로지름

평균이 조금 높다는 관측과, 더 나은 method라는 결론은 다른 주장이다

재현 가능한 비교의 기록

독자가 같은 조건을 재구성하고 결과의 범위를 판단할 수 있어야 한다



재현성은 code 공개 하나가 아니라, 비교를 규정한 조건과 불확실성을 함께 남기는 일이다

논문 결과의 적용 범위

권고안은 중요한 출발점이지만, source가 주장하지 않은 보편 법칙으로 넓히면 안 된다

경계	원문 근거	해석
algorithm·task	policy-gradient와 MuJoCo continuous control	모든 RL family의 실증 증명은 아님
trial 수	대부분 평가 5 trials, seed 실험 10	보편적으로 충분한 N을 제시하지 않음
통계	여러 test와 bootstrap을 탐색	RL에 맞는 최선의 test는 추가 연구 필요
현실 적용	benchmark는 real-world proxy	deployment robustness를 보장하지 않음

좋은 보고는 더 강한 결론을 꾸미는 일이 아니라, 결론이 성립하는 조건을 남기는 일이다

결론: 성능 주장은 조건과 불확실성을 포함해야 한다

이 논문은 ‘어떤 algorithm이 이겼는가’보다 ‘그 비교를 믿을 근거가 충분한가’를 묻는다

- seed·environment의 intrinsic variance와 hyperparameter·codebase의 extrinsic 선택을 구분한다
- 환경별 결과, implementation, 평균 밖의 uncertainty를 함께 제시해야 비교의 뜻이 분명해진다
- bootstrap·power·검정은 유용한 출발점이지만 RL에 맞는 보편 해법으로 단정하지 않는다
- 재현 가능한 baseline과 공개된 설정·코드·평가 절차가 누적 가능한 연구의 기반이 된다