

Dueling Network Architecture

Dueling Network Architectures for Deep Reinforcement Learning

Ziyu Wang, Tom Schaul, Matteo Hessel, Hado van Hasselt, Marc Lanctot, Nando de Freitas
(2016)

상태에 공통인 가치와 행동별 차이를 나누어 Q 벡터를 표현하는 방법

Q network가 예측하는 값

Q 값은 지금의 보상이 아니라 이후 정책까지 포함한 기대 할인 return이다

기호	뜻	읽는 질문
s	현재 상태	에이전트가 무엇을 보고 있는가
a	현재 선택할 행동	이 상태에서 무엇을 할 것인가
$Q^{\pi}(s,a)$	a 이후 π 를 따를 기대 할인 return	이 행동의 장기적 가치는 얼마인가
Q 벡터	상태 s 에서 가능한 모든 행동의 Q 값	어떤 행동의 값이 가장 큰가

Dueling 구조도 최종적으로는 행동마다 하나의 Q 값을 출력한다

정책의 가치와 advantage

정의상 advantage는 한 행동의 Q 값이 정책 평균에서 얼마나 벗어나는지 나타낸다

정책량	정의	의미
$V^{\pi}(s)$	π 가 고르는 행동에 대한 Q^{π} 의 기댓값	상태 s에서 정책 전체의 평균적 가치
$A^{\pi}(s,a)$	$Q^{\pi}(s,a) - V^{\pi}(s)$	행동 a가 정책 가치보다 높은지 낮은지
기댓값 성질	π 에 따른 A^{π} 의 기댓값은 0	양수와 음수의 편차가 정책 평균에서 상쇄

정책량의 정의와 network stream의 출력 의미를 먼저 구분해야 한다

일반적인 Q network

하나의 feature representation에서 행동별 Q 값을 직접 출력한다

- | | | |
|----|------------|-----------------------------------|
| 01 | 상태 입력 | Atari에서는 여러 frame을 묶은 상태를 받는다 |
| ↓ | | |
| 02 | 공통 feature | convolution layer가 상태 표현을 만든다 |
| ↓ | | |
| 03 | 단일 상위 경로 | 한 fully connected 경로가 행동별 값을 계산한다 |
| ↓ | | |
| 04 | Q 벡터 | 각 이산 행동에 하나의 Q 값을 출력한다 |

기존 구조는 상태 공통 성분과 행동별 차이를 명시적으로 나누지 않는다

비슷한 행동이 많은 상태


행동 선택이 거의 영향을 주지 않는 상태와 즉시 구별해야 하는 상태가 함께 존재한다

상태	행동 간 차이	필요한 표현
충돌 위험이 멀리 있음	여러 조향 행동의 단기 결과가 비슷할 수 있음	상태 전반의 공통 가치
장애물이 바로 앞에 있음	조향 선택이 결과를 크게 바꿈	행동별 상대 차이
논문의 가설	비슷한 행동이 많을수록 공통 성분을 공유할 여지가 큼	공통 성분과 행동 차이의 분리

Enduro 사례는 동기를 설명하는 해석 자료이며 보편적 인과 증명이 아니다

Dueling network의 분기와 결합

공통 feature 뒤에서 scalar stream과 행동 수 크기의 vector stream이 갈라진다



Architecture와 학습 알고리즘의 구분


Dueling, Double DQN, prioritized replay는 서로 다른 부분을 바꾼다

방법	바꾸는 대상	Dueling과의 관계
Dueling	Q 벡터의 network 표현	공통 성분과 행동별 차이를 분리
DQN	Q-learning target과 network 학습	Dueling 출력을 학습할 수 있음
Double DQN	다음 행동의 선택과 평가 역할	논문의 Atari 실험에서 함께 사용
Prioritized replay	replay 표본의 추출 확률	추가로 결합할 수 있으나 효과가 상호작용

Dueling은 target 식이나 replay sampling을 대체하지 않는다

단순 합산 Eq. (7)

정의에서 출발하면 $Q(s,a) = V(s) + A(s,a)$ 라는 결합이 자연스럽게 보인다



Eq. (7)의 non-identifiability

공통 offset을 두 stream 사이에서 옮겨도 최종 Q 벡터는 그대로다

교육용 설정	V	raw A	$Q = V + A$
첫 표현	10	[3, 0, -1]	[13, 10, 9]
공통 offset c	+4	각 원소에서 4를 뺀	변화 없음
둘째 표현	14	[-1, -4, -5]	[13, 10, 9]
관찰 가능한 값	서로 다름	서로 다름	완전히 같음

Q supervision만으로는 공통 offset이 V와 raw A 중 어디에 속하는지 식별할 수 없다

Max-centered 대안 Eq. (8)


가장 큰 raw advantage를 빼서 greedy 행동의 centered advantage를 0으로 만든다

항목	Eq. (8)의 처리	결과
기준값	모든 raw A 중 최댓값	greedy 행동을 기준으로 삼음
중심화	각 raw A에서 최댓값을 뺌	greedy 행동의 centered A가 0
Q 결합	V에 centered A를 더함	greedy 행동에서는 Q와 V가 같음
논문의 선택	가능한 제약으로 제시	보고된 실험은 Eq. (9)를 사용

Eq. (8)은 모호성을 제한하지만 논문의 최종 실험 aggregation은 Eq. (9)다

Mean-centered aggregation Eq. (9)

raw A의 평균을 빼서 행동별 상대 차이만 남긴 뒤 scalar V와 결합한다



Eq. (9) 수치 계산

교육용 예시에서 raw A를 중심화하고 최종 Q를 직접 계산한다

계산 단계	값	확인
Stream 출력	$V_{\text{raw}} = 10, A_{\text{raw}} = [5, 2, 2]$	세 행동은 left, straight, right
A 평균	$(5 + 2 + 2) / 3 = 3$	공통 offset 3
Centered A	$[5, 2, 2] - 3 = [2, -1, -1]$	합은 0
최종 Q	$10 + [2, -1, -1] = [12, 9, 9]$	Q 평균은 10
행동 선택	$\text{argmax } Q = \text{left}$	raw A의 순위와 같음

Eq. (9)이 보존하는 것

Mean centering은 하나의 표현 규칙을 정하지만 stream에 참된 정책 의미를 감독하지 않는다

성질	보존 또는 성립	보장되지 않는 해석
행동 간 차이	$Q(a1) - Q(a2)$ 는 raw A의 차이와 같음	행동별 Q 값이 서로 독립이라는 뜻
행동 순위	$\text{argmax } Q$ 와 argmax raw A 가 같음	A stream만으로 target 값을 계산한다는 뜻
평균	행동에 대한 Q의 단순 평균은 V scalar	V가 모든 정책의 V^{π} 라는 뜻
표현 제약	centered A의 합이 0	raw A의 offset이 별도 정답으로 정해졌다는 뜻

Network stream 이름과 참된 V^{π} , A^{π} 의 의미 사이에는 해석 경계가 남는다

기존 Q-learning 방식으로 학습

별도의 V label이나 A label 없이 aggregated Q의 TD error가 두 stream으로 역전파된다

01	Replay 표본	상태, 행동, 보상, 다음 상태를 꺼낸다
↓		
02	학습 target	DQN이나 DDQN 방식으로 bootstrap 값을 만든다
↓		
03	Aggregated Q	선택한 행동의 최종 Q 값을 조회한다
↓		
04	TD error	target과 Q의 차이를 계산한다
↓		
05	공동 역전파	공통 feature와 V, A stream을 함께 갱신한다

Dueling은 Q loss가 흐르는 내부 표현을 바꾸며 별도 학습 알고리즘을 추가하지 않는다

Corridor 실험의 통제 조건

No-op 행동을 추가해 비슷한 행동 수만 바꾸고 policy evaluation error를 비교한다

01	세 corridor	수직 두 구간 10 state와 수평 50 state
↓		
02	기본 행동 5개	상하좌우 이동과 no action을 둔다
↓		
03	행동 수 변형	추가 no-op으로 5, 10, 20개를 만든다
↓		
04	고정 정책 평가	epsilon 0.001의 정책을 TD로 평가한다
↓		
05	오차 측정	학습 Q와 정확한 Q^{π} 의 squared error 합

이 실험은 exploration 전체가 아니라 비슷한 행동 수와 가치 추정의 관계를 분리한다

Corridor 결과가 지지하는 범위

행동 수가 늘어난 조건에서 dueling의 squared-error curve가 더 낮아졌다

행동 수	논문의 관찰	해석 범위
5	두 architecture의 수렴 속도가 비슷함	기본 조건에서는 뚜렷한 차이가 작음
10	Dueling curve가 single-stream보다 낮아짐	추가 no-op에서 공통 성분 공유가 유리
20	Dueling의 상대적 차이가 더 커짐	통제된 corridor에서 가설을 더 강하게 지지
범위 밖	연속 행동이나 다른 task는 시험하지 않음	행동 수가 크면 항상 우세하다는 정리 아님

Figure 3은 설계된 환경의 메커니즘 근거이며 모든 큰 action space에 대한 보장은 아니다

Atari 실험 설계

57개 게임에서 comparable-capacity single stream과 dueling DDQN을 비교한다

항목	설정	읽는 법
환경	Arcade Learning Environment 57개 게임	raw pixel과 reward로 학습
공통 하위 구조	DQN과 같은 세 convolution layer	저수준 feature 조건을 맞춤
Dueling 상위 구조	512-unit fully connected stream 두 개	Eq. (9)으로 Q 벡터를 생성
Single Clip	유사한 parameter 수로 다시 학습한 baseline	architecture 비교의 통제를 강화
학습 알고리즘	Atari dueling model은 DDQN 사용	representation과 target 변경을 결합

두 Atari 평가 조건

30 no-ops와 Human Starts는 서로 다른 시작 상태 다양성을 시험한다

평가	시작 상태	점수 해석
30 no-ops	시작 전에 0회부터 30회의 no-op	비교적 제한된 시작 변형
Human Starts	전문가 trajectory에서 게임당 100개 상태 표본	사람이 도달한 다양한 상태에서 시작
Human Starts 보상	표본 시작 이후 보상만 집계	시작 전 전문가 보상은 제외
실행 상한	표본 상태에서 시작한 평가 episode를 최대 108,000 frame 실행	평가 길이 조건을 함께 읽음
표 수치	Human-normalized score의 mean과 median	확률이나 승률이 아님

Table 1의 aggregate 결과

57개 게임의 human-normalized score이며 각 게임에서 항상 우세했다는 뜻은 아니다

Model	No-op mean	No-op median	HS mean	HS median
Single Clip	341.2%	132.6%	302.8%	114.1%
Duel Clip	373.1%	151.5%	343.8%	117.1%
Duel - Single	+31.9%p	+18.9%p	+41.0%p	+3.0%p

Duel Clip의 aggregate score는 높지만 개별 게임 우세를 보장하지 않는다

결합 실험과 해석 경계

Prior. Duel Clip과 saliency map은 각각 호환성과 해석을 지지하지만 단일 원인 증명은 아니다

근거	지지하는 설명	넘어서는 설명
Prior. Duel Clip	Prioritized replay와 dueling을 함께 사용할 수 있음	결합 성능 향상을 dueling 하나의 효과로 귀속
Gradient clipping	학습 설정의 일부로 함께 적용	Duel Clip이 stream 분리만 뜻한다고 단정
9-game retuning	결합 구성에서 hyperparameter 상호작용을 고려	모든 Atari 게임에 독립적으로 같은 설정을 최적화
Saliency map	학습된 model이 본 입력 영역을 해석	Stream의 참된 인과 의미를 증명

결합 결과는 방법 간 호환성을 보여 주지만 architecture 효과의 단일 변수 ablation이 아니다

Dueling architecture의 핵심

Q 벡터의 공통 성분과 행동별 차이를 분리하고 식별 가능한 규칙으로 다시 결합한다

- | | | |
|----|-----------|-------------------------------------|
| 01 | 표현 문제 | 비슷한 행동도 Q 값을 각각 출력해야 한다 |
| ↓ | | |
| 02 | Stream 분리 | 공통 scalar와 행동별 raw vector를 만든다 |
| ↓ | | |
| 03 | Eq. (9) | raw A의 평균을 빼고 V와 합쳐 Q를 만든다 |
| ↓ | | |
| 04 | 학습 방식 | 기존 DQN이나 DDQN target으로 Q를 학습한다 |
| ↓ | | |
| 05 | 실험 범위 | Corridor와 Atari에서 가설을 지지하는 결과를 보고한다 |

Dueling은 Q-learning의 출력 형식을 유지하면서 network 내부 representation을 재구성한다

부록 : Network parameter 표기

논문의 θ , α , β 는 공유 부분과 두 stream의 parameter 집합을 구분한다

기호	담당 부분	출력과의 관계
θ	공통 convolutional feature	V와 A stream이 함께 사용
β	Value stream의 parameter	상태마다 scalar V를 출력
α	Advantage stream의 parameter	행동마다 raw A를 출력
전체 Q	θ , α , β 를 모두 사용	Eq. (9) aggregation 뒤 TD loss로 학습

Parameter 집합은 나뉘지만 shared feature와 Q loss 때문에 두 stream은 공동으로 학습된다

부록 : Dueling Double DQN의 한 update

Representation과 target 계산을 한 학습 단계 안에서 각각 구분한다

단계	Dueling이 담당	Double DQN이 담당
현재 상태 Q	V와 centered A를 합쳐 Q 벡터 생성	현재 행동의 Q를 그대로 사용
다음 행동 선택	Online network 내부에서 같은 aggregation 수행	Online Q가 가장 큰 행동을 선택
다음 행동 평가	Target network도 dueling Q 벡터 생성	Target Q가 선택된 행동의 값을 평가
Loss와 update	Aggregated Q의 gradient가 두 stream에 전달	분리한 target으로 online parameter를 갱신

Dueling은 Q 표현이고 Double DQN은 두 snapshot의 target 역할 분담이다