

차량의 작업 순서와 오프로딩을 함께 결정하기

Hierarchical Reinforcement Learning Empowered Task Offloading in V2I Networks

Xinyu You, Haojie Yan, Yuedong Xu, Lifeng Wang, Liangui Dai (2024)

DHVO: 그래프 주의집중과 계층형 Q-learning | 철회된 2024년 사전공개 원고의 교육적 분석

원고의 상태와 이 자료의 읽기 범위

분석 대상은 2024년 v1이며, arXiv는 2025년 12월 철회를 공지했다

구분	확인된 사실	학습할 때의 의미
분석 원문	arXiv:2405.11352v1 · 2024-05-18	해당 버전의 설계·실험을 설명
현재 상태	2025-12-04 철회	현재 출판된 검증 기술로 소개하지 않음
공개 사유	후속 개발·투고를 진행하지 않음	이유를 오류·부정행위로 확대하지 않음
활용 범위	DAG 표현 + 혼합 행동 설계 사례	결과의 한계와 표기 불일치도 함께 읽기

철회 상태를 숨기지 않고, 무엇을 제안했는지와 무엇이 확인되지 않았는지를 구분한다

문제: 차량은 이동하고, 작업은 선행 결과를 기다린다


차량-인프라 통신(V2I)에서 계산 속도뿐 아니라 연결 범위, 작업 순서, 비용을 함께 고려한다

- 차량 단말(UE)은 속도가 변하면서 여러 도로변 기지국(RSU)의 통신 범위를 지난다
- 한 응용프로그램은 방향성 비순환 그래프(DAG)로 표현한 여러 작업으로 나뉜다
- 후속 작업은 바로 앞의 모든 선행 작업이 완료되어야 시작할 수 있다
- 목적값 TESC는 작업 시간·단말 에너지·서비스 요금을 가중합한 비용이다

어떤 작업을 먼저, 어디서, 어느 자원 수준으로 처리할지를 함께 정한다

무선 RSU 관계와 task DAG 관계는 다르다

RSU coverage는 통신 가능성을, DAG edge는 실행 순서를 뜻한다



local과 edge 선택은 서로 다른 cost 항을 만든다


edge path는 upload, edge execution, download에 coverage 이탈 시 migration delay·charge가 더해진다

path	time / energy	charge 또는 constraint
local $k=0$	$t_{\text{local}}=C/f$; $e_{\text{local}}=\kappa C f^2$	local service charge 없음
edge $k=1$	upload + edge + download + migration	UE energy는 uplink만 계산
통신 범위	시작 위치 + 처리 중 이동거리가 범위를 넘는가	넘으면 전파 지연·이관 요금 발생
precedence	$T_{\text{start}}(i) \geq \max \text{predecessor end}$	ready task만 실행 가능

edge가 항상 빠르거나 싼 것은 아니다. coverage 이탈은 시간과 service cost를 바꾼다

목적은 비용의 합을 줄이되 실행 제약을 지키는 것

시간·단말 에너지·서비스 요금의 가중합이 TESC다. 선행 작업 완료와 자원 상한도 만족해야 한다



GAT에는 작업 특성·차량 상태·DAG를 함께 넣는다

그래프 주의집중 신경망(GAT)은 인접 관계를 이용해 작업마다 새로운 특성 벡터를 만든다

입력 또는 단계	담는 정보	역할
작업 특성	입력량·출력량·연산량·완료 여부	무엇을 처리하며 어떤 작업이 남았는가
차량 상태	좌표·남은 작업 수·최근 5초 속도	작업 특성에 함께 붙이는 환경 정보
인접 행렬	작업 DAG의 연결 관계	어느 이웃 정보를 모을 것인가
GAT 출력	2개 head × 6개 = 작업당 12개 특성	전체 작업 벡터를 구성하고 길이를 맞춤

작업·환경 정보와 인접 행렬은 공동 입력이다. 서로를 순차 변환하는 단계가 아니다

attention coefficient가 뜻하는 것과 뜻하지 않는 것


GAT는 node i 의 neighbor j feature가 i encoding에 얼마나 반영될지를 learned coefficient로 정한다

source operation	교육적 해석	피해야 할 해석
$e_{ij}=a(W h_i, W h_j)$	pairwise feature relevance score	DAG scheduling priority 자체
softmax over neighbors	i 주변의 normalized attention	network bandwidth allocation
multi-head concatenate	여러 relation view를 feature로 결합	여러 task를 동시에 실행
one GAT layer	source의 small-DAG design choice	모든 graph depth를 본다는 보장

attention은 task 관계를 state에 넣지만 precedence constraint를 대체하지 않는다

한 action은 세 층으로 정해진다

ready task를 고른 뒤 local 또는 edge를 정하고, 그 branch에만 맞는 continuous parameter를 선택한다



PNAF는 이산 선택별로 연속 행동의 Q를 구성한다

Parameterized Normalized Advantage Function: 값 V와 연속 행동의 이득 A를 합쳐 Q를 만든다

신경망의 출력·계산	의미	결합 관계
$V(s, a_d)$	이산 행동 a_d =(작업, 실행 위치)의 값	연속 행동이 중심일 때 $Q=V$
연속 중심 μ , 하삼각 L	해당 분기의 연속 행동과 곡률을 예측	V 와 병렬 출력; $P=L L^T$
$A=-\frac{1}{2}(a_c-\mu)^TP(a_c-\mu)$	중심에서 벗어나면 줄어드는 이득	P 가 양의 정부호이면 $A\leq 0$
$Q=V+A$	현재 후보 연속 행동까지 포함한 평가	각 분기에 맞는 f 또는 p 만 사용

중심 μ 에서 $A=0$ 이다. 학습한 Q의 최대점이지 실세계 최적성 보장은 아니다.

계산 예시: 연속 행동이 중심에서 벗어나면 Q가 줄어든다

한 유효 분기에서 $V=2$, $\mu =0.6$, $P=4$ 로 가정한다. 원문 측정값이 아닌 1차원 교육 예시다

연속 후보 a_c	차이 $a_c-\mu$	$A=-\frac{1}{2}\times 4\times (\text{차이})^2$	$Q=2+A$
0.2	-0.4	-0.32	1.68
0.6	0	0	2.00
0.9	+0.3	-0.18	1.82

이 분기의 Q는 0.6에서 최대다. 다른 분기나 실제 비용의 최적성을 뜻하지 않는다.

순서 예시: 선행 작업 A가 끝나야 B를 선택할 수 있다

가중치는 각각 1/3, 성분은 무차원 교육용 값이다. 원문 실험값이나 최적 정책의 재현이 아니다

단계	유효한 행동	가정한 비용 성분	재계산
1	A만 준비됨; 엿지 $k=1$, $p=0.5$	시간 .6, 에너지 .3, 요금 .9	합/3 = .60
2	A 완료 $\rightarrow$ B가 준비됨	1단계에서 B는 선택 불가	선행 제약 충족
3	B를 단말에서 $k=0$, $f=0.8$	시간 .8, 에너지 .6, 요금 0	합/3 $\approx$.47
분기	엿지는 p , 단말은 f 만 사용	관련 없는 연속 변수는 제외	공통 이산 선택 + 분기별 자원

준비된 작업 $\rightarrow$ 실행 위치 $\rightarrow$ 그 위치의 자원 변수 순으로 선택을 해석한다

실행 결과의 음수 비용을 replay에 저장해 학습한다


선택 작업의 TESC가 작을수록 보상은 커진다. 할인된 보상으로 Q를 학습한다

01	관찰	GAT 상태 표현
↓		
02	선택	y, k, f 또는 p
↓		
03	실행	작업 처리
↓		
04	보상	$r = -\text{작업 TESC}$
↓		
05	replay 갱신	목표 V' · 제공오차

음수 TESC의 할인 합($\gamma = .99$)은 비할인 비용 합과 정확히 같지 않다.

최근 속도는 통신 범위 이탈의 비용을 학습하는 입력이다

시작 위치와 처리 중 이동거리가 범위를 넘으면 작업 이관의 지연과 요금이 추가된다



학습 절차와 원문의 표기 불일치를 구분하자

본문은 목표값과 Q 의 제곱오차 최소화를 설명한다. 인쇄된 갱신식을 그대로 실행 코드로 옮기면 안 된다

항목	원문 근거	읽을 때 주의
경험·목표	$(s,a,r,s') \rightarrow z=r+\gamma \max V'$	Algorithm 1의 θ_p 에는 목표 prime 누락
손실·학습	제곱오차 L ; 본문은 gradient descent	식 40-41은 $+\nabla L$ 로 인쇄되어 불일치
목표 GAT	$\theta_{g'} \leftarrow \theta_g$	온라인 값을 복사
목표 PNAF	$\theta_{p'} \leftarrow \tau \theta_p + (1-\tau) \theta_{p'}$	복사가 아니라 soft update

학습 의도와 표기 불일치를 분리한다. 인쇄식만으로 실행 구현을 확정하지 않는다.

Table II: simulation 환경을 먼저 고정한다

아래 수치가 고정 또는 변화될 때에만 이후 TESC plots를 해석할 수 있다

category	source setting	value
road	RSU coverage; slot	200 m; 1 s
application	tasks; input/output	8- 12; 2.5-3.5 MByte
compute	cycles; local / edge peak	800-1200 Mcycles; 10^8 / 10^9 cycles/s
radio	bandwidth; peak power; distance	2 MHz; 200 mW; 100 m
cost	beta1, beta2, beta3	.33, .33, .33

결과는 작업 크기·통신·요금·범위·가중치라는 실험 조건에 묶여 있다

speed input과 neural-network 조건

실험은 real-world speed data를 input으로 쓰지만, V2I system과 workload는 simulation으로 구성한다

item	source condition	boundary
speed trajectories	CPIPC data; four tailored 100 s traces	7일간 초 단위 수집
GAT	1층; 2 heads $\times$ 6개 특성	작업당 12개; 길이 맞춤
PNAF network	one hidden layer; 128 neurons; ReLU	Adam; lr=.01
training	gamma=.99; soft update=.1	max 20 episodes in Table III
platform	PyTorch / Python 3.5; Ubuntu server	not a vehicle deployment

실제 속도 이력을 입력했어도 전체 비용 결과는 시뮬레이션이다

비교 대상은 무엇을 고정하거나 단순화하는가

DHVO의 비교는 다섯 policy family가 같은 simulation 조건에서 내는 TESC를 보는 방식이다

method	source rule	비교 기준
ALE	all local at peak local CPU	offloading 없는 기준
AO	all edge at peak transmit power	always offload 기준
GOE	30 km/h constant-speed return prediction	greedy edge rule
DQN10	10 equally spaced continuous values + GAT DQN	finite discretization
DHVO	GAT + PNAF hierarchical actions	proposed method

비교 우위는 이 네 기준 정책과 해당 실험 조건에 한정된다

convergence 수치는 두 실험 조건을 구분해야 한다

별도 convergence setup과 parameter-sweep comparison은 training episodes와 목적이 다르다

- convergence subsection: buffer transition 500개 초과 후 training, batch 256
- source는 DHVO가 해당 setup에서 14 episode 안에 converge했다고 보고한다
- reported batch training time는 1.58 s, inference는 .0018 s다
- later parameter comparisons: DQN10과 DHVO를 40 episodes train하고 50 individual tests 평균

14회 수렴 관찰과 40회 학습 비교는 서로 다른 실험 절차다

Figs. 8- 11 : 어떤 parameter가 바뀔 때의 TESC인가

plot의 공통 결론보다, 바꾼 variable과 비교 범위를 먼저 읽는다

figure	varied parameter	source interpretation
Fig. 8	RSU coverage	ALE는 local-only라 constant; other costs decrease
Fig. 9	bandwidth	below 2.25 MHz에서는 ALE가 AO보다 낮다고 보고
Fig. 10	cycles; input/output size	cycles는 local, data size는 edge 영향이 큼
Fig. 11	compute price; migration price	migration price가 AO/GOE에 더 큰 영향
all	Table II defaults except varied	simulation trend, deployment guarantee 아님

엣지의 이점은 대역폭·통신 범위·이관 요금에 따라 달라진다

정책의 선택과 비용 성분으로 결과를 해석한다

action count와 TESC composition은 저자 해석을 보조하지만 각각 동일한 evidence type은 아니다

evidence	reported condition	safe reading
Fig. 12	200 applications, each 8- 12 tasks	DHVO local/ edge balance; migration count 비교
Fig. 13	delay, energy, cost distribution	ALE energy; AO/GOE migration charge 해석
Fig. 14	small fading complex Gaussian	curve is less smooth but learning observed
mechanism claim	last-five-second speed feature	source explanation, general forecast proof 아님

저자는 단말·엣지의 혼합 선택이 이관을 줄였다고 해석한다. 근거는 시뮬레이션이다

구성요소 제거 실험: DHVO의 정규화 비용이 가장 낮다

Fig. 15의 세로축은 Normalized TESC다. 성능 점수가 아니라 비용이므로 낮을수록 좋다

방법	바꾼 구성	확인된 해석
DHVO	GAT + PNAF	그림에서 가장 낮은 비용; 기준 막대 1.0
PNAF	GAT 없이 PNAF만 사용	그래프 특성 추출의 기여 비교
GDQN2/5/10	GAT + 연속 구간의 이산화 DQN	PNAF와 이산화 방법 비교
학습 예산	모두 같은 수의 episode	저자는 5/10의 미수렴이 영향을 줬다고 설명

두 구성요소의 기여는 확인되지만, 이산화 구간을 늘리면 항상 나쁘다는 뜻은 아니다

무엇을 이 결과에서 결론내릴 수 없는가

DHVO는 source의 V2I simulator에서 TESC를 줄이는 정책이며, 모든 road deployment를 해결했다는 증거는 아니다

- 원문 system model은 한 vehicle UE와 한 application DAG를 중심으로 둔다
- edge server는 abundant resource와 fixed frequency를 가정한다
- 실제 입력은 속도 이력이다. 작업·통신·요금·RSU는 모의 환경이다
- GAT one-layer and task count assumptions은 source design 범위다
- 철회된 원고다. 식에 불일치가 있고 최적성·현장 배포는 검증되지 않았다

속도 이력 기반 시뮬레이션의 가능성이지 실제 도로에서의 성능 보장은 아니다

DHVO의 설계를 한 흐름으로 정리하면

DAG와 이동 상태를 표현하고, 작업·실행 위치·자원을 골라 실행한 결과로 Q를 학습한다

01 V2I + DAG 위치·속도·준비 작업



02 GAT 이웃 정보로 표현



03 PNAF y, k, f 또는 p



04 환경 시간·에너지·요금



05 replay 음수 비용으로 학습

그래프 표현과 분기별 Q 구성을 배우되, 철회 상태와 재현 한계도 함께 기억한다