

DRL 실험의 random seed: 몇 번이 아니라 어떻게 설계할까


How Many Random Seeds? Statistical Power Analysis in Deep Reinforcement Learning Experiments

Cédric Colas, Olivier Sigaud, Pierre-Yves Oudeyer (2018)

효과크기·변동성·오류 위험을 함께 정해 비교 실험의 N을 계획하는 2018년 tutorial


5개 seed의 그럴듯한 그림이 왜 위험한가

학습곡선의 평균과 band는 출발점일 뿐, 두 알고리즘의 차이 검정 그 자체가 아니다



한 seed 실행은 평균이 아니라 확률변수의 한 관측이다

같은 설정에서도 seed·초기 상태·환경 확률성 때문에 실행 성능이 달라질 수 있다



N이 커지면 평균·SD 추정은 안정하지만, N은 효과와 오류 목표에 따라 정한다

비교 전에 무엇을 주장할지: 양측과 단측

대칭적인 차이 질문과 방향을 사전에 가진 질문은 서로 다른 가설 계약이다

질문	귀무가설 H_0	대립가설 H_a
양측	$\mu_{\text{diff}} = 0$	$\mu_{\text{diff}} \neq 0$
단측	$\mu_{\text{diff}} \leq 0$	$\mu_{\text{diff}} > 0$
p-value	H_0 아래의 극단성	H_0 가 참일 확률은 아님

단측은 Algo 1이 더 낫다는 방향을 관측 전부터 정당화할 수 있을 때만 원문이 제시한다

두 오류와 power: 같은 threshold의 두 위험

검정은 H_0 또는 H_a 를 결정하지만, 실제 상태와 판단은 엇갈릴 수 있다

판단 / 실제	H_0 가 참	H_a 가 참
H_0 를 유지	true negative: $1-\alpha$	false negative: β
H_0 를 기각	false positive: α	true positive: $1-\beta$
power	—	$1-\beta$: 참 차이를 잡을 확률

α 를 낮추면 보수적이 되지만, N 을 늘리지 않으면 β 가 커질 수 있다

여러 비교를 하면 α 하나로 끝나지 않는다

원문은 NE개의 비교에서 familywise false positive 위험을 따로 다룬다

- | | | |
|----|--------------|---|
| 01 | 비교 family 정의 | 어떤 알고리즘·환경 대비를 함께 판단할지 정한다 |
| ↓ | | |
| 02 | 각 비교의 검정 | 선택한 α 와 같은 규칙을 적용 |
| ↓ | | |
| 03 | 누적 위험 | 원문은 NE가 늘면 false positive가 증가한다고 경고 |
| ↓ | | |
| 04 | 보정 예 | Bonferroni: $\alpha_{\text{Bon}} = \alpha / NE$ |
| ↓ | | |
| 05 | 보고 | 비교 수와 보정 규칙을 함께 공개 |

원문은 다중 비교 보정은 다루지만, 중간 p값으로 N을 늘리는 순차 설계는 정의하지 않는다

두 검정 도구의 역할과 전제

원문은 unequal variance 비교에는 Welch를, 분포 가정이 어려울 때는 bootstrap CI를 설명한다

도구	무엇을 계산하는가	핵심 전제·주의
2-sample t-test	평균 차이의 t 통계량	두 분산이 같다는 가정
Welch t-test	평균 차이와 추정 자유도	연속·대표성·독립·종형 분포
bootstrap CI	재표집 mean difference의 구간	표본이 분포를 충분히 대표해야 함
KS test	두 분포가 같은지	원문은 순서 관계 주장에는 부적절하다고 설명

‘distribution-free’ bootstrap도 작은 표본이 분포를 대표한다는 문제를 없애지 않는다

Welch t-test는 평균 차이를 불확실성으로 나눈다

같은 N을 쓰는 경우에도 두 알고리즘의 표본 SD는 서로 달라도 된다

Algo 1 표본

$\bar{x}_1, s_1, N_1$

Algo 2 표본

$\bar{x}_2, s_2, N_2$

Welch statistic


평균 차이 ÷ 두 표본의 표준오차

판정

t와 자유도를 α 기준으로 비교

유의하지 않음은 ‘같다’가 아니다

원문은 t 가 임계값보다 작을 때 증거 부족과 type-II error 가능성을 구분한다



bootstrap CI: 재표집 평균 차이의 구간

두 알고리즘의 표본을 각각 replacement로 재표집하고, 반복 mean difference의 분위수를 사용한다

01	원 표본	Algo 1과 Algo 2의 N개 성능을 준비
↓		
02	B회 재표집	각 표본에서 N개를 replacement로 다시 뽑기
↓		
03	각 평균	재표집마다 두 empirical mean 계산
↓		
04	mean difference	B개의 평균 차이를 모은다
↓		
05	CI 판정	0이 구간에 들어가는지 본다

B>1000은 재표집 횟수의 예일 뿐, 작은 원 표본의 대표성 문제를 고치지 못한다

pilot·power 결정·최종 평가는 역할이 다르다

원문의 3단계는 pilot n으로 변동성을 추정한 뒤, 목표 beta를 만족하는 최종 N을 선택하고 검정한다

01 질문 고정 비교, 양측/단측, α , 목표 효과 ε 를 정한다



02 pilot n 각 알고리즘의 평균과 s_1, s_2 를 추정



03 power 계산 ε 와 α 에서 β 대 N 곡선을 계산



04 final N 선택 허용 β 를 만족하는 각 알고리즘의 N



05 최종 평가 각 알고리즘의 N개 표본으로 검정 실행

pilot에서 본 차이는 N 결정을 위한 입력이며, 같은 관측을 최종 확증 증거로 과장하지 않는다

원문 pilot: 작은 n은 planning 입력

Half-Cheetah에서 두 DDPG perturbation variant를 $n=5$ 로 관찰한 조건부 사례다

항목	Algo 1	Algo 2	해석
변형	action noise	parameter noise	두 DDPG variant 비교
pilot 평균	3523	4905	차이 $\bar{x}_{diff} = 1382$
pilot SD	1341	990	power 계산의 입력
Welch 결과	$p = 0.1$	—	$\alpha = 0.05$ 에서는 H_0 미기각
bootstrap CI	[795, 2692]	—	0을 포함하지 않는 구간

두 검정이 다를 수 있으므로, 수치 하나를 진실로 읽지 말고 전제와 power를 함께 점검한다

원문의 power curve를 읽는 법: N은 조건부 출력

α , 목표 효과 ε , pilot SD 추정치가 고정될 때만 β 대 N의 곡선이 정의된다

고정한 입력	원문 조건	curve에서 읽는 결과
검정·유의수준	Welch; $\alpha = 0.05$	critical value와 β 계산에 사용
pilot SD	$s_1=1341, s_2=990$	변동성이 큰 만큼 더 큰 N 필요
목표 효과	$\varepsilon = 1382$	관측 차이를 해당 curve에 표시
N=5	$\beta = 0.51$	그 효과를 놓칠 확률이 51%
N=10	$\beta = 0.19$	$\beta \leq 0.2$ 요구를 이 사례에서 충족

N=10은 이 효과·분산· α · β 요구 아래의 예시일 뿐 다른 task의 권장 seed 수가 아니다

원문 N=10 관측: 더 좁은 구간

N을 늘린 뒤 같은 Half-Cheetah 비교에서 두 검정이 모두 H0를 기각한 사례다

항목	원문 N=5	원문 N=10
각 알고리즘 표본 수	5	10
평균 (Algo 1, Algo 2)	3523, 4905	3690, 5323
SD (Algo 1, Algo 2)	1341, 990	1086, 1454
Welch	p = 0.1	p = 0.0037
bootstrap CI	[795, 2692]	[732, 2612]

더 많은 seed는 불확실성을 줄일 수 있지만, 결과는 이 알고리즘·환경·지표 조건의 관측이다

자체 제작 산술 예시: Welch statistic을 손으로 따라가기

아래 값은 원문 데이터가 아닌, Eq. (4)의 입력·출력을 확인하기 위한 새 예시다

계산 단계	방법 A	방법 B	차이 검정 입력
5개 seed return	96, 99, 100, 103, 102	91, 94, 95, 98, 97	강의용으로 만든 수
표본 평균	$\bar{x}_1 = 100$	$\bar{x}_2 = 95$	$\bar{x}_{diff} = 5$
표본 SD	$s_1 \approx 2.74$	$s_2 \approx 2.74$	$SE = \sqrt{(7.5/5 + 7.5/5)} \approx 1.73$
Welch 계산	—	—	$t \approx 5 / 1.73 = 2.89; df \approx 8$

평균 차이뿐 아니라 seed별 변동과 표본 수가 t를 바꾼다; power는 별도로 설계한다

같은 알고리즘 split으로 empirical α 점검

H0가 참임을 알 수 있는 동일 알고리즘의 2N회 결과를 이용해 false-positive 비율을 추정한다



nominal α 가 아니라 이 데이터·test·N에서 실제 false-positive 비율을 확인하는 audit다

Fig. 6의 작은-N 경고를 과장하지 않기


원문은 42개 성능 관측에서 $N=2..21$ 을 바꾸어 nominal $\alpha = 0.05$ 와 empirical false-positive를 비교했다

원문 관측	설명	말할 수 없는 것
bootstrap, 작은 N	그 실험에서 nominal 5%보다 훨씬 큰 false positive	모든 DRL task의 같은 비율
Welch, 작은 N	더 보수적이지만 empirical α 가 약간 과소평가될 수 있음	가정 위반이 없다는 보장
Fig. 6의 데이터	42 available measures; $N=2..21$	모든 algorithm의 calibration curve
결론의 보수적 문구	bootstrap CI는 $N < 20$ 에 쓰지 말 것	모든 비교의 N은 20이면 충분

원문은 α 의 경험적 점검을 권하지만, 한 calibration 그림을 범용 benchmark로 만들지 않는다

pilot SD 과소추정은 power를 낙관시킨다

작은 n 에서 $s_1 \cdot s_2$ 가 실제보다 작게 추정되면 β 를 낮게 보고 필요한 N 도 작게 선택할 수 있다



원문의 '20'을 올바른 자리에서 읽기

서로 다른 숫자와 역할을 섞으면 '항상 20 seed'라는 잘못된 규칙이 된다

기호·수치	원문에서의 역할	바꾸면 안 되는 주장
pilot $n \geq 20$	$s_1 \cdot s_2$ 를 robust하게 추정하라는 final recommendation	모든 최종 비교 N이 20이면 충분
bootstrap $N < 20$	final conclusion의 bootstrap CI 사용 금지 경계	Welch에도 같은 보편 cutoff
Example $N = 10$	특정 ε , α , pilot SD, β 에서의 Half-Cheetah 사례	다른 task의 권장 seed 수
larger N	SD 오차 보상을 위한 source guidance	정확한 보편 여유분

최종 N은 지표 변동성, 목표 효과, $\alpha \cdot \beta$ 요구, 검정 가정과 calibration에 따라 정한다

논문에 남겨야 할 비교 설계 카드

‘seed를 몇 개 썼다’만으로는 독자가 오류 위험과 재현 가능성을 평가할 수 없다

보고 항목	반드시 적을 조건	이 논문과의 연결
estimand·metric	한 실행의 성능 정의와 집계 방식	X, xi, 평균·SD의 대상
가설· α	양측/단측, 사전 방향, 유의수준	type-I error 계약
pilot과 final	n , $s_1 \cdot s_2$, 목표 $\epsilon \cdot \beta$, 각 알고리즘 N	power analysis의 입력·출력
test·가정	Welch/bootstrp, 독립·분포·대표성 점검	가정 위반 시 α 가 흔들림
비교 family	NE와 보정, stopping design	Bonferroni 예와 source 경계

재현 가능한 비교는 seed 수뿐 아니라 그 수의 오류 목표와 조건도 기록한다

결론: seed 수는 관례가 아니라 검정 설계의 결과다

원문의 가장 중요한 기여는 ‘더 많이’보다 ‘어떤 오류를, 어떤 조건에서 줄일 것인가’를 묻게 만든 데 있다

- 한 run은 확률변수의 관측이며, 평균 곡선만으로 성능 우위를 단정할 수 없다.
- $P(\text{false positive})=\alpha$, $P(\text{false negative})=\beta$, $\text{power}=1-\beta$.
- pilot n 으로 SD를 추정하고 목표 $\varepsilon \cdot \alpha \cdot \beta$ 아래 final N 을 정해 비교한다.
- 검정 전제·empirical α 와 다중 비교·stopping rule을 공개한다.
- $n \geq 20$, bootstrap $N < 20$, Example $N=10$ 은 문맥별 숫자이지 보편 seed 수가 아니다.

좋은 DRL 비교는 seed 수보다 조건부 오류 위험을 투명하게 설계·검증·보고한다