

Learning to Optimize: DNN으로 WMMSE 전력 제어를 근사하기

Learning to Optimize: Training Deep Neural Networks for Wireless
Resource Management

Haoran Sun, Xiangyi Chen, Qingjiang Shi, Mingyi Hong, Xiao Fu, Nikos D. Sidiropoulos (2017)

반복 최적화의 channel-to-power mapping을 Deep Neural Network로 학습하는 SPAWC 2017
논문

간섭 채널 전력 제어 문제


K개의 송신기와 수신기 쌍이 같은 대역에서 동시에 통신한다

기호	논문에서의 뜻	결정과 영향
IC	interference channel	다른 송신기의 신호가 수신기 잡음처럼 들어온다
p_k 와 h	power와 channel	직접 신호와 다른 링크의 간섭을 함께 바꾼다
SINR	신호 대 간섭 잡음 비	각 링크 rate를 정하는 신호 품질
WSR	weighted sum-rate	모든 링크 rate의 가중 합을 크게 만드는 목적
$P_{\max}$	각 송신기의 power budget	각 p_k 는 0과 $P_{\max}$ 사이여야 한다

전력 하나가 두 역할을 하므로 각 링크를 독립적으로 최적화할 수 없다

WSR은 원하는 신호와 간섭을 함께 계산한다

수신기 k의 SINR 분모에는 다른 모든 송신기의 power가 들어간다



강의용 두 링크 계산 예시

원문 Eq. (1)의 구조를 재계산한 예시이며 원문 실험값은 아니다

01	가정	$P_{\max}=1$, direct gain=1, cross gain=0.2, noise=0.10
↓		
02	feasible power	$p=(1, 0.5)$ 로 선택하면 두 값 모두 0과 1 사이
↓		
03	링크 1	$SINR_1=1/(0.04 \times 0.5 + 0.10)=8.3333$
↓		
04	링크 2	$SINR_2=0.5/(0.04 \times 1 + 0.10)=3.5714$
↓		
05	WSR 항	자연로그 기준 $\ln(9.3333)+\ln(4.5714)=3.7534$

두 분모가 서로의 power를 포함하므로 좋은 출력은 하나의 p 벡터여야 한다

WMMSE는 반복으로 power를 갱신한다


weighted minimum mean-square error 절차에서 v , u , w 를 수렴할 때까지 갱신한다

01	v 초기화	0부터 $\sqrt{P_{\max}}$ 사이에서 v_0 설정
↓		
02	초기 u 와 w	v_0 로 u_0 를 계산한 뒤 w_0 계산
↓		
03	v , u , w 반복	v 를 먼저 갱신한 뒤 u 와 w 를 갱신
↓		
04	수렴 확인	목적값 변화가 ϵ 이하면 반복 종료
↓		
05	최종 power	$p_k = (v_k)^2$ 출력

WMMSE의 반복 계산이 offline label을 만들고 DNN은 그 최종 mapping을 배운다


이 논문은 WMMSE 단계를 한 층씩 펼치지 않는다

고정된 초기화에서 channel 입력과 최종 power 출력의 end-to-end mapping을 학습한다



WMMSE 출력이 supervised training label이 된다

각 channel realization마다 WMMSE를 실행해 power vector를 저장하고 MSE로 DNN weight를 학습한다



학습 목표는 WSR 값을 직접 높이는 reward가 아니라 WMMSE power label과의 MSE다

DNN은 channel magnitude를 feasible power로 바꾼다

공통 출력은 연속 clipping이며 Gaussian IC 실험에서만 0 또는 $P_{\max}$ 로 한 번 더 이산화한다



Eq. (7)의 연속 clipping과 Gaussian IC 결과의 binary 후처리를 구분해야 한다

Theorem 1은 approximation 가능성의 조건부 주장이다

finite iteration의 각 단계가 continuous이고 입력과 초기화 domain이 compact일 때의 결과다

정리의 요소	논문이 말하는 것	발표에서 유지할 경계
대상	$y_{t+1}=f_t(y_t, x)$ 형태의 finite iterative algorithm	무한 반복이나 임의 algorithm 전체를 뜻하지 않는다
조건	X와 Y_0 가 compact이고 각 f_t 가 continuous	채널 분포 변화나 학습 데이터 부족은 이 조건만으로 해결되지 않는다
결론	충분히 큰 one-hidden-layer sigmoid network가 final mapping을 임의 오차까지 근사	200/80/80 실험 network의 오차 보장은 아니다
WMMSE 연결	각 WMMSE iteration이 continuous라고 확인	global WSR optimum이나 deployment robustness 정리는 아니다

정리는 end-to-end approximation의 근거이며 finite DNN의 성능 보증을 대신하지 않는다

실험 조건과 구현 환경

수치 결과는 두 channel model과 같은-distribution test protocol에서 얻었다

항목	원문 조건	해석 범위
구현	Py3.6, TF1.0, 2 CPU, 2 GPU, 128 GB	GPU는 training만
Gaussian IC	$K=10,20,30$; $0/P_{\max}$ 이산화	Gaussian 결과에만 binary 적용
Practical IMAC	$(3,16)$, $(3,24)$, $(3,60)$, $(7,28)$	source cell model
data	시나리오마다 100만 channel	99% training, 1% validation
test	주실험은 training과 같은 분포	$K/2$ 외 shift 미검증

결과는 논문이 정한 simulator와 training-test distribution 관계 안에서 읽어야 한다

Figure 3: 두 지정 조건에서의 sum-rate CDF

DNN, WMMSE, maximum power, random power를 10,000개 test point에서 비교한다

panel	condition	DNN/WMMSE	interpretation
(a)	Gaussian K=10; binary 후처리	97.92%	Fig. 3 CDF average
(b)	IMAC, N=3 K=24	93.02%	Fig. 3 CDF average
baseline	RAND, MP	heuristic	DNN CDF가 오른쪽으로 이동

Figure 3의 97.92%와 93.02%는 각 panel의 정의된 조건에 붙는 상대 성능이다

Table I: Gaussian IC에서 K가 늘어날 때

WMMSE와 Greedy를 각각 teacher로 학습한 DNN 실험을 함께 제시한다

K	10	20	30
DNN sum-rate / WMMSE	0.9792	0.9265	0.8566
Greedy 학습 DNN rate / Greedy	0.9666	0.9187	0.8521
test time / WMMSE Python	0.0032	0.0016	0.0012
test time / WMMSE C	0.1739	0.0517	0.0314
Greedy 학습 DNN time / Greedy	0.0052	0.0011	0.0005

이 table에서는 K가 커질수록 DNN/WMMSE rate ratio가 0.9792에서 0.8566으로 낮아진다

Table II: IMAC에서의 relative sum-rate와 CPU time


각 열은 서로 다른 base-station과 user 수를 가진 source의 simulation condition이다

(N,K)	(3,18)	(3,24)	(7,28)	(3,60)
DNN sum-rate / WMMSE	0.9532	0.9302	0.9207	0.9058
RAND sum-rate / WMMSE	0.3362	0.3024	0.3898	0.2316
MP sum-rate / WMMSE	0.3207	0.3026	0.3946	0.2310
test time / WMMSE Python	0.0009	0.0006	0.0003	0.0002
test time / WMMSE C	0.0322	0.0162	0.0070	0.0032

IMAC table의 DNN/WMMSE rate ratio는 네 조건에서 0.9058부터 0.9532 사이다

반복 WMMSE와 DNN forward pass의 test time

offline training 비용과 online test compute를 분리해야 Table I과 II를 올바르게 읽을 수 있다



논문이 남긴 적용 범위와 다음 질문

저자들은 이 결과를 preliminary step으로 두고 distribution shift와 더 어려운 signal design을 후속 과제로 남긴다

- DNN은 WMMSE final power label을 배운다. global WSR solver 증명은 없다.
- train-test distribution mismatch는 저자들이 남긴 future question이다.
- 200/80/80 architecture와 source hyperparameter는 보편 설계가 아니다.
- 실험 대상은 IC와 IMAC scalar power control이며 beamforming은 future work다.
- test time은 end-to-end latency나 battery energy를 측정하지 않는다.

핵심은 matched simulation에서 WMMSE mapping을 빠르게 근사한 결과다

논문의 전체 구조

복잡한 iterative optimizer를 offline teacher로 사용하고 online에는 constrained DNN inference를 둔다

01	IC	모든 power가 WSR의 signal과 interference를 함께 바꾼다
↓		
02	WMMSE teacher	channel에서 stationary power allocation을 반복 계산한다
↓		
03	supervised dataset	WMMSE output을 power label로 저장하고 MSE로 학습한다
↓		
04	DNN inference	새 channel을 한 번 통과시켜 raw power를 만든다
↓		
05	feasible action	Eq. (7) clipping으로 각 p_k 를 0과 $P_{\max}$ 사이에 둔다

빠른 forward pass는 offline WMMSE label과 power clipping에 기반한다