

# Calibration Data가 LLM PTQ-Pruning 에 미치는 영향

On the Impact of Calibration Data in Post-training Quantization and Pruning

---

Miles Williams and Nikolaos Aletras (2024)

작은 unlabeled text set이 압축 weight 선택과 downstream 성능에 왜 영향을 줄 수 있는가

# 먼저 범위: calibration은 training data가 아니다


이 논문은 이미 학습된 model을 다시 학습시키지 않는 post-training compression을 다룬다

| 구분            | calibration data                         | evaluation data                  |
|---------------|------------------------------------------|----------------------------------|
| 용도            | layer activation을 만들어 압축 weight 선택에 사용   | 압축 뒤 성능을 측정                      |
| 라벨            | 작은 unlabeled text set                    | zero-shot task 정답과 WikiText test |
| weight update | 학습 gradient로 모델을 update하지 않음             | weight를 update하지 않음              |
| 논문의 보호 장치     | zero-shot evaluation data를 source로 쓰지 않음 | calibration과 분리해 측정              |

calibration은 retraining용 정답 데이터가 아니라, 압축 결정을 위한 activation 표본이다.

# Calibration text가 압축 선택에 들어가는 경로

원 model의 학습 weight는 고정된 채, calibration activation에 맞는 compressed weight를 고른다



X가 바뀌면 layer proxy가 바뀌고, 압축 weight 선택도 달라질 수 있다.

# 교육용 toy: activation 표본이 후보 순위를 바꾼다

보고된 실험 수치가 아닌, layer proxy의 역할을 검산하는 작은 예

| activation  | 원 output        | 후보 C1=(1,0) | 후보 C2=(0,1) | proxy 선택 |
|-------------|-----------------|-------------|-------------|----------|
| $x_A=(2,0)$ | $W \cdot x_A=2$ | 오차 0        | 오차 4        | C1       |
| $x_B=(0,2)$ | $W \cdot x_B=2$ | 오차 4        | 오차 0        | C2       |

같은 W와 후보라도, X의 방향이 달라지면 proxy의 후보 순위가 뒤집힌다.

# 같은 calibration도 compressor가 읽는 방식은 다르다

| 방법        | 종류           | activation/Hessian의 역할                  | 논문 setting                           |
|-----------|--------------|-----------------------------------------|--------------------------------------|
| GPTQ      | quantization | inverse-Hessian 정보                      | 4-bit weight                         |
| SpQR      | quantization | Hessian과 outlier 처리                     | 4-bit weight, high-precision outlier |
| SparseGPT | pruning      | inverse-Hessian으로 순차 prune·update       | 2:4 sparsity                         |
| Wanda     | pruning      | weight magnitude와 input activation norm | 2:4 sparsity                         |

calibration sensitivity는 data만이 아니라 compressor와의 결합된 성질이다.

# 연구는 calibration 선택을 큰 실험 격자로 바꿨다

source와 random set을 바꾸고, compressor·model·evaluation을 교차했다

|    |               |                      |
|----|---------------|----------------------|
| 01 | 5 source      | 서로 다른 text source    |
| ↓  |               |                      |
| 02 | 10 set씩       | 총 50 calibration set |
| ↓  |               |                      |
| 03 | 4 × 9         | compressor와 LLM 교차   |
| ↓  |               |                      |
| 04 | 1,800 model   | 압축된 model 수          |
| ↓  |               |                      |
| 05 | 11 evaluation | 19,800 measurements  |

$5 \times 10 \times 4 \times 9 = 1,800$  compressed models, 그리고  $1,800 \times 11 = 19,800$  evaluations이다.

# 50 calibration set의 생성 규칙

각 source에서 128개 example을 중복 없이 뽑고, source 안에서는 10개 set이 서로 겹치지 않게 했다



128 × 2,048 tokens/set을 고정하고 random-sampling variation을 따로 관찰했다.

# Source 비교는 단일 속성의 조작 실험이 아니다

| source               | 논문이 설명한 성격                                    | 해석 시 남는 묶인 요인                               |
|----------------------|-----------------------------------------------|---------------------------------------------|
| C4                   | filtered Common Crawl의 clean English web text | web text, filtering, length, content가 함께 변함 |
| CNN/DM               | news article 기반 long-form text                | news genre만의 효과를 분리하지 않음                    |
| RedPajama            | LLaMA pretraining data의 open reproduction     | pretraining similarity를 직접 조작하지 않음          |
| RefinedWeb·Wikipedia | curated web / cleaned encyclopedic text       | curation·domain·time 등 다수 속성이 함께 변함         |

source 비교는 유용하지만, 단일 data feature의 causal effect를 식별하지는 않는다.

# 나머지 조건도 함께 고정해 읽어야 한다

| 축            | 실제 조건                                                  | 숫자를 읽을 때의 경계                                |
|--------------|--------------------------------------------------------|---------------------------------------------|
| LLM          | LLaMA·Vicuna: 7B/ 13B/ 33B; OPT: 6.7B/ 13B/ 30B        | 9개 English LLM의 결과                          |
| pruning      | GPU acceleration을 위한 2:4 semi-structured, 50% sparsity | unstructured pruning 일반 결과가 아님              |
| quantization | GPTQ·SpQR의 4-bit weight setting                        | 다른 bit width에 그대로 적용 불가                     |
| 실행           | single NVIDIA A100 SXM 80GB, LM Evaluation Harness     | throughput/production latency benchmark가 아님 |

‘calibration 효과’는 model family, compressor setting, task와 함께 붙여야 의미가 있다.

# 평가는 ‘mean accuracy 하나’가 아니라 두 종류의 지표다

| 지표                         | 무엇을 재나                                | 읽는 데 필요한 주의                                   |
|----------------------------|---------------------------------------|-----------------------------------------------|
| 10 zero-shot task accuracy | ARC-e/c, BoolQ, HellaSwag 등 task별 정확도 | 평균은 task별 큰 range를 가릴 수 있음                    |
| mean zero-shot accuracy    | 10 task accuracy의 평균                  | 같은 source의 10 set에 대해 mean·standard deviation |
| WikiText perplexity        | language-model prediction quality     | downstream task robustness의 대용물이 아님           |
| RTE                        | 277-example evaluation split          | 작은 task set이라 range estimate가 덜 안정적일 수 있음     |

PPL과 task accuracy는 다른 지표다. 하나가 안정적이어도 다른 하나는 아닐 수 있다.

# 결과 1 : 같은 C4 source 안에서도 sample range가 보였다

LLaMA- 7B를 SparseGPT로 prune하고, C4에서 뽑은 10 calibration set을 비교한 한 configuration

| task  | 가장 낮은 accuracy | 가장 높은 accuracy | range |
|-------|----------------|----------------|-------|
| RTE   | 52.7%          | 61.7%          | 9.0%p |
| BoolQ | 66.4%          | 73.0%          | 6.6%p |

같은 source라도 결과가 같지는 않다. 이 range는 한 model·method·task 조건의 관찰이다.

# 결과 2: sensitivity는 method·model에 따라 달랐다

50 calibration set에서 본 OPT-6.7B mean zero-shot accuracy의 best-worst range

| compression method | range | 논문이 허용하는 해석                     |
|--------------------|-------|---------------------------------|
| GPTQ               | 1.6%p | 이 model과 4-bit setting에서의 range |
| SpQR               | 0.9%p | 이 model과 4-bit setting에서의 range |
| SparseGPT          | 2.4%p | 이 model과 2:4 setting에서의 range   |
| Wanda              | 2.4%p | 이 model과 2:4 setting에서의 range   |

pruning 쪽 range가 대체로 컸지만, universal ranking이나 causal proof는 아니다.

# 결과 3: ‘최고 calibration corpus’ 하나는 나오지 않았다

| 관찰    | 원전의 예                                                   | 정확한 결론                   |
|-------|---------------------------------------------------------|--------------------------|
| 일부 경향 | SparseGPT에서 RefinedWeb은 9 model 중 8개에서 최고 mean accuracy | configuration별 pattern   |
| 반례    | LLaMA-7B + Wanda는 RedPajama 52.7%, RefinedWeb 52.2%     | source winner가 고정되지 않음   |
| 작은 차이 | SpQR source 차이는 보통 약 0.2%                               | source 간 우열이 불명확한 경우도 있음 |

핵심 질문은 ‘최고 corpus’가 아니라 내 configuration의 set sensitivity다.

# 결과 4: PPL 안정성이 task 안정성은 아니다

Vicuna-7B-SparseGPT-CNN/DM의 10 calibration set 비교

| metric         | mean $\pm$ SD    | 관찰 범위       | 해석                             |
|----------------|------------------|-------------|--------------------------------|
| WikiText PPL   | 12.72 $\pm$ 0.18 | 표준편차가 작음    | LM metric만 보면 안정적으로 보일 수 있음    |
| BoolQ accuracy | 66.7% $\pm$ 4.7  | 57.0%–71.6% | downstream task에서는 큰 variation |

PPL만으로 calibration robustness를 판단하지 말고 intended task도 함께 본다.

# Calibration example 수와 compression cost

LLaMA-7B-C4에서 1-512 example을 비교한 quantity sweep

| 관찰                      | 원전의 수치                                                                | 과잉 해석 방지                         |
|-------------------------|-----------------------------------------------------------------------|----------------------------------|
| GPTQ PPL                | 1 example $6.13 \pm 0.05 \rightarrow$ 128 examples $5.90 \pm 0.03$    | 이 source·model·setting의 변화       |
| SparseGPT PPL           | 1 example $55.26 \pm 10.82 \rightarrow$ 128 examples $11.12 \pm 0.26$ | 작은 n에서 특히 불안정할 수 있음              |
| SparseGPT task accuracy | 128의 4배 example에서 mean zero-shot +0.4%                                | example 증가에는 compression cost도 듦 |
| SpQR                    | PPL $5.74 \pm 0.01$ 로 거의 일정                                           | method별 plateau가 다름              |

128은 공통 protocol일 뿐 universal optimum은 아니다. sample 수와 비용은 조건별로 달랐다.

# 분산 읽기: 10 set의 평균·표준편차·range

| 표현                            | 이 논문에서 뜻하는 것                              | 뜻하지 않는 것                           |
|-------------------------------|-------------------------------------------|------------------------------------|
| mean $\pm$ standard deviation | 같은 source의 10 calibration set에 대한 summary | training randomness만의 error bar    |
| best-worst range              | 선택한 calibration set에 따른 관찰 범위             | 모집단의 신뢰구간                          |
| source comparison             | 5 source의 set summary 비교                  | source feature 하나의 causal estimate |
| task difference               | task별 dispersion이 다름                      | 모든 task가 같은 안정성을 가짐                |

이 uncertainty는 sample variation이지, statistical superiority나 causal proof는 아니다.

# 저자들의 세 가지 권고: release · vary · inspect

성능 보장 규칙이 아니라 reproducibility와 diagnosis를 위한 실무 권고

01 Release calibration data 자체를 공유

---



02 Version source·sampling artifact를 기록

---



03 Vary 여러 set에서 task 성능 확인

---



04 Inspect 작은 set의 anomalous example 점검

---

seed만 공유하지 말고 calibration artifact를 보존하며, 하나의 set으로 결론내리지 않는다.

# 이식 가능한 연구·실무 습관

| 습관                    | 이 논문이 주는 근거                      | 안전한 적용                                         |
|-----------------------|----------------------------------|------------------------------------------------|
| artifact 관리           | sample variation이 결과를 바꿀 수 있음    | source, set ID, tokenizer, software version 기록 |
| multi-set stress test | source당 10 non-overlap set을 사용   | 목표 model·method·task에서 repeat                  |
| metric 분리             | PPL과 BoolQ variation이 엇갈린 예      | PPL과 intended task를 함께 측정                      |
| 조건 표기                 | model·method·source별 pattern이 다름 | bit width·sparsity·hardware도 함께 표기             |

calibration data는 metadata가 아니라 압축 실험의 versioned input이다.

# 이 논문이 아직 답하지 않는 것

## 원전이 지지하는 결론

명시된 English model·data·task·method 조건에서 calibration choice에 따른 variation

dataset-level source comparison

PPL과 downstream task가 엇갈릴 수 있는 예

release/vary/inspect 권고

## 원전만으로는 말할 수 없는 결론

모든 LLM·language·compressor에 대한 universal law

뉴스성·길이·curation 하나의 causal effect

PPL이 쓸모없거나 항상 misleading함

권고를 따르면 accuracy가 반드시 상승함

결론은 조건부 sensitivity다. 원인과 보편성은 controlled study가 더 필요하다.

# 마무리: calibration은 압축 과정의 숨은 입력이다

- calibration text는 activation  $X$ 를 만들고,  $X$ 는 layer-wise quantization-pruning 선택에 들어간다.
- 같은 source 안 random set, source, model, compressor, task에 따라 결과 pattern이 달랐다.
- PPL 하나로 downstream robustness를 대체하지 말고, mean-range-task 조건을 함께 읽어야 한다.
- 실무의 안전한 행동은 artifact를 기록하고 여러 calibration set에서 intended task를 확인하는 것이다.

---

핵심은 ‘최고 corpus’가 아니라 내 compression configuration의 calibration sensitivity다.