

Calibration Data가 LLM PTQ-Pruning 에 미치는 영향

On the Impact of Calibration Data in Post-training Quantization and Pruning

Miles Williams and Nikolaos Aletras (2024)

작은 unlabeled text set이 압축 weight 선택과 downstream 성능에 왜 영향을 줄 수 있는가

먼저 범위: calibration은 training data가 아니다


이 논문은 이미 학습된 model을 다시 학습시키지 않는 post-training compression을 다룬다

구분	calibration data	evaluation data
용도	layer activation을 만들어 압축 weight 선택에 사용	압축 뒤 성능을 측정
라벨	작은 unlabeled text set	zero-shot task 정답과 WikiText test
weight update	학습 gradient로 모델을 update하지 않음	weight를 update하지 않음
논문의 보호 장치	zero-shot evaluation data를 source로 쓰지 않음	calibration과 분리해 측정

calibration은 retraining용 정답 데이터가 아니라, 압축 결정을 위한 activation 표본이다.

Calibration text가 압축 선택에 들어가는 경로

원 model의 학습 weight는 고정된 채, calibration activation에 맞는 compressed weight를 고른다



X가 바뀌면 layer proxy가 바뀌고, 압축 weight 선택도 달라질 수 있다.

교육용 toy: activation 표본이 후보 순위를 바꾼다

보고된 실험 수치가 아닌, layer proxy의 역할을 검산하는 작은 예

activation	원 output	후보 C1=(1,0)	후보 C2=(0,1)	proxy 선택
$x_A=(2,0)$	$W \cdot x_A=2$	오차 0	오차 4	C1
$x_B=(0,2)$	$W \cdot x_B=2$	오차 4	오차 0	C2

같은 W와 후보라도, X의 방향이 달라지면 proxy의 후보 순위가 뒤집힌다.

같은 calibration도 compressor가 읽는 방식은 다르다

방법	종류	activation/Hessian의 역할	논문 setting
GPTQ	quantization	inverse-Hessian 정보	4-bit weight
SpQR	quantization	Hessian과 outlier 처리	4-bit weight, high-precision outlier
SparseGPT	pruning	inverse-Hessian으로 순차 prune·update	2:4 sparsity
Wanda	pruning	weight magnitude와 input activation norm	2:4 sparsity

calibration sensitivity는 data만이 아니라 compressor와의 결합된 성질이다.

연구는 calibration 선택을 큰 실험 격자로 바꿨다

source와 random set을 바꾸고, compressor·model·evaluation을 교차했다

01	5 source	서로 다른 text source
↓		
02	10 set씩	총 50 calibration set
↓		
03	4 × 9	compressor와 LLM 교차
↓		
04	1,800 model	압축된 model 수
↓		
05	11 evaluation	19,800 measurements

$5 \times 10 \times 4 \times 9 = 1,800$ compressed models, 그리고 $1,800 \times 11 = 19,800$ evaluations이다.

50 calibration set의 생성 규칙

각 source에서 128개 example을 중복 없이 뽑고, source 안에서는 10개 set이 서로 겹치지 않게 했다



128 × 2,048 tokens/set을 고정하고 random-sampling variation을 따로 관찰했다.

Source 비교는 단일 속성의 조작 실험이 아니다

source	논문이 설명한 성격	해석 시 남는 묶인 요인
C4	filtered Common Crawl의 clean English web text	web text, filtering, length, content가 함께 변함
CNN/DM	news article 기반 long-form text	news genre만의 효과를 분리하지 않음
RedPajama	LLaMA pretraining data의 open reproduction	pretraining similarity를 직접 조작하지 않음
RefinedWeb·Wikipedia	curated web / cleaned encyclopedic text	curation·domain·time 등 다수 속성이 함께 변함

source 비교는 유용하지만, 단일 data feature의 causal effect를 식별하지는 않는다.

나머지 조건도 함께 고정해 읽어야 한다

축	실제 조건	숫자를 읽을 때의 경계
LLM	LLaMA·Vicuna: 7B/ 13B/ 33B; OPT: 6.7B/ 13B/ 30B	9개 English LLM의 결과
pruning	GPU acceleration을 위한 2:4 semi-structured, 50% sparsity	unstructured pruning 일반 결과가 아님
quantization	GPTQ·SpQR의 4-bit weight setting	다른 bit width에 그대로 적용 불가
실행	single NVIDIA A100 SXM 80GB, LM Evaluation Harness	throughput/production latency benchmark가 아님

‘calibration 효과’는 model family, compressor setting, task와 함께 붙여야 의미가 있다.

평가는 ‘mean accuracy 하나’가 아니라 두 종류의 지표다

지표	무엇을 재나	읽는 데 필요한 주의
10 zero-shot task accuracy	ARC-e/c, BoolQ, HellaSwag 등 task별 정확도	평균은 task별 큰 range를 가릴 수 있음
mean zero-shot accuracy	10 task accuracy의 평균	같은 source의 10 set에 대해 mean·standard deviation
WikiText perplexity	language-model prediction quality	downstream task robustness의 대용물이 아님
RTE	277-example evaluation split	작은 task set이라 range estimate가 덜 안정적일 수 있음

PPL과 task accuracy는 다른 지표다. 하나가 안정적이어도 다른 하나는 아닐 수 있다.

결과 1 : 같은 C4 source 안에서도 sample range가 보였다

LLaMA-7B를 SparseGPT로 prune하고, C4에서 뽑은 10 calibration set을 비교한 한 configuration

task	가장 낮은 accuracy	가장 높은 accuracy	range
RTE	52.7%	61.7%	9.0%p
BoolQ	66.4%	73.0%	6.6%p

같은 source라도 결과가 같지는 않다. 이 range는 한 model·method·task 조건의 관찰이다.

결과 2: sensitivity는 method·model에 따라 달랐다

50 calibration set에서 본 OPT-6.7B mean zero-shot accuracy의 best-worst range

compression method	range	논문이 허용하는 해석
GPTQ	1.6%p	이 model과 4-bit setting에서의 range
SpQR	0.9%p	이 model과 4-bit setting에서의 range
SparseGPT	2.4%p	이 model과 2:4 setting에서의 range
Wanda	2.4%p	이 model과 2:4 setting에서의 range

pruning 쪽 range가 대체로 컸지만, universal ranking이나 causal proof는 아니다.

결과 3: ‘최고 calibration corpus’ 하나는 나오지 않았다

관찰	원전의 예	정확한 결론
일부 경향	SparseGPT에서 RefinedWeb은 9 model 중 8개에서 최고 mean accuracy	configuration별 pattern
반례	LLaMA-7B + Wanda는 RedPajama 52.7%, RefinedWeb 52.2%	source winner가 고정되지 않음
작은 차이	SpQR source 차이는 보통 약 0.2%	source 간 우열이 불명확한 경우도 있음

핵심 질문은 ‘최고 corpus’가 아니라 내 configuration의 set sensitivity다.

결과 4: PPL 안정성이 task 안정성은 아니다

Vicuna-7B-SparseGPT-CNN/DM의 10 calibration set 비교

metric	mean $\pm$ SD	관찰 범위	해석
WikiText PPL	12.72 $\pm$ 0.18	표준편차가 작음	LM metric만 보면 안정적으로 보일 수 있음
BoolQ accuracy	66.7% $\pm$ 4.7	57.0%–71.6%	downstream task에서는 큰 variation

PPL만으로 calibration robustness를 판단하지 말고 intended task도 함께 본다.

Calibration example 수와 compression cost

LLaMA-7B-C4에서 1-512 example을 비교한 quantity sweep

관찰	원전의 수치	과잉 해석 방지
GPTQ PPL	1 example $6.13 \pm 0.05 \rightarrow$ 128 examples 5.90 ± 0.03	이 source-model-setting의 변화
SparseGPT PPL	1 example $55.26 \pm 10.82 \rightarrow$ 128 examples 11.12 ± 0.26	작은 n에서 특히 불안정할 수 있음
SparseGPT task accuracy	128의 4배 example에서 mean zero-shot +0.4%	example 증가에는 compression cost도 듦
SpQR	PPL 5.74 ± 0.01 로 거의 일정	method별 plateau가 다름

128은 공통 protocol일 뿐 universal optimum은 아니다. sample 수와 비용은 조건별로 달랐다.

분산 읽기: 10 set의 평균·표준편차·range

표현	이 논문에서 뜻하는 것	뜻하지 않는 것
mean $\pm$ standard deviation	같은 source의 10 calibration set에 대한 summary	training randomness만의 error bar
best-worst range	선택한 calibration set에 따른 관찰 범위	모집단의 신뢰구간
source comparison	5 source의 set summary 비교	source feature 하나의 causal estimate
task difference	task별 dispersion이 다름	모든 task가 같은 안정성을 가짐

이 uncertainty는 sample variation이지, statistical superiority나 causal proof는 아니다.

저자들의 세 가지 권고: release · vary · inspect

성능 보장 규칙이 아니라 reproducibility와 diagnosis를 위한 실무 권고

01 Release calibration data 자체를 공유



02 Version source·sampling artifact를 기록



03 Vary 여러 set에서 task 성능 확인



04 Inspect 작은 set의 anomalous example 점검

seed만 공유하지 말고 calibration artifact를 보존하며, 하나의 set으로 결론내리지 않는다.

이식 가능한 연구·실무 습관

습관	이 논문이 주는 근거	안전한 적용
artifact 관리	sample variation이 결과를 바꿀 수 있음	source, set ID, tokenizer, software version 기록
multi-set stress test	source당 10 non-overlap set을 사용	목표 model·method·task에서 repeat
metric 분리	PPL과 BoolQ variation이 엇갈린 예	PPL과 intended task를 함께 측정
조건 표기	model·method·source별 pattern이 다름	bit width·sparsity·hardware도 함께 표기

calibration data는 metadata가 아니라 압축 실험의 versioned input이다.

이 논문이 아직 답하지 않는 것

원전이 지지하는 결론

명시된 English model·data·task·method 조건에서 calibration choice에 따른 variation

dataset-level source comparison

PPL과 downstream task가 엇갈릴 수 있는 예

release/vary/inspect 권고

원전만으로는 말할 수 없는 결론

모든 LLM·language·compressor에 대한 universal law

뉴스성·길이·curation 하나의 causal effect

PPL이 쓸모없거나 항상 misleading함

권고를 따르면 accuracy가 반드시 상승함

결론은 조건부 sensitivity다. 원인과 보편성은 controlled study가 더 필요하다.

마무리: calibration은 압축 과정의 숨은 입력이다

- calibration text는 activation X 를 만들고, X 는 layer-wise quantization-pruning 선택에 들어간다.
- 같은 source 안 random set, source, model, compressor, task에 따라 결과 pattern이 달랐다.
- PPL 하나로 downstream robustness를 대체하지 말고, mean-range-task 조건을 함께 읽어야 한다.
- 실무의 안전한 행동은 artifact를 기록하고 여러 calibration set에서 intended task를 확인하는 것이다.

핵심은 ‘최고 corpus’가 아니라 내 compression configuration의 calibration sensitivity다.