

OWQ: 민감한 가중치 열을 보존하는 LLM 양자화

OWQ: Outlier-Aware Weight Quantization for Efficient Fine-Tuning and Inference of Large Language Models

Changhun Lee, Jungyu Jin, Taesu Kim, Hyungjun Kim, Eunhyeok Park (2024)

activation outlier가 만드는 weak column을 fp16으로 남기고 나머지 가중치를 저비트로 압축하는 weight-only PTQ

OWQ의 정확한 범위

구분	OWQ가 하는 것	범위 밖
대상	linear layer의 weight	activation·KV cache 양자화
절차	calibration 기반 layer-wise PTQ	대규모 재학습을 전제로 한 QAT
정밀도	저비트 dense weight + fp16 일부 열	모든 값이 같은 3.01-bit scalar
예외	embedding과 head는 full precision	완전한 W3A3 모델

OWQ는 weight-only 혼합 정밀도 PTQ이며 3.01-bit는 평균 저장 비용이다.

문제 정의: 가중치 오차가 아니라 출력 오차를 줄인다

- | | | |
|----|-----------------------------|---|
| 01 | 원래 weight W | full-precision linear layer의 가중치다. |
| ↓ | | |
| 02 | calibration X | 대표 입력 activation으로 민감도를 관찰한다. |
| ↓ | | |
| 03 | 양자화 weight W_{hat} | 압축 목표를 만족하는 저정밀 표현이다. |
| ↓ | | |
| 04 | 출력 비교 | WX 와 $W_{\text{hat}} X$ 의 제곱 오차를 최소화한다. |

같은 weight 오차라도 자주 크고 중요한 입력 방향에 놓이면 출력 영향이 커질 수 있다.

Weak column은 작은 열이 아니라 양자화에 민감한 열이다

판별 기준

Weight magnitude

Weight perturbation

Activation sensitivity

Weak column

보는 값

가중치 자체의 절댓값

반올림 전후 weight 변화

calibration 입력 방향의 에너지

두 요소가 만든 출력 영향

OWQ와의 관계

선택 기준이 아님

민감도 점수의 한 요소

Hessian 대각값으로 반영

상위 k개 열을 fp16 보존

OWQ는 큰 weight outlier가 아니라 output error에 민감한 전체 입력 열을 고른다.

Calibration activation에서 열별 민감도로

- 01 입력 행렬 X 행은 input feature, 열은 calibration token이다.
↓
- 02 $H = 2XX^T$ transpose layer output error의 곡률을 나타내는 행렬이다.
↓
- 03 대각값 λ_j feature j 의 calibration activation 에너지를 반영한다.
↓
- 04 열별 점수 λ_j 와 해당 열의 양자화 오차를 곱한다.

λ_j 는 calibration 데이터에서 얻은 민감도 성분이며 영구적인 중요도 보장은 아니다.

교육용 계산 1 : X가 Hessian 대각값을 만든다

논문 실험값이 아니라 식 4를 설명하기 위해 독립적으로 계산한 2×2 예다.

행렬	열 1	열 2	의미
X의 feature 1	1	0	feature 1 크기 1
X의 feature 2	0	3	feature 2 크기 3
$H = 2XX^T$	2	18	대각값 λ_1, λ_2

feature 2가 3배 크므로 제공 에너지는 9배, Hessian 대각값도 9배가 된다.

교육용 계산 2: 더 작은 weight 오차의 열이 선택된다

열 j	λ_j	ΔW 열의 제곱합	점수 s_j	fp16 보존
1	2	0.0200	0.0400	아니오
2	18	0.0032	0.0576	예

열 2는 raw weight 오차가 더 작아도 activation 민감도가 커서 fp16 예산을 받는다.

Weak column 선택 절차

- | | | |
|----|---------------------|--|
| 01 | 임시 양자화 | 각 열의 저비트 반올림 결과를 만든다. |
| ↓ | | |
| 02 | Weight perturbation | 원래 열과 임시 양자화 열의 차이를 계산한다. |
| ↓ | | |
| 03 | Sensitivity score | λ_j 와 열 perturbation 제곱합을 곱한다. |
| ↓ | | |
| 04 | Top-k 선택 | 점수가 큰 k개 input column을 weak로 지정한다. |
| ↓ | | |
| 05 | 정밀도 분리 | weak 열은 fp16, 나머지는 저비트 대상으로 둔다. |

Hessian만도 weight 오차만도 아닌 두 요소의 결합이 OWQ 선택 기준이다.

Ablation: weight 오차만 보면 민감한 열을 놓친다

WikiText- 2 perplexity이며 낮을수록 좋다.

모델	제안 점수	Hessian만	Weight 오차만	Weight 크기합
OPT-6.7B	11.23	11.25	13.08	14.77
LLaMA-7B	6.64	6.76	11.57	10.12

이 설정에서는 activation sensitivity를 포함한 기준이 weight-only 기준보다 낮다.

OWQ 저장 형식: 전체 열 단위 혼합 정밀도

열 2가 weak로 선택된 3 × 4 weight matrix의 편집 가능한 구조 예시다.

출력 행	열 1	열 2 weak	열 3	열 4
row 1	3-bit	fp16	3-bit	3-bit
row 2	3-bit	fp16	3-bit	3-bit
row 3	3-bit	fp16	3-bit	3-bit
별도 저장	dense low-bit	idx=2 + fp16 열	dense low-bit	dense low-bit

저비트 행렬의 weak 위치는 0으로 두고, fp16 열과 column index를 별도 보관한다.

나머지 열은 OPTQ로, weak 열은 마지막에 남긴다

01 열 순서 재배치 저비트 대상 열을 앞에, weak fp16 열을 뒤에 둔다.



02 저비트 열 양자화 OPTQ가 열을 순차적으로 quantize한다.



03 오차 보상 아직 양자화하지 않은 열의 값을 갱신한다.



04 Weak 열 유지 보상값을 받은 weak 열은 끝까지 fp16으로 남는다.

마지막까지 유연한 fp16 열이 앞선 저비트 양자화 오차를 흡수할 수 있다.

논문의 OPTQ 기준과 나중 repository 옵션을 구분한다

구분	원래 OPTQ 설명	논문 실험의 처리
기본 열 순서	순차 column quantization	OWQ의 weak 열은 뒤로 이동
Act-order	원 논문 이후 repository에 추가	OPTQ 기준선에 TS+AO 사용
True-sequential	원 논문 이후 repository에 추가	OPTQ 기준선에 TS+AO 사용
OWQ 적용	별도 선택 사항	명시되지 않으면 TS·AO 미사용

OPTQ라는 이름이 가리키는 기본 논문 방법과 이후 코드 옵션은 같은 조건이 아니다.

OWQ는 quantization range도 calibration으로 조정한다

01 Min-max 초기 범위 weight의 전체 범위에서 step과 zero point를 시작한다.



02 후보 범위 축소 truncation 정도를 바꾸며 2D grid search한다.




03 RTN 오차 평가 각 후보의 reconstruction error를 비교한다.



04 OPTQ 적용 선택된 설정 위에서 순차 보상 양자화를 수행한다.

범위 축소의 이점은 weak 열을 fp16으로 보호한 이 설정에서 관찰된 구현 선택이다.

추론은 두 GeMV 경로의 출력을 더한다



WCT는 선택된 기존 열만 학습한다

항목	WCT	LoRA·QLoRA
학습 대상	OWQ가 남긴 fp16 weak columns	추가된 low-rank adapter
Base weight	저비트 dense 부분 고정	base weight 고정
추가 구조	기존 weight 열을 직접 갱신	별도 저랭크 branch 추가
OWQ와 관계	OWQ 생성 뒤 task별 tuning	서로 다른 PEFT 구조

WCT는 LoRA의 다른 이름이 아니라 weak column 선택을 학습 파라미터 선택에도 재사용한다.

결과를 읽기 전에 실험 조건을 고정한다

항목	논문 조건
모델	OPT 125M-66B, LLaMA 7B-65B
Calibration	C4 무작위 128개 $\times$ 2,048 tokens
PTQ	재학습 없이 layer-wise quantization
반복	OWQ 수치는 서로 다른 seed 3회와 오차 범위
하드웨어	A100 80 GB 또는 RTX3090 24 GB

성과 overhead 수치는 이 calibration, 모델, 구현, GPU 조건에서 해석해야 한다.

WikiText-2: 작은 fp16 예산이 3-bit 손실을 줄인다

모델	방법	Effective bits	Perplexity 낮을수록 좋음
OPT-6.7B	OPTQ	3	12.88
OPT-6.7B	OWQ	3.01	11.21 $\pm$ 0.05
OPT-6.7B	OPTQ	4	11.14
OPT-6.7B	OWQ	3.1	11.14 $\pm$ 0.03
LLaMA-7B	OPTQ $\rightarrow$ OWQ	3 $\rightarrow$ 3.01	8.13 $\rightarrow$ 6.66 $\pm$ 0.04

선택된 설정에서 OWQ 3.1-bit는 OPTQ 4-bit와 비슷하지만 fp16에는 아직 못 미친다.

Few-shot 평균에서도 3-bit 기준선 격차를 줄인다

LLaMA-7B의 ARC-Challenge 25-shot, HellaSwag 10-shot, MMLU 5-shot 평균이다.

방법	Effective bits	평균 점수 높을수록 좋음	조건
Full precision	16	54.81	원본 모델
OPTQ	4	52.91	4-bit 기준선
OWQ	3.1	51.93 ± 0.48	fp16 weak 열 포함
OWQ	3.01	50.21 ± 0.45	fp16 weak 열 포함
OPTQ	3	47.06	TS+AO 기준선

OWQ의 이득은 perplexity뿐 아니라 지정된 few-shot 묶음에서도 관찰된다.

Group-wise 양자화와 OWQ는 서로 직교한다

LLaMA-7B 방법	WikiText-2 PPL	C4 PPL	Winogrande
OPTQ 3-bit	8.08	10.26	64.33
OPTQ 3-bit, group 128	6.56	8.36	67.60
OWQ 3.01-bit	6.65	8.62	67.05
OWQ 3.01-bit, group 128	6.40	8.18	69.57

Grouping을 OWQ에 더할 수 있지만, 별도 quantization parameter 저장 비용도 생긴다.

Weak column 예산이 늘면 품질 이득은 포화된다

OPT-6.7B, OPTQ 3-bit 기준 상대 overhead이며 latency 절댓값이 아니다.

Effective bits	WikiText- 2 PPL	Latency overhead	Memory overhead
3.005	11.38	2.89%	0.21%
3.01	11.22	2.91%	0.41%
3.05	11.19	4.19%	2.04%
3.10	11.17	6.21%	3.95%
3.30	11.13	8.69%	10.95%

Top-k 비율은 정확도·latency·memory를 교환하는 조절점이지 고정된 최적값이 아니다.

Latency 주장은 custom kernel 내부 비교다

LLaMA-7B layer group	OWQ 3.01-bit overhead	비교 기준
k/q/v/o	3.21%	논문의 3-bit OPTQ kernel
up/gate	2.34%	논문의 3-bit OPTQ kernel
down	2.03%	논문의 3-bit OPTQ kernel

이 수치는 fp16 대비 end-to-end speedup이나 모든 3-bit 형식의 보편 overhead가 아니다.

WCT 결과는 작은 GPT-4 judge 평가에 조건부다

설정	WCT r=64	QLoRA	해석
비교 결과	81 wins	54 wins	25 ties
평가 표본	Vicuna 80 questions	두 제시 순서	총 160 judgments
Base와 tuning	LLaMA-7B 4-bit OWQ	OpenAssistant subset	task adaptation
생성 조건	nucleus p=0.9	temperature 0.7	GPT-4 judge

WCT가 더 많이 이긴 결과는 이 judge·질문·생성 설정을 벗어난 일반 선호도 증명이 아니다.

OWQ를 주변 방법과 구분하기

방법	핵심 단위	OWQ와의 차이
RTN	각 weight 독립 반올림	출력 민감도·순차 보상 없음
OPTQ·GPTQ	Hessian 기반 순차 weight 보상	weak 전체 열을 fp16으로 남기지 않음
Magnitude outlier	큰 weight 값	OWQ는 출력 민감도로 열 선택
LoRA·QLoRA	추가 low-rank adapter	WCT는 기존 weak 열을 갱신
W4A4·KV 방법	activation 또는 cache도 압축	OWQ weight-only 범위 밖

OWQ는 민감한 input column을 보존과 tuning에 함께 쓴다.

논문이 보여 준 것과 남은 한계

축	확인된 근거	해석 한계
정확도	OPT·LLaMA의 PPL과 few-shot 개선	모든 LLM·task로 일반화 불가
민감도	Calibration Hessian 기반 열 선택	분포 이동 시 열 순위 변화 가능
효율	A100 custom kernel overhead 측정	다른 hardware의 속도 보장 아님
예산	Effective bit sweep의 trade-off	보편 최적 top-k 없음
미세조정	GPT-4 judge에서 WCT 비교	소규모 judge 평가에 조건부

열 선택과 속도는 calibration과 kernel에 의존한다.