

OWQ: 민감한 가중치 열을 보존하는 LLM 양자화

OWQ: Outlier-Aware Weight Quantization for Efficient Fine-Tuning and Inference of Large Language Models

Changhun Lee, Jungyu Jin, Taesu Kim, Hyungjun Kim, Eunhyeok Park (2024)

activation outlier가 만드는 weak column을 fp16으로 남기고 나머지 가중치를 저비트로 압축하는 weight-only PTQ

OWQ의 정확한 범위

구분	OWQ가 하는 것	범위 밖
대상	linear layer의 weight	activation·KV cache 양자화
절차	calibration 기반 layer-wise PTQ	대규모 재학습을 전제로 한 QAT
정밀도	저비트 dense weight + fp16 일부 열	모든 값이 같은 3.01-bit scalar
예외	embedding과 head는 full precision	완전한 W3A3 모델

OWQ는 weight-only 혼합 정밀도 PTQ이며 3.01-bit는 평균 저장 비용이다.

문제 정의: 가중치 오차가 아니라 출력 오차를 줄인다

- | | | |
|----|-----------------------------|---|
| 01 | 원래 weight W | full-precision linear layer의 가중치다. |
| ↓ | | |
| 02 | calibration X | 대표 입력 activation으로 민감도를 관찰한다. |
| ↓ | | |
| 03 | 양자화 weight W_{hat} | 압축 목표를 만족하는 저정밀 표현이다. |
| ↓ | | |
| 04 | 출력 비교 | WX 와 $W_{\text{hat}} X$ 의 제곱 오차를 최소화한다. |

같은 weight 오차라도 자주 크고 중요한 입력 방향에 놓이면 출력 영향이 커질 수 있다.

Weak column은 작은 열이 아니라 양자화에 민감한 열이다

판별 기준	보는 값	OWQ와의 관계
Weight magnitude	가중치 자체의 절댓값	선택 기준이 아님
Weight perturbation	반올림 전후 weight 변화	민감도 점수의 한 요소
Activation sensitivity	calibration 입력 방향의 에너지	Hessian 대각값으로 반영
Weak column	두 요소가 만든 출력 영향	상위 k개 열을 fp16 보존

OWQ는 큰 weight outlier가 아니라 output error에 민감한 전체 입력 열을 고른다.

Calibration activation에서 열별 민감도로

- 01 입력 행렬 X 행은 input feature, 열은 calibration token이다.
↓
- 02 $H = 2XX^T$ transpose layer output error의 곡률을 나타내는 행렬이다.
↓
- 03 대각값 λ_j feature j 의 calibration activation 에너지를 반영한다.
↓
- 04 열별 점수 λ_j 와 해당 열의 양자화 오차를 곱한다.

λ_j 는 calibration 데이터에서 얻은 민감도 성분이며 영구적인 중요도 보장은 아니다.

교육용 계산 1 : X가 Hessian 대각값을 만든다

논문 실험값이 아니라 식 4를 설명하기 위해 독립적으로 계산한 2×2 예다.

행렬	열 1	열 2	의미
X의 feature 1	1	0	feature 1 크기 1
X의 feature 2	0	3	feature 2 크기 3
$H = 2XX^T$	2	18	대각값 λ_1, λ_2

feature 2가 3배 크므로 제공 에너지는 9배, Hessian 대각값도 9배가 된다.

교육용 계산 2: 더 작은 weight 오차의 열이 선택된다

열 j	lambda_j	delta W 열의 제곱합	점수 s_j	fp16 보존
1	2	0.0200	0.0400	아니오
2	18	0.0032	0.0576	예

열 2는 raw weight 오차가 더 작아도 activation 민감도가 커서 fp16 예산을 받는다.

Weak column 선택 절차

- | | | |
|----|---------------------|--|
| 01 | 임시 양자화 | 각 열의 저비트 반올림 결과를 만든다. |
| ↓ | | |
| 02 | Weight perturbation | 원래 열과 임시 양자화 열의 차이를 계산한다. |
| ↓ | | |
| 03 | Sensitivity score | λ_j 와 열 perturbation 제곱합을 곱한다. |
| ↓ | | |
| 04 | Top-k 선택 | 점수가 큰 k개 input column을 weak로 지정한다. |
| ↓ | | |
| 05 | 정밀도 분리 | weak 열은 fp16, 나머지는 저비트 대상으로 둔다. |

Hessian만도 weight 오차만도 아닌 두 요소의 결합이 OWQ 선택 기준이다.

Ablation: weight 오차만 보면 민감한 열을 놓친다

WikiText- 2 perplexity이며 낮을수록 좋다.

모델	제안 점수	Hessian만	Weight 오차만	Weight 크기합
OPT-6.7B	11.23	11.25	13.08	14.77
LLaMA-7B	6.64	6.76	11.57	10.12

이 설정에서는 activation sensitivity를 포함한 기준이 weight-only 기준보다 낮다.

OWQ 저장 형식: 전체 열 단위 혼합 정밀도

열 2가 weak로 선택된 3×4 weight matrix의 편집 가능한 구조 예시다.

출력 행	열 1	열 2 weak	열 3	열 4
row 1	3-bit	fp16	3-bit	3-bit
row 2	3-bit	fp16	3-bit	3-bit
row 3	3-bit	fp16	3-bit	3-bit
별도 저장	dense low-bit	idx=2 + fp16 열	dense low-bit	dense low-bit

저비트 행렬의 weak 위치는 0으로 두고, fp16 열과 column index를 별도 보관한다.

나머지 열은 OPTQ로, weak 열은 마지막에 남긴다

01 열 순서 재배치 저비트 대상 열을 앞에, weak fp16 열을 뒤에 둔다.



02 저비트 열 양자화 OPTQ가 열을 순차적으로 quantize한다.



03 오차 보상 아직 양자화하지 않은 열의 값을 갱신한다.



04 Weak 열 유지 보상값을 받은 weak 열은 끝까지 fp16으로 남는다.

마지막까지 유연한 fp16 열이 앞선 저비트 양자화 오차를 흡수할 수 있다.

논문의 OPTQ 기준과 나중 repository 옵션을 구분한다

구분	원래 OPTQ 설명	논문 실험의 처리
기본 열 순서	순차 column quantization	OWQ의 weak 열은 뒤로 이동
Act-order	원 논문 이후 repository에 추가	OPTQ 기준선에 TS+AO 사용
True-sequential	원 논문 이후 repository에 추가	OPTQ 기준선에 TS+AO 사용
OWQ 적용	별도 선택 사항	명시되지 않으면 TS·AO 미사용

OPTQ라는 이름이 가리키는 기본 논문 방법과 이후 코드 옵션은 같은 조건이 아니다.

OWQ는 quantization range도 calibration으로 조정한다

01 Min-max 초기 범위 weight의 전체 범위에서 step과 zero point를 시작한다.



02 후보 범위 축소 truncation 정도를 바꾸며 2D grid search한다.




03 RTN 오차 평가 각 후보의 reconstruction error를 비교한다.



04 OPTQ 적용 선택된 설정 위에서 순차 보상 양자화를 수행한다.

범위 축소의 이점은 weak 열을 fp16으로 보호한 이 설정에서 관찰된 구현 선택이다.

추론은 두 GeMV 경로의 출력을 더한다



WCT는 선택된 기존 열만 학습한다

항목	WCT	LoRA·QLoRA
학습 대상	OWQ가 남긴 fp16 weak columns	추가된 low-rank adapter
Base weight	저비트 dense 부분 고정	base weight 고정
추가 구조	기존 weight 열을 직접 갱신	별도 저랭크 branch 추가
OWQ와 관계	OWQ 생성 뒤 task별 tuning	서로 다른 PEFT 구조

WCT는 LoRA의 다른 이름이 아니라 weak column 선택을 학습 파라미터 선택에도 재사용한다.

결과를 읽기 전에 실험 조건을 고정한다

항목	논문 조건
모델	OPT 125M–66B, LLaMA 7B–65B
Calibration	C4 무작위 128개 $\times$ 2,048 tokens
PTQ	재학습 없이 layer-wise quantization
반복	OWQ 수치는 서로 다른 seed 3회와 오차 범위
하드웨어	A100 80 GB 또는 RTX3090 24 GB

성능과 overhead 수치는 이 calibration, 모델, 구현, GPU 조건에서 해석해야 한다.

WikiText-2: 작은 fp16 예산이 3-bit 손실을 줄인다

모델	방법	Effective bits	Perplexity 낮을수록 좋음
OPT-6.7B	OPTQ	3	12.88
OPT-6.7B	OWQ	3.01	11.21 ± 0.05
OPT-6.7B	OPTQ	4	11.14
OPT-6.7B	OWQ	3.1	11.14 ± 0.03
LLaMA-7B	OPTQ $\rightarrow$ OWQ	$3 \rightarrow 3.01$	$8.13 \rightarrow 6.66 \pm 0.04$

선택된 설정에서 OWQ 3.1-bit는 OPTQ 4-bit와 비슷하지만 fp16에는 아직 못 미친다.

Few-shot 평균에서도 3-bit 기준선 격차를 줄인다

LLaMA-7B의 ARC-Challenge 25-shot, HellaSwag 10-shot, MMLU 5-shot 평균이다.

방법	Effective bits	평균 점수 높을수록 좋음	조건
Full precision	16	54.81	원본 모델
OPTQ	4	52.91	4-bit 기준선
OWQ	3.1	51.93 ± 0.48	fp16 weak 열 포함
OWQ	3.01	50.21 ± 0.45	fp16 weak 열 포함
OPTQ	3	47.06	TS+AO 기준선

OWQ의 이득은 perplexity뿐 아니라 지정된 few-shot 묶음에서도 관찰된다.

Group-wise 양자화와 OWQ는 서로 직교한다

LLaMA-7B 방법	WikiText-2 PPL	C4 PPL	Winogrande
OPTQ 3-bit	8.08	10.26	64.33
OPTQ 3-bit, group 128	6.56	8.36	67.60
OWQ 3.01-bit	6.65	8.62	67.05
OWQ 3.01-bit, group 128	6.40	8.18	69.57

Grouping을 OWQ에 더할 수 있지만, 별도 quantization parameter 저장 비용도 생긴다.

Weak column 예산이 늘면 품질 이득은 포화된다

OPT-6.7B, OPTQ 3-bit 기준 상대 overhead이며 latency 절댓값이 아니다.

Effective bits	WikiText- 2 PPL	Latency overhead	Memory overhead
3.005	11.38	2.89%	0.21%
3.01	11.22	2.91%	0.41%
3.05	11.19	4.19%	2.04%
3.10	11.17	6.21%	3.95%
3.30	11.13	8.69%	10.95%

Top-k 비율은 정확도·latency·memory를 교환하는 조절점이지 고정된 최적값이 아니다.

Latency 주장은 custom kernel 내부 비교다

LLaMA-7B layer group	OWQ 3.01-bit overhead	비교 기준
k/q/v/o	3.21%	논문의 3-bit OPTQ kernel
up/gate	2.34%	논문의 3-bit OPTQ kernel
down	2.03%	논문의 3-bit OPTQ kernel

이 수치는 fp16 대비 end-to-end speedup이나 모든 3-bit 형식의 보편 overhead가 아니다.

WCT 결과는 작은 GPT-4 judge 평가에 조건부다

설정	WCT r=64	QLoRA	해석
비교 결과	81 wins	54 wins	25 ties
평가 표본	Vicuna 80 questions	두 제시 순서	총 160 judgments
Base와 tuning	LLaMA-7B 4-bit OWQ	OpenAssistant subset	task adaptation
생성 조건	nucleus p=0.9	temperature 0.7	GPT-4 judge

WCT가 더 많이 이긴 결과는 이 judge·질문·생성 설정을 벗어난 일반 선호도 증명이 아니다.

OWQ를 주변 방법과 구분하기

방법	핵심 단위	OWQ와의 차이
RTN	각 weight 독립 반올림	출력 민감도·순차 보상 없음
OPTQ·GPTQ	Hessian 기반 순차 weight 보상	weak 전체 열을 fp16으로 남기지 않음
Magnitude outlier	큰 weight 값	OWQ는 출력 민감도로 열 선택
LoRA·QLoRA	추가 low-rank adapter	WCT는 기존 weak 열을 갱신
W4A4·KV 방법	activation 또는 cache도 압축	OWQ weight-only 범위 밖

OWQ는 민감한 input column을 보존과 tuning에 함께 쓴다.

논문이 보여 준 것과 남은 한계

측	확인된 근거	해석 한계
정확도	OPT·LLaMA의 PPL과 few-shot 개선	모든 LLM·task로 일반화 불가
민감도	Calibration Hessian 기반 열 선택	분포 이동 시 열 순위 변화 가능
효율	A100 custom kernel overhead 측정	다른 hardware의 속도 보장 아님
예산	Effective bit sweep의 trade-off	보편 최적 top-k 없음
미세조정	GPT-4 judge에서 WCT 비교	소규모 judge 평가에 조건부

열 선택과 속도는 calibration과 kernel에 의존한다.