

PIQA: 자연어로 묻는 물리적 상식


PIQA: Reasoning about Physical Commonsense in Natural Language

Yonatan Bisk, Rowan Zellers, Ronan Le Bras, Jianfeng Gao, Yejin Choi (2019)

일상 물체를 어떻게 다루지 묻는 두 선택지 benchmark가 언어모델의 물리 상식을 어떻게 진단하는가

왜 자연어 모델에 물리적 상식을 따로 묻는가

사람이 글로 자주 쓰는 해결책과 물체의 실제 성질·관계는 같은 정보가 아니다



PIQA의 한 문항: goal과 두 solution

입력 q, s1, s2가 주어지며 두 solution 중 정확히 하나가 가장 적절한 정답이다

요소	역할	무엇을 판단하는가
goal q	달성할 post-condition	무엇이 성공인가
solution s1	후보 절차 하나	물리적으로 성립하는가
solution s2	다른 후보 절차	더 적절한 선택은 무엇인가
label	정답 하나	두 후보 중 선택

PIQA는 새 계획을 만드는 문제가 아니라 주어진 두 후보를 비교하는 문제다

형식을 읽는 자체 제작 예시


아래 문항은 PIQA 원문·데이터가 아니라 두 선택지 형식을 설명하기 위해 새로 만든 예시다

항목	내용	판단 근거
goal	비 오는 날 메모를 젖지 않게 보관	물이 종이에 닿지 않아야 함
선택지 A	지퍼 비닐 봉투에 메모를 넣기	차단된 봉투가 물을 막음
선택지 B	젖은 수건으로 메모를 감싸기	수분이 종이에 전달됨
정답	A	이 예시에서만 물리적 판단

문장 유창성보다 goal의 성공 조건과 각 행동의 물리적 결과를 연결해야 한다

원문이 보인 두 종류의 물리적 판단

Fig. 2는 물체의 기본 속성을 묻는 경우와 여러 방법 중 더 편리한 것을 고르는 경우를 함께 보인다



데이터는 어떻게 만들어졌는가

how-to 자료는 annotator가 비전형적 일상 재료를 떠올리게 하는 발상 scaffold였다

01	Instructables 참고	여섯 범주의 how-to를 발상으로 사용
↓		
02	physical goal	성공 post-condition을 문장으로 작성
↓		
03	valid solution	goal을 달성하는 절차를 작성
↓		
04	plausible trick	그렇듯하지만 틀린 변형을 작성
↓		
05	QA pair	두 solution 중 하나만 정답으로 구성

trick은 무작위 오답이 아니라 물리·전제조건을 미세하게 어긴 그럴듯한 후보다

사람이 만든 문항도 검증과 제거를 거친다

qualification과 후속 validation은 애매하거나 전문 지식에 의존하는 문항을 줄이려는 장치다



정답 label은 자동 추론 결과가 아니라 사람의 작성·검증·합의 필터를 거친 결과다

원문이 보고한 데이터 규모와 균형 단서

정답과 trick의 표면 길이·어휘를 가깝게 만들어 단순한 문장 단서만으로 맞추기 어렵게 하려 했다

항목	원문 보고	의미
split	train 16K 초과; dev 약 2K; test 약 3K	v1에서의 대략 규모
길이	goal 7.8단어; solution 21.3단어 평균	정답·trick 길이 분포가 거의 같음
어휘	품사별 정답·trick 어휘 최소 85% 겹침	표면 단서 축소를 시도
어휘량	3.7M 초과 train lexical token	일상 물체·조작 표현 포함

길이와 어휘 균형은 필요한 통제지만, 모든 annotation artifact를 없애지는 못한다

AFLite: 쉽게 맞힐 수 있는 표면 artifact를 더 줄이기

AFLite는 표현 embedding만으로 label을 너무 잘 예측하게 만드는 instance를 찾아 버리는 bias-reduction 절차다



AFLite는 물리 정답 판정기가 아니라 표현 기반 예측 가능성을 낮추려는 filter다

평가: 각 후보를 score하고 둘 중 하나를 고른다

원문의 transformer fine-tuning은 goal과 각 solution을 독립적으로 넣고 두 score에 softmax를 적용한다



측정되는 것은 두 문장 후보의 상대적 선택 정확도이며, 실제 행동을 실행한 성공률이 아니다

2019년 원문 Table 1: 모델과 사람의 격차

가장 높은 test 모델 수치는 RoBERTa 77.1%였고, human 94.9%는 development set majority vote로 측정됐다

방법	Validation accuracy	Test accuracy
random / majority	50.0% / 50.5%	50.0% / 50.4%
OpenAI GPT 124M	70.9%	69.2%
Google BERT 340M	67.1%	66.8%
FAIR RoBERTa 355M	79.2%	77.1%
human	94.9%	원문 표에 test 값 없음

human·모델 차이는 원문 조건의 진단 신호이며, 조건을 지운 단일 순위가 아니다

작은 문장 차이도 물리적 결과를 크게 바꾼다

원문은 train-validation의 약 60%가 두 solution 사이 1-2단어 edit라고 보고하며, 이를 진단에 활용한다

관찰	원문의 방법	해석
편집 거리	tokenized-lowercase string의 edit distance	두 후보가 얼마나 다른지 측정
분포	약 60%가 1-2단어 edit	미세한 차이도 혼함
난이도	거리가 커질수록 대체로 어려움 증가	작은 edit도 충분히 혼동 가능
진단	한 phrase 차이를 가진 사례를 분석	어떤 상식 지식이 필요한지 관찰

두 답이 비슷해 보여도, 차이를 물리 결과와 연결해야 정답을 고를 수 있다

무엇에서 어려움을 보였는가

원문의 RoBERTa 진단은 흔한 단어라도 관계·다양한 affordance·동사 변화가 어려울 수 있음을 보였다

원문 관찰	Validation 분석 수치	읽는 방법
관계어	before·after·top·bottom 에서 거의 chance	미묘한 공간·시간 관계
water	75%	여러 물성과 용도를 가진 폭넓은 명사
spoon	90%	범위가 더 좁은 affordance 사례
freeze	66%	동사 변화도 어려운 사례

이 값은 선택된 validation subset의 진단값이지, 전체 물리 상식 점수는 아니다

자체 제작 trace: 한 단어 차이를 물성으로 검증하기

아래는 원문 문항이 아닌 강의용 예시로, goal의 성공 조건을 먼저 적으면 선택 근거를 재계산할 수 있다

단계	자체 제작 예시	검증
goal	젖은 접시를 닦아 물기를 없앤다	접시 표면의 물을 흡수해야 함
A	마른 천으로 접시를 닦는다	천이 물을 흡수하므로 성공
B	비닐 랩으로 접시를 닦는다	흡수가 아니라 표면에 물을 밀 수 있음
선택	A	목적의 post-condition으로 역검증

정답을 고른 뒤에도 ‘어떤 물성 때문에 goal이 달성되는가’를 말할 수 있어야 한다

PIQA 점수로 말할 수 있는 것과 없는 것

PIQA는 자연어 두 후보의 물리적 적절성 선택을 진단하지만, 실제 행동의 모든 능력을 직접 측정하지는 않는다

PIQA가 직접 측정	직접 보장하지 않음	원문이 남긴 방향
goal과 두 solution의 상대 선택	새 solution 생성·장기 계획	world interaction과 language 연결
자연어 표현의 physical commonsense	로봇의 실제 조작 성공	interaction으로 지식을 정교화
선택된 모델의 오류 양상	모든 언어·문화의 상식	언어만의 학습 한계 탐색

PIQA는 물리 상식의 일부를 드러내는 diagnostic이며, 실제 조작 능력의 완결된 시험은 아니다

PIQA를 읽는 다섯 가지 핵심

benchmark의 구성 요소와 평가 수치를 함께 보아야 ‘물리 상식’이라는 주장 범위를 정확히 읽을 수 있다

- 문제는 자연어의 유창함보다 goal을 이루는 물리 결과를 고르는 것이다.
- Instructables와 human-written trick은 비전형적 도구·미세 오류를 끌어낸다.
- 길이·어휘 균형과 AFLite는 다른 표면 artifact를 줄이려는 장치다.
- Table 1과 오류 분석은 특정 모델·split·subset의 조건부 증거다.
- 결론은 언어와 세계 interaction을 연결하는 표현을 향한다.

좋은 PIQA 해석은 높은 점수 하나가 아니라 문항 생성·통제·오류 양상을 함께 설명한다