

Potential-Based Shaping: 목표를 바꾸지 않는 보너스

Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping

Andrew Y. Ng, Daishi Harada, and Stuart Russell (1999)

추가 reward가 학습을 안내하면서도 원래 MDP의 최적 policy를 보존하려면 무엇이 필요한가

진행 보너스는 목표를 바꿀 수 있다

국소적으로 좋아 보이는 event reward가 반복 가능한 loop를 더 매력적으로 만들 수 있다

01 원래 과제 Goal에 도달하는 policy가 원래 reward에서 최선



02 추가 보너스 Goal 쪽으로 움직일 때마다 양의 reward를 더함



03 반복 경로 가까워지는 이동만 반복해 보너스를 누적



04 정책 변화 Goal보다 loop가 transformed reward에서 유리해질 수 있음

Shaping은 반복 loop를 원래 goal보다 유리하게 만들 수 있다

원래 MDP와 학습용 transformed MDP

상태와 dynamics는 그대로 두고 learner가 받는 transition reward만 R 에서 $R+F$ 로 바꾼다

구성	원래 M	학습용 M'	바뀌지 않는 것
Reward	$R(s,a,s')$	$R(s,a,s') + F(s,a,s')$	같은 transition에서 계산
State·action	S, A	S, A	상태와 선택지는 동일
Dynamics	T	T	다음 상태의 확률은 동일
질문	원래 task의 최적 policy	학습 중 최적 policy	두 argmax가 같은가

F는 같은 transition에 덧붙이는 training reward다

보존하려는 것은 reward 값이 아니라 행동 순위


한 상태에서 가능한 행동 중 어느 것이 최대 Q값을 갖는지가 원래 과제의 policy를 정한다

고정된 상태 s	행동 left	행동 right	Policy 판단
원래 Q*	10	8	left가 최대
Shaping 후 Q' *	7	5	둘 다 3만큼 이동
보존 여부	값은 달라짐	값은 달라짐	최대 행동은 동일
일반식	$Q' = Q^* - \phi(s)$	같은 state offset	argmax가 유지됨

Policy invariance는 reward 값이 아니라 action ranking의 보존이다

Transition마다 potential의 할인된 변화를 더한다

F는 도착 상태만의 보너스가 아니라 출발 potential을 함께 빼는 transition-level signal이다



Potential-based shaping의 정확한 형태는 $F(s,a,s') = \gamma \phi(s') - \phi(s)$ 다

$\gamma = 1$ 에서 closed cycle의 shaping 합은 0


순수한 potential difference는 출발 state로 돌아오면 누적 보너스를 남기지 않는다

순서	Transition	Shaping term	누적에서 남는 항
1	$u \rightarrow v$	$\phi(v) - \phi(u)$	$+\phi(v), -\phi(u)$
2	$v \rightarrow w$	$\phi(w) - \phi(v)$	$+\phi(w), -\phi(v)$
3	$w \rightarrow u$	$\phi(u) - \phi(w)$	$+\phi(u), -\phi(w)$
합	closed cycle	0	각 state 항이 상쇄

Closed loop에 양의 보너스가 남으면 순수 potential difference가 아니다

Discounted trajectory에서도 중간 potential은 지워진다

시간을 앞으로 펼치면 각 state의 플러스 항과 다음 transition의 마이너스 항이 같은 γ 거듭제곱으로 만난다



$\sum \gamma^t F_t$ 는 $-\phi(S_0) + \gamma^{(T+1)} \phi(S_{(T+1)})$ 로 정리된다

Residual을 없애는 조건은 γ 에 따라 다르다

수식의 cancellation만 보지 말고 마지막 potential을 통제하는 가정까지 함께 읽어야 한다

Setting	필요한 조건	남는 term의 처리	발표에서 말할 결론
$0 < \gamma < 1$	ϕ 가 bounded	$\gamma^{T+1} \phi(S_{T+1}) \rightarrow 0$	discounted return은 $-\phi(s)$ 만 이동
$\gamma = 1$	absorbing s_0 , 모든 policy proper	결국 s_0 에 도달	$\phi(s_0)=0$ 으로 WLOG 정규화
finite state	유한한 ϕ range	boundedness가 자동	정리의 기본 대상
infinite state	추가 regularity와 bounded ϕ	기댓값 존재도 필요	원 논문은 조건부 일반화만 언급

$\gamma = 1$ 은 proper absorption이 핵심이며, terminal constant는 WLOG 정규화한다

Bellman equation은 transformed Q의 형태를 고정한다

원래 optimal Q에서 $\phi(s)$ 를 뺀 후보가 $R+F$ 를 쓰는 M' 의 Bellman equation을 만족한다

01	원래 optimal Q	R과 미래 최대 Q로 Bellman update
↓		
02	state offset	$Q_{M^*}(s,a)$ 에서 $\phi(s)$ 를 뺀
↓		
03	F 대입	$\gamma \phi(s') - \phi(s)$ 를 R에 더함
↓		
04	같은 Bellman 식	후보 Q가 M' 의 optimal equation을 만족
↓		
05	결론	$Q_{M'}^*(s,a) = Q_{M^*}(s,a) - \phi(s)$

증명은 shaping return의 직관을 Bellman optimality equation으로 엄밀하게 확인한다

같은 state에서는 모든 action에 같은 값을 뺀다

$\phi(s)$ 는 action a 가 아니라 출발 state s 에만 의존하므로 action ordering을 바꾸지 않는다

state s	원래 $Q_M^*(s,a)$	Shaped $Q_M'^*(s,a)$	argmax
action a_1	$Q_M^*(s,a_1)$	$Q_M^*(s,a_1) - \phi(s)$	원래와 같은 비교
action a_2	$Q_M^*(s,a_2)$	$Q_M^*(s,a_2) - \phi(s)$	원래와 같은 비교
action a_3	$Q_M^*(s,a_3)$	$Q_M^*(s,a_3) - \phi(s)$	원래와 같은 비교
최적 policy	가장 큰 원래 Q 선택	같은 가장 큰 index 선택	optimal set 보존

Potential-based shaping은 original optimal-policy set을 보존한다

‘필요’는 unknown MDP에 대한 보장의 범위다

Non-potential F는 어떤 fixed MDP에서는 우연히 관찰을 수 있지만 arbitrary proper MDP 전체에는 보장할 수 없다

질문	Fixed known MDP	T와 R을 모르는 universal setting
무엇을 아는가	특정 T와 R의 구조를 안다	S, A, γ 외의 상세를 모른다
Non-potential F	특정 task에서 ranking이 우연히 보존될 수 있음	어떤 proper T,R에서는 policy를 바꿀 수 있음
Theorem 1의 necessity	다른 설계를 완전히 금지하지 않음	Potential form이 필요
정확한 표현	task-specific analysis 필요	universal policy-invariance guarantee

Potential form의 necessity는 unknown MDP 전체에 대한 보장이다

할인된 loop 보너스도 원래 최적 행동을 뒤집을 수 있다

교육용 $\gamma = 0.9$ 예시: 원래 goal 보상은 1, loop 보상은 0이다

01 원래 선택 u 또는 $v \rightarrow \text{Goal: } R=1, F=0$



02 $u \rightarrow v$ $R=0, F=+1$



03 $v \rightarrow u$ $R=0, F=+1$



04 계속 반복 $R+F \text{ return} = 1 / (1 - 0.9) = 10$

원래는 즉시 Goal이 최선이지만, 잘못된 shaping 후에는 loop의 return이 10이다

Policy invariance와 learning speed는 다른 주장

Theorem은 objective ranking을 다루고, 실험은 특정 learner와 heuristic 아래의 learning curve를 보여준다

구분	논문이 이론으로 보임	실험 또는 별도 평가가 필요한 것
최적 policy	원래 M 과 M' 의 optimal set 보존	가정이 맞는지 확인
Near-optimal policy	임의 policy에도 value offset identity	finite training에서 얼마나 가까운지
Learning speed	일반적 속도 정리는 아님	ϕ , exploration, learner에 의존
Approximation	neural optimizer를 직접 분석하지 않음	function approximation과 tuning 평가
실행 결과	transformed reward만으로 충분하지 않음	terminal 처리와 implementation 점검

Policy 보존 theorem은 자동 speedup theorem이 아니다

Exact value와 heuristic은 모두 potential 후보

$\phi = V_M^*$ 는 transformed optimal value를 0으로 만들지만, theorem은 정확한 V_M^* 를 요구하지 않는다

Potential 선택	의미	논문에서의 역할
$\phi(s) = V_M^*(s)$	이상적으로 정확한 original optimal value	$V_M^*(s) = 0$ 이 되는 특별한 선택
거리 heuristic	Goal까지 남은 비용의 거친 estimate	10×10 shortest path에서 ϕ_0 구성
$0.5 \phi_0$	정확한 value에서 더 먼 scaled heuristic	그래도 learning guidance가 될 수 있음을 비교
Subgoal heuristic	ordered progress를 potential jump로 표현	5×5 flags task에서 사용

Potential은 exact optimal value일 필요가 없다

Distance-to-goal grid world의 실험 조건

이 결과는 no-discount shortest-path task에서 Sarsa가 받은 shaping을 비교한 historical experiment 다

항목	10×10 task	50×50 task	공통 학습 조건
시작과 goal	서로 반대 corner	같은 shortest-path 구성	steps-to-goal 측정
Reward	매 step -1, no discount	같은 reward	원래 task reward
Action dynamics	4 compass, 80% intended	같은 dynamics	20% random; 경계 stay
Potential 비교	none, ϕ_0 , $0.5 \phi_0$	같은 비교	Sarsa; $\epsilon = 0.10$; $\alpha = 0.02$
집계	40 independent runs 평균	40 independent runs 평균	Fig. 1 curve

Reported curve는 stochastic dynamics와 Sarsa protocol 아래의 결과다

거리 heuristic은 potential로 바뀌야 한다


목표까지의 Manhattan distance를 0.8로 보정한 ϕ_θ 를 사용하고, result는 reported steps-to-goal curve로 읽는다

구성	정의 또는 조건	Fig. 1에서의 관찰	말할 수 없는 것
ϕ_θ	$-\text{MANHATTAN}(s, \text{GOAL}) / 0.8$	no shaping보다 빠른 학습 curve	정확한 V_M^* 라는 주장
$0.5 \phi_\theta$	ϕ_θ 의 절반	초기 학습을 여전히 도움	모든 task에서 같은 개선율
50×50	같은 구성의 더 큰 grid	visual gap이 더 크게 보임	현재 hardware benchmark
Result 범위	reported Sarsa averages	steps-to-goal 감소	모든 RL algorithm의 speedup

거친 distance estimate도 potential form이면 learning guidance가 될 수 있다

Ordered subgoal은 state progress를 확장한다

5 × 5 task에서는 1, 2, 3, 4, G를 정해진 순서로 방문했는지가 state에 포함된다



Subgoal potential은 collected flag를 포함한 expanded state 위에 정의된다

Subgoal reward도 potential jump로 구성한다

단순 ϕ_0 는 nonfinal subgoal을 지나면 jump하고, refined ϕ_1 는 state별 remaining time estimate를 사용한다

Potential	구성 아이디어	Transition에서 생기는 F	Fig. 2 비교
단순 ϕ_0	남은 subgoal 수와 예상 time	nonfinal subgoal 도달 때 potential jump	no shaping보다 빠른 curve
Refined ϕ_1	각 state의 남은 time을 더 세밀하게 estimate	같은 $\gamma \phi(s') - \phi(s)$ form	ϕ_0 보다 더 좋은 curve
공통 조건	5×5 ordered flags task	policy ranking 보존 form	Sarsa averages
해석	subgoal bonus를 임의로 누적하지 않음	departure term도 포함	specific task evidence

Subgoal bonus도 potential difference로 만들면 original goal을 대체하지 않는다

적용 전 확인할 다섯 가지

이 checklist는 논문의 theorem boundary를 새 task에 옮길 때 빠뜨리기 쉬운 조건을 드러낸다

질문	확인할 내용	놓치면 생기는 위험
Discount는?	F에 같은 γ 를 사용했는가	discounted guarantee가 사라짐
Terminal은?	$\gamma = 1$: proper absorption, terminal 상수 정규화	종료 tail 통제 불가
Potential은?	ϕ 가 state만의 bounded function인가	action preference 주입
원래 objective는?	R과 R+F의 optimal policy를 구분했는가	보너스 loop를 task로 오인
실제 효율은?	learner와 exploration에서 별도 evaluate했는가	invariance를 speedup으로 과장

Potential form 검증과 empirical learning evaluation은 서로 대체할 수 없는 두 단계다

결론: 보너스가 바뀌면 안 되는 것은 action ranking이다

Potential-based shaping은 learning signal을 추가하면서도 original MDP의 optimal-policy set을 유지하는 정리된 방법이다

- $F(s,a,s') = \gamma \phi(s') - \phi(s)$ 는 discounted return에서 중간 potential을 상쇄시킨다.
- 각 state의 Q에는 같은 $-\phi(s)$ 가 더해져 argmax가 보존된다.
- 필요충분은 unknown MDP 전체의 guarantee이지 fixed MDP 설계 금지가 아니다.
- $\gamma = 1$ 은 absorbing proper, $\gamma < 1$ 은 bounded ϕ 가 필요하다.
- Grid result는 Sarsa 조건의 evidence이며 speedup theorem은 아니다.

Bonus는 discounted potential difference로 설계해야 original action ranking을 지킨다