

COLA: 압축 뒤 LLM 능력을 지키는 보정 데이터 큐레이션

Preserving LLM Capabilities through Calibration Data Curation: From
Analysis to Optimization

Bowei He, Lihao Yin, Huiling Zhen, Shuqi Liu, Han Wu, Xiaokun Zhang, Mingxuan Yuan, Chen Ma (2025)

압축 알고리즘을 바꾸지 않고, 그 알고리즘이 볼 보정 입력을 고르는 방법을 묻는다

이 강의가 따르는 공개 원문

arXiv v1을 기준으로, 보고된 실험과 방법의 범위를 분리해 읽는다

- arXiv:2510.10618v1, 2025년 10월 12일 제출본
- 공개 arXiv record는 NeurIPS 2025 accepted를 표시한다
- 저자 8명: Bowei He 외 7명
- 이 자료의 수치·식·페이지는 해당 42쪽 v1 PDF를 따른다
- 후속 개정본이나 미확인 구현 결과를 덧붙이지 않는다

‘accepted’ 표기는 공개 record의 상태이며, 이 텍스트의 과학적 근거는 고정된 v1 PDF다

보정 데이터는 기존 압축기가 보는 관측 창이다

작은 입력 묶음이 layer activation을 만들고, 그 activation이 기존 압축 결정을 안내한다

01	보정 입력	작은 calibration 입력 표본
↓		
02	forward pass	압축 전 LLM에 표본을 통과
↓		
03	layer activation	입력별 반응 패턴을 얻는다
↓		
04	기존 압축기	가중치 제거·근사 규칙을 적용
↓		
05	압축 모델	여러 능력 평가로 보존 정도를 본다

같은 압축 방법이라도 어떤 보정 입력을 보았는지에 따라 다른 능력이 더 손실될 수 있다

COLA가 바꾸는 것과 바꾸지 않는 것

압축기 자체가 아니라, 그 앞단의 calibration set을 고르고 가공하고 대표 표본을 뽑는다

대상	COLA가 하는 일	COLA가 하지 않는 일
압축 방법	기존 방법에 맞는 입력을 준비	AWQ·GPTQ·SparseGPT·Wanda를 대체하지 않음
모델 가중치	압축 전 반응을 관찰	사전학습·fine-tuning으로 새 능력을 가르치지 않음
보정 데이터	도메인·형식·활성화 공간을 기준으로 큐레이션	원 학습 코퍼스를 복원한다고 주장하지 않음
목표	이미 학습된 능력의 손실을 줄이려 시도	모든 능력 보존을 보장하지 않음

논문은 네 질문을 순서대로 잇는다

관찰(Q1·Q2)에서 최적성(Q3), 그리고 실제 큐레이션(Q4)로 넘어간다

질문	무엇을 바꾸나	다음 단계에 주는 근거
Q1	길이·개수·출처·형식	구성적 속성의 영향
Q2	언어·주제·추론 난이도	배포 도메인 대응
Q3	관찰을 하나의 기준으로 묶기	대표성·다양성의 정의
Q4	후보 데이터에서 실제 set 만들기	COLA 3단계 프레임워크

COLA는 먼저 데이터 민감성을 실험으로 관찰한 뒤, 그 관찰을 선택 규칙으로 바꾼다

관찰을 해석하기 위한 실험 조건

결론은 두 Instruct 모델, 네 사후학습 압축 설정, 정해진 능력 평가 안에서 나온다

항목	논문 조건	해석 경계
LLM	LLaMA3-8B-Instruct, Qwen2.5-7B-Instruct	모든 모델 구조를 대표하지 않음
pruning	SparseGPT 50%, Wanda 4:8	구조적 pruning은 평가하지 않음
quantization	GPTQ·AWQ, 4-bit	다른 bit·activation 설정의 보장 아님
기본 보정	출처별 128개 × 2,048 token	길이·개수 실험에서는 달라짐
능력 평가	PPL·상식·수학·코드·다국어	지표마다 방향과 의미가 다름

Q1: 텍스트의 구성적 속성도 압축 뒤 능력을 바꾼다

한 축을 늘리는 단순 규칙이 아니라, 능력·모델·압축법별 반응을 함께 본다

바꾼 축	논문이 관찰한 패턴	바로 일반화할 수 없는 이유
sequence length	수학·pruning이 특히 민감한 경우	code는 비단조 곡선을 보임
sample amount	핵심 activation 뒤에는 체감 이득	더 많은 표본이 특화 과제를 악화시킬 수 있음
source	C4·WikiText·SlimPajama 선호가 다름	선호는 능력과 compressor마다 다름
format	명시적 reasoning QA가 추론 과제에서 유리	모든 과제·입력에서의 보장 아님

반례: 표본 수 증가가 code 점수를 올리지는 않는다

Figure 3의 두 조건은 ‘보정 표본 수 증가 = 성능 향상’이라는 해석을 막는다

모델·압축	16개 표본	128개 표본	논문이 보여 주는 점
LLaMA3-8B + AWQ	code 46.40	code 38.71	더 많은 표본이 이 조건에서는 하락
Qwen2.5-7B + GPTQ	code 57.67	code 34.03	비단조 반응이 더 크게 나타남
LLaMA3-8B + SparseGPT	적은 표본에서 math 17.9% 하락	별도 조건	pruning은 표본 수에 더 민감할 수 있음

COLA가 sample count를 고정 상수가 아니라 선택해야 할 설계 변수로 다루는 출발점이다

Q2: 배포 도메인에 맞춘 입력은 다른 경로를 활성화한다

언어·주제·난이도를 목표 능력과 맞추되, 일반 성능과의 trade-off를 함께 점검한다

대응 축	원문의 관찰	큐레이션에 주는 질문
언어	특화 능력에서 차이가 크며, 다국어 평가는 같은 언어 입력이 유리할 수 있음	주 사용자 언어는 무엇인가
주제	MathQA·CodeQA 등이 대응 능력을 높일 수 있음	어떤 능력을 우선 보존할 것인가
난이도	hard는 reasoning 이득, mixed는 균형을 보일 수 있음	전문 과제인가 일반 배포인가

주제 일치의 이득에는 PPL 비용이 있을 수 있다

Table 1의 Qwen2.5-7B + AWQ 사례는 MathQA가 math를 높이면서 PPL을 높이는 모습을 보인다

calibration data	PPL 낮을수록 좋음	Math 높을수록 좋음	읽는 법
WikiText	17.36	47.34	일반 텍스트 기준선
MathQA	19.25	54.42	목표 math는 상승, PPL은 악화
CodeQA	18.95	43.85	다른 주제는 math 보존의 대안이 아님

‘가장 좋은 calibration’은 하나의 점수가 아니라 배포 우선순위가 정하는 다목적 선택이다

관찰을 두 기준으로 압축하기: 대표성 + 다양성

저자들은 좋은 보정 set을 텍스트의 표면적 특징보다 activation space의 두 성질로 설명한다

- 대표성: 목표 도메인에서 전형적인 activation pattern을 잘 유발하는가
- 다양성: 서로 다른 activation pattern을 충분히 폭넓게 포함하는가
- 도메인·언어·주제의 일치는 대표성의 한 단서가 될 수 있다
- mixed 난이도·format richness·여러 표본은 다양성의 한 단서가 될 수 있다
- 두 기준의 균형은 general deployment와 targeted deployment에서 다를 수 있다
- 이는 원문 실험에서 얻은 설계 관점이며, 최적성 정리는 아니다

COLA의 핵심 선택 단위는 ‘좋아 보이는 문장’이 아니라 모델이 보이는 activation 공간이다

COLA 흐름: 데이터셋에서 대표 표본까지

세 큐레이션 단계가 끝난 뒤에만 기존 compressor가 그 작은 set을 읽는다

01	후보 데이터 D	사전학습·도메인 후보 풀
↓		
02	Stage 1 선택	목표 능력·도메인에 맞는 출처
↓		
03	Stage 2 가공	길이·형식·reasoning richness 조정
↓		
04	Stage 3 표본	activation 공간에서 대표·다양 표본
↓		
05	기존 압축	선택 set으로 AWQ·GPTQ·pruning 수행

COLA의 output은 압축된 가중치가 아니라, 기존 압축기에 넣을 calibration set이다

Stage 1: 먼저 배포 목표에 맞는 후보 출처를 고른다

원문 Eq. (1)은 capability별 우선순위와 coverage를 이용해 S를 D에서 선택한다

기호	의미	Stage 1에서의 역할
D	사용 가능한 dataset 후보 풀	S를 고를 출발점
C	보존하려는 capability 집합	예: language·math·code
w_c	capability c의 중요도	배포 우선순위를 반영
coverage(S,c)	S가 c를 얼마나 덮는지	가중 합을 크게 하는 S를 선택

읽기 쉬운 형태로 쓰면 ‘ $S \subseteq D$ 에서 $\sum w_c \times \text{coverage}(S,c)$ 를 최대화’하는 선택이다

Stage 2: 출처를 과제 맞춤 입력으로 가공한다

원문은 길이와 format richness를 조정하되, 한 가지 길이·형식이 항상 최고라고 말하지 않는다

01	선택한 출처	Stage 1에서 고른 dataset
↓		
02	길이 설정	보통 2,048 token, 방법별 조정 가능
↓		
03	구조 확인	질문·답·추론 구조가 있는지 본다
↓		
04	format 보강	가능할 때 explicit reasoning QA로 변환
↓		
05	처리된 후보	Stage 3가 고를 sample pool

형식 보강은 모든 텍스트에 reasoning을 만들라는 뜻이 아니라 조건부 처리 단계다

Stage 3: activation 공간에서 대표 표본을 고른다

원문 Eqs. (2)–(3)은 압축 전 모델 반응을 줄여서 군집화하고, 각 중심에 가까운 표본을 택한다

01	원 모델 forward	후보 x_i 를 압축 전 모델에 통과
↓		
02	activation 벡터	layer별 hidden state를 집계
↓		
03	random projection	D차원을 더 작은 d차원으로 축소
↓		
04	k-means	투영 벡터를 k개 cluster로 묶음
↓		
05	centroid 대표	각 중심에 가장 가까운 x_i 를 선택

k는 final sample 수이며, centroid 가까움은 그 cluster의 대표성을 노린다

강의용 계산: centroid 대표를 직접 고르기

가정: 투영 뒤 $a=(1,1)$, $b=(1,2)$, $c=(2,2)$ 는 C1, $d=(8,8)$ 는 C2이며 $k=2$ 다

표본	projected a-prime	cluster	centroid까지 거리	선택
a	(1, 1)	C1	약 0.75	아님
b	(1, 2)	C1	약 0.47	C1 대표
c	(2, 2)	C1	약 0.75	아님
d	(8, 8)	C2	0	C2 대표

최종 set은 {b, d}: 각 cluster에서 '가장 대표적인' activation 반응 하나씩이다

이 toy가 보여 주는 것과 보여 주지 않는 것

nearest-centroid 규칙은 selection 규칙을 설명하지만, 실제 모델의 activation 계산을 대체하지 않는다

- b와 d는 원문 실험에서 최고 점수를 낸 문장이 아니다
- ‘두 cluster’는 toy의 선택이며, 실제 k는 최종 sample 수를 제어한다
- random projection 숫자도 toy의 가정이며, 논문 측정값이 아니다
- 한 cluster의 중심에 가까움은 그 cluster 안에서의 대표성이다
- 여러 cluster를 남기는 것이 activation-space 다양성을 표현한다
- 텍스트 의미가 비슷해도 activation이 같다는 뜻은 아니다

COLA는 전역 최고 문장 순위보다 여러 activation 영역을 대표 표본으로 덮는 방식에 가깝다

일반 배포 결과: 한 조건을 같은 행에서 비교하기

Table 2의 LLaMA3-8B + SparseGPT 50%에서 commonsense score는 COLA가 가장 높다

calibration approach	commonsense score	WikiText 대비	조건
WikiText random	41.85	기준	general deployment
Self-Gen	43.61	+1.76 point	같은 SparseGPT 50%
COLA	44.23	+2.38 point	LLaMA3-8B

이 수치는 한 model-compressor-metric의 경험적 1-2 point대 개선일 뿐, 보장은 아니다

목표 배포 결과: code용 calibration을 고른 조건

Table 6의 Qwen2.5-7B + AWQ 4-bit, code deployment에서 COLA가 가장 높은 code score를 보고한다

calibration approach	code score	CodeQA random 대비	조건
CodeQA random	68.73	기준	targeted code deployment
Self-Gen	70.05	+1.32 point	같은 AWQ 4-bit
COLA	72.18	+3.45 point	Qwen2.5-7B

목표 도메인 선택은 이 조건에서 차이가 컸지만, 다른 deployment 성능을 대변하지 않는다

더 큰 모델에서도 본 조건부 관찰

Appendix H는 큰 모델의 general deployment에서도 같은 비교 틀을 추가로 보고한다

모델·압축	metric	WikiText random	COLA	차이
LLaMA3.1-70B + AWQ 4-bit	commonsense	71.84	74.15	+2.31 point
Qwen2.5-32B + GPTQ 4-bit	math	45.62	47.26	+1.64 point

대형 모델 표도 가능성을 보일 뿐, 논문이 측정한 조합에 한정된다

spectral analysis는 보조 설명이지 정리는 아니다

Appendix E는 GPTQ 4-bit에서 FFN weight의 주파수·energy 그림을 비교해 activation-space 해석을 보강한다

- Figure 7은 LLaMA3-8B 32개 layer의 FFN spectrum을 시각화한다
- Figure 8은 compressed/original magnitude ratio가 1에 가까운지를 본다
- Figure 9는 low·mid·high band energy 분포를 layer별로 비교한다
- 저자들은 COLA가 원 모델의 분포에 더 가까운 패턴을 보인다고 해석한다
- 그러나 이 분석은 GPTQ 4-bit와 해당 시각화 설정의 empirical evidence다
- 특정 frequency band가 특정 능력을 ‘저장한다’는 인과 정리를 증명하지 않는다

이 그림들은 COLA 설계의 해석 근거이지, activation-space 최적성의 형식 증명은 아니다

Proxy pilot: coverage 추정 가능성

Appendix J는 작은 proxy 평가가 full evaluation 기반 coverage와 얼마나 맞는지 별도로 살핀다

capability	상관 r	proxy 설정	해석 경계
commonsense	0.97	BoolQ 대표 benchmark	이 논문의 후보 데이터 5회 평균
math	0.93	GSM8K 대표 benchmark	full evaluation을 일반적으로 대체한다는 보장 아님
code	0.91	HumanEval 대표 benchmark	unseen dataset까지 검증하지 않음
end-to-end	평균 gap ≤ 0.2 point	LLaMA3-8B만	시간 제한으로 제한된 실험

proxy는 수동 heuristic을 줄일 가능성을 보인 pilot이지, 자동 선택 보장은 아니다

큐레이션의 one-time offline 비용

Table 14는 general scenario에서 네 main compressor에 평균한 Self-Gen과 COLA breakdown을 보고한다

모델	Self-Gen 시간	COLA 전체 시간	COLA peak memory
LLaMA3-8B	2.58 min	6.35 min	7.90 GB
Qwen2.5-7B	2.35 min	5.54 min	7.52 GB

COLA에는 compact calibration set을 위한 one-time offline 비용이 있다

Pretraining/SFT와 calibration curation은 다르다

Appendix P는 ‘새 능력을 가르치는 데이터’와 ‘압축 중 기존 능력을 보존할 입력’을 구분한다

관점	pretraining / SFT	post-training calibration curation
시점	학습 중 능력 습득·정렬	학습 뒤 압축 중 능력 보존
규모	대규모 corpus 중심	대개 매우 작은 표본 set
데이터 역할	지식·행동을 새로 학습	기존 parameter 반응을 드러내는 진단 입력
선정 기준	일반화용 coverage와 품질	activation-space 대표성·다양성

둘 다 curation이지만, COLA를 fine-tuning recipe로 읽으면 안 된다

마무리: calibration 최적성은 조건부다

COLA는 deployment-aligned source·processing·activation-space selection을 묶어 기존 압축 앞단을 바꾼다

- 문제: compressor가 볼 작은 input set이 능력 손실의 방향을 바꿀 수 있다
- 제안: domain·구성·activation-space의 3단계 curation
- 근거: 두 base LLM과 정해진 pruning·quantization 조건에서의 empirical tables
- 한계: 더 많은 architecture·압축 비율·능력·장기 domain shift는 미검증
- 이론: optimal calibration의 최소 조건이나 보장은 아직 제시되지 않았다
- 실무: 우선 보존 능력을 정한 뒤 coverage weight를 정한다

압축법이 관찰할 activation도 설계 대상이라는 관점이 핵심이다