

QECO-Adapt: 고밀도 MEC의 초기 학습 손실 줄이기

Dense MEC 환경에서 QECO-ADAPT의 부하 적응형 오프로딩 성능 분석

나현우, 이창우 (2026)

기존 D3QN/LSTM을 유지하며, 부하에 따라 energy cost와 offloading 제어를 조정한다

왜 최종 성능만으로는 부족한가

학습이 진행되는 동안 생긴 지연과 미완료 task도 서비스가 치르는 비용이다

- 많은 사용자가 하나의 edge에 요청하면 queue와 deadline 실패가 늘 수 있다
- 후반에 비슷한 성능에 도달하더라도 초반 손실은 이미 누적된다
- QECO-Adapt는 전체 학습 구간의 QoE·지연·에너지·미완료 task를 함께 본다
- 목표는 dense 조건의 warm-up 손실 완화이며, 최종 정책의 보편적 우위가 아니다

1x·3x·5x·8x는 어떻게 정했는가

기준은 QECO 원문의 평균 밀도 $50 \text{ MD} / 5 \text{ EN} = 10 \text{ MD/EN}$ 이다

사용자 N	edge M	N/M	기준 대비
10	1	10	1x
30	1	30	3x
50	1	50	5x
80	1	80	8x

밀도 배율은 사용자 수 / edge 수의 비율이며, 시스템 전체의 동등성을 뜻하지 않는다

effective load에 들어가는 네 가지 양

$L_{\text{eff}} = N \times \bar{b} \times \bar{a} / M$: edge당 평균 task pressure를 나타내는 proxy

기호	정의	역할
N, M	사용자 수, edge 수	N 이 크거나 M 이 작으면 부하 증가
$\bar{b}$	시간대별 arrival profile의 평균	시간에 따른 task 생성 경향
$\bar{a}$	사용자별 활동성 계수의 평균	사용자 집단의 평균 활동성
L_{eff}	$N \times \bar{b} \times \bar{a} / M$	관측 queue length 자체는 아님

생성 확률과 load proxy는 항상 같지 않다


교육용 예: 사용자 한 명, edge 하나, $b=0.8$, $a=2$ 를 가정한다

계산	값	의미
$b \times a$	1.6	clipping 전 곱
$p_{\text{arrive}} = \text{clip}(1.6, 0, 1)$	1	생성 확률은 1을 넘지 않음
$L_{\text{eff}} = N \times \bar{b} \times \bar{a} / M$	1.6	원고 식으로 계산한 proxy

L_{eff} 는 부하를 제어값으로 바꾸기 위한 지표이지, queue stability의 증명은 아니다

부하 지표가 제어에 반영되는 경로

g 는 부하 강도, w_E 는 energy cost의 상대 가중치다



g 의 수치가 곧 task를 차단할 확률이라는 해석은 원고로 뒷받침되지 않는다

부하가 커질 때 energy weight는 어떻게 변하나

원고의 식과 상수: $w_0=1.20$, $\rho =0.35$, $\lambda =10$

항목	식 또는 성질	해석
gating strength	$g = L_{\text{eff}} / (L_{\text{eff}} + M\lambda)$	고정 M에서 L_{eff} 증가 $\rightarrow$ g 증가
energy weight	$w_E = 1.2 \times (1+g)^{0.35}$	g 증가 $\rightarrow$ energy cost 가중치 증가
범위	$0 \leq g < 1$	$L_{\text{eff}} \geq 0$, $M\lambda > 0$ 일 때
한계값	$1.2 \leq w_E < \text{약 } 1.5295$	상한은 이 식에서 계산한 값

교육용 계산: 같은 profile에서 사용자를 늘리면

$\bar{b}=0.2$, $\bar{a}=1$, $M=1$ 을 가정한 계산이며 원고의 실험 설정값이 아니다

N	L_eff	g	w_E
10	2	0.1667	1.2665
30	6	0.3750	1.3415
50	10	0.5000	1.3830
80	16	0.6154	1.4193

제어 계수의 증가와 실제 시스템 성능 향상은 별도로 검증할 사항이다

학습 보상: 완료 보너스에서 cost를 뺀다

$$C = 2 \times [sD + (1-s)w_E E_{sc}], \text{ 완료 보너스는 } 4D_{\max}$$

항목	정의	현재 설정
s	단말 energy state	delay·energy cost의 상대 반영
D, E_sc	task delay, scaled energy	w_E는 energy 항에만 적용
미완료 task	reward = -C	deadline 안에 끝나지 않음
완료 task	reward = 4D_max - C	D_max=10 → 완료 보너스 40

교육용 계산: 완료 여부와 cost를 분리한다

N=50 구성 예의 $w_E \approx 1.383$ 에 $s=0.5$, $D=4$, $E_{sc}=2$ 를 넣는다

단계	계산	결과
delay 항	$sD = 0.5 \times 4$	2
energy 항	$(1-s)w_E E_{sc}$	약 1.383
합산 cost	$C = 2 \times (2 + 1.383)$	약 6.766
완료 / 미완료	$40-C / -C$	약 33.234 / -6.766

왜 policy-invariant shaping이 아닌가

기존 QECO의 최적 정책을 보존한다고 증명된 reward shaping이 아니다

- w_E 가 energy 항의 비중을 바꾸므로 delay와 energy 사이의 선호가 달라진다
- offloading gating까지 적용하면 실제 실행되는 행동도 영향을 받을 수 있다
- D3QN/LSTM과 action space를 유지해도 최적화 목표까지 같아지는 것은 아니다
- 따라서 기존 QECO의 최적 정책을 보존한다는 보장은 주장하지 않는다

기존 QECO에서 유지한 것과 바꾼 것

변경 지점은 부하 적응형 cost-제어이며, 새로운 network architecture를 제안하지 않는다

구분	원고의 설명	공개된 상세 수준
학습기	Dueling Double DQN 유지	전체 network·target update는 재서술하지 않음
history 입력	LSTM 기반 load history 유지	기본 QECO 구조를 따름
reward	energy cost에 w_E 반영	cost와 완료/미완료 식 제시
action 제어	offloading gating, action space 유지	구체적 gate 판정식은 미제시

실험 조건과 지표를 먼저 고정한다

실험은 edge 하나, 사용자 네 조건, 총 400 episodes이다

조건	원고에 제시된 내용	해석 범위
부하	$N=10,30,50,80$; $M=1$	single-edge dense stress
주 지표	전체 episode 평균	최종 구간 평균과 다름
비교	QECO·DROO·Tang&Wong DQN	그림 1-4에 표시된 구현 비교
불확실성	seed 수·분산·CI 미보고	통계적 우위를 확정할 수 없음

3x 결과: 그림 1의 평균값

30 users / 1 edge · 전체 400 episodes · QECO와 QECO-Adapt 비교

지표	QECO	QECO-Adapt	유리한 방향
QoE	11.40	12.65	높아짐
Delay	8.000	7.896	낮아짐
Energy	19.17	18.14	낮아짐
Dropped tasks	362.1	340.8	낮아짐

같은 표 안에서는 동일한 그림의 값만 사용하며, 불일치하는 변화량을 섞지 않는다

5x·8x 결과: 그림 2와 그림 3

각 셀은 QECO → QECO-Adapt이며, 원고 그림에 표시된 평균값이다

지표	5x: 50 users	8x: 80 users
QoE ↑	6.488 → 9.177	3.728 → 7.066
Delay ↓	8.375 → 8.219	8.584 → 8.437
Energy ↓	19.88 → 17.45	19.95 → 16.30
Dropped ↓	771.0 → 692.0	1386.8 → 1231.9

정량 해석: 표와 그림이 다른 경우

원고의 일부 절대 변화량·부호는 그림과 일치하지 않아 하나의 수치로 확정하지 않는다

항목	Table 1 표시	그림 표시값에서 계산
3x QoE 비율	-10.97%	11.40→12.65 : 약 +10.96%
3x Energy 변화	-2.142	19.17→18.14 : -1.03
5x Dropped 변화	-2.1422	771.0→692.0 : -79.0
8x Energy 변화	-2.142	19.95→16.30 : -3.65

원자료 확인 전에는 서로 다른 값의 평균이나 혼합 표를 만들지 않는다

저부하 손실과 runtime 비용도 남는다

고밀도에서의 유리한 관측만으로 적용 범위를 무제한 확대할 수 없다

조건	원고의 보고	의미
1x	Energy 감소, QoE·Delay·Drop 악화	낮은 부하의 무조건적 개선 아님
3x	네 주요 지표 개선 방향	Fig. 1의 조건부 관측
5x·8x	runtime 약 11% 증가 보고	Table1 기준 추가 계산 비용
DROO 비교	8x의 energy는 DROO가 더 낮음	energy 단독 최고 성능 아님

교육용 예: 같은 최종값, 다른 전체 평균

네 시점만 둔 가상 QoE trace이며 QECO 실험값이 아니다

가상 trace	초반 2시점	후반 2시점	전체 평균
A	0, 0	10, 10	5
B	6, 6	10, 10	8
비교	B의 초반 손실이 작음	둘 다 평균 10	전체 평균은 B가 높음

전체 평균의 이득은 초반 손실 감소로도 생길 수 있으며, 최종 성능 상승과 동의어가 아니다

8x 곡선: 이동평균의 교차를 읽는다

Fig.4는 window=25 이동평균이며, 본문은 DROO와의 교차 시점을 설명한다

지표	본문이 언급한 시점	무엇을 뜻하나
Delay	약 195 episodes 이후	표시된 smoothed trace에서 더 낮음
QoE	약 272 episodes 이후	표시된 smoothed trace에서 더 높음
Dropped tasks	약 265 episodes 이후	표시된 smoothed trace에서 더 낮음
Energy	DROO가 전 구간 더 낮음	QECO-Adapt의 단독 우위 아님

이 연구로 답한 것과 아직 남은 것

부하 적응 아이디어의 정의와 실험 관측, 재현 가능한 완전한 알고리즘은 구분한다

대상	현재 근거	남은 검증
수식	load proxy·g·w_E·reward	arrival clipping·multi-edge 조건
gating	제어 적용을 서술	구체적 action rule·threshold
성능	단일 edge의 평균·smoothed trace	다중 seed·CI·공통 평가 산식
정량 비교	표·그림의 일부 불일치	원자료·timing 조건·수치 정합성

정리: dense 환경의 초반 손실에 개입한다

학습기의 구조 변경보다, 부하에 따른 목적 함수·제어 변화에 초점을 둔 연구다

- $L_{\text{eff}} \rightarrow g \rightarrow w_E$ 가 energy cost를 부하에 적응시킨다
- 기존 QECO의 D3QN/LSTM과 action space를 유지하지만 최적화 목표는 달라진다
- 보고된 3x 이상 그림에서 QECO 대비 평균 지표가 유리하게 관측된다
- 전체 평균의 개선, 최종 성능, 통계적 우위는 서로 다른 주장이다