

의미 추출과 작업 전송의 공동 최적화

QoE-Driven Multi-Task Offloading for Semantic-Aware Edge Computing Systems

Xuyang Chen, Daquan Feng, Wei Jiang, Qu Luo, Gaojie Chen, Yao Sun (2026)

지연·에너지·정확도를 함께 고려하는 다중 작업 MEC와 MAPPO

이 논문이 푸는 문제

서로 다른 작업의 지연·에너지·정확도를 한 QoE 척도로 맞추는 뒤, 의미 추출과 MEC 자원을 공동 최적화한다

- 텍스트·이미지·시각 질의응답은 계산량과 정확도 척도가 다르다
- 단말 실행, 직접 전송, 의미 추출 후 전송 중 실행 방식을 고른다
- 의미 추출 수준과 무선·계산 자원을 함께 선택한다
- 목표: 지연·에너지·정확도로 정의한 전체 QoE의 합을 높인다

얼마나 전송할지와 어디서 계산할지를 함께 결정한다

먼저 구분할 구성요소와 기호


장치·작업·학습 방법을 구분하고, 결정변수는 다음 그림에서 연결한다

기호·약자	뜻	역할
UE / ES	사용자 단말 / 엣지 서버	작업 실행 위치
OFDMA	직교 주파수 분할 다중 접속	상향 전송 자원 배분
VQA	이미지에 관한 질문에 답하기	텍스트와 영상을 함께 처리
ρ / μ	전송 여부 / 의미 추출 계수	실행 방식과 전송량 결정
MAPPO	다중 에이전트 정책 학습	여러 UE의 선택 학습

μ 가 작으면 더 압축하지만, 단말 계산 부담이 늘 수 있다

작업마다 세 실행 경로 중 하나를 고른다

단말에서 완료하거나, 원래 데이터를 보내거나, 의미를 추출한 특징을 ES에 보낸다



단말 완료 경로는 ES로 가지 않으며, 직접 전송은 의미 추출을 생략한다

ρ 와 μ 가 세 실행 방식을 구분한다

한 작업의 완료 위치를 고르되, 의미 전송에서는 일부 모델 계산을 단말이 수행한다

모드	선택 조건	단말에서 하는 일	ES에서 하는 일
단말 완료	$\rho = 0$	전체 작업 계산	해당 작업 실행 없음
직접 전송	$\rho = 1, \mu = 1$	의미 추출 없이 전송	전송된 작업 실행
의미 전송	$\rho = 1, \mu < 1$	특징 추출 후 전송	특징으로 작업 완료

atomic task는 임의의 작업 비율을 나누는 결정변수가 없다는 뜻이다

μ 가 작아질수록 무엇이 바뀌나

더 강한 의미 추출은 전송량을 줄이지만, 단말 부담과 server-side task 성능 손실 가능성을 함께 만든다

μ 의 선택	단말 의미 추출	상향 전송	작업 성능
$\mu = 1$	추가 추출 없음	추출에 의한 축소 없음	추출 손실 없음; 채널 영향 별도
$\mu_{\min} \leq \mu < 1$	더 작으면 부담 증가	더 작으면 전송량 감소	과도한 압축 시 저하
최소 μ	정확도·배터리 고려	허용 범위의 최소 계수	설정만으로 충족 보장 아님

추출 계산·전송량·정확도의 상충관계를 함께 고려한다

OFDMA 전송: 채널을 받은 UE만 upload한다

x_{kn} 은 채널 k 의 UE n 할당 여부, R_n 은 업로드 속도다

항	원문 정의	제약/해석
rate R_n	$\sum_k B \log_2(1+x_{kn} g_{kn} ^2 p_n / \sigma_z^2)$	Rayleigh fading, AWGN
upload time t_n	$\rho_n s_n (\mu_n)^p / R_n$	$\rho_n=0$ 이면 offload upload 없음
UE별 channel	$\sum_k x_{kn} \leq \rho_n$	UE당 최대 한 채널
channel별 UE	$\sum_n x_{kn} \leq 1$	채널당 최대 한 UE

전송량 μ 와 채널·전력 배분은 함께 결정한다

실행 time과 energy를 어떻게 세나

offload면 upload와 ES compute를 더하고, semantic mode면 UE extraction time도 남는다

01	단말 계산	t_U : 전체 local 계산 또는 의미 추출
↓		
02	상향 전송	t_{tx} : $\rho = 1$ 일 때 데이터 업로드
↓		
03	서버 계산	t_S : 전체 offload 계산량 / 서버 처리 능력
↓		
04	작업 지연	$t_{task} = t_U + \rho (t_{tx} + t_S)$
↓		
05	에너지	원문 Eq. 8: $E_{task} = E_{UE} + E_{ES}$

작업 지연에서 단말 추출·업로드·서버 계산을 빠뜨리지 않는다

서로 다른 작업을 local 기준으로 QoE화한다

time·energy는 작을수록, accuracy는 클수록 높은 logistic score가 되며, 세 weight의 합은 1이다



각 지표를 local 기준 점수로 바꾼 뒤, 가중합과 큐 평균을 구한다

교육용 계산: local 기준보다 얼마나 좋아졌나

$\sigma(z) = 1 / (1 + \exp(-z))$; 가상 입력 $z = (1, 0.5, -0.1)$, 한 작업·세 가중치 1/3

지표	local 대비 방향	점수 $\sigma(z)$
지연	단축: $z_t = 1$	0.7311
에너지	절약: $z_e = 0.5$	0.6225
정확도	하락: $z_a = -0.1$	0.4750
가중 평균	$(0.7311 + 0.6225 + 0.4750) / 3$	약 0.6095

local과 같으면 각 $z = 0$, 세 점수는 0.5이므로 QoE도 0.5다

P0가 요구하는 조건과 학습 결과를 구분한다

원래 최적화 문제에는 제약이 있지만, 아래 조건이 모든 학습 행동에서 자동으로 만족된다는 보장은 없다

결정변수	범위	의미
ρ, x	0 또는 1	전송 여부·채널 선택
μ	$\mu_{\min} \leq \mu \leq 1$	의미 추출 수준
p, f	$p \leq p_{\max}; f \leq f_{\max}$	송신 전력·GPU 주파수
지연·에너지	$t \leq t_{\max}; E \leq E_{\max}$	서비스·배터리 한계
정확도	$\varepsilon \geq \varepsilon_{\min}$	작업별 최소 요구

이산·연속 변수와 비선형 QoE가 결합된 혼합 정수 최적화 문제다

관측 → 공동 행동 → 결과 → 벌점 포함 보상


단말별 QoE에서 지연·에너지·정확도 위반 벌점을 빼고, 모든 단말의 보상을 합친다

01	관측	채널·계산량·지연·에너지·정확도·제약
↓		
02	행동	전송 ρ , 전력 p , 주파수 f , 추출 μ , 채널 x
↓		
03	환경 실행	선택한 계산·전송으로 다음 상태와 성과 관측
↓		
04	단말 보상	$QoE_n - \text{지연 벌점} - \text{에너지 벌점} - \text{정확도 벌점}$
↓		
05	학습 목표	전체 $r_t = \sum_n r_n$ 의 기대 할인 누적값 최대화

유한한 벌점을 주는 것은 위반 행동을 항상 금지하는 것과 다르다

actor와 critic은 서로 다른 출력을 학습한다

각 경로는 상태 입력을 받아 두 개의 256-unit MLP와 GRU를 거친다; 화살표는 신경망 계산 순서다



actor는 행동 확률분포를, critic은 상태의 누적 보상 추정값을 출력한다

semantic-aware MAPPO의 학습 순서

sampling policy로 trajectory를 모으고, GAE와 clipped objective로 actor·critic을 여러 epoch 갱신한다

01	초기화	학습 정책 θ , 수집 정책 θ' , critic ϕ
↓		
02	복사	episode 시작: $\theta' \leftarrow \theta$
↓		
03	자료 수집	고정된 θ' 로 T step 실행, trajectory 저장
↓		
04	기대 이득 추정	보상·critic으로 GAE 계산
↓		
05	여러 epoch	actor: clip+entropy; critic: value loss

같은 수집 정책의 자료를 여러 번 학습하고, 다음 수집 전에 정책을 갱신한다

PPO clip은 확률 비율을 강제로 고정하지 않는다

교육용 $\epsilon = 0.2$: 한 표본의 목적값은 $\min(rA, g)$ 이며, r 은 새 정책 / 수집 정책의 행동 확률 비율이다

r, A	rA	경계 항 g	목적값 $\min$
1.1, +2	2.2	$1.2 \times 2 = 2.4$	2.2
1.4, +2	2.8	$1.2 \times 2 = 2.4$	2.4
0.9, -2	-1.8	$0.8 \times (-2) = -1.6$	-1.8
0.6, -2	-1.2	$0.8 \times (-2) = -1.6$	-1.6

$r=1.4$ 가 존재해도 목적값은 더 커지지 않는다; $r \leq 1.2$ 보장은 아니다

교육용 계산: 의미 추출이 줄인 전송 시간

가상 시간 단위: local=4, 추출= $0.2/\mu$, 업로드= 3μ , ES=0.5; $p=q=1$ 인 한 작업을 가정한다

경로	단말 계산	업로드 + ES	총 지연
local: $\rho = 0$	4	없음	4
직접: $\mu = 1$	0	$3+0.5$	3.5
의미: $\mu = 0.5$	$0.2/0.5=0.4$	$1.5+0.5$	2.4
의미: $\mu = 0.1$	$0.2/0.1=2$	$0.3+0.5$	2.8

더 작은 μ 가 항상 더 빠르지는 않다; 최종 선택에는 에너지·정확도도 필요하다

실험의 semantic task와 model 부담

semantic codec은 하나의 범용 encoder가 아니라 modality별 사전 학습 모델이다

작업	dataset+encoder	보고된 model complexity
텍스트 분류	SST-2; BERT	3.72 GFLOPs
이미지 분류	CIFAR-10; ViT	8.43 GFLOPs
시각 질의응답	VQAv2; BERT+ViT	8.31 GFLOPs

GFLOPs는 모델의 연산량이며, 특정 장치에서 측정한 지연 시간이 아니다

QoE 결과를 읽기 위한 simulation 조건

결과 곡선은 4 UE·20개 task queue·10 MHz training point 등의 특정 환경에서 나온다

항목	원문 설정	해석상 주의
무선	4 UE; 채널당 10 MHz; 잡음 2 mW	대역폭·잡음 sweep 별도
GPU	UE 1280 cores, 1.5–1.7 GHz; ES 65536 cores, 2.2 GHz	시뮬레이션 처리 능력
제약	μ : (0.1,1); 최소 정확도50%; 최대 지연5 ms	범용 앱 요구조건 아님
학습·평가	MAPPO 학습300 episode; 평가200회 평균	큐 길이20; 유형·채널 변화

같은 환경의 비교 결과이며, 실제 장치 측정과 구분한다

비교 baseline이 무엇을 바꾸고 무엇을 고정했나

semantic awareness와 continuous/hybrid action 처리의 차이를 분리해 읽는다

방법	의미 추출 μ	행동 공간
제안 MAPPO	적응적으로 선택	이산·연속 혼합
MAPPO-discrete	적응적으로 선택	연속 행동을 이산화
unaware MAPPO	1로 고정	그 외 설정 동일
D3QN / unaware D3QN	적응 선택 / 1	둘 다 이산화
Local	전송 없음	전부 단말 실행

의미 추출 유무와 행동 이산화 여부는 서로 다른 비교 축이다

QoE 곡선의 조건부 결론

10 MHz에서 학습한 policy를 bandwidth·noise·UE 수 조건에서 시험했을 때 semantic-aware MAPPO가 가장 높았다

보고 항목	원문 관찰	해석 경계
학습 곡선	MAPPO 약100; D3QN 약2000 episode	같은 벽시계 시간이 아님
대역폭	제시한 모든 B에서 제안 QoE 최고	10 MHz 학습 후 평가
unaware MAPPO 대비	QoE 12.68% 개선	논문이 보고한 상대값
unaware D3QN 대비	QoE 14.48% 개선	이산 행동 비교 포함

개선율에는 비교 방법·QoE 정의·학습과 평가 조건을 함께 붙인다

QoE weight를 바꾸면 ‘최선’도 바뀐다

각 preference에 맞춰 다시 학습한 결과이며, 한 policy를 즉시 재가중한 결과라고 읽으면 안 된다

preference	delay (ms)	energy (J)	accuracy (%)
no preference	0.523	0.0186	51.37
delay: $\omega_{_t}=1$	0.369	0.0192	43.08
energy: $\omega_{_e}=1$	3.50	0.0163	56.85
accuracy: $\omega_{_a}=1$	1.67	0.0682	71.99

지연 우선의 정확도 43.08%는 설정표의 최소 50%와 맞지 않아 주의가 필요하다

벌점이 있다는 것과 제약을 지킨다는 것은 다르다

보고된 설정과 결과를 나란히 놓고, 논문이 설명하지 않은 차이는 남겨 둔다

근거	내용	해석
P0, Eq. 11	정확도 $\varepsilon \geq \varepsilon_{\min}$	최적화 문제의 요구
학습, Eq. 12	위반량에 유한한 벌점	위반 금지와 다름
Table IV	$\varepsilon_{\min}=50\%$	기본 시뮬레이션 설정
Table V	자연 우선 정확도 43.08%	50% 조건과 불일치

논문은 임계값 변경 여부를 명확히 설명하지 않아 충족 보장을 주장할 수 없다

무엇이 아직 모델 밖에 남나

logistic slope와 μ 관계는 empirical abstraction이며, 논문도 더 일반적인 codec과 정량 관계를 향후 과제로 둔다

- 기울기가 크면 logistic 점수가 0 또는 1에 가까워져 포화될 수 있다
- 기울기가 0에 가까우면 점수가 0.5에 몰려 차이를 구별하기 어렵다
- μ 와 계산·전송·정확도 관계는 경험적 모델이며 보편 법칙이 아니다
- 작업은 atomic이고 결과 다운로드 지연은 생략한다

가중치별 재학습과 고정 정책의 점수 함수 민감도 실험은 다르다

한 줄로 다시 읽기

의미 추출·계산·전송의 상충관계를 모델링하고 정책으로 선택한다; 작은 μ 자체가 목적은 아니다

- 모형: 작업별 코덱과 세 실행 경로
- 목표: local 기준의 지연·에너지·정확도 QoE
- 방법: 이산·연속 결정을 함께 학습하는 MAPPO
- 근거: 조건부 시뮬레이션 결과와 미해결 제약 차이

실행 경로 $\rightarrow$ 비용·QoE $\rightarrow$ 벌점과 학습 $\rightarrow$ 조건부 결과로 이해한다