

QulP: 보장이 있는 2비트 LLM 양자화

QulP: 2-Bit Quantization of Large Language Models With Guarantees

Jerry Chee, Yaohui Cai, Volodymyr Kuleshov, Christopher M. De Sa (2023)

좌표계를 바꾸고 오차를 다음 좌표에 전달해 layer 출력 proxy를 줄이는 weight-only PTQ

QuIP의 문제 범위

구분	QuIP이 하는 일	범위 밖의 주장
대상	linear layer의 weight	activation 전체 양자화
시점	학습 뒤 calibration으로 PTQ	원 모델의 재학습
목적	layer 출력 변화의 quadratic proxy	전체 task loss 직접 최적화
표현	낮은 bit의 scalar grid	QuIP#의 vector codebook
검증	정리의 proxy bound와 LLM 실험	모든 2비트 모델의 정확도 보장

QuIP은 weight-only PTQ이며 이론과 end-to-end 실험을 서로 다른 증거로 제시한다

2비트에서 독립 반올림이 어려운 이유


같은 크기의 weight 오차도 입력이 자주 쓰는 방향에 따라 출력 영향이 달라진다

상황	weight 오차	출력에 미치는 영향
자주 쓰는 입력 방향	작아 보여도 반복 증폭	layer 출력 변화가 클 수 있음
드문 입력 방향	같은 크기의 오차	출력 영향이 상대적으로 작을 수 있음
소수의 큰 좌표	좁은 grid range를 차지	나머지 좌표의 resolution을 줄임
독립 반올림	각 좌표를 따로 선택	서로 상쇄할 기회를 사용하지 못함

QuIP은 weight MSE 대신 입력 민감도로 가중한 출력 proxy를 사용한다

보존 대상은 calibration 입력에서의 layer 출력

$$\text{proxy: } E_x \| (W_{\text{hat}} - W)x \|^2 = \text{tr}((W_{\text{hat}} - W)H(W_{\text{hat}} - W)^T)$$



H는 입력 방향의 민감도와 상관을 기록한다


$H=E\{xx^T\}$ 는 calibration 입력의 second moment이며 whole-model Hessian이 아니다

기호	형식	직관
W	$m \times n$ weight matrix	양자화할 한 linear layer
W_{hat}	W 와 같은 크기	grid 값으로 표현한 weight
x	n 차원 입력	calibration set에서 뽑은 layer 입력
H	$E\{xx^T\}$	입력 방향의 크기와 좌표 간 상관
$H_{12}=0.8$	교육용 correlated 예	1번과 2번 좌표의 오차가 함께 작용

H의 off-diagonal 항이 크면 두 좌표의 오차 부호 조합도 proxy를 바꾼다

adaptive rounding은 과거 오차를 미래 좌표에 전달한다

이미 grid에 고정한 column은 되돌리지 않고 아직 자유로운 column만 보정한다



strictly upper-triangular U가 앞선 column에서 뒤 column으로만 피드백을 보낸다

LDLQ 식에서 각 항의 역할

$W_{\text{hat}} = Q(W + (W - W_{\text{hat}})U)$, U 는 strictly upper triangular

항	역할	처리 시점
Q	nearest 또는 unbiased stochastic rounding	현재 column의 code 고정
$W - W_{\text{hat}}$	이미 처리한 column의 residual	고정 뒤 계산
U	residual을 뒤 column에 전달하는 계수	H에서 선택
$W + (W - W_{\text{hat}})U$	보정된 아직 자유로운 값	다음 rounding 입력
column k	1부터 n 까지 순서대로 처리	미래 code는 아직 미정

LDLQ의 Q 는 scalar quantizer이고 성능 차이는 피드백 U 와 전처리에서 나온다

H의 LDL 분해가 피드백 U를 정한다

$H = (U_{\text{bar}} + I)D(U_{\text{bar}} + I)^T$ 로 분해하고 $U = U_{\text{bar}}$ 를 선택한다

01	proxy geometry H	입력 민감도와 상관을 담음
↓		
02	LDL factorization	H를 triangular factor와 diagonal D로 분해
↓		
03	feedback U	strict upper factor U_{bar} 를 사용
↓		
04	sequential rounding	앞선 residual을 뒤 column에 전달
↓		
05	proxy bound	loss가 $\text{tr}(D)$ 로 표현됨

LDLQ는 H의 좌표 결합 구조를 rounding 순서의 보정 계수로 바꾼다

교육용 2×2 LDLQ 재계산의 설정

논문 실험이 아닌 unbounded integer grid 예시이며 nearest rounding을 사용한다

항목	값	의미
한 row w	[0.49, 0.49]	두 column을 1 번부터 처리
H	[[1,0.8],[0.8,1]]	positive correlation
D	diag(0.36, 1)	LDL diagonal
U_12	0.8	첫 residual을 둘째 값에 전달
grid	모든 integer	finite 2-bit grid가 아님

이 예시는 feedback 방향과 proxy 산술만 계산하며 LLM 성능을 나타내지 않는다

첫 residual이 둘째 code를 0에서 1로 바꾼다

단계	독립 nearest	LDLQ feedback
첫 code	$q_1=0$	$q_1=0$
첫 residual	$0.49-0=0.49$	$0.49-0=0.49$
둘째 입력	0.49	$0.49+0.49 \times 0.8=0.882$
둘째 code	$q_2=0$	$q_2=1$
최종 error q-w	$[-0.49, -0.49]$	$[-0.49, 0.51]$

positive coupling에서는 같은 부호의 두 오차보다 반대 부호 오차가 덜 비쌀 수 있다

교육용 proxy loss를 직접 확인한다

한 row의 proxy는 eHe^T 이며 $e=q-w$ 로 계산한다

방법	error e	eHe^T	해석
독립 nearest	$[-0.49, -0.49]$	0.86436	같은 부호가 coupling을 더함
LDLQ	$[-0.49, 0.51]$	0.10036	반대 부호가 coupling을 상쇄
차이	같은 grid와 순서	0.76400 감소	이 예시 안에서만 성립

LDLQ는 개별 error가 아니라 결합된 quadratic cost를 줄인다

Theorem 1 이 실제로 보장하는 범위

구분	내용	경계
방법론	Eq. 2의 linear-feedback rounding	U는 H에만 의존
입력 geometry	positive semidefinite H	layer-local proxy 설정
grid	모든 integer로 rounding	finite clamp는 별도 문제
quantizer	nearest 또는 stochastic	정리의 지정 조건
결론	LDLQ가 stated worst-average bound 최소	end-to-end 정확도 정리 아님

여기서 optimal은 제한된 방법론과 proxy bound에 대한 표현이다

피드백만으로 해결되지 않는 좌표 집중

중요한 크기나 민감도 방향이 특정 축에 몰리면 작은 uniform grid가 불리하다

대상	집중된 상태	rounding에 생기는 문제
weight W	소수 entry가 매우 큼	range가 큰 entry에 맞춰짐
geometry H	eigenvector가 coordinate axis와 정렬	중요 방향이 한 좌표에 집중
low-bit grid	표현 level 수가 작음	집중된 축을 세밀하게 표현하기 어려움
LDLQ	오차 결합은 조정	나쁜 좌표계 자체는 남음

QuIP의 두 번째 전략은 rounding 전에 더 고른 좌표계로 바꾸는 것이다

incoherence는 고르게 퍼진 좌표 구조를 뜻한다

대상	논문의 조건	교육적 해석
W	각 entry가 Frobenius norm에 비해 작음	몇 weight가 range를 독점하지 않음
H	eigenvector entry가 $\mu / \sqrt{n}$ 이하	민감 방향이 한 축에 정렬되지 않음
μ	incoherence 정도를 나타내는 상수	작을수록 더 고르게 퍼짐
random basis	높은 확률로 μ 가 polylog 크기	모든 entry가 정확히 같다는 뜻은 아님

incoherence는 정보 삭제가 아니라 같은 양을 다른 basis에 분산하는 구조적 조건이다

Lemma 2의 low-rank 직관에는 조건이 붙는다

$\text{tr}(D) \leq (\mu^2/n) (\text{tr}(H^{1/2}))^2$ 이며 $\text{rank}(H)=k$ 이면 spectrum bound를 연결할 수 있다

필요 조건	bound에서의 역할	생략하면 안 되는 이유
H PSD	LDL과 proxy geometry 정의	임의 행렬에 적용하지 않음
μ -incoherent H	$\text{tr}(D)$ 를 spectrum으로 제한	μ 가 크면 이득이 약해짐
$\text{rank}(H)=k$	trace 관계로 k를 도입	무조건적인 k/n 개선이 아님
$\mu^2 k \ll n$	baseline보다 작은 asymptotic bound	dimension과 rank 조건 필요

low-rank 이점은 incoherence $\mu \cdot k \cdot n$ 조건을 함께 만족할 때의 proxy bound다

QulP의 전처리·양자화·후처리 경로

W,H를 rescale하고 같은 seed의 직교 basis에서 LDLQ한 뒤 matched inverse를 적용한다

01	W,H 입력	full-precision weight와 calibration geometry
↓		
02	rescale	diagonal conditioning과 finite range 준비
↓		
03	orthogonal basis	W와 H를 incoherent basis로 이동
↓		
04	LDLQ와 clamp	피드백 rounding으로 low-bit code 생성
↓		
05	inverse	같은 seed로 원래 convention에 복원

transform 전 proxy identity와 rounding 뒤 approximation은 다르다


Algorithm 3의 실제 데이터와 seed 의존성

main path는 W, H 에서 W_{hat} 으로 진행하고 seed는 transform과 inverse를 같은 쌍으로 묶는다



seed가 transform과 inverse를 같은 orthogonal pair로 묶는다

unbounded 정리와 finite grid의 조건 차이



finite-grid 보장에는 별도 알고리즘이 필요하다

경로	동작	논문에서의 위치
base QulP	LDLQ 뒤 finite range에 clamp	일반 실험에서 사용
위험	clipping이 feedback trace를 왜곡	Fig. 4 counterexample
Algorithm 5	추가 convex program과 stochastic rounding	finite-grid bound용
Theorem 7	적절한 조건에서 no overflow와 proxy bound	기본 path의 자동 보장 아님
실용 선택	clipping이 드물어 base QulP 선호	추가 계산을 피함

논문의 stronger finite-grid theorem은 더 비싼 special procedure에 붙어 있다


LDLQ와 OPTQ의 관계는 지정된 알고리즘에 한정된다

비교	논문 결론	주의
방법론	OPTQ가 Eq. 2의 linear feedback에 포함	임의 OPTQ 구현 전체가 아님
출력	paper setup에서 LDLQ와 equivalence	clamp·order 조건을 유지
계산	LDLQ는 inversion 없이 one Cholesky	논문의 구현 비교
IncP	QuIP=LDLQ+incoherence processing	LDLQ 단독과 QuIP을 구분

QuIP의 차별점은 LDLQ 피드백뿐 아니라 incoherence pre-post processing의 결합이다

calibration의 blockwise 전파

128개의 C4 segment를 사용하고 각 segment 길이는 2048 token이다



뒤 block의 H는 앞서 quantized된 출력의 영향을 반영한다

Llama 2 70B 2비트 결과의 조건부 비교

Table 1의 같은 protocol 안에서 PPL은 낮을수록 좋고 task accuracy는 높을수록 좋다

방법	WikiText2 PPL ↓	C4 PPL ↓	ArcE ↑	PiQA ↑
FP16	3.319	5.709	59.72	80.90
OPTQ 2-bit	123.908	70.541	25.34	50.54
QulP 2-bit	6.326	8.937	54.38	75.08
QulP 3-bit	3.853	6.135	59.81	80.25

이 표는 해당 Llama 2 70B 평가에서 QulP 2-bit와 OPTQ 2-bit의 큰 차이를 보여 준다

OPT-30B 2비트 ablation에서 IncP의 영향

Table 2의 WikiText2 PPL이며 동일 model·bit·metric 조건 안에서 비교한다

rounding	baseline processing	incoherence processing	읽는 방법
OPTQ / QuIP	71.70	11.48	LDLQ 계열에 IncP 추가
LDLQ-RG	49.40	11.68	reorder-greedy variant
Greedy	4816.6	11.59	같은 Table 2 조건
Nearest	41547.8	12.04	IncP 뒤 nearest도 viable
FP16 reference	9.56	9.56	양쪽 표의 동일 기준

이 control은 OPT-30B Table 2에서 preprocessing이 2비트 결과를 크게 바꾼다는 증거다

reported inference time에는 hardware 조건이 붙는다

A6000, OPT-66B, batch 1, generated sequence length 128의 average per-token time

방법	평균 per-token time	비교	해석 경계
OPTQ	53 ms	baseline	efficient quantized forward pass
QuIP	81 ms	약 $1.5 \times$ 느림	IncP addition은 PyTorch 구현
측정 조건	A6000	batch 1	OPT-66B, length 128
용어	latency/time	낮을수록 빠름	paper heading의 throughput과 구분

2 bits per weight만으로도 total deployment memory나 speed가 자동 결정되지는 않는다

QulP이 확립한 것과 남은 경계

구분	확립한 내용	확립하지 않은 내용
proxy	layer input으로 가중한 quadratic objective	whole-model task loss와 동일
LDLQ	제한된 linear-feedback family의 bound	finite codebook의 global optimum
incoherence	높은 확률의 구조 개선과 proxy 분석	rounding error 소멸
finite grid	별도 Algorithm 5와 Theorem 7	base clamp path의 자동 보장
LLM 결과	지정 model·dataset의 empirical evidence	모든 2-bit LLM 정확도 보장

QulP의 guarantee는 좋은 basis와 feedback 아래의 proxy를 다룬다

QulP과 QulP#은 별개 방법이다

구분	QulP	QulP#
발표	NeurIPS 2023	ICML 2024
incoherence transform	random orthogonal Kronecker factors	randomized Hadamard transform
quantizer	scalar LDLQ	BlockLDLQ와 E8 lattice codebook
추가 단계	base method에 fine-tuning 없음	inter-layer fine-tuning 포함
관계	incoherence와 feedback의 출발점	그 계보를 확장한 후속 논문

Hadamard·E8 codebook·fine-tuning을 QulP의 내부 단계로 설명하면 논문이 섞인다

핵심 notation

기호	뜻	결정되는 시점
W	한 linear layer의 full-precision weight	quantization 전
W_{hat}	grid code를 거친 quantized weight	rounding 뒤
x	calibration set의 layer input	data forward 시
H	$E[xx^T]$ second-moment geometry	calibration에서 계산
U, D, μ	feedback, LDL diagonal, incoherence 정도	factorization·analysis에서 결정

공개 출처

자료	공개 위치	용도
QulP proceedings	NeurIPS 2023 paper record	서지와 abstract
QulP paper	NeurIPS public PDF	식·정리·알고리즘·실험
QulP arXiv	arXiv 2307.13304	공개 version history
QulP code	github.com/Cornell-RelaxML/QulP	저자 공개 구현
QulP# paper	PMLR 235, tseng24a	후속 방법의 경계 비교