

Self-Calibration: 보정 데이터를 모델에서 얻기

Self-calibration for Language Model Quantization and Pruning

Miles Williams, George Chrysostomou, Nikolaos Aletras (2025)

외부 코퍼스 대신 압축할 LLM이 만든 텍스트로 post-training compression을 보정한다

어떤 공개 논문인가

NAACL 2025 Long Paper의 공개 proceedings record를 기준으로 읽는다

- 저자: Miles Williams, George Chrysostomou, Nikolaos Aletras

- NAACL 2025 Long Papers, pp. 10149–10167

- DOI: 10.18653/v1/2025.naacl-long.509

- 핵심 대상은 post-training 양자화와 프루닝의 보정 입력이다

이 발표의 수치와 결론은 이 논문이 정한 영어 zero-shot 실험 조건에서만 해석한다

보정 데이터는 압축기의 입력이다


레이블 없는 텍스트가 layer activation을 만들고, 압축 방법은 그 activation을 기준으로 결정을 조정한다

01	사전학습 LLM	압축할 가중치가 이미 주어진다
↓		
02	보정 예시	작은 레이블 없는 텍스트 묶음
↓		
03	forward pass	각 layer의 activation을 얻는다
↓		
04	기존 압축기	activation을 참고해 양자화·프루닝한다
↓		
05	압축 모델	다운스트림 성능을 가능한 유지한다

보정 텍스트가 바뀌면 같은 압축 방법도 다른 activation을 보고 다른 결과를 낼 수 있다


왜 무작위 웹 텍스트만으로는 충분하지 않을까

논문은 대표성과 가용성이라는 서로 다른 문제를 분리한다



바뀌는 것은 압축기보다 보정 데이터의 출처다

두 경로는 비교 조건이며, 한 번의 실행에서 둘을 함께 적용한다는 뜻은 아니다



self-calibration은 어떻게 텍스트를 만드는가

기본 절차는 외부 prompt 없이 BOS에서 시작한다; 보고된 일부 영어 실험에는 첫 token 제한이 있다

01	BOS만 입력	시작 토큰 외의 prompt를 넣지 않는다
↓		
02	실험의 첫 token	Gemma·Mistral·Llama: 영어 stop-word 목록으로 제한
↓		
03	다음 token 샘플링	logits 확률분포에 온도 스케줄을 적용한다
↓		
04	종료 조건	EOS 또는 최대 길이까지 생성한다
↓		
05	보정 묶음	짧은 생성은 이어 붙여 필요한 길이를 맞춘다

외부 보정 코퍼스가 없다는 뜻이지, 생성 모델의 가중치나 forward pass가 없다는 뜻은 아니다

온도는 next-token 확률의 날카로움을 조절한다

논문은 token i 에서 logits u 를 temperature t_i 로 나눈 뒤 softmax를 적용한다

- $P(w_i \mid w_{1:i-1}) = \exp(u_i/t_i) / \sum_j \exp(u_j/t_i)$
- 낮은 t 는 높은 확률 token에 더 집중한다
- 높은 t 는 확률질량을 더 넓게 분산한다
- 처음 n token에서 t_{initial} 에서 t_{final} 까지 선형 이동한다
- i 가 n 보다 크면 t_{final} 을 유지한다

온도 효과는 별도 ablation에서 확인하며, 모든 결과에 자동 적용되지 않는다

강의용 계산: 선형 온도 schedule을 직접 따라가기

예시 조건: $t_{\text{initial}}=2.0$, $t_{\text{final}}=1.0$, $n=4$. 이 표는 논문의 성능 결과가 아니다

token i	계산	t_i
1	$2.0 + 1/4 \times (1.0 - 2.0)$	1.75
2	$2.0 + 2/4 \times (1.0 - 2.0)$	1.50
3	$2.0 + 3/4 \times (1.0 - 2.0)$	1.25
4	$2.0 + 4/4 \times (1.0 - 2.0)$	1.00
5	$i > n$ 이므로 final 유지	1.00

schedule은 생성 전략을 표현하지만 최적값을 보장하지 않는다

무엇과 비교했는가: 다섯 보정 데이터 출처

real, 외부 synthetic, 모델-자체 synthetic을 같은 수량 규칙 안에서 비교한다

분류	출처	핵심 성격
real	C4	필터링·중복 제거 웹 텍스트
real	WikiText	편집된 Wikipedia 텍스트
synthetic	Vocabulary	특수 token을 뺀 무작위 vocabulary token
synthetic	Cosmopedia	큰 외부 모델이 만든 합성 텍스트
synthetic	Self-calibration	압축할 모델이 생성한 텍스트

self-calibration의 비교 대상은 실제 텍스트와 두 종류의 합성 텍스트를 모두 포함한다

결과를 해석하기 위한 실험 조건

모든 성능 수치는 이 표의 모델·압축·데이터·평가 조건에 묶여 있다

항목	논문 조건	해석 주의
보정 수량	128 예시 × 2,048 token; 출처별 5개 set	표의 아래첨자는 5개 set 표준편차
모델	Gemma 2B, Phi-2, OPT, Mistral, Llama	세 모델 첫 token은 English stop-word 제한; prompt 아님
양자화	AWQ·GPTQ, 4-bit weight	activation 양자화 결과가 아니다
프루닝	SparseGPT·Wanda, 2:4 semi-structured	다른 sparsity와 같다고 할 수 없다
평가	여러 영어 zero-shot 과제 평균	단일 과제·서빙 지연시간이 아니다

주요 결과: 합성 기준선과의 비교

Table 2의 주 비교에서는 self-calibration의 initial-final temperature를 모두 1.0으로 고정했다

- 20개 method-model 조합 중 17개에서 다른 합성 데이터와 같거나 더 높다
- Gemma 2B를 GPTQ로 압축: self 59.9, Cosmopedia 58.5, Vocabulary 57.9
- Llama 3.1 8B를 SparseGPT로 프루닝: self 53.8, Cosmopedia 50.9
- Phi-2·Gemma·OPT에서는 한 예외를 빼고 모든 출처 중 최고 평균을 보고한다
- Mistral·Llama에서는 real data를 이기지 못한 경우도 있어 결과는 조건부다

외부 데이터 없이도 여러 조건에서 경쟁력 있는 보정을 만들 수 있다는 결과다

반례를 함께 읽기: OPT 6.7B의 SparseGPT

self-calibration이 모든 데이터 출처보다 최고라는 주장을 막는, Table 2의 가장 작은 차이

모델	압축 방법	보정 출처	평균 정확도
OPT 6.7B	SparseGPT	C4	52.8
OPT 6.7B	SparseGPT	Self-calibration	52.7

0.1 point 차이지만, 결과를 항상 최고라고 부르지 않아야 하는 직접 근거다

왜 프루닝 결과를 별도로 볼까

Gemma 2B에서 best-to-worst calibration-source range가 양자화보다 프루닝에서 더 넓게 보고된다

방법	종류	range	논문이 제시한 읽기
AWQ	4-bit 양자화	0.6	출처 선택에 상대적으로 덜 민감
GPTQ	4-bit 양자화	2.0	출처 선택에 상대적으로 덜 민감
SparseGPT	2:4 프루닝	7.5	보정 출처의 영향이 더 크게 보임
Wanda	2:4 프루닝	3.2	보정 출처의 영향이 더 크게 보임

이 표는 Gemma 2B의 논문 실험 관찰이며, 모든 압축법에 대한 일반 법칙은 아니다

보정 예시는 많이 필요할까: 수량 ablation의 한 사례

Fig. 2는 resource 제약 때문에 Gemma 2B와 Phi-2에서만 1~128 예시를 조사한다

조건	예시 수	평균 정확도	비교
Phi-2 + SparseGPT + C4	128	54.3	외부 real data
Phi-2 + SparseGPT + Self	16	54.5	self-calibration
수량 범위	1, 2, 4, 8, 16, 32, 64, 128	Fig. 2	Gemma 2B·Phi-2만

적은 self 예시도 경쟁력 있을 수 있지만, 전 모델의 보장값은 아니다

온도 설정은 효과가 있지만, main result의 전제는 아니다

Fig. 3은 Gemma 2B-Phi-2에서 $n=10$, initial-final 값을 0~2로 탐색한다

initial, final	동등한 decoding	논문 해석
0, 0	greedy decoding	매 시점 가장 높은 확률 token
1, 1	standard sampling	main Table 2의 self 설정
같은 값	constant-temperature	전체 생성 동안 온도 유지
다른 값	temperature schedule	초기·후반 생성 특성을 다르게 함

standard sampling도 최대값 0.5 point 이내가 될 수 있으나, 최적 schedule은 아니다

좋은 성능이 곧 더 다양한 텍스트라는 뜻은 아니다

Llama 3.1 8B의 Table 4는 self-generated text가 real data보다 덜 diverse할 수 있음을 보인다

측정	Self	C4	WikiText
Vocabulary coverage	0.15	0.18	0.16
N-gram diversity	0.58	0.62	0.65
Zipf coefficient	1.24	1.16	1.12

생성 텍스트가 coherent해도 실제 텍스트보다 다양하다는 뜻은 아니다

남는 한계와 윤리적 경계

논문 자체가 영어 범위, 다국어 일반화의 미검증, 생성 텍스트의 유해 가능성을 명시한다

- 실험은 영어 모델·과제·보정 데이터에 한정된다
- 다국어 모델에 일반화될 것이라는 기대는 후속 연구 과제다
- 생성 텍스트는 부정확·편향·유해한 내용을 포함할 수 있다
- 저자들은 그런 내용이 원 모델 가중치에 이미 인코딩돼야 한다고 논증한다
- 그 논증은 안전성 검증이나 유해성 제거를 의미하지 않는다

외부 데이터 의존을 줄여도 분포·언어·안전 문제가 자동 해결되지는 않는다

한 문장으로 다시 조립하기

학습 데이터를 직접 얻지 못할 때, 모델이 만든 무라벨 텍스트를 기존 PTQ·pruning의 보정 입력으로 사용한다

- | | | |
|----|----|---------------------------|
| 01 | 문제 | 외부 보정 표본은 대표성이 불확실하다 |
| ↓ | | |
| 02 | 개입 | 압축 대상 모델이 BOS부터 텍스트를 생성한다 |
| ↓ | | |
| 03 | 연결 | 기존 압축기가 그 activation을 읽는다 |
| ↓ | | |
| 04 | 근거 | 여러 조건에서 합성 기준선과 경쟁력 있다 |
| ↓ | | |
| 05 | 경계 | 영어·선택 방법·조건부 실험 결과다 |

보정 입력의 출처를 바꾸면 기존 압축기의 품질도 달라질 수 있다