

SkySearch: 대규모 위성 비디오 검색

SkySearch: Satellite Video Search at Scale

Minyoung Choe, Geon Lee, Changhun Han, Suji Kim, Woong Hu, Hyebeen Hwang, Geunseok Park, Byeongyeon Kim, Hyesook Lee, Ha-Myung Park, Kijung Shin (2025)

라벨 없는 시계열을 압축하고, 시간 구간과 그래프를 함께 탐색하는 검색 시스템

논문과 공개 구현의 위치

검색·머신러닝·기상 위성 운영이 만나는 응용 연구

- KDD 2025 Applied Data Science Track의 12쪽 논문이다
- Corrected Version of Record V1.1은 2025년 8월 15일 공개되었다
- 한국 기상청 운영 환경에 배포한 시스템과 실험을 함께 보고한다
- 공식 저장소는 압축·예측 코드와 온라인 부록을 공개한다

이 논문은 검색 알고리즘 하나가 아니라 학습·인덱스·질의·UI를 잇는 시스템을 평가한다

출발점: 지금과 비슷했던 과거를 찾고 싶다

분류 이름보다 구름의 모양과 시간에 따른 변화 자체가 중요한 검색 문제

- 질의는 한 장의 사진이 아니라 연속된 위성 영상이다
- 과거 기록에서 공간 형태와 시간 변화가 모두 비슷한 구간을 찾는다
- 각 비디오에 태풍·전선 같은 정답 라벨이 있다고 가정하지 않는다
- 운영자는 검색된 과거 사례를 비교해 현재 상황을 해석할 수 있다

SkySearch의 목표는 사건을 분류하는 것이 아니라 유사한 과거 전개를 검색하는 것이다

검색 문제를 정확히 정의하면

시간표가 있는 이미지 데이터베이스에서 길이 L 의 연속 구간을 후보로 만든다

01	이미지 기록 D	각 위성 이미지에 관측 시각이 있음
↓		
02	후보 비디오	1시간 간격 L 장 sliding window
↓		
03	외부 질의 Q	후보와 같은 형식의 L 장 비디오
↓		
04	유사도 검색	공간 형태와 시간 변화를 비교
↓		
05	순위 목록 C	가장 유사한 후보 비디오를 반환

기본 설정에서 $L=12$ 이므로 한 후보는 12시간의 변화를 담는다

원본 그대로 비교하기 어려운 규모

비디오 한 개의 픽셀과 전체 후보 수가 동시에 커진다

대상	논문 설정	규모가 만드는 문제
비디오 1개	$600 \times 748 \times 12 = 5,385,600$ pixels	모든 후보와 원본 픽셀 비교가 무거움
COMS	837,525 images, 295,713 videos	10년 기록에서 후보가 계속 누적
GK2A	292,506 images, 209,373 videos	추가 위성도 같은 검색 체계가 필요
전체	1,130,031 images, 505,086 videos	압축·인덱스·후보 제한이 모두 필요

SkySearch는 계산량을 한 번에 줄이지 않고 표현 크기·후보 수·시간 범위를 차례로 줄인다

다섯 모듈이 하나의 질의를 처리한다

학습된 표현과 검색 인덱스는 사전에 준비하고, 질의 때 후보를 좁혀 순위를 만든다

01	압축	비디오를 256차원 embedding으로 변환
↓		
02	선택적 예측	현재 질의 뒤의 미래 frame을 생성
↓		
03	후보 검색	시간 block과 kNN graph를 탐색
↓		
04	순위화	거리 또는 perceptual metric으로 정렬
↓		
05	시각화	관측 시각과 유사 영상을 UI에 표시

예측은 선택 사항이지만 압축·후보 검색·순위화는 기본 검색 경로다

압축은 검색용 표현을 만든다


원본 비디오와 검색용 embedding은 서로 다른 역할을 가진다

표현	크기	검색에서의 역할
원본 비디오	약 5.14 MB	세부 픽셀과 사람이 볼 영상을 보존
256-d embedding	1 KB	후보 간 거리를 빠르게 계산
보고된 감소	5,260 ×	인덱싱과 대규모 비교를 현실화

embedding은 원본 저장의 대체물이 아니라 검색 후보를 빠르게 비교하기 위한 요약이다

시간 간격이 학습 신호가 된다

사건 라벨 대신 촬영 시각의 가까움과 멀음으로 positive-negative를 만든다



공간을 먼저 배우고 시간 변화를 이어서 배운다

두 단계 학습으로 프레임 표현과 비디오 표현을 분리한다

- | | | |
|----|-----------------|--|
| 01 | 단일 이미지 | 위성 frame 한 장을 입력 |
| ↓ | | |
| 02 | Spatial encoder | 합성곱·pooling으로 image embedding 학습 |
| ↓ | | |
| 03 | 공간부 고정 | 학습한 spatial encoder의 parameter를 freeze |
| ↓ | | |
| 04 | ConvRNN | 연속 image embedding의 시간 관계를 학습 |
| ↓ | | |
| 05 | Video embedding | 12시간 구간을 256차원으로 요약 |

검색 표현은 한 프레임의 모양과 프레임 사이의 변화 정보를 함께 담도록 설계된다

장기 검색에서는 질의의 미래를 선택적으로 덧붙인다

현재까지의 12시간만 있을 때 다음 12시간을 예측해 24시간 검색 질의를 만든다

01 관측 12 frames 현재 시점까지 확보한 query video



02 SimVP 기반 예측 다음 12 frames를 생성



03 Query 결합 관측 12 + 예측 12 = 24시간



04 장기 후보 검색 24시간 변화가 유사한 과거를 검색

예측은 현재 조건을 질의할 때 쓰는 선택 경로이며 단기 검색의 필수 단계가 아니다

예측 모델은 세 학습 목적을 번갈아 사용한다

각 학습 step에서 하나의 목적을 확률적으로 선택하는 방식

선택 목적	역할	논문 설정 확률
MSE	예측 frame과 실제 frame의 pixel 차이를 줄임	0.3
Generator adversarial	판별기를 속일 수 있는 미래 frame을 생성	0.6
Discriminator adversarial	실제와 생성 frame을 구분하도록 판별기 학습	0.1

세 손실을 한 식으로 단순 합산한다고 설명하면 논문의 학습 절차와 다르다

검색 공간을 kNN graph로 바꾼다

모든 후보와 비교하는 대신 가까운 embedding을 간선으로 연결해 탐색한다



k가 크면 연결성과 search accuracy에 유리하지만 index memory와 탐색량도 늘어난다

후보 검색은 가장 유망한 정점부터 graph를 넓힌다

본문 후보 검색 절차는 candidate set과 visited set을 분리해 관리한다

01	무작위 시작	전체 DB에서 C개 embedding을 candidate로 선택
↓		
02	Best-first 방문	query similarity가 가장 큰 candidate를 꺼냄
↓		
03	동적 문턱	현재 C번째 visited similarity + epsilon
↓		
04	Neighbor 확장	문턱을 넘지 않으면 미방문 이웃을 추가
↓		
05	Top C 반환	방문한 정점 중 가장 유사한 C개

동적 문턱은 이웃 확장을 멈추는 기준이며 결과의 exactness를 보장하는 식이 아니다

강의용 추적: candidate와 visited가 어떻게 바뀌는가


구성 예시: $C=2$, $\epsilon=.05$; similarity $A=.92$, $B=.88$, $C=.61$, $D=.79$

순서	꺼낸 정점	판정	다음 candidate
초기	—	A와 C를 무작위 시작점으로 둬	A, C
1	A	$\text{visited} < 2$ 이므로 이웃 B 추가	B, C
2	B	$.88 + .05 = .93$; $.88 \leq .93$	C, D
3	D	$.79 \leq .93$; 새 이웃 없음	C
4	C	후보 소진; visited의 상위 2개 선택	결과 A, B

이 숫자와 graph는 교육용 구성 예시이며 논문 실험의 한 query를 복제한 것이 아니다


시간 구간 조건을 언제 적용할 것인가

넓은 전체 graph를 먼저 찾고 나중에 거르면 좁은 시간 query에서 낭비가 커진다



MBI는 시간을 계층 block으로 묶는다

작은 인접 block을 상위 block으로 묶고, 각 완성 block에 검색 graph를 둔다



미완성 leaf는 전수 비교하고 완성된 block graph는 lazy하게 만든다

최종 순위는 속도와 정밀도를 선택한다

candidate search 뒤의 작은 후보 집합에 더 비싼 metric을 선택적으로 적용할 수 있다

순위 방식	입력	장점	비용·주의
Embedding distance	256-d vectors	기본값, 가장 빠름	perceptual 세부 비교는 제한
LPIPS	원본 frames	deep feature 기반 비교	기본 대비 4.29×10^3 overhead
FSIM	원본 frames	feature similarity	기본 대비 4.16×10^5 overhead
SSIM	원본 frames	구조적 유사도	기본 대비 7.19×10^3 overhead
Lite variants	50% downsample	약 75% runtime 감소	성능 저하 최대 0.21%

비싼 metric은 검색 전체가 아니라 정확도가 중요한 경우의 refinement 단계다

운영 화면까지 이어지는 질의 경로

위성·channel·시작 시각을 고르고, 결과의 시각과 거리를 함께 확인한다

01	Query 선택	satellite, channel, initial timestamp
↓		
02	조건 적용	검색할 time period를 선택
↓		
03	검색 실행	query embedding과 block graph를 탐색
↓		
04	결과 표시	rank, 날짜, 거리와 frames를 함께 제시

논문의 UI는 알고리즘 결과를 기상 실무자가 사례 단위로 검토하게 한다

배포와 평가의 시스템 조건

속도 수치는 데이터·hardware·index 설정과 함께 읽어야 한다

항목	논문 조건	해석
CPU server	AMD EPYC 7742, 64 cores, 256 threads	candidate search와 시스템 처리
Memory	1 TB RAM	대규모 graph index를 메모리에 유지
GPU	NVIDIA A100 40 GB	compression·prediction 학습과 추론
Input channels	IR, SWIR, WV	개별 적용; joint input은 미래 과제
Image preprocessing	약 $1300 \times 1500 \rightarrow 600 \times 748$	mean pooling과 crop 후 실험

논문의 초 단위 응답을 임의의 edge device나 작은 memory 환경으로 그대로 옮길 수는 없다

검색 품질 실험의 조건

질의 기간과 prediction 유무에 따라 비교 대상의 길이가 달라진다

항목	설정	주의점
학습·DB	COMS IR, 2014–2018	과거 기간을 database로 사용
Query	2019–2020에서 무작위 2,000개	시간적으로 뒤의 기간에서 sampling
Short-term	12시간 query와 12시간 result	prediction 없는 변형이 직접 비교
Long-term	관측 12 + 예측 12시간	비교 방식은 이후 12시간까지 평가
Metrics	LPIPS ↓, FSIM ↑, SSIM ↑	기상학적 정답 metric은 아님

성능표는 동일한 query 길이와 평가 구간을 확인한 뒤 읽어야 한다

단기와 장기에서 유리한 변형이 다르다

Table 2의 best 값은 task horizon별로 읽는다

설정	LPIPS ↓	FSIM ↑	SSIM ↑	해석
Short: w/o prediction	.1943	.3502	.2784	12시간 세 metric 모두 best
Short: w/ prediction	.1960	.3495	.2775	단기에는 소폭 낮음
Long: w/o prediction	.1974	.3490	.2751	후반 frame에서 품질 저하
Long: w/ prediction	.1965	.3494	.2766	24시간 세 metric 모두 best

prediction은 장기 변화 검색을 돕지만 단기 결과까지 항상 개선하지는 않는다

후보 검색 속도는 recall 조건과 함께 보고된다

query interval length가 넓은지 좁은지에 따라 비교 baseline의 병목도 달라진다

평가 항목	논문 조건	보고된 관찰
결과 수	C=50, 500	두 retrieval 규모를 평가
시간 범위	전체 기간의 1%–100%	좁고 넓은 interval을 모두 포함
정확도 filter	recall $\geq 99\%$ 인 설정만 보고	99%가 이론적 보장은 아님
대 BSBF	최대 $112.50 \times$ 빠름	넓은 interval에서 전체 비교 비용 회피
대 PyNNDescent	최대 $943.87 \times$ 빠름	좁은 interval에서 시간 block 활용

최대 speedup은 특정 interval·C·dataset 설정의 관측값이다

빠른 graph search에는 index memory 비용이 따른다

Deep1B subset은 위성 자료 밖의 고차원 vector에서도 scalability를 확인한다

대상	크기	의미
원본 vectors	10M × 96-d, 3.92 GB	임의 timestamp를 붙인 Deep1B subset
SkySearch index	18.24 GB	원본의 약 5배 memory
평가 결론	QPS·recall 비교	큰 vector DB에도 query는 가능
남는 비용	graph와 block 중복	memory가 충분한 server 조건이 필요

SkySearch는 원본보다 작은 index를 보장하지 않으며 속도를 위해 추가 memory를 사용한다

예측 모듈은 평균과 실패 사례를 함께 봐야 한다

장기 평균은 개선되지만 구름 형태에 따라 예측 난도가 달라진다

근거	관찰	해석
Prediction LPIPS	SkySearch .2170, SimVP .3907	제안 학습이 평균 예측 품질 개선
delta ablation	8시간에서 모든 변형 best	default positive 범위의 실험 근거
24-frame curve	prediction 변형이 후반부에 안정적	장기 검색 품질 유지에 기여
Scattered clouds	불만족스러운 예측 사례	복잡한 구름은 여전히 어려움
Ground truth 비교	마지막 20-24h는 실제 미래가 소폭 우세	예측이 관측과 같지는 않음

평균 향상은 개별 query의 미래 예측 신뢰도를 제공하지 않는다

논문이 보여 준 것과 아직 보여 주지 않은 것

시스템 성과와 해석 경계를 함께 기억한다

보여 준 것	조건	아직 남은 질문
초 단위 대규모 검색	서버·RAM·평가 dataset	더 작은 hardware에서의 성능
라벨 없는 표현 학습	시간 근접성으로 학습	기상 현상 의미와의 완전한 일치
장기 검색 평균 개선	예측을 붙인 COMS IR 평가	query별 prediction confidence
IR·SWIR·WV 적용 사례	channel별 입력	joint multichannel representation
metric 기반 유사도	LPIPS·FSIM·SSIM proxy	표준 기상학적 similarity 기준

실용적 검색 기반이지만 similarity와 uncertainty 문제는 남는다

SkySearch를 한 문장씩 다시 연결하면

각 구성요소는 서로 다른 병목을 해결한다

01	Learn	시간 근접성으로 검색 embedding을 학습
↓		
02	Index	embedding을 kNN graph와 시간 block으로 구성
↓		
03	Search	유망한 neighbor와 겹치는 block만 방문
↓		
04	Rank	거리 또는 선택적 perceptual metric으로 정렬
↓		
05	Inspect	과거 사례의 시각·시각값·거리로 비교

표현·시간·graph·UI를 잇는 검색 설계가 핵심이다