

SafeRL과 CMDP: 보상, 제약, 보장의 조건

A Survey of Safe Reinforcement Learning and Constrained MDPs: A Technical Survey on Single-Agent and Multi-Agent Safety

Ankita Kushwaha, Kiran Ravish, Preeti Lamba, Pawan Kumar, and Anuj Mahajan (2026)

보상 최대화에 제약을 더할 때, 무엇이 보장되고 무엇이 남는가

보상만 최대화할 때 남는 질문

큰 평균 보상만으로는 어떤 손실을 허용했는지 알 수 없다



SafeRL은 보상과 명시된 안전 비용을 함께 다룬다

이 survey의 범위

CMDP foundations, SafeRL methods, SafeMARL의 열린 문제를 잇는 technical survey

부분	핵심 질문	읽을 때의 경계
foundations	CMDP 제약을 어떻게 쓰는가	정의와 이론 조건
methods	제약을 어떻게 다루는가	대표 방법의 survey
SafeMARL	여러 agent의 제약은 어떻게 묶이는가	협력과 경쟁을 분리
open problems	무엇이 아직 해결되지 않았는가	배포 보장으로 확대하지 않음

이 논문은 새 단일 알고리즘보다 개념 지도와 조건부 주장을 제공한다

MDP의 기본 상호작용

CMDP를 이해하려면 먼저 state, action, transition, reward의 역할을 분리한다



MDP의 $J(\pi)$ 는 할인된 reward의 기대값이다

CMDP: reward 옆의 cost와 budget

같은 policy interaction에 cost c 와 threshold d 를 추가해 feasible policy를 정의한다



Π_{safe} 는 지정된 expected discounted cost를 만족하는 정책 집합이다

CMDP의 핵심 최적화 문제

목적 J 와 cost return $J_c(i)$ 를 같은 policy π_i 에 대해 계산한다

항	읽는 법	제약의 역할
$J(\pi_i)$	discounted reward의 기대값	최대화할 성과
$J_c(i) (\pi_i)$	i 번째 discounted cost의 기대값	한도와 비교할 위험
$d(i)$	사전에 정한 cost budget	$J_c(i) \leq d(i)$ 의 기준
Π_{safe}	모든 budget을 만족하는 policy	feasible set

문제는 $\max J(\pi_i)$, subject to $J_c(i) (\pi_i) \leq d(i)$ 이다

기대비용 제약이 말하는 것과 말하지 않는 것

$J_c(\pi) \leq d$ 는 policy distribution 아래의 expected discounted cost 조건이다

질문	CMDP expected-cost 제약	추가 장치가 필요한 경우
평균 비용	budget 이하를 요구	cost model과 estimate 필요
한 trajectory	큰 cost가 나올 수 있음	instantaneous 또는 risk constraint
학습 초기	violation을 막지 않음	safe exploration 또는 shield
모델 오류	정의만으로 다루지 않음	robustness model 등

expected safety, per-step safety, training safety는 서로 다른 주장이다

교육용 가상 예시: fast와 cautious

한 단계 CMDP에서 action을 섞어 expected cost budget을 맞춘다

action	reward r	safety cost c
fast	10	0.8
cautious	7	0.2
budget d	-	0.5

교육용 가상 예시: fast를 확률 p 로 고르는 policy를 계산한다

교육용 가상 예시를 계산한다

p 는 fast를 선택하는 확률이며, budget은 p 의 feasible range를 제한한다

01	reward	$J(p)=7+3p$
↓		
02	cost	$J_c(p)=0.2+0.6p$
↓		
03	feasibility	$0.2+0.6p \leq 0.5$
↓		
04	range	$p \leq 0.5$
↓		
05	optimum	$p^*=0.5, J=8.5$

이 toy의 feasible optimum은 $J_c=0.5$ 를 쓰는 $p=0.5$ 다

확률 policy가 필요한 상황

여러 constraint에서 randomization은 finite CMDP의 가능한 optimum 형태다

policy	reward	cost와 budget
always fast	10	$0.8 > 0.5$, infeasible
always cautious	7	$0.2 \leq 0.5$, feasible
$\pi_{0.5}$	8.5	$0.5 = 0.5$, feasible

randomization은 이 toy의 해법이며, 모든 CMDP에서의 의무 규칙은 아니다

Lagrange multiplier: cost의 가격

lambda는 reward와 constraint violation의 trade-off를 optimizer에 전달한다



violation이 크면 lambda가 올라가 cost가 더 비싸게 평가된다

primal-dual update의 인과

policy update와 multiplier update는 같은 rollout의 reward와 cost estimate를 다르게 사용한다



dual update는 expected cost estimate에 반응하며 per-step filter가 아니다

occupancy measure와 linear program

finite known-model CMDP에서는 discounted visitation mass로 reward, cost, flow를 linear하게 쓸 수 있다

quantity	의미	조건과 한계
$x(s,a)$	normalized discounted visitation mass	합이 1인 state-action 분포
reward J	$[\sum x(s,a) r(s,a)] / (1-\gamma)$	discounted cumulative return
cost budget	$\sum x(s,a) c(i)(s,a) \leq (1-\gamma) d(i)$	원래 누적 cost 한도 $d(i)$ 와 동치
flow	discounted flow conservation	finite known model에서 직접 사용

occupancy LP는 CMDP의 이론 기준선이며 대규모 deep RL recipe가 아니다

안전 제약의 문법 다섯 가지


무엇을 bound하는가에 따라 safe라는 말의 의미가 달라진다

encoding	무엇을 제한하는가	해석의 주의
instantaneous	매 step의 $c(s_t, a_t) \leq d$	hard stepwise condition
expected cost	$J_c(\pi) \leq d$	source의 기본 CMDP
failure probability	$\Pr\{\text{failure}\} \leq \delta$	horizon과 discount 명시
risk measure	CVaR 또는 variance	tail 또는 dispersion
temporal logic	시간적 specification	automaton 또는 shield

하나의 safety label이 이 다섯 constraint를 서로 바꾸어 주지는 않는다

매 step 제약과 기대비용 제약

같은 cost signal이라도 검사 시점과 quantifier가 다르면 safety claim이 달라진다



failure probability, CVaR, temporal logic

희귀 사건의 발생 가능성, tail loss, 행동 sequence specification은 서로 다른 질문이다

form	질문	CMDP와의 관계
$\Pr\{\text{failure}\} \leq \delta$	failure event의 가능성은 낮은가	indicator cost로 표현 가능
$\text{CVaR}_\alpha(\text{loss}) \leq d$	worst alpha tail의 평균 손실은 낮은가	classic LP structure를 잃을 수 있음
LTL specification	시간 순서가 맞는가	state augmentation 또는 shield

CVaR은 failure probability와 같지 않고, temporal logic은 scalar cost만이 아니다

이 survey의 SafeRL 방법 지도


네 분류는 source의 organizing lens이며 실제 method는 결합될 수 있다

묶음	핵심 mechanism	대표 경계
constrained optimization	Lagrange, CPO, Lyapunov update	estimate와 surrogate 조건
shield or correction	proposal을 runtime에서 filter	safety model 또는 spec 필요
risk or distribution	tail과 return distribution을 모델링	ordinary expected cost와 다름
multi-agent	joint action과 shared constraints	협력과 경쟁을 분리

shield 위에 Lagrangian learner를 둘 수 있으므로 네 묶음은 배타적 법칙이 아니다

Lagrangian actor-critic의 역할 분담

actor는 penalty를 포함해 갱신되고, reward critic과 cost critic은 다른 estimate를 제공한다



cost critic과 multiplier가 있어도 early training violation이 자동으로 사라지지 않는다

CPO의 trust-region update

current feasible policy에서 reward surrogate를 높이되 cost surrogate와 KL radius를 함께 제한한다

01	feasible start	current π_k 가 feasible
↓		
02	surrogates	reward와 cost를 근사
↓		
03	trust region	KL radius 안에서 탐색
↓		
04	constrained solve	cost surrogate를 만족
↓		
05	new policy	$\pi_{(k+1)}$ 을 생성

CPO는 unconstrained policy gradient step을 그대로 쓰지 않고 constrained surrogate를 푼다

CPO 보장의 조건과 범위

near-constraint statement는 feasible start, solved surrogate, approximation term과 함께 읽는다

source proposition

필요한 조건

말하지 않는 것

cost bound

feasible current policy

임의 초기 policy의 무위반

trust region

KL-bounded update

true dynamics의 완전한 지식

surrogate solve

cost advantage estimate

estimate error가 0이라는 주장

upper bound

approximation term 포함

literal zero violation

CPO의 safety statement는 조건부 expected-cost bound이며 deployment proof가 아니다

shield와 action correction의 runtime 위치

agent의 proposed action과 environment에 전달되는 executed action을 분리한다



shield claim은 safety model, specification, prediction의 정확성 조건에 달려 있다

shield의 장점과 trade-off

runtime intervention은 strong safety intent를 주지만 knowledge requirement와 exploration bias를 만든다

특성	얻는 것	대가 또는 조건
action filtering	unsafe proposal을 막거나 수정	model, safe set, spec 필요
formal shield	forbidden action을 사전 계산	abstraction과 automaton 정확성
safety layer	가까운 safe action으로 projection	local linearization 가정
exploration	위험 행동을 줄임	보수성으로 state space 편향

shield는 모든 환경에서 공짜로 안전한 exploration을 주는 일반 해법이 아니다

risk-sensitive와 distributional route


tail risk와 full return distribution은 ordinary expected cumulative cost와 다른 안전 표현이다

route	무엇을 학습 또는 제한	주의할 점
risk-sensitive	utility, variance, CVaR	risk definition을 먼저 정함
distributional RL	return distribution	lower tail에 초점을 둘 수 있음
CMDP conversion	risk cost를 별도 constraint로	auxiliary variable나 sample approximation

tail-risk method와 expected-cost CMDP는 같은 guarantee를 뜻하지 않는다

SafeMARL: joint action과 shared constraint

N명의 action은 joint action을 만들고, cost는 agent별 또는 global로 정의될 수 있다



SafeMARL constraint는 한 agent가 혼자 평가 못 하는 joint state를 포함할 수 있다

centralized와 decentralized SafeMARL

관측 가능 정보와 constraint decomposition 방식이 architecture의 핵심 차이다

architecture	정보와 policy	안전 난점
centralized	global state와 joint policy	joint action space가 커짐
decentralized	local observation과 local policy	global constraint를 보지 못할 수 있음
k-hop coordination	제한된 이웃 통신	먼 agent effect를 truncate
constraint decomposition	global cost를 local costs로 분해	모든 constraint가 분해되지는 않음

decentralization은 local information과 global safety의 간극을 다룬다

cooperative SafeMARL 보장의 경계


Proposition 4.2는 cooperative joint objective와 sequential KL-bounded update를 전제로 한다

source statement	조건	확장할 수 없는 결론
team reward	cooperative joint objective	competitive equilibrium
cost satisfaction	agent-wise constraints	arbitrary shared constraint
monotonic update	sequential optimization	동시 임의 update
KL radii	chosen agent-wise budgets	partial observation generality

Prop. 4.2는 협력 환경의 조건부 result이며 competitive SafeMARL 보장이 아니다

competitive SafeMARL은 다른 문제를 낸다

공통 team reward의 constrained optimization과 agent별 objective의 constrained equilibrium을 구분한다



libraries와 environments의 올바른 읽기

Tables 2-3은 reproduction infrastructure를 분류하며 cross-method winner table이 아니다

종류	source의 예	말하지 않는 것
algorithm libraries	OmniSafe, SafePO, Safety Starter Agents	동일 safety guarantee
benchmark suites	Safety-Gymnasium, Safe-Control-Gym	실환경 배포 성능
environments	Safety Gym, SafeLife, SMARTS	한 숫자의 방법 순위

도구와 benchmark는 비교 가능성의 출발점이지 safety proof의 대체물이 아니다

결론을 지지하는 다섯 열린 문제

source의 open problems는 safe deployment가 아직 조건부라는 근거다

문제	핵심 난점	범위
zero-violation exploration	학습 중 violation을 막기	single-agent
partial observability	안전 state를 완전히 보지 못함	single-agent
decentralized SafeMARL	global constraint와 local view	multi-agent
competitive SafeMARL	constraint와 equilibrium	multi-agent
non-stationarity	environment와 agents가 변함	multi-agent

안전은 constraint satisfaction 외에 exploration과 information의 문제이기도 하다

SafeRL claim을 읽는 다섯 단계

formula, constraint semantics, mechanism, assumptions, evidence type을 순서대로 확인한다

01	formulate	reward와 cost를 명시
↓		
02	specify	expectation, step, tail을 구분
↓		
03	mechanize	optimizer 또는 shield 선택
↓		
04	condition	model, estimate, KL을 확인
↓		
05	interpret	보장의 범위를 말함

CMDP는 안전을 명확히 쓰는 언어이며, 안전 보장은 조건을 보존할 때만 읽을 수 있다